

离散去噪模型的连续时间框架

Andrew Campbell¹Joe Benton¹Valentin De Bortoli²Tom Rainforth¹George Deligiannidis¹Arnaud Doucet¹¹牛津大学统计系, 英国²法国巴黎高等师范学院-CNRS, 法国

{campbell, benton, rainforth, deligian, doucet}@stats.ox.ac.uk

valentin.debortoli@gmail.com

摘要

我们提供了首个用于离散数据去噪扩散模型的完整连续时间框架。这是通过将正向去噪过程和相应的反向时间生成过程表述为连续时间马尔可夫链（CTMCs）实现的。该模型可以使用ELBO的连续时间版本进行高效训练。我们使用化学物理领域开发的技术模拟高维CTMC，并利用我们的连续时间框架推导出高性能采样器，这些采样器在离散数据上被证明优于离散时间方法。连续时间处理还使我们能够推导出一个新的理论结果，该结果界定了生成样本分布与真实数据分布之间的误差。

1 引言

扩散/评分式/去噪模型 [1, 2, 3, 4] 是一类流行的生成模型，它们在保持数据分布 [5] 良好覆盖的同时，实现了最先进的样本质量，且使用稳定、非对抗、易于实现的训练目标。该通用框架是定义一个正向去噪过程，该过程接收数据并逐渐将其破坏，直到数据分布被转换为易于采样的简单分布。然后模型通过学习噪声边缘分布的对数梯度（即评分）来逆向这个过程。

以往关于去噪模型的研究大多基于连续状态空间。然而，存在许多问题，我们希望建模的数据是离散的。例如，在文本、分割图、分类特征、离散潜在空间以及图像的直接8位表示中。以往的研究尝试将去噪框架的优势应用于离散数据问题，并取得了初步的积极成果 [6, 7, 8, 9, 10, 11, 12, 13]。

所有这些先前方法都在离散时间中对模型进行训练和采样。不幸的是，在离散时间中工作有显著的缺点。它通常迫使用户在训练时选择过程的一个划分，并且模型仅学习在这些固定的时间点去噪。由于固定的划分，我们随后仅限于简单的祖先采样策略。在连续时间中，模型相反学习在过程的任何任意时间点去噪。这种对逆过程的完整指定使得在定义逆采样方案方面具有更大的灵活性。例如，在连续状态空间中，已经设计出大大减少采样时间的连续时间采样器 [14, 15, 16, 17] 以及提高样本质量的 [4, 18]。连续时间解释还促成了有趣的理论属性的推导，例如连续状态空间中的误差界限 [19]。




图1: 正向噪声过程根据 R_t 污染数据, 污染事件在时间 t 的发生率为 R_t 。噪声过程的时间逆转给出生成过程, 该过程通过 $\hat{R}_t^\theta$ 定义, 其中 $\hat{R}_t^\theta$ 是时间 t 生成事件的发生率。 $\hat{R}_t^\theta$ 通过去噪网络 $p_{0|t}^\theta(x_0|x_t)$ 进行参数化, 该网络输出关于干净 x_0 值的条件分类概率, 条件为噪声 x_t 。

为了使这些优势也能被离散状态空间所利用, 我们为离散去噪模型制定了一个连续时间框架。具体来说, 我们的贡献如下。我们将正向噪声过程制定为连续时间马尔可夫链 (CTMC), 并确定该过程的时反过程是生成性 CTMC。然后, 我们界定生成数据分布的对数似然, 给出连续时间的 ELBO 等价物, 可用于对真实生成逆过程的参数近似进行高效训练。为了高效模拟参数逆过程, 我们利用 tau-leaping [20] 并提出了一种新的预测-校正类型方案, 可用于提高模拟精度。连续时间框架使我们能够推导出真实数据分布与使用 tau-leaping 模拟的近似逆过程生成的样本之间的误差界限。最后, 我们在 CIFAR-10 数据集图像和单音音乐序列的生成建模上展示了我们提出的方法。值得注意的是, 我们发现我们的 tau-leaping 与预测-校正采样器可以提供比先前离散时间离散状态方法更高的质量 CIFAR10 样本, 进一步缩小了当图像被建模为离散数据或连续数据时的性能差距。

所有命题和定理的证明都在附录中给出。

2 离散去噪模型的背景

在离散时间、离散状态空间的情况下, 我们旨在对具有有限基数的离散数据 $x_0 \in \mathcal{X}$ 进行建模。我们假设 $x_0 \sim p_{\text{data}}(x_0)$ 对于某些离散数据分布 $p_{\text{data}}(x_0)$ 。我们定义一个正向噪声过程, 该过程将 $p_{\text{data}}(x_0)$ 转换为某个近似于易于采样的分布 $p_{\text{ref}}(x_K)$ 的分布 $q_K(x_K)$ 。这是通过定义所有都接受 p_{ref} 作为稳态分布并且混合得相对较快的正向核 $q_{k+1|k}(x_{k+1}|x_k)$ 来实现的。例如, 可以使用一个简单的均匀核 [6, 8], $q_{k+1|k}(x_{k+1}|x_k) = \delta_{x_{k+1} x_k} (1 - \beta) + (1 - \delta_{x_{k+1} x_k}) \beta / (S - 1)$, 其中 δ 是克罗内克函数。相应的 p_{ref} 是所有状态上的均匀分布。其他选择包括: 一个吸收状态核——其中每个状态都有一个小的概率转移到某个吸收状态——或一个离散化高斯核——其中只有转移到附近状态的概率显著 (适用于具有序数结构的空间) [8]。

在定义了 $q_{k+1|k}$ 之后, 我们有一个正向关节分解, 如下所示

$$q_{0:K}(x_{0:K}) = p_{\text{data}}(x_0) \prod_{k=0}^{K-1} q_{k+1|k}(x_{k+1}|x_k).$$

关节分布 $q_{0:K}(x_{0:K})$ 也允许一个反向分解:

$$q_{0:K}(x_{0:K}) = q_K(x_K) \prod_{k=0}^{K-1} q_{k|k+1}(x_k|x_{k+1}) \text{ where } q_{k|k+1}(x_k|x_{k+1}) = \frac{q_{k+1|k}(x_{k+1}|x_k) q_k(x_k)}{q_{k+1}(x_{k+1})}.$$

这里 $q_k(x_k)$ 表示 $q_{0:K}(x_{0:K})$ 在时间 k 的边缘。如果能够获取 $q_{k|k+1}$ 并精确采样 q_K , 那么可以从 $p_{\text{data}}(x_0)$ 中生成样本, 方法是先采样 $x_K \sim q_K(\cdot)$, 然后进行反向祖先采样, 即 $x_k \sim q_{k|k+1}(\cdot|x_{k+1})$ 。

然而，在实践中， $q_{k|k+1}$ 是难以处理的，需要用参数化反向核 $p_{k|k+1}^\theta$ 来近似。这个核通常通过解析 $q_{k|k+1|0}$ 分布和参数化“去噪”模型 $p_{0|k+1}^\theta$ [6, 8] 来定义，

$$\begin{aligned} p_{k|k+1}^\theta(x_k|x_{k+1}) &\triangleq \sum_{x_0} q_{k|k+1,0}(x_k|x_{k+1}, x_0) p_{0|k+1}^\theta(x_0|x_{k+1}) \\ &= q_{k+1|k}(x_{k+1}|x_k) \sum_{x_0} \frac{q_{k|0}(x_k|x_0)}{q_{k+1|0}(x_{k+1}|x_0)} p_{0|k+1}^\theta(x_0|x_{k+1}). \end{aligned} \quad (1)$$

尽管 $q_K(x_K)$ 也是难以处理的，但对于大的 K ，我们可以用 $p_{\text{ref}}(x_K)$ 可靠地近似它。请注意，转换混合得越快，这种近似就越准确。然后可以通过采样生成联合分布来获得来自 $p_{\text{data}}(x_0)$ 的近似样本

$$p_{0:K}^\theta(x_{0:K}) = p_{\text{ref}}(x_K) \prod_{k=0}^{K-1} p_{k|k+1}^\theta(x_k|x_{k+1}),$$

其中 θ 通过最小化负离散时间 (DT) ELBO 进行训练，而负离散时间 (DT) ELBO 是负模型似然的上界

$$\mathbb{E}_{p_{\text{data}}(x_0)} [-\log p_0^\theta(x_0)] \leq \mathbb{E}_{q_{0:K}(x_{0:K})} \left[-\log \frac{p_{0:K}^\theta(x_{0:K})}{q_{1:K|0}(x_{1:K}|x_0)} \right] = \mathcal{L}_{\text{DT}}(\theta).$$

在 [1] 中表明 $\mathcal{L}_{\text{DT}}$ 可以重写为

$$\begin{aligned} \mathcal{L}_{\text{DT}}(\theta) &= \mathbb{E}_{p_{\text{data}}(x_0)} \left[\text{KL}(q_{K|0}(x_K|x_0) || p_{\text{ref}}(x_K)) - \mathbb{E}_{q_{1|0}(x_1|x_0)} \left[\log p_{0|1}^\theta(x_0|x_1) \right] \right. \\ &\quad \left. + \sum_{k=1}^{K-1} \mathbb{E}_{q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0) || p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \right] \end{aligned}$$

其中 KL 是 Kullback-Leibler 散度。前向核 $q_{k+1|k}$ 被选择为使得 $q_{k|0}(x_k|x_0)$ 可以在时间独立于 k 的情况下高效计算。有了这个， θ 可以通过在每个小批量中从 $\mathcal{L}_{\text{DT}}$ 中随机选择项并执行随机梯度步来高效训练

3 连续时间框架

3.1 前向过程及其时间反转

我们的方法基于从 $t=0$ 到 $t=T$ 的连续时间过程。在此过程中，状态转换可以随时发生，而离散时间情况下，转换仅在应用有限数量的转换核之一时才会发生（见图1）。该过程称为连续时间马尔可夫链 (CTMC)，我们在附录A中简要介绍了CTMC，以供完整性参考。在此给出直观介绍，我们可以通过初始分布 q_0 和转换率矩阵 $R_t \in \mathbb{R}^{S \times S}$ 来定义CTMC。如果当前状态是 $\tilde{x}$ ，那么转换率矩阵中的 $R_t(\tilde{x}, x)$ 是状态 $\tilde{x}$ 转换到状态 x 的瞬时速率（单位时间内发生次数）。粗略地说，过程中下一个状态很可能是 $R_t(\tilde{x}, x)$ 较高的状态，而且速率越高，该转换发生所需时间就越短。

结果表明，跃迁率 R_t 也定义了两个时间点 $t - \Delta t$ 和 t 之间过程的微分跃迁概率

$$q_{t|t-\Delta t}(x|\tilde{x}) = \delta_{x,\tilde{x}} + R_t(\tilde{x}, x)\Delta t + o(\Delta t),$$

其中 $o(\Delta t)$ 表示以比 Δt 更快速度趋于零的项。与离散时间情况相比，我们发现 R_t 扮演了与离散时间前向核 $q_{k+1|k}$ 类似的角色，即在我们定义前向过程时的作用。因此，正如在离散时间中一样，我们设计 R_t 使得：i) 前向过程快速混合到易于采样（平稳）的分布 p_{ref} （例如均匀分布），ii) 我们可以解析地获得 $q_{t|0}(x_t|x_0)$ 分布以实现高效训练（参见第 4.1 节了解如何实现）。我们将前向 CTMC 在时间 $q_0(x_0) = p_{\text{data}}(x_0)$ 初始化于 $t=0$ 。我们将时间 $t=T$ 的边缘记为 $q_T(x_T)$ ，它应接近 $p_{\text{ref}}(x_T)$ 。

我们现在考虑正向过程的逆时间过程，这将带我们从边缘 $q_T(x_T)$ 通过反向转移率矩阵

$\hat{R}_t \in \mathbb{R}^{S \times S}$ 回到数据分布 $p_{\text{data}}(x_0)$ ：

$$q_{t|t+\Delta t}(\tilde{x}|x) = \delta_{\tilde{x},x} + \hat{R}_t(x, \tilde{x})\Delta t + o(\Delta t).$$

在离散时间中，人们使用贝叶斯法则从 $q_{k+1|k}$ 推导到 $q_{k|k+1}$ 。我们可以使用类似的思想来[^]计算 R_t 从 $\hat{R}_t$ ，如下面的结果所示。

命题 1. 对于一个正向的连续时间马尔可夫链 (CTMC), $\{x_t\}_{t \in [0, T]}$, 具有速率矩阵 R_t 、初始分布 $p_{\text{data}}(x_0)$ 和终止分布 $q_T(x_T)$, 存在一个 CTMC, 其初始分布为 $q_T(x_T)$ 在 $t = T$, 终止分布为 $p_{\text{data}}(x_0)$ 在 $t = 0$, 以及反向时间运行的转移速率矩阵 $\hat{R}_t$, 它在几乎处处上等同于正向 CTMC 的时间反转, $\{x_t\}_{t \in [T, 0]}$. 此外, R_t 与 $\hat{R}_t$ 通过以下表达式相关。

$$\hat{R}_t(x, \tilde{x}) = R_t(\tilde{x}, x) \sum_{x_0} \frac{q_{t|0}(\tilde{x}|x_0)}{q_{t|0}(x|x_0)} q_{0|t}(x_0|x) \quad \text{for } x \neq \tilde{x},$$

前向过程的条件边缘分布在哪里 $q_{t|0}(x|x_0)$, 以及 $q_{0|t}(x_0|x) = q_{t|0}(x|x_0)p_{\text{data}}(x_0)/q_t(x)$ 与 $q_t(x)$ 作为前向过程在时间 t 的边缘分布。当 $x = \tilde{x}$ $\hat{R}_t(x, x) = -\sum_{x' \neq x} \hat{R}_t(x, x')$ 时, 因为每一行必须加起来为零 (见附录 A)。

不幸的是, $\hat{R}_t$ 由于 $q_t(x)$ 和因此的 $q_{0|t}(x_0|x)$ 的不可计算性而不可计算。因此, 我们考虑通过用参数化去噪模型 $p_{0|t}^\theta(x_0|x)$ 近似 $q_{0|t}(x_0|x)$ 来近似 $\hat{R}_t$:

$$\hat{R}_t^\theta(x, \tilde{x}) = R_t(\tilde{x}, x) \sum_{x_0} \frac{q_{t|0}(\tilde{x}|x_0)}{q_{t|0}(x|x_0)} p_{0|t}^\theta(x_0|x) \quad \text{for } x \neq \tilde{x}$$

并且 $\hat{R}_t^\theta(x, x) = -\sum_{x' \neq x} \hat{R}_t^\theta(x, x')$ 与之前一样。作为离散时间情况的进一步类比, 请注意, 当 $x \neq \tilde{x}$ 时, $\hat{R}_t^\theta$ 与离散时间参数化反向核 $p_{k|k+1}^\theta$ (在等式(1)中定义) 具有相同的形式, 但将前向核 $q_{k+1|k}$ 替换为前向速率 R_{t_0} 。

3.2 连续时间 ELBO

在离散时间中, θ 通过最小化由正向和反向过程形成的离散时间负 ELBO, $\mathcal{L}_{\text{DT}}$ 进行训练。我们在连续时间中镜像这种方法, 通过最小化以下推导出的相应连续时间 (CT) 负 ELBO, $\mathcal{L}_{\text{CT}}$ 。

命题 2. 对于具有初始分布 $p_{\text{ref}}(x_T)$ 、终端分布 $p_0^\theta(x_0)$ 和反向速率 $\hat{R}_t^\theta$ 的时间反演 CTMC, 负模型对数似然的上界 $\mathbb{E}_{p_{\text{data}}(x_0)}[-\log p_0^\theta(x_0)]$ 由下式给出:

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x) r_t(\tilde{x}|x)} \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x') \right\} - Z^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] + C,$$

其中 C 是与 θ 无关的常数, 且

$$Z^t(x) = \sum_{x' \neq x} R_t(x, x') \quad r_t(\tilde{x}|x) = (1 - \delta_{\tilde{x}, x}) R_t(x, \tilde{x}) / Z^t(x)$$

这里 $r_t(\tilde{x}|x)$ 给出了在已知在时间 t 发生转换的情况下, 从 x 转换到 $\tilde{x}$ 的概率。我们可以使用随机梯度下降高效地优化此目标。对于梯度更新, 我们从 $p_{\text{data}}(x_0)$ 采样一批数据点, 使用随机时间噪声每个数据点, $t \sim \mathcal{U}(0, T)$ $x \sim q_{t|0}(x|x_0)$, 最后为每个 x 从 $r_t(\tilde{x}|x)$ 采样一个辅助 $\tilde{x}$ 。直观地, $(x, \tilde{x})$ 是遵循时间正向噪声过程的一对状态。最小化 $\mathcal{L}_{\text{CT}}$ 中的第二项最大化这对的逆速率, 但在反向方向上, $\tilde{x}$ 到 x 。这就是 $\hat{R}_t^\theta$ 学习反转噪声过程的方式。第一项的直观理解以及与 $\mathcal{L}_{\text{DT}}$ 的直接比较在附录 C.1 中给出。

$\hat{R}_t^\theta$ 的第一个参数被输入到 $p_{0|t}^\theta$ 中, 因此我们需要在 x 和 $\tilde{x}$ 上进行两次网络前向传递来评估目标。我们可以通过用 $\tilde{x}$ 近似第一个项中的 $q_t(x)$ 样本来避免这一点, 这意味着我们只需要在 $\tilde{x}$ 上评估网络一次。这种近似是有效的, 因为正如我们在附录 C.4 中所示, 对于非常小的 δt , $\tilde{x}$ 近似地按照 $q_{t+\delta t}$ 分布。

4 高效前向和反向采样

4.1 前向过程的选择

转移率矩阵 R_t 需要选择, 以便正向过程: i) 快速混合到 p_{ref} , ii) $q_{t|0}(x|x_0)$ 分布可以解析获得。柯尔莫哥洛夫

CTMC 的微分方程需要积分以获得 $q_{t|0}(x|x_0)$ 。当 R_t 和 $R_{t'}$ 对所有 t, t' 交换时，这可以解析完成，见附录 E。满足此条件的一种简单方法是让 $R_t = \beta(t)R_b$ ，其中 $R_b \in \mathbb{R}^{S \times S}$ 是用户指定的与时间无关的基础率矩阵， $\beta(t) \in \mathbb{R}$ 是与时间相关的标量。然后我们得到解析表达式

$$q_{t|0}(x = j|x_0 = i) = \left(Q \exp \left[\Lambda \int_0^t \beta(s) ds \right] Q^{-1} \right)_{ij}$$

$R_b = Q \Lambda Q^{-1}$ 在哪里是矩阵 R_b 的特征分解， $\exp[\cdot]$ 是逐元素的指数。我们选择 β 调度是由 [3, 4], $\beta(t) = ab^t \log(b)$ 指导的。超参数 a 和 b 的选择方式是，在终端时间 $t = T$ 时 $q_T(x) \approx p_{\text{ref}}(x)$ ，同时保持 ‘信息腐败’ 的稳定速度，这确保了 R_t 在短时间内不会快速变化。

我们实验了各种 R_b 矩阵，例如，均匀速率 $R_b = \mathbb{1}\mathbb{1}^T - S\text{Id}$ ，其中 $\mathbb{1}\mathbb{1}^T$ 是一个全 1 矩阵， Id 是单位矩阵。对于具有重空间偏差的问题，例如图像，我们可以改用仅鼓励向附近状态转换的前向速率；详细信息和与相应离散时间过程的链接可以在附录 E 中找到。

4.2 按维度分解

我们的目标是建模一个 D 维的数据，每个维度从 S 种可能性中选择一个值。我们现在稍微重新定义符号，并说 $\mathbf{x}^{1:D} \in \mathcal{X}^D$ $|\mathcal{X}| = S$ 。在这种情况下，天真地计算转换概率将需要计算与每个可能的下一个状态对应的 S^D 速率值。这对于任何合理大小的 S 和 D 来说都是不可行的。我们通过简单地分解前向过程，使每个维度独立传播，从而避免了这个问题。由于这是一个连续时间过程，并且每个维度的前向过程与其他维度独立，因此两个或多个维度在同一时间精确转换的概率为零。因此，在完整维度的前向 CTMC 中，每次转换只涉及恰好一个维度的变化。对于时间反转 CTMC，每次转换中也恰好有一个维度会变化。这使得计算可行，因为 S^D 速率值中，只有 $D \times (S - 1) + 1$ 是非零的——那些对应于恰好一个维度变化的转换以及无变化转换的值。最后，我们注意到，即使维度在前向方向上独立传播，它们在反向方向上也不是独立的，因为非分解的 p_{data} 中每个维度前向过程的起点不是独立的。以下命题显示了在这种情况下前向和反向速率的精确形式。

命题3. 如果正向过程可以分解为 $q_{t|s}(\mathbf{x}_t^{1:D}|\mathbf{x}_s^{1:D}) = \prod_{d=1}^D q_{t|s}(x_t^d|x_s^d)$ $t > s$ ，那么正向和反向速率的形式为

$$R_t^{1:D}(\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}) = \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}},$$

$$\hat{R}_t^{1:D}(\mathbf{x}^{1:D}, \tilde{\mathbf{x}}^{1:D}) = \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \sum_{x_0^d} q_{0|t}(x_0^d|\mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)},$$

其中 $R_t^d \in \mathbb{R}^{S \times S}$ 和 $\delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$ 在所有维度（除 d 外）相等时为 1。

要找到 $\hat{R}_t^{\theta 1:D}$ ，我们只需将 $q_{0|t}(x_0^d|\mathbf{x}^{1:D})$ 替换为 $p_{0|t}^{\theta}(x_0^d|\mathbf{x}^{1:D})$ ，后者可以通过一个输出条件独立状态概率的神经网络来轻松建模。在附录 C.3 中，我们推导出当使用 $R_t^{1:D}$ 和 $\hat{R}_t^{\theta 1:D}$ 的分解形式时 $\mathcal{L}_{\text{CT}}$ 的形式。

4.3 使用 Tau-Leaping 模拟生成反向过程

参数化生成反向过程是一个具有速率矩阵 $\hat{R}_t^{\theta 1:D}$ 的 CTMC。从分布 $p_{\text{ref}}(\mathbf{x}_T^{1:D})$ 在时间 $t = T$ 回到 $t = 0$ 模拟此过程将产生近似来自 $p_{\text{data}}(\mathbf{x}_0^{1:D})$ 的样本。该过程可以使用 Gillespie 算法 [21, 22, 23] 精确模拟，该算法在以下步骤之间交替：i) 抽样保持时间以保持当前状态，ii) 根据当前速率矩阵 $\hat{R}_t^{\theta 1:D}$ 抽样新状态（见附录 F）。这对于大的 D 效率低下，因为我们需要逐个遍历每个转换，因此在每个模拟步骤中只有一个维度会改变。

相反，我们使用 tau-leaping [20, 23]，这是一种在化学物理中开发出来的非常流行的近似模拟方法。tau-leaping 不是通过时间一步步从一个状态过渡到下一个状态，而是直接跳跃

从 t 跳跃到 $t - \tau$ ，并同时应用在 $[t - \tau, t]$ 中发生的所有状态转移。为了进行跳跃，我们假设 $\hat{R}_t^{\theta 1:D}$ 和 $\mathbf{x}_t^{1:D}$ 在 $[t - \tau, t]$ 期间保持不变。当我们从 t 传播到 $t - \tau$ 时，我们统计所有发生的状态转移，但暂不实际应用它们，直到我们到达 $t - \tau$ ，从而确保 $\mathbf{x}_t^{1:D}$ 在 $[t - \tau, t]$ 期间保持不变。假设 $\hat{R}_t^{\theta 1:D}$ 和 $\mathbf{x}_t^{1:D}$ 保持不变，那么在 $\mathbf{x}_t^{1:D}$ 到 $\tilde{\mathbf{x}}^{1:D}$ 的状态转移在 $[t - \tau, t]$ 中发生的次数服从均值为 $\tau \hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \tilde{\mathbf{x}}^{1:D})$ 的泊松分布。一旦我们到达 $t - \tau$ ，我们就应用所有同时发生的状态转移，即 $\mathbf{x}_{t-\tau}^{1:D} = \mathbf{x}_t^{1:D} + \sum_i P_i(\tilde{\mathbf{x}}_i^{1:D} - \mathbf{x}_t^{1:D})$ ，其中 P_i 是一个均值为 $\tau \hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \tilde{\mathbf{x}}_i^{1:D})$ 的泊松随机变量。请注意，求和假设存在一个从 $\mathcal{X}$ 到 $\mathbb{Z}$ 的映射。




图2: 来自 $\mathbf{x}_t^{1:2} = \{S_4, S_1\}$ 到 $\mathbf{x}_{t-\tau}^{1:2} = \{S_2, S_3\}$ 的一个tau跳跃步骤的3D可视化。这里， $D = 2$ ， $|\mathcal{X}| = 5$ ， $P_{12} = 1$ ， $P_{22} = 2$ ，以及其他 $P_{ds} = 0$ 。

利用我们对 $\hat{R}_t^{\theta 1:D}$ 的了解，我们可以进一步拆解这个更新。具体来说， $\hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \tilde{\mathbf{x}}^{1:D})$ 只能非零当且仅当 $\tilde{\mathbf{x}}^{1:D}$ 在某个维度上与 $\mathbf{x}_t^{1:D}$ 的值不同（多维变化的速率为零）。明确地，我们对这些选项求和得到 $\mathbf{x}_{t-\tau}^{1:D} = \mathbf{x}_t^{1:D} + \sum_{d=1}^D \sum_{s=1 \setminus x_t^d}^S P_{ds}(s - x_t^d) \mathbf{e}^d$ ，其中 $\mathbf{e}^d$ 是一个 one-hot 向量，在维度 d 处为1，而 P_{ds} 是一个均值为 $\tau \hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \mathbf{x}_t^{1:D} + (s - x_t^d) \mathbf{e}^d)$ 的泊松随机变量。由于多个 P_{ds} 可以非零，我们看到tau跳跃允许 $\mathbf{x}_t^{1:D}$ 在单个步骤中在多个维度上变化。图2可视化了这一概念。在 $[t - \tau, t]$ 区间内，维度1发生一次跳跃，维度2发生两次跳跃。一旦我们达到 $t - \tau$ ，这些跳跃会同时应用。当我们的离散数据具有序数结构（例如，第6.2节）时，我们的映射到 $\mathbb{Z}$ 不是任意的，在同一个维度 ($\sum_{s=1 \setminus x_t^d}^S P_{ds} > 1$) 内进行多次跳跃是有意义的。在非序数/分类情况下（例如，第6.3节），映射到 $\mathbb{Z}$ 是任意的，因此，尽管在不同维度内同时进行跳跃是有意义的，但在同一个维度内进行多次跳跃则没有意义。对于这类数据，我们拒绝任何 x_t^d 的变更，只要 d 满足 $\sum_{s=1 \setminus x_t^d}^S P_{ds} > 1$ 。在实践中，当 $R_t^{1:D}$ 适合分类数据（例如，均匀分布）时，拒绝率非常小，参见附录H.3。在第4.5节中，我们的误差界考虑了这种拒绝的低概率，以及我们在序数情况下实践中观察到的超出边界的跳跃的低概率。

tau-跳跃近似随着 τ 的减小而提高，在 $\tau \rightarrow 0$ 的极限下恢复精确模拟。精确模拟与自回归模型类似，每步仅有一个维度发生变化。增加 τ 并从而增加每步变化的平均维度数量，为我们提供了一种自然的方式来调节模型的‘自回归性’，并在样本质量与计算量之间进行权衡（图4右）。我们称使用tau-跳跃来模拟反向CTMC的方法为 τ LDR（tau-跳跃去噪反转），并在附录F中的算法1中对其进行了形式化。

我们注意到，理论上，可以在区间 $[t - \tau, t]$ 中将 $\hat{R}_t^{\theta 1:D}$ 近似为常数，并通过求解具有矩阵指数 $P_{t-\tau|t} \approx \exp(\tau \hat{R}_t^{\theta 1:D})$ 的正向柯尔莫哥洛夫方程来构建转移概率矩阵。然而，对于学习的 $\hat{R}_t^{\theta 1:D} \in \mathbb{R}^{S^D \times S^D}$ 矩阵，计算这个矩阵指数是不可行的，因此我们使用tau-跳跃进行采样。

4.4 预测-校正

在近似反向采样过程中，我们希望时间 t 处样本的边缘分布接近 $q_t(x_t)$ （即真实 CTMC 在时间 t 处的边缘分布）。连续时间框架使我们能够利用额外信息更准确地跟踪边缘分布的反向演变， $\{q_t(x_t)\}_{t \in [T, 0]}$ 并提高样本质量。具体来说，在以速率 $\hat{R}_t^{\theta}$ 执行 τ 跳跃的‘预测’步骤后，我们可以应用以速率 R_t^c 为其平稳分布的‘校正’步骤， $q_t(x_t)$ 使时间 t 处样本的分布在时间 $q_t(x_t)$ 处的边缘分布更接近目标边缘分布。 R_t^c 如下所述，很容易计算

命题4. 对于一个具有边缘分布 $\{q_t(x_t)\}_{t \in [0, T]}$ 的前向连续时间马尔可夫链（CTMC）、前向速率 R_t 以及相应的反向CTMC速率 $\hat{R}_t$ ，速率 $R_t^c = R_t + \hat{R}_t$ 的平稳分布为 $q_t(x_t)$ 。

在实践中，我们通过用 $\hat{R}_t^\theta$ 替换 R_t 来近似 R_t^c 。这直接类似于连续状态空间 [4] 中的预测-校正采样器，它们通过积分反向随机微分方程（SDE）进行预测，并使用基于分数的马尔可夫链蒙特卡洛步骤进行校正，请参见附录F.2以进一步讨论。

4.5 误差界限

我们的连续时间框架还允许我们针对真实数据分布与通过tau-leaping（不使用预测-校正步骤）生成的样本分布之间的误差，提供一种新的理论界限，该界限基于我们对反向速率的近似误差以及正向噪声过程的混合程度。

我们假设在 $\mathcal{X}$ 上存在一个时间齐次速率矩阵 R_t ，通过为每个 d 设置 $R_t^d = R_t$ ，我们构建出在 $\mathcal{X}^D$ 上的分解速率矩阵 $R_t^{1:D}$ 。请注意，通过将时间缩放 β 倍（ t ），我们可以将4.1节的速率选择转换为时间齐次。我们将表示 $|R| = \sup_{t \in [0, T]} \sup_{x \in \mathcal{X}} |R_t(x, x)|$ ，并让 t_{mix} 表示具有速率 R_t 的CTMC的（1/4）混合时间（参见第4. [24, 章.5]）。

定理1。 对于任何 $D \geq 1$ 和 $\mathcal{X}^D$ 上的分布 p_{data} ，设 $\{x_t\}_{t \in [0, T]}$ 是一个以 p_{data} 为初始状态、速率矩阵为上述 $R_t^{1:D}$ 的CTMC。假设 $\hat{R}_t^{\theta 1:D}$ 是反向速率矩阵的近似，并设 $(y_k)_{k=0}^N$ ， $N = \lfloor T/\tau \rfloor$ ，是具有最大步长 τ 的tau-leaping反向动力学近似。假设进一步存在一个与 D 无关的常数 $M > 0$ ，使得

$$\sum_{y \neq x} \left| \hat{R}_t^{1:D}(x, y) - \hat{R}_t^{\theta 1:D}(x, y) \right| \leq M \quad (2)$$

对所有 $t \in [0, T]$ 适用。然后在附录B.5的假设下，存在常数 $C_1, C_2 > 0$ ，依赖于 $\mathcal{X}$ 和 R_t 但不依赖于 D ，使得 if $\mathcal{L}(y_0)$ 表示 y_0 的定律，我们有总变差界

$$\|\mathcal{L}(y_0) - p_{\text{data}}\|_{\text{TV}} \leq 3MT + \left\{ (|R|SDC_1)^2 + \frac{1}{2}C_2(M + C_1SD|R|) \right\} \tau T + 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

上述界的第一项捕获了我们用 $\hat{R}_t^{\theta 1:D}$ 近似反向率 $\hat{R}_t^{1:D}$ 引入的误差。第二项反映了tau-leaping近似引入的误差，并且与 T 和 τ 线性相关，表明随着我们将tau-leaping步长取为任意小，tau-leaping引入的误差趋于零。最后一项描述了前向链的混合，并捕获了由于 p_{ref} 和 q_T 不完全相等的误差。

我们选择使界对维度 D 的依赖性显式化，因为我们特别关注将tau-leaping应用于高维问题，在这些问题中我们在单个时间步长中同时在不同维度中进行转换。界在最坏情况下在维度上呈二次方增长，而不是例如指数增长。因此，界在表明我们不需要在高维中将 τ 取得过于不切实际的小值方面是有用的。除了获得这些直观理解外，我们预计在实践中界不会特别紧密，并且由于难以找到 M 、 C_1 和 C_2 ，计算它也不切实际。

附录B.5中列出的假设在实际的tau-leaping中近似成立，当我们使用针对有序数据的偏置率使得跳跃大小较小，或使用针对非有序数据的统一率使得维度拒绝率较小时。然而，这些假设可以被弱化，但定理1将变得非常复杂，从而掩盖问题的直观性和结构。

5 相关工作

去噪模型应用于离散数据首次在 [1] 中描述，使用二项式扩散过程对二元数据集进行处理。每个反向核 $p_{k|k+1}^\theta$ 直接参数化，而未使用去噪模型 $p_{0|k}^\theta$ 。在 [25] 中提出了一种用于离散分类数据的方法，使用均匀正向噪声核 $q_{k+1|k}$ ，以及通过去噪模型参数化的反向核，尽管该方法未进行实验验证。随后在 [6] 中使用类似模型对文本和分割图进行了实验。在 [8] 中引入了其他正向核，如更适合特定数据类型（如空间偏置高斯核）的核。[9, 13] 将该方法应用于离散潜在空间建模，使用均匀和吸收状态正向核。




图3: 左: 精确模拟或tau-leaping下, 真实训练分布与生成样本分布之间的Hellinger距离。当 τ 较小时, 我们使用与精确模拟相同保真度的反向CTMC进行模拟。右上: 使用tau-leaping模拟反向生成过程的边缘直方图, 其中 $\tau = 0.004$ 使用。较深和较大的菱形代表密度增加。右下: 相同情况适用于 $\tau = 0.1$, 注意样本质量降低。

虽然 [8], 中提到了正向过程与连续时间的联系, 但所有这些方法都在离散时间中进行训练和采样。我们在附录 G 中表明, 这涉及对多维数据进行隐式近似。我们通过在连续时间中进行训练和采样来扩展这项工作。

其他工作也在离散空间中运行, 但较少严格遵循扩散框架。在 [12], 中提出了一种针对文本的损坏过程, 其中还包含了标记删除和插入。[26] 也关注文本, 创建了一个重复应用相同去噪核的生成反向链。损坏分布也通过相同的去噪核定义, 以减少训练和采样之间的分布偏差。在 [7], 中使用更标准的基于掩码的前向过程, 但反转是从无序自回归的角度解释的。他们还描述了如何将他们的模型解释为连续时间吸收状态扩散的反转, 但在训练或采样中未使用此视角。[27] 提出了一种可用于二进制数据的去噪类型框架, 其中前向和反向过程共享相同的转移核。最后, 在 [11], 中, VQVAE的离散潜在空间通过量化基础连续状态空间扩散来建模, 使用概率量化函数。

6 实验

6.1 示例说明

我们首先验证该方法能够从数据分布的整个支撑集上准确生成样本, 并验证tau-leaping能够准确模拟反向CTMC。为此, 我们创建一个数据集, 其中包含32维状态空间中的2d样本, 并排列成训练数据集的直方图形成 ‘ τ ’ 形状。我们使用 $\mathcal{L}_{CT}$ 目标函数训练去噪模型, 该目标函数通过残差MLP参数化 (详细信息见附录H.1)。然后, 我们使用精确方法 (需要数值积分反向速率) 和tau-leaping对参数化反向过程进行采样。图3右上显示了使用 $\tau = 0.004$ 时的反向模拟边缘分布, 我们确实生成了来自 p_{data} 整个支撑集的样本。此外, 我们发现当 τ 足够小时, 我们可以匹配反向CTMC精确模拟的保真度 (图3左)。 τ 的值根据 $NFE = T/\tau$ 决定了反向过程中的网络评估次数。在所有实验中我们使用 $T = 1$ 。由于学习到的 $\hat{R}_t^\theta$ 模型存在不完美性, 精确模拟导致生成的分布和训练分布之间存在非零的Hellinger距离。

6.2 图像建模

我们现在证明, 我们的连续时间框架在生成建模方面比操作离散时间表现更优。我们在CIFAR-10图像数据集上展示了这一点。图像通常存储为离散数据, 每个像素通道从256种可能性中取一个值。连续状态空间方法必须设法绕过这一事实, 例如, 在生成过程的末尾添加离散化函数 [3], 或向数据中添加均匀噪声。

表1: 离散状态空间中模拟CIFAR10的扩散方法的样本质量指标和模型似然度。为参考, 还包括了在连续空间中模拟CIFAR10的扩散方法。Inception Score (IS) 和Fréchet Inception Distance (FID) 根据标准实践, 使用50000个生成的样本相对于训练数据集进行计算。ELBO值以比特/维度的形式报告在测试集上。

	方法	IS ($\uparrow$)	FID ($\downarrow$)	ELBO ($\uparrow$)
离散状态	D3PM 吸收 [8]	6.78	30.97	-4.40
	D3PM 高斯 [8]	8.56	7.34	-3.44
	τ LDR-0 (我们)	8.74	8.10	-3.59
	τ LDR-10 (我们)	9.49	3.74	-3.59
连续状态	DDPM [3]	9.46	3.17	-3.75
	NCSN [4]	9.89	2.20	-




图4: 左: 我们 τ LDR-10模型的无条件CIFAR10样本 右: 生成的CIFAR10样本的FID分数与采样过程中 $p_{0|t}^\theta$ 评估次数的关系 (由 τ 变化引起)。使用10k个样本计算, 因此与表 1 [28]存在差异。

在这里, 我们直接在离散空间中对图像进行建模。我们使用标准U-net架构 $p_{0|t}^\theta$ 进行参数化 $p_{0|t}^\theta$, 并结合 [8]提出的针对离散状态空间的修改。我们使用空间偏置率矩阵, 并使用包含直接 $p_{0|t}^\theta$ 监督的增强 $\mathcal{L}_{CT}$ 损失进行训练, 完整实验细节在附录H.2中。

图4左显示了模型生成的随机无条件CIFAR10样本, 我们在表1中报告了样本质量指标。我们看到我们的方法 (τ LDR-0) 具有0个校正步骤时, 在Inception分数上表现更好, 但在FID上比D3PM离散时间方法更差。然而, 我们 τ LDR-10方法在反向采样过程的每一步预测器步长中使用10个校正步骤 ($t < 0.1T$)极大地提高了样本质量, 在两个指标上都超越了离散时间方法, 并进一步缩小了与将图像建模为连续数据的方法的性能差距。使我们获得这种改进性能的校正率推导需要我们的连续时间框架。D3PM实现了最高的ELBO, 但我们注意到这与样本质量并不相关。在表1中, τ 被调整, 使得 τ LDR-0和 τ LDR-10在反向采样过程中使用 1000 $p_{0|t}^\theta$ 评估。我们展示了FID分数如何随 $p_{0|t}^\theta$ 评估次数的变化而变化, 针对 τ LDR- $\{0, 3, 10\}$, 在图4右。校正步骤的最佳数量取决于采样预算, 对于更紧的预算, 较少的校正步骤是最佳选择。这是因为在使用更多校正步骤时, 为了维持固定预算需要更多的 τ 。

6.3 单音音乐

在本实验中, 我们展示了我们的连续时间模型在非序数/分类离散数据上的生成质量得到了提升。我们使用Lakh钢琴卷数据集 [29, 30] 对歌曲进行建模。我们从数据集中选择所有单音序列, 使得在 256个时间步中, 要么播放 128 个音符中的一个, 要么是休止符。因此, 我们的数据具有状态空间大小 $S = 129$ 和维度 $D = 256$ 。在映射到 $\mathbb{Z}$ 时, 我们打乱状态空间的顺序以破坏任何序数结构。我们使用 transformer 架构 [31] 对 $p_{0|t}^\theta$ 进行参数化, 并使用 $\mathcal{L}_{CT}$ 的条件形式进行训练, 目标是给定歌曲的前 2 小节 (48 个时间步), 对最后 14 小节 (224 个时间步) 的条件分布。我们使用均匀的前向率矩阵 R_t , 完整的实验细节

表 2: 比较生成的条件样本和真实完成结果的指标。我们在测试集上计算这些指标, 显示每个测试歌曲的 5 个样本的平均值 $\pm$ 标准差。

模型	Hellinger 距离	离群值比例
τ LDR-0 出生/死亡	0.3928 ± 0.0010	0.1316 ± 0.0012
τ LDR-0 均匀	0.3765 ± 0.0013	0.1106 ± 0.0010
τ LDR-2 均匀	0.3762 ± 0.0015	0.1091 ± 0.0014
D3PM 均匀 [8]	0.3839 ± 0.0002	0.1137 ± 0.0010




图5: 未见过音乐序列的条件补全。条件2小节显示在黑色线的左侧。更多示例和音频录音链接在附录 H.3中。

在附录 H.3 中给出。对未见过的测试歌曲的条件补全结果如图 5 所示。模型能够忠实地以与条件小节相同的风格完成作品。

我们在表2中量化了样本质量。我们使用了两个指标: 生成音符和真实音符的直方图之间的 Hellinger 距离, 以及生成中但真实数据中不存在的外部音符的比例。使用我们的方法, 我们比较了出生/死亡和均匀正向率矩阵 R_0 。出生/死亡率仅对相邻状态非零, 而均匀率允许任意状态之间的转换, 这对于分类情况更合适, 因此提高了样本质量。每预测步骤添加2个校正步骤进一步提高了样本质量。我们还与离散时间方法 D3PM [8] 进行了比较, 该方法最适合分类数据的污染过程。我们发现它比我们的连续时间方法表现更差。

7 讨论

我们提出了一种用于离散去噪模型的连续时间框架。我们展示了如何使用 tau-leaping 高效地采样生成过程, 并提供了生成样本误差的界限。在离散数据问题上, 我们发现我们的预测-校正采样器相对于离散时间方法提高了样本质量。关于局限性, 我们的模型需要多次模型评估才能生成一个样本。我们的工作为将提高连续数据采样速度的工作应用于离散数据问题打开了大门 [14, 15, 16, 17, 32]。在图像上的建模性能也略低于连续状态空间模型, 我们希望随着定制的离散状态架构和污染过程调整, 这个差距能进一步缩小。最后, 我们注意到 CIFAR10 上离散时间模型的 ELBO 值优于我们的方法。在这项工作中, 我们专注于样本质量, 而不是使用我们的模型来提供数据似然性, 例如用于下游压缩任务。

致谢

Andrew Campbell 和 Joe Benton 感谢来自 EPSRC 现代统计与统计机器学习研究生院 (EP/S023151/1) 的支持。Arnaud Doucet 部分由 EPSRC 资助 (EP/R034710/1)。他还感谢英国国防科学与技术实验室 (DSTL) 和 EPSRC 在资助 (EP/R013616/1) 下的支持。这是美国国防部、英国国防部以及英国 EPSRC 在跨学科大学研究计划下的合作的一部分。该项目使用了由 EPSRC 资助 (EP/T022205/1) 的 Tier 2 高性能计算设施 JADE2 的时间。

参考文献

- [1] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. *International Conference on Machine Learning*, 2015.
- [2] Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. *Advances in Neural Information Processing Systems*, 2019.
- [3] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 2020.
- [4] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. *International Conference on Learning Representations*, 2021.
- [5] Prafulla Dhariwal and Alexander Nichol. Diffusion models beat GANs on image synthesis. *Advances in Neural Information Processing Systems*, 2021.
- [6] Emiel Hooeboom, Didrik Nielsen, Priyank Jaini, Patrick Forré, and Max Welling. Argmax flows and multinomial diffusion: Learning categorical distributions. *Advances in Neural Information Processing Systems*, 2021.
- [7] Emiel Hooeboom, Alexey A Gritsenko, Jasmijn Bastings, Ben Poole, Rianne van den Berg, and Tim Salimans. Autoregressive diffusion models. *International Conference on Learning Representations*, 2022.
- [8] Jacob Austin, Daniel Johnson, Jonathan Ho, Daniel Tarlow, and Rianne van den Berg. Structured denoising diffusion models in discrete state-spaces. *Advances in Neural Information Processing Systems*, 2021.
- [9] Patrick Esser, Robin Rombach, Andreas Blattmann, and Bjorn Ommer. Imagebart: Bidirectional context with multinomial diffusion for autoregressive image synthesis. *Advances in Neural Information Processing Systems*, 2021.
- [10] Emiel Hooeboom, Victor Garcia Satorras, Clément Vignac, and Max Welling. Equivariant diffusion for molecule generation in 3d. *International Conference on Machine Learning*, 2022.
- [11] Max Cohen, Guillaume Quispé, Sylvain Le Corff, Charles Ollion, and Eric Moulines. Diffusion bridges vector quantized variational autoencoders. *International Conference on Machine Learning*, 2022.
- [12] Daniel D Johnson, Jacob Austin, Rianne van den Berg, and Daniel Tarlow. Beyond in-place corruption: Insertion and deletion in denoising probabilistic models. *ICML Workshop on Invertible Neural Networks, Normalizing Flows, and Explicit Likelihood Models (INNF+)*, 2021.
- [13] Shuyang Gu, Dong Chen, Jianmin Bao, Fang Wen, Bo Zhang, Dongdong Chen, Lu Yuan, and Baining Guo. Vector quantized diffusion model for text-to-image synthesis. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.
- [14] Alexia Jolicoeur-Martineau, Ke Li, Rémi Piché-Taillefer, Tal Kachman, and Ioannis Mitliagkas. Gotta go fast when generating data with score-based models. *arXiv preprint arXiv:2105.14080*, 2021.
- [15] Qinsheng Zhang and Yongxin Chen. Fast sampling of diffusion models with exponential integrator. *arXiv preprint arXiv:2204.13902*, 2022.
- [16] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. *International Conference on Learning Representations*, 2022.
- [17] Hyungjin Chung, Byeongsu Sim, and Jong Chul Ye. Come-closer-diffuse-faster: Accelerating conditional diffusion models for inverse problems through stochastic contraction. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

- [18] Tim Dockhorn, Arash Vahdat, and Karsten Kreis. Score-based generative modeling with critically-damped Langevin diffusion. *International Conference on Learning Representations*, 2022.
- [19] Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion schrödinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 2021.
- [20] Daniel T Gillespie. Approximate accelerated stochastic simulation of chemically reacting systems. *The Journal of Chemical Physics*, 115(4):1716–1733, 2001.
- [21] Daniel T Gillespie. A general method for numerically simulating the stochastic time evolution of coupled chemical reactions. *Journal of Computational Physics*, 22(4):403–434, 1976.
- [22] Daniel T Gillespie. Exact stochastic simulation of coupled chemical reactions. *The Journal of Physical Chemistry*, 81(25):2340–2361, 1977.
- [23] Darren J Wilkinson. *Stochastic Modelling for Systems Biology*. Chapman and Hall/CRC, 2018.
- [24] David Levin, Yuval Peres, and Elizabeth Wilmer. *Markov Chains and Mixing Times*. American Mathematical Society, 2009.
- [25] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *International Conference on Learning Representations*, 2021.
- [26] Nikolay Savinov, Junyoung Chung, Mikolaj Binkowski, Erich Elsen, and Aaron van den Oord. Step-unrolled denoising autoencoders for text generation. *International Conference on Learning Representations*, 2022.
- [27] Anirudh Goyal, Nan Rosemary Ke, Surya Ganguli, and Yoshua Bengio. Variational walkback: Learning a transition operator as a stochastic recurrent net. *Advances in Neural Information Processing Systems*, 2017.
- [28] Min Jin Chong and David Forsyth. Effectively unbiased fid and inception score and where to find them. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020.
- [29] Colin Raffel. *Learning-based methods for comparing sequences, with applications to audio-to-midi alignment and matching*. PhD thesis, Columbia University, 2016.
- [30] Hao-Wen Dong, Wen-Yi Hsiao, Li-Chia Yang, and Yi-Hsuan Yang. Musegan: Multi-track sequential generative adversarial networks for symbolic music generation and accompaniment. *AAAI Conference on Artificial Intelligence*, 2018.
- [31] Gautam Mittal, Jesse Engel, Curtis Hawthorne, and Ian Simon. Symbolic music generation with diffusion models. *International Society for Music Information Retrieval*, 2021.
- [32] Fan Bao, Chongxuan Li, Jun Zhu, and Bo Zhang. Analytic-dpm: an analytic estimate of the optimal reverse variance in diffusion probabilistic models. *International Conference on Learning Representations*, 2022.
- [33] David F Anderson. A modified next reaction method for simulating chemical systems with time dependent propensities and delays. *The Journal of Chemical Physics*, 127(21):214107, 2007.
- [34] Chie Furusawa, Shinya Kitaoka, Michael Li, and Yuri Odagiri. Generative probabilistic image colorization. *arXiv preprint arXiv:2109.14518*, 2021.
- [35] Ethan Perez, Florian Strub, Harm De Vries, Vincent Dumoulin, and Aaron Courville. Film: Visual reasoning with a general conditioning layer. *AAAI Conference on Artificial Intelligence*, 2018.
- [36] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.

- [37] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. *International Conference on Medical Image Computing and Computer-assisted Intervention*, 2015.
- [38] Tim Salimans, Andrej Karpathy, Xi Chen, and Diederik P Kingma. Pixelcnn++: Improving the pixelcnn with discretized logistic mixture likelihood and other modifications. *International Conference on Learning Representations*, 2017.
- [39] Xi Chen, Nikhil Mishra, Mostafa Rohaninejad, and Pieter Abbeel. Pixelsnail: An improved autoregressive generative model. *International Conference on Machine Learning*, 2018.
- [40] Stefan Elfving, Eiji Uchibe, and Kenji Doya. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning. *Neural Networks*, 107:3–11, 2018.
- [41] Maximilian Seitzer. pytorch-fid: FID Score for PyTorch. <https://github.com/mseitzer/pytorch-fid>, August 2020. Version 0.2.1.

附录

目录

连续时间马尔可夫链入门 15 B 证明 16 B.1 命题1的证明.16 B.2 命题2的证明.17 B.3 命题3的证明.21 B.4 命题4的证明.22 B.5 定理1的证明.22 C 连续时间ELBO详解 27 C.1 与离散时间ELBO的比较.27 C.2 条件形式.27 C.3 基于分解假设的连续时间ELBO.27 C.4 单次前向传递.29 D 直接去噪模型监督 30 E 前向过程的选择 32 F CTMC模拟 34 F.1 精确CTMC和tau-leaping.34 F.2 预测-校正讨论.34 G 离散时间中隐含的维度假设 36 H 实验细节 37 H.1 示例.37 H.2 图像建模.38 H.3 单音音乐.39

I 伦理考量

42

附录的结构如下。在A节中，我们提供了连续时间马尔可夫链的简要介绍，包括本文使用的相关结果。正文中的所有命题和定理的证明都在B节中。然后，我们在C节中描述了我们提出的对象 $\mathcal{L}_{CT}$ 的一些附加直觉和形式。在D节中，我们描述了如何将一个额外的直接去噪模型监督项添加到目标中以提高经验性能。我们模型中前向过程的定义细节可以在E节中找到。F节更详细地描述了如何模拟CTMC，并包括tau-leaping的算法描述。我们在G节中论证，在多维数据上使用分解的前向过程时，离散时间操作会引入一个隐含假设。所有调查的完整实验细节以及我们模型的附加图表和结果都可以在H节中找到。最后，在I节中，我们考虑了我们的研究的社会影响。




图6: 具有3个状态的1维连续时间马尔可夫链的示意图。

连续时间马尔可夫链入门

连续时间马尔可夫链 (CTMC) 是一个满足马尔可夫性质的右连续随机过程 $\{x_t\}_{t \in [0, T]}$, 其中 x_t 取值于离散状态空间 $\mathcal{X}$ 。由于CTMC是马尔可夫的, 因此过程未来的行为仅取决于当前状态, 而与历史无关。CTMC路径的示意图如图6所示。该过程在等待随机确定的时间后, 会重复地从一种状态转移到另一种状态。

CTMC可以通过其跳跃和持有时间完全表征。具体来说, 每次跳跃或持有时间服从均值为 $\nu(x)$ 的指数分布, 其中 x 是过程处于持有状态时的状态。跳跃到的下一个状态是从跳跃概率分布 $r(\tilde{x}|x)$ 中抽取的。然后重复执行持有和跳跃过程。

存在一个等价定义, 涉及转移率矩阵, $R \in \mathbb{R}^{S \times S}$, 我们在主论文中使用该定义。转移率矩阵定义为

$$R(\tilde{x}, x) = \lim_{\Delta t \rightarrow 0} \frac{q_{t|t-\Delta t}(x|\tilde{x}) - \delta_{x,\tilde{x}}}{\Delta t} \quad (3)$$

其中 $R(\tilde{x}, x)$ 是转移率矩阵的 $(\tilde{x}, x)$ 元素, $q_{t|t-\Delta t}(x|\tilde{x})$ 是在给定过程在时间 $t - \Delta t$ 处于状态 $\tilde{x}$ 的情况下, 过程在时间 t 处于状态 x 的无限小转移概率。反过来, CTMC本身也可以通过这个无限小转移概率来定义。

$$q_{t|t-\Delta t}(x|\tilde{x}) = \delta_{x,\tilde{x}} + R(\tilde{x}, x)\Delta t + o(\Delta t) \quad (4)$$

$o(\Delta t)$ 表示那些比 Δt 衰减得更快趋于零的项。从这个转移率矩阵的定义中, 我们可以推断出以下性质:

$$R(\tilde{x}, x) \geq 0 \quad \text{for } \tilde{x} \neq x, \quad R(x, x) \leq 0, \quad R(x, x) = -\sum_{x' \neq x} R(x, x') \quad (5)$$

$R(\tilde{x}, x)$ 是从状态 $\tilde{x}$ 到状态 x 的概率质量移动的速率。 $R(x, x)$ 是概率质量从状态 x 移出的总速率, 因此是负数。

在时间齐次的情况下, R 与跳跃和持有时间定义有简单的关联。

$$\nu(x) = -\frac{1}{R(x, x)} \quad r(\tilde{x}|x) = (1 - \delta_{\tilde{x}, x}) \frac{R(x, \tilde{x})}{-R(x, x)}$$

在非齐次时间情况下, 我们的转移率矩阵现在将依赖于时间、 R_t , 并且这些与跳跃时间和保持时间定义的简单关系不再成立。然而, R_t 仍然会遵循方程(3)、(4)和(5)。

CTMC转移概率满足柯尔莫哥洛夫前向和后向方程。对于 $t > s$,

$$\text{Kolmogorov forward equation} \quad \partial_t q_{t|s}(x|\tilde{x}) = \sum_y q_{t|s}(y|\tilde{x}) R_t(y, x)$$

$$\text{Kolmogorov backward equation} \quad \partial_s q_{t|s}(x|\tilde{x}) = - \sum_y R_s(\tilde{x}, y) q_{t|s}(x|y)$$

Kolmogorov前向方程还给出了CTMC边缘的微分方程。

$$\partial_t q_t(x) = \sum_y q_t(y) R_t(y, x).$$

指数分布和泊松随机变量 在时间齐次的情况下, 持有时间服从均值为 $\nu(x) = -1/R(x, x)$ 的指数分布。tau跳跃算法依赖于这样一个事实: 当事件间隔服从均值为 ν 的指数分布时, 区间 $[0, t]$ 内的事件数服从均值为 νt 的泊松分布。

B 证明

B.1命题1的证明

证明。我们回忆到, 如果一个取值于 $\mathcal{X}$ 的过程 $\{x_t\}_{t \in [0, T]}$ 是右连续的并且满足马尔可夫性质, 则称其为CTMC。记 $\{y_t\}_{t \in [0, T]} = \{x_{T-t}\}_{t \in [0, T]}$ 除以正向过程 τ_n 的跳跃时间外, 用 $n \in \mathbb{N}$ 表示, 其中 $y_{T-\tau_n} = x_{\tau_n}^- = \lim_{t \leq \tau_n, t \rightarrow \tau_n} x_t$ 。因此, $\{y_t\}_{t \in [0, T]}$ 几乎处处等于 $\{x_{T-t}\}_{t \in [0, T]}$ 并且是右连续的。由于马尔可夫性质是对称的, 我们得到 $\{y_t\}_{t \in [0, T]}$ 是一个CTMC。我们现在计算其转移矩阵。令 $\tilde{x} \in \mathcal{X}$, 根据Kolmogorov前向方程, 我们有

$$\partial_t p_{t|s}(\tilde{x}|x) = \sum_{y \in \mathcal{X}} p_{t|s}(y|x) \hat{R}_{T-t}(y, \tilde{x}),$$

其中 $\{p_{t|s}, s, t \in [0, T], t > s\}$ 是与 $\{y_t\}_{t \in [0, T]}$ 相关的转移概率系统, 而 $\{\hat{R}_{T-t}\}_{t \in [0, T]}$ 是与 $\{y_t\}_{t \in [0, T]}$ 相关的转移率矩阵。请注意,

$$\begin{aligned} p_{t|s}(x = j|\tilde{x} = i) &= \mathbb{P}(y_t = j | y_s = i) \\ &= \mathbb{P}(x_{T-t} = j | x_{T-s} = i) \\ &= \mathbb{P}(x_{T-s} = i | x_{T-t} = j) \frac{\mathbb{P}(x_{T-t} = j)}{\mathbb{P}(x_{T-s} = i)} \\ &= q_{T-s|T-t}(\tilde{x} = i|x = j) \frac{q_{T-t}(x = j)}{q_{T-s}(\tilde{x} = i)} \end{aligned}$$

其中 $\{q_{t|s}, s, t \in [0, T], t > s\}$ 是与 $\{x_t\}_{t \in [0, T]}$ 相关的转移概率系统, 而 $\{q_t, t \in [0, T]\}$ 是 $\{x_t\}_{t \in [0, T]}$ 的边缘。现在, 为 $\{x_t\}_{t \in [0, T]}$ 写后向柯尔莫哥洛夫方程

$$\partial_s q_{t|s}(\tilde{x}|x) = - \sum_{y \in \mathcal{X}} R_s(x, y) q_{t|s}(\tilde{x}|y)$$

重新标记时间索引后, 我们得到,

$$\begin{aligned} \partial_{T-t} q_{T-s|T-t}(\tilde{x}|x) &= - \sum_{y \in \mathcal{X}} R_{T-t}(x, y) q_{T-s|T-t}(\tilde{x}|y) \\ \partial_t q_{T-s|T-t}(\tilde{x}|x) &= \sum_{y \in \mathcal{X}} R_{T-t}(x, y) q_{T-s|T-t}(\tilde{x}|y) \end{aligned}$$

让 $s \rightarrow t$ 并使用该 $\lim_{s \rightarrow t} q_{T-s|T-t}(x|\tilde{x}) = 0$, 我们得到

$$\begin{aligned}
\hat{R}_{T-t}(x, \tilde{x}) &= \lim_{s \rightarrow t} \partial_t p_{t|s}(\tilde{x}|x) \\
&= \lim_{s \rightarrow t} \partial_t \left(q_{T-s|T-t}(x|\tilde{x}) \frac{q_{T-t}(\tilde{x})}{q_{T-s}(x)} \right) \\
&= \lim_{s \rightarrow t} \left[\partial_t (q_{T-s|T-t}(x|\tilde{x})) \frac{q_{T-t}(\tilde{x})}{q_{T-s}(x)} + q_{T-s|T-t}(x|\tilde{x}) \frac{\partial_t q_{T-t}(\tilde{x})}{q_{T-s}(x)} \right] \\
&= \lim_{s \rightarrow t} \partial_t (q_{T-s|T-t}(x|\tilde{x})) \frac{q_{T-t}(\tilde{x})}{q_{T-s}(x)} \\
&= R_{T-t}(\tilde{x}, x) \frac{q_{T-t}(\tilde{x})}{q_{T-t}(x)}
\end{aligned}$$

对速率矩阵中的时间索引重新标记, 我们得到

$$\hat{R}_t(x, \tilde{x}) = R_t(\tilde{x}, x) \frac{q_t(\tilde{x})}{q_t(x)}$$

现在我们将边缘比率 $\frac{q_t(\tilde{x})}{q_t(x)}$ 以不同的形式写出

$$\begin{aligned}
\frac{q_t(\tilde{x})}{q_t(x)} &= \sum_{x_0} \frac{p_{\text{data}}(x_0)}{q_t(x)} q_{t|0}(\tilde{x}|x_0) \\
&= \sum_{x_0} \frac{q_{0|t}(x_0|x)}{q_{t|0}(x|x_0)} q_{t|0}(\tilde{x}|x_0).
\end{aligned}$$

将此形式代入边缘比率, 即可完成证明。 □

B.2 定理2的证明

在本节中, 我们详细介绍了定理2的两个证明。第一个是一个使用随机过程结果的正式证明。然后我们提供了一个关于相同结果的非正式证明, 以获得对仅依赖于CTMC基本结果的 $\mathcal{L}_{\text{CT}}$ 目标的直观理解。

证明1 - 随机过程

证明。让我们记 $\mathbb{Q}$ 为正向 CTMC 的路径测度, 其速率矩阵为 R_t ; 记 $\hat{\mathbb{Q}}$ 为其精确时间逆转的路径测度; 记 $\mathbb{P}^\theta$ 为近似逆转过程的路径测度, 其速率矩阵为 $\hat{R}_t^\theta$ 。此外, 我们使用上标来表示在起始点上的条件, 例如 $\mathbb{Q}^{x_0}$ 表示正向过程在起始于 x_0 的条件下的路径测度。

有了这种记法, 我们有

$$\begin{aligned}
-\log p_0^\theta(x_0) &= -\log \int p_{\text{ref}}(dx_T) \int_{\{\hat{W}_T=x_0\}} \mathbb{P}^{\theta, x_T}(dw) \\
&= -\log \int q_{T|0}(dx_T) \int_{\{\hat{W}_T=x_0\}} \hat{\mathbb{Q}}^{x_T}(dw) \frac{dp_{\text{ref}}}{dq_{T|0}}(x_T) \frac{d\mathbb{P}^{\theta, x_T}}{d\hat{\mathbb{Q}}^{x_T}}(w) \\
&= -\log \int q_{T|0}(dx_T) \int \hat{\mathbb{Q}}(dw|\hat{W}_0 = x_T, \hat{W}_T = x_0) \frac{dp_{\text{ref}}}{dq_{T|0}}(x_T) \frac{d\mathbb{P}^{\theta, x_T}}{d\hat{\mathbb{Q}}^{x_T}}(w) \mathbb{Q}^{x_T}\{\hat{W}_0 = x_0\} \\
&\leq \int q_{T|0}(dx_T) \int \hat{\mathbb{Q}}(dw|\hat{W}_0 = x_T, \hat{W}_T = x_0) \left\{ -\log \frac{d\mathbb{P}^{\theta, x_T}}{d\hat{\mathbb{Q}}^{x_T}}(w) \right\} + C,
\end{aligned}$$

在 $\mathbb{P}^\theta$ 和 $\hat{\mathbb{Q}}$ 运行在逆向时间方向上。将 $\hat{W}_s$ 写为逆向路径并关于 $p_{\text{data}}(dx_0)$ 积分, 我们得到

$$\int p_{\text{data}}(x_0)[- \log p_0^\theta(x_0)] \leq \int p_{\text{data}}(x_0) \int q_{T|0}(dx_T) \int \hat{\mathbb{Q}}(d\hat{W}|\hat{W}_0 = x_T, \hat{W}_T = x_0) \\ \times \left\{ \int_{s=0}^T \hat{R}_{T-s}^\theta(\hat{W}_s) ds - \sum_{s: \hat{W}_{s-} \neq \hat{W}_s} \log \mathbb{P}_{T-s}^\theta(\hat{W}_s|\hat{W}_{s-}) \hat{R}_{T-s}^\theta(\hat{W}_{s-}) \right\} + C,$$

其中 $\hat{R}_t^\theta(x)$ 是 $-\hat{R}_t^\theta(x, x)$ 的简写。

当 $x_0 \sim p_{\text{data}}, x_T \sim q_{T|0}(\cdot|x_0), W \sim \mathbb{Q}(dW|W_0 = x_T, W_T = x_0)$ 时, 反向路径根据 $p_{\text{data}}(dx_0)\mathbb{Q}_{x_0}(dW)$ 分布, 因此 $(\hat{W}_{s-}, \hat{W}_s)$ 像 $(W_{T-s}, W_{(T-s)-})$ 一样分布, 所以我们有

$$\int p_{\text{data}}(x_0)[- \log p_0^\theta(x_0)] \\ \leq \int p_{\text{data}}(x_0)\mathbb{Q}_{x_0}(dW) \left\{ \int_{s=0}^T \hat{R}_{T-s}^\theta(W_{(T-s)-}) ds - \sum_{s: W_{(T-s)-} \neq W_{T-s}} \log \mathbb{P}_{T-s}^\theta(W_{(T-s)-}|W_{T-s}) \hat{R}_{T-s}^\theta(W_{T-s}) \right\} + C$$

使用 Dynkin 引理和 $\mathbb{P}_t^\theta(x|y)\hat{R}_t^\theta(y) = \hat{R}_t^\theta(y, x)$ 这一事实, 我们可以重新表达这一最终行

$$= \iint_{s=0}^T q_{T-s}(dx) \left\{ \sum_{z \neq x} \hat{R}_{T-s}^\theta(x, z) - \sum_{z \neq x} R_{T-s}(x, z) \frac{\sum_{y \neq x} R_{T-s}(x, y)}{\sum_{z \neq x} R_{T-s}(x, z)} \log \hat{R}_{T-s}^\theta(y, x) \right\} \\ = \iint_{s=0}^T q_{T-s}(dx) r_{T-s}(dy|x) \left\{ \sum_{z \neq x} \hat{R}_{T-s}^\theta(x, z) - \sum_{z \neq x} R_{T-s}(x, z) \log \hat{R}_{T-s}^\theta(y, x) \right\} \\ = \iint_{s=0}^T q_s(dx) r_s(dy|x) \left\{ \sum_{z \neq x} \hat{R}_s^\theta(x, z) - \sum_{z \neq x} R_s(x, z) \log \hat{R}_s^\theta(y, x) \right\}$$

这重新排列为命题 2 形式的连续时间 ELBO。

□

证明 2 - 离散时间 ELBO 的极限

证明。考虑 $[0, T]$ $0 = t_0 < t_1 < \dots < t_{k-1} < t_k < t_{k+1} < \dots < t_{K-1} < t_K = T$ 的划分。令 $t_k - t_{k-1} = \Delta t$ 对所有 k 成立。在下标中, 我们使用 k 作为 t_k 的简写, 当这样不会引起混淆时。考虑具有这种时间划分的 CTMC 将问题转换为具有正向转移核

$q_{k+1|k}(x_{k+1}|x_k)$ 和参数化反向核 $p_{k|k+1}^\theta(x_k|x_{k+1})$ 的离散时间马尔可夫链。因此, 我们可以将负 ELBO 写为其离散时间形式, $\mathcal{L}_{\text{DT}}$

$$\mathcal{L}_{\text{DT}}(\theta) = \mathbb{E}_{p_{\text{data}}(x_0)} \left[\text{KL}(q_{K|0}(x_K|x_0)||p_{\text{ref}}(x_K)) - \mathbb{E}_{q_{1|0}(x_1|x_0)} \left[\log p_{0|1}^\theta(x_0|x_1) \right] \right. \\ \left. + \sum_{k=1}^{K-1} \mathbb{E}_{q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0)||p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \right]$$

在以下内容中, 我们将基于 CTMC 速率矩阵写出转移核, 并取 $\Delta t \rightarrow 0$ 的极限, 以获得连续时间负 ELBO。

首先, 考虑来自内部和 $\mathcal{L}_{\text{DT}}$ 的一个项

$$L_k = \mathbb{E}_{p_{\text{data}}(x_0)q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0)||p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \\ = -\mathbb{E}_{p_{\text{data}}(x_0)q_{k+1|0}(x_{k+1}|x_0)q_{k|k+1,0}(x_k|x_{k+1}, x_0)} \left[\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] + C \\ = -\mathbb{E}_{q_k(x_k)q_{k+1|k}(x_{k+1}|x_k)} \left[\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] + C$$

其中我们已经将不依赖于 θ 的项吸收到 C 中。我们现在用 $\hat{R}_k^\theta$ 表示 $p_{k|k+1}^\theta(x_k|x_{k+1})$

$$\begin{aligned}
p_{k|k+1}^\theta(x_k|x_{k+1}) &= \delta_{x_k, x_{k+1}} + \hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \\
\log p_{k|k+1}^\theta(x_k|x_{k+1}) &= \log \left(\delta_{x_k, x_{k+1}} + \hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \\
&= \delta_{x_k, x_{k+1}} \log \left(1 + \hat{R}_k^\theta(x_k, x_k)\Delta t + o(\Delta t) \right) \\
&\quad + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \\
&= \delta_{x_k, x_{k+1}} \left(\hat{R}_k^\theta(x_k, x_k)\Delta t + o(\Delta t) \right) \\
&\quad + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \tag{6}
\end{aligned}$$

在最后一行中，我们使用了适用于 $\log(1+z) = z - \frac{z^2}{2} + o(z^2)$ 的级数展开， $|z| \leq 1, z \neq -1$ 。

对于任何有限的 $\hat{R}_k^\theta(x_k, x_k)$ ， Δt 都可以取得足够小，使得级数展开成立。我们现在将这个形式代入 $\log p_{k|k+1}^\theta$ 中，并进一步将期望值对

$q_{k+1|k}(x_{k+1}|x_k) = \delta_{x_k, x_{k+1}} + R_k(x_k, x_{k+1})\Delta t + o(\Delta t)$ 写作一个显式求和。

$$\begin{aligned}
L_k = -\mathbb{E}_{q_k(x_k)} \left[\sum_{x_{k+1}} \left\{ \left[\delta_{x_k, x_{k+1}} + R_k(x_k, x_{k+1})\Delta t + o(\Delta t) \right] \times \right. \right. \\
\left. \left[\delta_{x_k, x_{k+1}} \left(\hat{R}_k^\theta(x_k, x_k)\Delta t + o(\Delta t) \right) \right. \right. \\
\left. \left. + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \right] \right\} \right] + C
\end{aligned}$$

$$\begin{aligned}
L_k = -\mathbb{E}_{q_k(x_k)} \left[\sum_{x_{k+1}} \left\{ \delta_{x_k, x_{k+1}} \hat{R}_k^\theta(x_k, x_k)\Delta t \right. \right. \\
\left. \left. + (1 - \delta_{x_k, x_{k+1}}) R_k(x_k, x_{k+1})\Delta t \times \right. \right. \\
\left. \left. \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) + o(\Delta t) \right\} \right] + C
\end{aligned}$$

我们可以通过以下重新排列，在对数中隔离 $\hat{R}_k^\theta$

$$\begin{aligned}
&\Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \\
&= \Delta t \log \Delta t + \Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) + o(1) \right) \\
&= \Delta t \log \Delta t + \Delta t \log(1 + o(1)) + \Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) \right)
\end{aligned}$$

其中前两项与 θ 无关，并且随着 $\Delta t \rightarrow 0$ 趋于 0。请注意，我们假设对于具有 $R_k(x_k, x_{k+1}) > 0$ 的 $x_{k+1} \neq x_k$ 对， $\hat{R}_k^\theta(x_{k+1}, x_k) > 0$ 成立。这个假设是有效的，因为对于 $x_{k+1} \neq x_k$ ，我们有

$$\hat{R}_k^\theta(x_{k+1}, x_k) = R_k(x_k, x_{k+1}) \sum_{x_0} \frac{q_{k|0}(x_k|x_0)}{q_{k|0}(x_{k+1}|x_0)} p_{0|k}^\theta(x_0|x_{k+1})$$

并且我们假设 $p_{0|k}^\theta(x_0|x_{k+1}) > 0$ ，这在我们将 $p_{0|k}^\theta$ 参数化为 softmax 输出时是有效的。

我们假设一个不可约马尔可夫链，因此 $q_{k|0} > 0$ 对 $t_k > 0$ 适用。

通过这种重新排列，并将吸收常数项合并到 C 中，我们得到

$$L_k = -\mathbb{E}_{q_k(x_k)} \left[\sum_{x_{k+1}} \left\{ \delta_{x_k, x_{k+1}} \hat{R}_k^\theta(x_k, x_k) \Delta t \right. \right. \\ \left. \left. + (1 - \delta_{x_k, x_{k+1}}) R_k(x_k, x_{k+1}) \Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) \right) \right. \right. \\ \left. \left. + o(\Delta t) \right\} \right] + C$$

$$L_k = -\mathbb{E}_{q_k(x_k)} \left[\hat{R}_k^\theta(x_k, x_k) \Delta t + \sum_{x_{k+1} \neq x_k} R_k(x_k, x_{k+1}) \Delta t \log \hat{R}_k^\theta(x_{k+1}, x_k) + o(\Delta t) \right]$$

第二项可以重新写成，这样用蒙特卡洛方法近似会更高效。目前去噪模型 $p_{0|k}^\theta$ 需要对求和 $\sum_{x_{k+1} \neq x_k}$ 中的每一项进行评估，这将需要神经网络进行多次前向传递。我们可以创建一个新的概率分布来从中采样，具体如下。定义

$$r_k(x_{k+1}|x_k) = (1 - \delta_{x_k, x_{k+1}}) \frac{R_k(x_k, x_{k+1})}{\mathcal{Z}^k(x_k)}$$

其中

$$\mathcal{Z}^k(x_k) = \sum_{x'_{k+1} \neq x_k} R_k(x_k, x'_{k+1})$$

所以我们现在有

$$L_k = -\mathbb{E}_{q_k(x_k) r_k(x_{k+1}|x_k)} \left[\hat{R}_k^\theta(x_k, x_k) \Delta t + \mathcal{Z}^k(x_k) \Delta t \log \hat{R}_k^\theta(x_{k+1}, x_k) + o(\Delta t) \right]$$

检查 $\mathcal{L}_{\text{DT}}$ 中的其他项，我们有 $\mathbb{E}_{p_{\text{data}}(x_0)} [\text{KL}(q_{K|0}(x_K|x_0) || p_{\text{ref}}(x_K))]$ ，它不依赖于 θ ，以及 $\mathbb{E}_{q_{1|0}(x_1|x_0)} [\log p_{0|1}^\theta(x_0|x_1)]$ ，我们在这里展开

$$\begin{aligned} & \mathbb{E}_{q_{1|0}(x_1|x_0)} [\log p_{0|1}^\theta(x_0|x_1)] \\ &= \sum_{x_1} \{ \delta_{x_1, x_0} + \Delta t R_1(x_0, x_1) + o(\Delta t) \} \log p_{0|1}^\theta(x_0|x_1) \\ &= \log p_{0|1}^\theta(x_0|x_0) + \Delta t \sum_{x_1} R_1(x_0, x_1) \log p_{0|1}^\theta(x_0|x_1) + o(\Delta t) \\ &= \Delta t \hat{R}_1^\theta(x_0, x_0) + \Delta t \sum_{x_1} R_1(x_0, x_1) \log p_{0|1}^\theta(x_0|x_1) + o(\Delta t) \end{aligned}$$

在最后一行我们使用了等式 6。总之，

$$\begin{aligned} \mathcal{L}_{\text{DT}} &= \Delta t \mathbb{E}_{p_{\text{data}}(x_0) q_{1|0}(x_1|x_0)} \left[-\hat{R}_1^\theta(x_0, x_0) + \sum_{x_1} R_1(x_0, x_1) \log p_{0|1}^\theta(x_0|x_1) \right] \\ &\quad - \Delta t \sum_{k=1}^{K-1} \mathbb{E}_{q_k(x_k) r_k(x_{k+1}|x_k)} \left[\hat{R}_k^\theta(x_k, x_k) + \mathcal{Z}^k(x_k) \log \hat{R}_k^\theta(x_{k+1}, x_k) \right] \\ &\quad + o(\Delta t) + C \end{aligned}$$

我们现在取 $\mathcal{L}_{\text{DT}}$ 在 $\Delta t \rightarrow 0$ 和 $K \rightarrow \infty$ 上的极限。

$$\lim_{\Delta t \rightarrow 0} \mathcal{L}_{\text{DT}} = \mathcal{L}_{\text{CT}} = - \int_0^T \mathbb{E}_{q_t(x) r_t(\tilde{x}|x)} \left[\hat{R}_t^\theta(x, x) + \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] dt + C$$

如果我们将该积分视为关于时间 $(0, T)$ 上均匀分布的期望，我们可以用蒙特卡洛方法来估计它。我们还明确地将 $\hat{R}_t^\theta(x, x)$ 写作负对角线行和，以得到

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x) r_t(\tilde{x}|x)} \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] + C.$$

□

B.3 命题3的证明

证明。我们假设 $q_{t|s}(\mathbf{x}_t^{1:D}|\mathbf{x}_s^{1:D})$ 可以分解为 $\prod_{d=1}^D q_{t|s}(x_t^d|x_s^d)$ 其中 $q_{t|s}(x_t^d|x_s^d)$ $d = 1 \dots D$, 是具有f的独立单维CTMC的转移概率, 是 rate $R_t^d(\tilde{x}^d, x^d)$. 在 he followi 这里, 我们会 去弃i 那些 bscri 关于 x 论点的 find the $R_t^{1:D}$ 与 R_t^d 之间的对应关系, 我们使用柯尔莫哥洛夫前向方程

$$\partial_t q_{t|s}(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}) = \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) R_t^{1:D}(\mathbf{y}^{1:D}, \mathbf{x}^{1:D})$$

将我们针对 $q_{t|s}$ 的分解形式代入左侧

$$\begin{aligned} \partial_t q_{t|s}(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}) &= \partial_t \left\{ \prod_{d=1}^D q_{t|s}(x^d|\tilde{x}^d) \right\} \\ &= \sum_{d=1}^D q_{t|s}(\mathbf{x}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) \partial_t q_{t|s}(x^d|\tilde{x}^d) \\ &= \sum_{d=1}^D q_{t|s}(\mathbf{x}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) \sum_{y^d} q_{t|s}(y^d|\tilde{x}^d) R_t^d(y^d, x^d) \\ &= \sum_{d=1}^D \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{x}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) q_{t|s}(y^d|\tilde{x}^d) R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}} \\ &= \sum_{d=1}^D \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) q_{t|s}(y^d|\tilde{x}^d) R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}} \\ &= \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) \sum_{d=1}^D R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}} \end{aligned}$$

因此我们得到

$$\sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) R_t^{1:D}(\mathbf{y}^{1:D}, \mathbf{x}^{1:D}) = \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) \sum_{d=1}^D R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}}$$

这对于所有可能的分解前向过程转换, 包括 $q_{t|s}$ 和 $q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) = \delta_{\mathbf{y}^{1:D}, \tilde{\mathbf{x}}^{1:D}}$, 都必须成立。这种选择给出了我们的前向速率关系

$$R_t^{1:D}(\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}) = \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$$

将此代入命题1中关于逆向速率的表达式, 我们得到

$$\begin{aligned} \hat{R}_t^{1:D}(\mathbf{x}^{1:D}, \tilde{\mathbf{x}}^{1:D}) &= \sum_{\mathbf{x}_0^{1:D}} \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \frac{q_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}_0^{1:D})}{q_t(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D})} q_{0|t}(\mathbf{x}_0^{1:D}|\mathbf{x}^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \\ &= \sum_{\mathbf{x}_0^{1:D}} \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)} q_{0|t}(\mathbf{x}_0^{1:D}|\mathbf{x}^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \\ &= \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \sum_{x_0^d} q_{0|t}(x_0^d|\mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)} \sum_{\mathbf{x}_0^{1:D \setminus d}} q_{0|t}(\mathbf{x}_0^{1:D \setminus d}|\mathbf{x}_0^d, \mathbf{x}^{1:D}) \\ &= \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \sum_{x_0^d} q_{0|t}(x_0^d|\mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)} \end{aligned}$$

□

B.4 命题4的证明

证明。根据对正向过程应用的柯尔莫哥洛夫前向方程，我们有

$$\partial_t q_t(x_t) = \sum_y R_t(y, x_t) q_t(y)$$

此外，将柯尔莫哥洛夫前向方程应用于反向过程，该过程与正向过程具有相同的边缘分布但时间反转，我们得到

$$-\partial_t q_t(x_t) = \sum_y \hat{R}_t(y, x_t) q_t(y)$$

将这两个方程相加得到

$$\sum_y \left\{ R_t(y, x_t) + \hat{R}_t(y, x_t) \right\} q_t(y) = 0$$

因此，通过与柯尔莫哥洛夫方程比较， $R_t + \hat{R}_t$ 是具有不变分布 q_t 的CTMC的速率矩阵。□

B.5 定理1的证明

在本节中，我们推导出我们tau跳跃扩散模型的误差界限。由于tau跳跃近似仅在沿不同维度在单步中发生多个跳跃的情况下才有意义，我们选择使我们的界限对模型维度的依赖性明确，而不是简单地考虑固定 D 和 $\tau \rightarrow 0$ 的情况。

从正文回忆起，我们在 $\mathcal{X}$ 上有一个时间齐次速率矩阵 R_t ，由此我们通过为每个 d 设置 $R_t^d = R_t$ 在 $\mathcal{X}^D$ 上构造分解的速率矩阵 $R_t^{1:D}$ ，并将 $|R| = \sup_{t \in [0, T]} \sup_{x \in \mathcal{X}} |R_t(x, x)|$ ，以及让 t_{mix} 是具有速率 R_t 的CTMC的 $(1/4)$ -混合时间。我们还使用从 $\mathcal{X}$ 到 $\mathbb{Z}$ 的映射，在状态空间 $\mathcal{X}^D$ 上定义加法，如第4.3节所述，并进行分量加法。

定理 1. 对于任何 $D \geq 1$ 和在 $\mathcal{X}^D$ 上的分布 p_{data} ，设 $\{x_t\}_{t \in [0, T]}$ 是一个以 p_{data} 为初始状态、速率矩阵如上所示的CTMC。假设 $\hat{R}_t^{\theta 1:D}$ 是反向速率矩阵的近似值，并设 $(y_k)_{k=0}^N$ ， θ 是具有最大步长 τ 的反向动力学的 *tau-leaping* 近似。假设存在一个与 D 无关的常数 $M > 0$ ，使得

$$\sum_{y \neq x} \left| \hat{R}_t^{1:D}(x, y) - \hat{R}_t^{\theta 1:D}(x, y) \right| \leq M$$

对于 $\text{all } t \in [0, T]$ 。然后在下面列出的假设下，存在常数 $C_1, C_2 > 0$ ，它们依赖于 $\mathcal{X}$ 和 R_t 但不依赖于 D ，使得 $\text{if } \mathcal{L}(y_0)$ 表示 y_0 的定律，我们有总变差界

$$\|\mathcal{L}(y_0) - p_{\text{data}}\|_{\text{TV}} \leq 3MT + \left\{ (|R|SDC_1)^2 + \frac{1}{2}C_2(M + C_1SD|R|) \right\} \tau T + 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

上述定理在以下假设下成立，其中我们用 $x \sim y$ 表示 $x, y \in S^D$ ，如果它们在最多一个坐标上不同的话。

假设 1. 数据分布 p_{data} 严格为正。

假设 2. 存在一个常数 $C_1 > 0$ ，它依赖于 S 和 R_t 但不依赖于 D ，使得对于所有 $t \in [0, T]$ 和 x ，满足 $y \in S^D$ 的 $x \sim y$ ，我们有

$$\frac{q_t(x)}{q_t(y)} \leq C_1.$$

假设 3. 存在一个常数 $C_2 > 0$ ，它依赖于 S 和 R_t 但不依赖于 D ，使得对于所有 $t \in [0, T]$ 和所有满足 $x \sim y$ 的 $xy \in S^D$ ，我们有

$$\sum_z \left| \hat{R}_t(x, x+z) - \hat{R}_t(y, y+z) \right| \leq C_2.$$

如果我们允许 C_1 和 C_2 依赖于维度 D ，那么假设 2 和假设 3 将会从假设 1 和状态空间的有限性中直接得出。然而，我们选择了上述更强的表述，以便明确地说明误差界限对维度的依赖性，正如之前所解释的那样。

如正文所述，在大多数具有实际意义的情形中（包括第6节探讨的两个示例），假设3仅近似成立。然而，我们仍期望假设3中的界限在 x 、 y 额外被选择，且反向过程的tau跳跃近似以合理高概率在这两者之间跳跃时仍然成立。例如，在我们的数据为有序数据的情况下，我们期望对于任何从 x 到 y 的 $x \sim y$ 跳跃，仅在 x 接近 y 时才常见，因此每当从 x 到 y 发生跳跃时， $R_t(x, x+z)$ 和 $R_t(y, y+z)$ 应保持合理接近。在较弱形式的这一假设下，定理1的证明可以沿类似思路进行修改，但技术性将显著增加。因此，我们选择专注于假设3成立的情况，因为它能阐明关键思想。

为了证明定理1，我们需要以下引理。

命题5. 设 $(x_t)_{t \in [0, T]}$ 和 $(y_t)_{t \in [0, T]}$ 是有限状态空间 S 上的连续时间马尔可夫链，分别具有生成器 G_t 和 H_t ，且它们在 t 中都是有界和连续的。设与 X 和 Y 相关的马尔可夫核分别为 K 和 L 。那么，对于任何 S 上的概率分布 ν ，我们有

$$\|\nu K - \nu L\|_{TV} \leq \int_0^T \sup_{x \in S} \left\{ \sum_{y \neq x} |G_t(x, y) - H_t(x, y)| \right\} dt$$

证明. 我们根据 [24] 的第20.1章中的构造，定义 $(x_t)_{t \in [0, T]}$ 和 $(y_t)_{t \in [0, T]}$ 的耦合如下。首先取 $Z \sim \nu$ 并设置 $x_0 = y_0 = Z$ 。还定义变量 $\tilde{x}_0 = \tilde{y}_0 = Z$ 。

接下来，固定 λ 使得 $|G_t(x, x)|, |H_t(x, x)| \leq \lambda$ ，对于所有 $x \in S$ ， $t \in [0, T]$ ，令 $(N_s)_{1 \leq s \leq T}$ 是 $[0, T]$ 上的泊松过程，速率为 λ ，并设置 $N_0 = 0$ 。我们写出 $N = N_T$ ，以及 $S_1, S_2, \dots, S_N$ 为到达时间，并设置 $S_{n+1} = T$ 。我们递归地为 $t > 0$ 构造 x_t 和 y_t 如下。对于 $t \in [0, S_1)$ ，令 $x_t = y_t = x_0$ 。令 $1 \leq j \leq N$ 。给定 $(x_r : r < S_j)$ ($y_r : r < S_j$)， $\dots$ ，和 $\tilde{x}_j, \tilde{y}_j, \dots$ ，定义以下概率测度

$$\begin{aligned} \rho_j(\tilde{x}_j, w) &:= \begin{cases} G_{S_j}(\tilde{x}_j, w)/\lambda, & w \neq \tilde{x}_j \\ 1 - G_{S_j}(\tilde{x}_j, w)/\lambda, & w = \tilde{x}_j, \end{cases} \\ \rho'_j(\tilde{y}_j, w) &:= \begin{cases} H_{S_j}(\tilde{y}_j, w)/\lambda, & w \neq \tilde{y}_j \\ 1 - H_{S_j}(\tilde{y}_j, w)/\lambda, & w = \tilde{y}_j. \end{cases} \end{aligned}$$

示例 $(\tilde{x}_{j+1}, \tilde{y}_{j+1})$ 来自 (ρ_j, ρ'_j) 和 $t \in [S_j, S_{j+1})$ 的最大耦合，设置 $x_t = \tilde{x}_{j+1}$ ， $y_t = \tilde{y}_{j+1}$ 。最后设置 $x_T = x_{S_N}$ 和 $y_T = y_{S_N}$ 。

现在，请注意，按照这种方式定义的 $(x_t, y_t)_{t \in [0, T]}$ 是给定马尔可夫链的耦合。此外，

$$\begin{aligned} \|\nu K - \nu L\|_{TV} &\leq \mathbb{P}(x_T \neq y_T) \\ &= \mathbb{E} \left[\sum_{j=1}^N \mathbb{I}\{x_{S_j} \neq y_{S_j}\} \right] \\ &= \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \sum_{j=0}^n \mathbb{E} [\mathbb{I}\{x_{S_j} \neq y_{S_j}\}] \end{aligned}$$

并且利用跳跃是最大耦合这一事实

$$\begin{aligned}
&= \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \sum_{j=0}^n \mathbb{E} \left[\mathbb{I} \{x_s = y_s, s < S_j\} \times \|\rho_j(X_{S_{j-1}}, \cdot) - \tilde{\rho}_j(X_{S_{j-1}}, \cdot)\|_{\text{TV}} \right] \\
&= \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \sum_{j=0}^n \mathbb{E} \left[\mathbb{I} \{x_s = y_s, s < S_j\} \frac{1}{\lambda} \sum_z |G_{S_j}(x_{S_{j-1}}, z) - H_{S_j}(x_{S_{j-1}}, z)| \right] \\
&= \frac{1}{\lambda} \mathbb{E} \left[\sum_{s: x_s \neq x_{s-}} \sum_z |G_s(x_{s-}, z) - H_s(x_{s-}, z)| \right] \\
&= \frac{1}{\lambda} \int_{s=0}^T \mathbb{E} \left[\lambda \sum_z |G_s(x_{s-}, z) - H_s(x_{s-}, z)| \right] ds \\
&= \int_{s=0}^T \mathbb{E} \left[\sum_z |G_s(x_{s-}, z) - H_s(x_{s-}, z)| \right] ds
\end{aligned}$$

按要求。 $\square$

命题 6. 对于所有 $t \in [0, T]$ 和 $x, y \in \mathcal{X}^D$, 满足 $x \sim y$, 我们有

$$|\partial_t \hat{R}_t(x, y)| \leq 2|R|^2 SDC_1^2$$

此外, 可以推出 R_t 在 t 中有界且连续。

证明。为简洁起见, 在符号清晰的情况下省略上标, 我们有

$$\begin{aligned}
\left| \partial_t \hat{R}_t^{1:D}(x^{1:D}, y^{1:D}) \right| &= \left| R_t(y, x) \partial_t \left\{ \frac{q_t(y)}{q_t(x)} \right\} \right| \\
&= \left| R_t(y, x) \left\{ \frac{q_t(y)}{q_t(x)} \frac{\sum_z R_t(z, y) q_t(z)}{q_t(y)} - \frac{q_t(y)}{q_t(x)} \frac{\sum_z R_t(z, x) q_t(z)}{q_t(x)} \right\} \right| \\
&\leq 2|R|^2 SDC_1^2
\end{aligned}$$

其中第二行来自科尔莫哥洛夫前向方程, 最后一不等式来自假设 2 加上事实: $R_t(z, x)$ (或 $R_t(z, y)$) 仅在 $x \sim z$ (resp $y \sim z$) 时非零, 并且最多有 $|S||D|$ 个 x (或 y) 的值满足此条件。 $\square$

我们现在给出定理 1 的证明。

定理1的证明。让我们用 $0 = t_0 < t_1 < \dots < t_N = T$ 标记tau-leaping中使用的时步, 用 $\tau_k = t_k - t_{k-1}$ 表示 $\tau_k = t_k - t_{k-1}$, 并用 $\pi^D(x^{1:D}) = \prod_{d=1}^D \pi(x^d)$ 表示目标平稳分布, 其中 π 是单维转移矩阵 R_t^1 的不变分布。

此外, 还让 $\mathcal{R}_k^{\theta, (\tau)}$ 作为应用 tau-leaping 近似所对应的马尔可夫核速率矩阵 $\hat{R}_{t_k}^{\theta}$ 从 t_k 移动到 t_{k-1} , 并记 $\mathcal{R}^{\theta, (\tau)} = \mathcal{R}_N^{\theta, (\tau)} \mathcal{R}_{N-1}^{\theta, (\tau)} \dots \mathcal{R}_1^{\theta, (\tau)}$, , , 使得 $\mathcal{R}^{\theta, (\tau)}$ 表达了完整的 tau 跳跃过程, 并且我们有 $\mathcal{L}(\hat{y}_0) = \pi^D \mathcal{R}^{\theta, (\tau)}$ 。

然后, 正如在 [19]中我们可以分解

$$\|\pi^D \mathcal{R}^{\theta, (\tau)} - p_d\|_{\text{TV}} \leq \|\pi^D \mathcal{R}^{\theta, (\tau)} - \pi^D(\mathbb{P}^R)_{T|0}\|_{\text{TV}} + \|\pi^D - q_T\|_{\text{TV}}$$

其中 $\mathbb{P}^R$ 是精确反向过程的路径度量。

我们先处理第二项。设 t_{mix} 为单维 CTMC 的 (1/4) 混合时间, 其速率矩阵为 R_t^1 , 即

$$t_{\text{mix}} = \inf \left\{ t \geq 0 : \sup_{x_0^1 \in S} \|q_t(\cdot | x_0^1) - \pi\|_{\text{TV}} \leq \frac{1}{4} \right\}$$

然后根据

$$\|q_{t|0}(\cdot | x_0^{1:D}) - \pi^D\|_{\text{TV}} \leq \sum_{d=1}^D \|q_{t|0}(\cdot | x_0^d) - \pi\|_{\text{TV}}$$

该 t_{mix}^D , 即全 CTMC 的 $(1/4)$ -混合时间, 具有速率矩阵 $R_t^{1:D}$, 满足不等式 $t_{\text{mix}}^D \leq \{1 + \lceil \log_2 D \rceil\} t_{\text{mix}}$ 。如果我们把 $(x_{mt_{\text{mix}}^D})_{m \in \mathbb{N}}$ 视为离散时间马尔可夫链, 那么马尔可夫链混合的标准结果 (例如, 参见 [24] 的第 4.5 章) 表明

$$\|q_{mt_{\text{mix}}^D|0}(\cdot | x_0^{1:D}) - \pi^D\|_{\text{TV}} \leq 2^{-m}$$

由此可得, 对于任何 $T \geq 0$, 我们有

$$\|\pi^D - q_T\|_{\text{TV}} \leq 2 \exp \left\{ -\frac{T \log 2}{t_{\text{mix}}^D} \right\} \leq 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

完成对第二项的界限估计。

为了界定第一项, 我们定义 $\mathcal{P}_k = (\mathbb{P}^R)_{T-t_{k-1}|T-t_k}$ 并将其分解为

$$\begin{aligned} \|\pi \mathcal{R}^{\theta,(\tau)} - \pi(\mathbb{P}^R)_{T|0}\|_{\text{TV}} &\leq \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} \dots \mathcal{R}_1^{\theta,(\tau)} - \nu \mathcal{P}_N \dots \mathcal{P}_1\|_{\text{TV}} \\ &\leq \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} \mathcal{R}_{N-1}^{\theta,(\tau)} \dots \mathcal{R}_1^{\theta,(\tau)} - \nu \mathcal{R}_N^{\theta,(\tau)} \mathcal{P}_{N-1} \dots \mathcal{P}_1\|_{\text{TV}} \\ &\quad + \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} \mathcal{P}_{N-1} \dots \mathcal{P}_1 - \nu \mathcal{P}_N \mathcal{P}_{N-1} \dots \mathcal{P}_1\|_{\text{TV}} \\ &\leq \sup_{\nu} \|\nu \mathcal{R}_{N-1}^{\theta,(\tau)} \dots \mathcal{R}_1^{\theta,(\tau)} - \nu \mathcal{P}_{N-1} \dots \mathcal{P}_1\|_{\text{TV}} + \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} - \nu \mathcal{P}_N\|_{\text{TV}} \\ &\leq \sum_{k=1}^N \sup_{\nu} \|\nu \mathcal{R}_k^{\theta,(\tau)} - \nu \mathcal{P}_k\|_{\text{TV}} \end{aligned}$$

通过归纳法进行推导。因此, 我们只需找到每个区间 $[t_{k-1}, t_k]$ 上累积的总变差距离的界限。

令 $\mathcal{R}_k^{\theta}$ 为对应于以常速率矩阵 $\hat{R}_{t_k}^{\theta}$ 从 t_k 运行到 t_{k-1} 的马尔可夫核。由于根据命题 6, 反向速率矩阵 $\hat{R}_t$ 在 t 中有界且连续, 利用命题 5 我们得出, 对于 S 上的任何分布 ν , 我们有

$$\begin{aligned} \|\nu \mathcal{P}_k - \nu \mathcal{R}_k^{\theta}\|_{\text{TV}} &\leq \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_t(x, y) - \hat{R}_{t_k}^{\theta}(x, y)| \right\} dt \\ &\leq \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_t(x, y) - \hat{R}_{t_k}(x, y)| \right\} dt \\ &\quad + \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_{t_k}(x, y) - \hat{R}_{t_k}^{\theta}(x, y)| \right\} dt \end{aligned}$$

根据平均值定理, 这个表达式的前半部分可以被界定。

$$\begin{aligned} \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_t(x, y) - \hat{R}_{t_k}(x, y)| \right\} dt &\leq \int_{t_{k-1}}^{t_k} |t - t_k| \cdot 2|R|^2 S^2 D^2 C_1^2 dt \\ &\leq (|R| S D C_1 \tau_k)^2 \end{aligned}$$

在第一行中, 我们使用了该加数仅在 $y \sim x$ 时非零, 并且最多有 $|S||D|$ 个 y 值满足此条件。第二项可以使用条件 (2) 进行界定, 得到

$$\int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_{t_k}(x, y) - \hat{R}_{t_k}^{\theta}(x, y)| \right\} dt \leq M \tau_k$$

结合这两个表达式，我们得到了对 $\|\nu\mathcal{P}_k - \nu\mathcal{R}_k^\theta\|_{\text{TV}}$ 的一个界定。

$$\|\nu\mathcal{P}_k - \nu\mathcal{R}_k^\theta\|_{\text{TV}} \leq (|R|SDC_1\tau_k)^2 + M\tau_k$$

仍需界定 $\|\nu\mathcal{R}_k^\theta - \nu\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}}$ 。注意，以速率矩阵 $\hat{R}_{t_k}^\theta$ 从 x_{t_k} 开始进行 tau-leaping 等同于从时间 t_k 到 t_{k-1} 以常速率矩阵 $\hat{R}_{t_k}^{\theta,(\tau)}$ （由下式给出）运行连续时间马尔可夫链，

$$\hat{R}_{t_k}^{\theta,(\tau)}(x, y) = \hat{R}_{t_k}^\theta(x_{t_k}, y - x + x_{t_k})$$

（可能随后进行钳位操作以将我们保持在 $\mathcal{X}^D$ ）内。根据命题 5 证明的类似论证，

$$\|\delta_{x_{t_k}}\mathcal{R}_k^\theta - \delta_{x_{t_k}}\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} \leq \int_{t_{k-1}}^{t_k} \mathbb{E} \left[\sum_{y \neq x_t} |\hat{R}_{t_k}^\theta(x_t, y) - \hat{R}_{t_k}^{\theta,(\tau)}(x_t, y - x_t + x_{t_k})| \right] dt$$

其中期望值是在按精确 CTMC 速率矩阵 $\hat{R}_{t_k}^\theta$ 分布的 $(x_t)_{t \in [t_{k-1}, t_k]}$ 上取的。（注意我们已忽略钳位操作，因此此操作只能减小最终的总变差距离。）

我们可以使用条件 (2) 将此界限改写为精确反向过程的表达式，得到

$$\|\delta_{x_{t_k}}\mathcal{R}_k^\theta - \delta_{x_{t_k}}\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} \leq \int_{t_{k-1}}^{t_k} \mathbb{E} \left[2M + \sum_{y \neq x_t} |\hat{R}_{t_k}(x_t, y) - \hat{R}_{t_k}(x_{t_k}, y - x_t + x_{t_k})| \right] dt$$

设 J_t 是 (x_t) 在 t_k 和 t 之间进行的跳跃次数，并将这些跳跃的时间标记为 $s_1 \dots s_j, \dots$ ，为方便起见，记 $t \leq s_1 \leq \dots \leq s_j \leq t_k$ 和 $j = J_t$ 。则根据假设 3，我们有

$$\begin{aligned} \sum_{y \neq x_t} |\hat{R}_{t_k}(x_t, y) - \hat{R}_{t_k}(x_{t_k}, y - x_t + x_{t_k})| &\leq \sum_z |\hat{R}_{t_k}(x_t, x_t + z) - \hat{R}_{t_k}(x_{s_1}, x_{s_1} + z)| + \dots \\ &\quad + \sum_z |\hat{R}_{t_k}(x_{s_j}, x_{s_j} + z) - \hat{R}_{t_k}(x_{t_k}, x_{t_k} + z)| \\ &\leq C_2 J_t \end{aligned}$$

我们在 $z = y - x_{t_k}$ 处进行了替换。因此我们得出结论

$$\begin{aligned} \|\delta_{x_{t_k}}\mathcal{R}_k^\theta - \delta_{x_{t_k}}\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} &\leq \int_{t_{k-1}}^{t_k} \mathbb{E} [2M + C_2 J_t] dt \\ &\leq 2M|t_k - t_{k-1}| + C_2 \int_{t_{k-1}}^{t_k} |t_k - t| \cdot \sup_x |\hat{R}_{t_k}^\theta(x, x)| dt \\ &\leq 2M\gamma_k + \frac{1}{2}C_2 |\hat{R}_{t_k}^\theta| \tau_k^2 \\ &\leq 2M\tau_k + \frac{1}{2}C_2 (M + C_1 SD |R|) \tau_k^2 \end{aligned}$$

在 $\mathbb{E}[J_t]$ 处进行界定时，我们观察到 (x_t) 的跳跃以不超过 $\sup_x |\hat{R}_{t_k}^\theta(x, x)|$ 的速率发生，并且在最后一行我们使用了条件 (2) 和假设 2。由于上述结论对任何 x_{t_k} 的选择都成立，因此可以得出

$$\sup_\nu \|\nu\mathcal{R}_k^\theta - \nu\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} \leq 2M\tau_k + \frac{1}{2}C_2 (M + C_1 SD |R|) \tau_k^2$$

对 k 求和并将所有界限放在一起，我们得到

$$\|\mathcal{L}(y_0) - p_{\text{data}}\|_{\text{TV}} \leq 3MT + \left\{ (|R|SDC_1)^2 + \frac{1}{2}C_2 (M + C_1 SD |R|) \right\} \tau T + 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

按要求。 $\square$

C 连续时间 ELBO 详情

C.1 与离散时间 ELBO 的比较

通过将其与离散时间对应物 $\mathcal{L}_{\text{CT}}$ 进行比较，并考察当我们将时间步长取为非常小时 $\mathcal{L}_{\text{DT}}$ 在极限中如何变为 $\mathcal{L}_{\text{CT}}$ ，最容易获得关于 $\mathcal{L}_{\text{DT}}$ 的直观理解。我们在此处为了方便，重申了 $\mathcal{L}_{\text{CT}}$ 的定义

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x) r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] + C.$$

回想一下，KL 和中的单个项在 $\mathcal{L}_{\text{DT}}$ 加上一个与 θ 无关的加性常数是

$$-\mathbb{E}_{q_k(x_k) q_{k+1|k}(x_{k+1}|x_k)} \left[\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right].$$

最小化这个项是要从正向动力学中采样 (x_k, x_{k+1}) ，然后最大化反向方向中分配的模型概率。

一个类似的想法可以用来理解 $\mathcal{L}_{\text{CT}}$ 。首先，我们将 $\log p_{k|k+1}^\theta(x_k|x_{k+1})$ 表示为 $\hat{R}_k^\theta$ 的函数，

$$\begin{aligned} \log p_{k|k+1}^\theta(x_k|x_{k+1}) &= \delta_{x_k, x_{k+1}} \left(\hat{R}_k^\theta(x_k, x_k) \Delta t + o(\Delta t) \right) \\ &\quad + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) \Delta t + o(\Delta t) \right) \end{aligned}$$

其中我们将 $x_k = x_{k+1}$ 和 $x_k \neq x_{k+1}$ 的情况分开（参见 $\mathcal{L}_{\text{CT}}$ 的证明以获取完整细节）。

第一项将成为 $\mathcal{L}_{\text{CT}}$ 中的 $\sum_{x' \neq x} \hat{R}_t^\theta(x, x')$ 项，而第二项将成为 $\mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right)$ 项。

现在，当我们最小化 $\mathcal{L}_{\text{CT}}$ 时，我们从正向过程中采样 $(x, \tilde{x})$ ，然后最大化反向方向中分配的模型概率，就像在 $\mathcal{L}_{\text{DT}}$ 中一样。微小的额外复杂性来自于我们分别考虑了 $x_k = x_{k+1}$ 和

$x_k \neq x_{k+1}$ 的情况。当 $x_k = x_{k+1}$ 时，这对应于 $\mathcal{L}_{\text{CT}}$ 中的第一项，我们可以看到这是最小化从 x 的逆向率，这恰好是最大化不发生转换的模型概率。当 $x_k \neq x_{k+1}$ 时，这对应于 $\mathcal{L}_{\text{CT}}$ 中的第二项，它最大化从 $\tilde{x}$ 到 x 的逆向率，进而最大化发生 $\tilde{x}$ 到 x 转换的模型概率。

C.2 条件形式

对于条件形式 $\mathcal{L}_{\text{CT}}$ ，记作 $\mathcal{L}_{\text{CT}}$ ，我们改为上界负条件模型对数似然，

$\mathbb{E}_{p_{\text{data}}(x_0, y)} [-\log p_0^\theta(x_0|y)]$ 其中 y 是我们的条件器。 $\bar{\mathcal{L}}_{\text{CT}}$ 具有以下形式

$$\bar{\mathcal{L}}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(x_0, y) q_{t|0}(x|x_0) r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x'|y) \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x|y) \right) \right] + C,$$

其中

$$\begin{aligned} \hat{R}_t^\theta(x, \tilde{x}|y) &= R_t(\tilde{x}, x) \sum_{x_0} \frac{q_{t|0}(\tilde{x}|x_0)}{q_{t|0}(x|x_0)} p_{0|t}^\theta(x_0|x, y) \quad \text{for } x \neq \tilde{x}. \\ &= - \sum_{x' \neq x} \hat{R}_t^\theta(x, x'|y) \quad \text{for } x = \tilde{x} \end{aligned}$$

这很容易从考虑离散时间 ELBO 的条件形式 $\mathcal{L}_{\text{DT}}$ ，并使用与之前相同的论证从离散时间过渡到连续时间得出。

$$\mathbb{E}_{p_{\text{data}}(x_0, y)} [-\log p_0^\theta(x_0|y)] \leq \mathbb{E}_{p_{\text{data}}(x_0, y) q_{1:K|0}(x_{1:K}|x_0)} \left[-\log \frac{p_{0:K}^\theta(x_{0:K}|y)}{q_{1:K|0}(x_{1:K}|x_0)} \right] = \bar{\mathcal{L}}_{\text{DT}}$$

C.3 带分解假设的连续时间 ELBO

在以下命题中，我们展示了当使用分解式前向过程时 $\mathcal{L}_{\text{CT}}$ 的形式。我们注意到在证明中我们将采样分布从 $p_{\text{data}}(\mathbf{x}_0^{1:D} | q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) r_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}^{1:D}))$ 重新排列为 $p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D}) \phi_t(\mathbf{x}^{1:D} | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D})$ 。这并非严格必要，但它允许我们分析性地对中间变量 $\mathbf{x}^{1:D}$ 求和，这大大降低了最终目标函数的方差。

命题7. 当用命题3中给出的前向和反向过程的分解式代入时, $\mathcal{L}_{CT}$ 目标函数为

$$\begin{aligned}\mathcal{L}_{CT} = & T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(\mathbf{x}_0^{1:D}) q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) \left[\sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x^d) \right] \\ & - T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D}) \left[\sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \phi_t(x^d | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D/d} \circ x^d) \log \left(\hat{R}_t^{\theta d}(\tilde{\mathbf{x}}^{1:D}, x^d) \right) \right] \\ & + C\end{aligned}$$

with

$$\begin{aligned}\hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, \tilde{x}^d) &= R_t^d(\tilde{x}^d, x^d) \sum_{x_0^d} p_{0|t}^{\theta}(x_0^d | \mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d | x_0^d)}{q_{t|0}(x^d | x_0^d)} \\ \mathcal{Z}^t(\mathbf{x}^{1:D}) &= \sum_{d=1}^D \sum_{\tilde{x}^d \neq x^d} R_t^d(x^d, \tilde{x}^d) \\ \phi_t(x^d | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) &= \frac{R_t^d(x^d, \tilde{x}^d) q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d | \mathbf{x}_0^{1:D})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d) \sum_{d'=1}^D \sum_{x'^{d'} \neq \tilde{x}^{d'}} \frac{R_t^{d'}(x'^{d'}, \tilde{x}^{d'})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x'^{d'})} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x'^{d'} | \mathbf{x}_0^{1:D})}\end{aligned}$$

$\circ$ 表示将一个 $D-1$ 维向量与一个标量 x^d 连接, 使得结果 D 维向量在其 d^{th} 维处有 x^d .

$\psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D})$ 定义为正向噪声过程的边缘 $\int q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) r_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}^{1:D}) d\mathbf{x}^{1:D}$.

证明。我们首先重写 $\mathcal{L}_{CT}$ 的一般形式

$$\mathcal{L}_{CT}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x) r_t(\tilde{x} | x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^{\theta}(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^{\theta}(\tilde{x}, x) \right) \right] + C$$

其中

$$\mathcal{Z}^t(x) = \sum_{x' \neq x} R_t(x, x') \quad r_t(\tilde{x} | x) = (1 - \delta_{\tilde{x}, x}) R_t(x, \tilde{x}) / \mathcal{Z}^t(x).$$

对于因子化的正向过程, $\hat{R}_t^{\theta}$ 变为

$$\hat{R}_t^{\theta 1:D}(\mathbf{x}^{1:D}, \tilde{\mathbf{x}}^{1:D}) = \sum_{d=1}^D \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, \tilde{x}^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$$

其中

$$\hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, \tilde{x}^d) = R_t^d(\tilde{x}^d, x^d) \sum_{x_0^d} p_{0|t}^{\theta}(x_0^d | \mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d | x_0^d)}{q_{t|0}(x^d | x_0^d)}$$

将此形式的 $\hat{R}_t^{\theta 1:D}$ 代入 $\mathcal{L}_{CT}$ 的第一项, 我们得到

$$\begin{aligned}& \sum_{\mathbf{x}'^{1:D} \neq \mathbf{x}^{1:D}} \sum_{d=1}^D \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x'^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{x}'^{1:D \setminus d}} \\ &= \sum_{d=1}^D \sum_{x'^d} \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x'^d) \sum_{\mathbf{x}'^{1:D \setminus d}} \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{x}'^{1:D \setminus d}} (1 - \delta_{\mathbf{x}'^{1:D}, \mathbf{x}^{1:D}}) \\ &= \sum_{d=1}^D \sum_{x'^d \neq x^d} \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x'^d)\end{aligned}$$

现在我们处理 $\mathcal{L}_{CT}$ 中的第二个项。我们首先重新排列取期望的分布:

$$p_{\text{data}}(\mathbf{x}_0^{1:D}) q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) r_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}^{1:D}) = p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D}) \phi_t(\mathbf{x}^{1:D} | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D})$$

我们有,

$$\begin{aligned}
\phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) &\propto q_{t|0}(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D})r_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}^{1:D}) \\
&= q_{t|0}(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D})(1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}}) \frac{\sum_{d=1}^D R_t^d(x^d, \tilde{x}^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}}{\mathcal{Z}^t(\mathbf{x}^{1:D})} \\
&= \sum_{d=1}^D \frac{R_t^d(x^d, \tilde{x}^d)}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d)} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d | \mathbf{x}_0^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} (1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}})
\end{aligned}$$

要找到归一化常数, 我们可以对 $\mathbf{x}^{1:D}$ 中的比例项求和

$$\begin{aligned}
&\sum_{\mathbf{x}^{1:D}} \sum_{d=1}^D \frac{R_t^d(x^d, \tilde{x}^d)}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d)} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d | \mathbf{x}_0^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} (1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}}) \\
&= \sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \frac{R_t^d(x^d, \tilde{x}^d)}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d)} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d | \mathbf{x}_0^{1:D})
\end{aligned}$$

因此,

$$\phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) = (1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}}) \sum_{d=1}^D \phi_t(x^d|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$$

其中

$$\phi_t(x^d|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) = \frac{R_t^d(x^d, \tilde{x}^d) q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d | \mathbf{x}_0^{1:D})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d) \sum_{d'=1}^D \sum_{x^{d'} \neq \tilde{x}^{d'}} \frac{R_t^{d'}(x^{d'}, \tilde{x}^{d'})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x^{d'})} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x^{d'} | \mathbf{x}_0^{1:D})}$$

现在我们将第二项写成

$$\begin{aligned}
&T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D})} \left[- \sum_{\mathbf{x}^{1:D}} \phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \mathcal{Z}^t(\mathbf{x}^{1:D}) \log \hat{R}_t^{\theta 1:D}(\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}) \right] \\
&= -T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D})} \left[\sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \phi_t(x^d|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d) \log \left(\hat{R}_t^{\theta d}(\tilde{\mathbf{x}}^{1:D}, x^d) \right) \right]
\end{aligned}$$

□

C.4 单次前向传播

为了评估 $\mathcal{L}_{\text{CT}}$ 目标, 我们天真地需要执行两次去噪网络的正向传递: $p_{0|t}^{\theta}(x_0|x)$ 来计算 $\hat{R}_t^{\theta}(x, x')$, $p_{0|t}^{\theta}(x_0|\tilde{x})$ 来计算 $\hat{R}_t^{\theta}(\tilde{x}, x)$ 。这是浪费, 因为 $\tilde{x}$ 是通过单次正向转换从 x 生成的, 在多维问题中这意味着 $\tilde{x}$ 与 x 仅在单个维度上不同。为了利用 $\tilde{x}$ 和 x 非常相似这一事实, 我们用样本 $\tilde{x} \sim \sum_x q_t(x) r_t(\tilde{x}|x)$ 来近似样本 $x \sim q_t(x)$ 。这给出了更高效的目标,

$$\mathcal{L}_{\text{eCT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x) r_t(\tilde{x}|x)} \left[\left\{ \sum_{x' \neq \tilde{x}} \hat{R}_t^{\theta}(\tilde{x}, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^{\theta}(\tilde{x}, x) \right) \right] + C$$

表3: 在单音音乐数据集上比较使用高效 $\mathcal{L}_{\text{eCT}}$ 目标与原始 $\mathcal{L}_{\text{CT}}$ 目标的指标。我们在测试集上计算这些指标, 显示每个测试歌曲的均值 $\pm$ 标准差, 针对5个样本进行计算。

模型		Hellinger距离	异常值比例
$\tau\text{LDR-0}$ 统一 $\mathcal{L}$	eCT	0.3765 ± 0.0013	0.1106 ± 0.0010
$\tau\text{LDR-0}$ 统一 $\mathcal{L}$	CT	0.3797 ± 0.0009	0.1128 ± 0.0007

这个近似是有效的, 因为 $q_t(x)$ 和 $\sum_x q_t(x)r_t(\tilde{x}|x)$ 是非常相似的分布, 我们现在来证明。

$$\begin{aligned}
\sum_x q_t(x)r_t(\tilde{x}|x) &= \sum_x q_t(x)(1 - \delta_{x,\tilde{x}}) \frac{R_t(x, \tilde{x})}{\sum_{x' \neq x} R_t(x, x')} \\
&\propto -q_t(\tilde{x})R_t(\tilde{x}, \tilde{x}) + \sum_x q_t(x)R_t(x, \tilde{x}) \\
&= q_t(\tilde{x}) \sum_{x' \neq \tilde{x}} R_t(\tilde{x}, x') + \partial_t q_t(\tilde{x}) \\
&\propto q_t(\tilde{x}) + \frac{1}{\sum_{x' \neq x} R_t(\tilde{x}, x')} \partial_t q_t(\tilde{x}) \\
&= q_t(\tilde{x}) + \delta t \partial_t q_t(\tilde{x})
\end{aligned}$$

在第三行我们使用了科尔莫哥洛夫前向方程并定义了 $\delta_t = 1/\sum_{x' \neq x} R_t(\tilde{x}, x')$ 。因此, 分布 $\sum_x q_t(x)r_t(\tilde{x}|x)$ 是通过在 $q_t(\tilde{x})$ 附近的一阶泰勒展开来近似计算的。我们注意到 δt 是在时间 t 下到下一个转换的平均时间。 δt 可以针对我们考虑的实际设置进行计算, 在图像建模任务中它介于 $2 \times 10^{-6}T$ 和 $2 \times 10^{-8}T$ 之间, 而在单音音乐任务中它是 $1 \times 10^{-3}T$ 。

我们在单音音乐数据集上进行了消融实验, 比较了使用 $\mathcal{L}_{\text{eCT}}$ 和 $\mathcal{L}_{\text{CT}}$ 进行训练的结果, 如表3所示。我们发现, 在使用更高效的 $\mathcal{L}_{\text{eCT}}$ 目标函数时, 性能得到了小幅提升, 同时效率也得到了改善。我们假设这是因为当 $\tilde{x}$ 在两个目标项之间共享时, $\mathcal{L}_{\text{eCT}}$ 目标函数的方差略有降低, 导致两个目标项之间的负相关性增加。

D 直接去噪模型监督

遵循 [8], 我们可以将直接 $p_{0|t}^\theta$ 监督引入优化目标, 该目标已被经验证明可以提升性能。我们首先通过明确表达 $\mathcal{L}_{\text{CT}}$ 对 $p_{0|t}^\theta$ 的依赖来对这一变化进行上下文化。

$$\begin{aligned}
\mathcal{L}_{\text{CT}} &= T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x)r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} R_t(x', x) \sum_{x_0} \frac{q_{t|0}(x'|x_0)}{q_{t|0}(x|x_0)} p_{0|t}^\theta(x_0|x) \right\} \right. \\
&\quad \left. - \mathcal{Z}^t(x) \log \left(R_t(x, \tilde{x}) \sum_{x_0} \frac{q_{t|0}(x|x_0)}{q_{t|0}(\tilde{x}|x_0)} p_{0|t}^\theta(x_0|\tilde{x}) \right) \right] + C
\end{aligned}$$

$p_{0|t}^\theta(x_0|x)$ 的信号通过一个对 x_0 求和得到, 权重由 $\frac{q_{t|0}(x|x_0)}{q_{t|0}(\tilde{x}|x_0)}$ 决定。我们也可以通过从损坏版本 x 预测干净数据点 x_0 并使用负对数似然损失来提供直接的去噪信号。

$$L_{\text{ll}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(x_0) q_{t|0}(x|x_0)} \left[-\log p_{0|t}^\theta(x_0|x) \right]$$

命题8. 真正的去噪分布 $q_{0|t}$ 最小化 L_{ll}

证明。

$$\begin{aligned} & T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x)} \left[\text{KL} \left(q_{0|t}(x_0|x) \parallel p_{0|t}^\theta(x_0|x) \right) \right] \\ &= T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(x_0) q_{t|0}(x|x_0)} \left[-\log p_{0|t}^\theta(x_0|x) \right] + C \end{aligned}$$

C 是一个与 θ 无关的常数。因此，最小化 L_{ll} 相当于最小化 $q_{0|t}$ 和 $p_{0|t}^\theta$ 之间的KL散度，当 $p_{0|t}^\theta = q_{0|t}$ 时达到最小值。 $\square$

如果我们获得真实的去噪分布 $p_{0|t}^\theta = q_{0|t}$ ，那么我们会得到真实的反向率 $\hat{R}_{t_0}$ [8] 发现，结合 L_{ll} 和 $\mathcal{L}_{\text{DT}}$ 的目标函数表现最佳，我们也可以在连续时间中进行优化。

$$\min_{\theta} \mathcal{L}_{\text{CT}}(\theta) + \lambda L_{ll}(\theta)$$

其中 λ 是一个超参数。在 [8], 中研究发现，仅使用 L_{ll} 进行训练的性能不如将ELBO包含在损失函数中的情况。我们在此提供一种理论假设来解释这可能的原因。我们证明，最小化 L_{ll} 相当于在离散时间中对负ELBO的上界进行最小化，因此通过使用 L_{ll} 进行训练，我们实际上是在最小化一个比直接使用负ELBO更宽松的模型负对数似然界。

命题 9. 最小化负对数似然和

$$\sum_{k=0}^{K-1} \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0)} \left[-\log p_{0|k+1}^\theta(x_0|x_{k+1}) \right]$$

等价于最小化负 $ELBO$ 的上界。

证明。

$$\begin{aligned} \mathcal{L}_{\text{DT}}(\theta) &= \mathbb{E}_{p_{\text{data}}(x_0)} \left[\text{KL}(q_{K|0}(x_K|x_0) \parallel p_{\text{ref}}(x_K)) - \mathbb{E}_{q_{1|0}(x_1|x_0)} \left[\log p_{0|1}^\theta(x_0|x_1) \right] \right. \\ &\quad \left. + \sum_{k=1}^{K-1} \mathbb{E}_{q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0) \parallel p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \right] \end{aligned}$$

考虑求和中的一个项

$$\begin{aligned} L_k &= \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0) \parallel p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \\ &= \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] \\ &\quad + \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0) q_{k|k+1,0}(x_k|x_{k+1}, x_0)} \left[\log q_{k|k+1,0}(x_k|x_{k+1}, x_0) \right] \end{aligned}$$

Now,

$$\begin{aligned} & \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] \\ &= \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log \sum_{\tilde{x}_0} q(x_k|\tilde{x}_0, x_{k+1}) p_{0|k+1}^\theta(\tilde{x}_0|x_{k+1}) \right] \\ &= \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log \sum_{\tilde{x}_0} \frac{q_{0|k}(\tilde{x}_0|x_k) q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(\tilde{x}_0|x_{k+1})} p_{0|k+1}^\theta(\tilde{x}_0|x_{k+1}) \right] \\ &\leq \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1}) q_{0|k}(\tilde{x}_0|x_k)} \left[-\log \frac{q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(\tilde{x}_0|x_{k+1})} p_{0|k+1}^\theta(\tilde{x}_0|x_{k+1}) \right] \\ &= \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0)} \left[-\log p_{0|k+1}^\theta(x_0|x_{k+1}) \right] \\ &\quad + \mathbb{E}_{p_{\text{data}}(x_0) q_{k|0}(x_k|x_0) q_{k+1|k}(x_{k+1}|x_k)} \left[-\log \frac{q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(x_0|x_{k+1})} \right] \end{aligned}$$

因此,

$$\begin{aligned}\mathcal{L}_{\text{DT}} \leq & \sum_{k=0}^{K-1} \left\{ \mathbb{E}_{p_{\text{data}}(x_0)} q_{k+1|0}(x_{k+1}|x_0) \left[-\log p_{0|k+1}^\theta(x_0|x_{k+1}) \right] \right\} \\ & + \mathbb{E}_{p_{\text{data}}(x_0)} [\text{KL}(q_{K|0}(x_K|x_0) || p_K(x_K))] \\ & + \sum_{k=1}^{K-1} \left\{ \mathbb{E}_{p_{\text{data}}(x_0)} q_{k+1|0}(x_{k+1}|x_0) q_{k|k+1,0}(x_k|x_{k+1},x_0) [\log q_{k|k+1,0}(x_k|x_{k+1},x_0)] \right. \\ & \left. + \mathbb{E}_{p_{\text{data}}(x_0)} q_{k|0}(x_k|x_0) q_{k+1|k}(x_{k+1}|x_k) \left[-\log \frac{q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(x_0|x_{k+1})} \right] \right\}\end{aligned}$$

我们可以看到, 只有第一项依赖于 θ 。 □

E 前向过程的选择

我们需要选择 R_t 的结构, 以便能够解析地获得 $q_{t|0}$ 边缘分布以实现高效训练。

命题 10. 如果 R_t 和 $R_{t'}$ 对所有 t 都可交换, 则 t' , 其中 $\exp$ 在此处理解为矩阵指数函数。

证明。令 $(P_t)_{ij} = q_{t|0}(x = j | x_0 = i)$ 。我们证明 $P_t = \exp\left(\int_0^t R_s ds\right)$ 是 Kolmogorov 前向方程的解, 其在矩阵形式下读作 $\partial_t P_t = P_t R_t$ 。将矩阵指数写成求和形式

$$\begin{aligned}P_t &= \sum_{k=0}^{\infty} \frac{1}{k!} \left(\int_0^t R_s ds \right)^k \\ &= \text{Id} + \int_0^t R_s ds + \frac{1}{2!} \left(\int_0^t R_s ds \right)^2 + \frac{1}{3!} \left(\int_0^t R_s ds \right)^3 + \dots\end{aligned}$$

现在, 求导并利用 R_t 、 $R_{t'}$ 可交换这一事实。

$$\begin{aligned}\partial_t P_t &= R_t + \int_0^t R_s ds R_t + \frac{1}{2!} \left(\int_0^t R_s ds \right)^2 R_t + \dots \\ &= \left\{ \sum_{k=0}^{\infty} \frac{1}{k!} \left(\int_0^t R_s ds \right)^k \right\} R_t \\ &= P_t R_t\end{aligned}$$

□

如正文所述, 我们通过选择 $R_t = \beta(t)R_b$ 来实现交换律, 其中 $\beta(t)$ 是一个时变标量, 而 R_b 是一个常基矩阵。我们可以利用特征分解

对 $R_b = Q\Lambda Q^{-1}$ 进行, 以高效计算 P_t ,

$$\begin{aligned}
P_t &= \exp\left(\int_0^t \beta(s) R_b ds\right) \\
&= \sum_{k=0}^{\infty} \frac{1}{k!} \left(\int_0^t \beta(s) R_b ds\right)^k \\
&= \sum_{k=0}^{\infty} \frac{1}{k!} \left(Q\Lambda Q^{-1} \int_0^t \beta(s) ds\right)^k \\
&= \sum_{k=0}^{\infty} \frac{1}{k!} Q \left(\Lambda \int_0^t \beta(s) ds\right)^k Q^{-1} \\
&= Q \left\{ \sum_{k=0}^{\infty} \frac{1}{k!} \left(\Lambda \int_0^t \beta(s) ds\right)^k \right\} Q^{-1} \\
&= Q \exp\left[\Lambda \int_0^t \beta(s) ds\right] Q^{-1}
\end{aligned}$$

由于 Λ 是对角矩阵, 矩阵指数与逐元素指数一致, 使得最终表达式易于计算。我们选择 $\beta(t) = ab^t \log b$, 因为这样可以使决定 $q_{t|0}$ 方差的积分具有简单的形式 $\int_0^t \beta(s) ds = ab^t - a_0$ 。

对于分类问题, 我们发现一个统一的速率矩阵效果很好, $R_t = \beta \mathbb{1}\mathbb{1}^T - \beta \text{Id}$ 。这直接类似于离散时间统一转移矩阵: $P = \alpha \mathbb{1}\mathbb{1}^T + (1 - S\alpha)\text{Id}$, 其中 α 取决于所用的时间离散化方法。实际上, 如果通过矩阵指数计算与统一 R_t 速率对应的离散转移矩阵, 则可以得到统一转移矩阵。另一种分类退化过程是吸收状态过程。在离散时间中, 转移矩阵由

$P = \alpha \mathbb{1} \mathbf{e}_*^T + (1 - \alpha)\text{Id}$ 给出, 其中 $\mathbf{e}_*$ 是吸收状态的独热编码。相应的吸收状态连续时间过程的转移速率矩阵为: $R_t = \beta \mathbf{1} \mathbf{e}_*^T - \beta \text{Id}$ 。对于更复杂的转移矩阵 (例如 [8] 中的离散高斯矩阵) 的对应关系, 通过解析方法很难找到, 尤其是在考虑时间非齐次情况时。对于具有序数结构的 datasets, 我们构建一个新的速率矩阵, 该矩阵使用与 [8] 构建离散高斯矩阵时类似的方法, 以保持对附近状态的偏好。

我们通过首先选择一个期望的稳态分布, p_{ref} , 然后填充矩阵元素, 以鼓励向邻近状态转换, 同时将 p_{ref} 作为我们的稳态分布来构建这个矩阵。具体来说, 我们让 p_{ref} 成为状态空间上的离散高斯分布, 即

$$p_{\text{ref}}(x) \propto \exp\left[-\frac{(x - \mu_0)^2}{2\sigma_0^2}\right]$$

为了找到一个条件, 使得这种情况成立, 回想一下边缘的柯尔莫哥洛夫微分方程

$$\partial_t q_t(x) = \sum_{\tilde{x}} q_t(\tilde{x}) R_b(\tilde{x}, x)$$

现在, 考虑一个与 p_{ref} 处于详细平衡状态的速率

$$p_{\text{ref}}(\tilde{x}) R_b(\tilde{x}, x) = p_{\text{ref}}(x) R_b(x, \tilde{x})$$

将此速率代入柯尔莫哥洛夫方程, 我们看到 p_{ref} 是稳态分布

$$\begin{aligned}
\partial_t p_{\text{ref}}(x) &= \sum_{\tilde{x}} p_{\text{ref}}(\tilde{x}) R_b(\tilde{x}, x) \\
&= \sum_{\tilde{x}} p_{\text{ref}}(x) R_b(x, \tilde{x}) \\
&= p_{\text{ref}}(x) \sum_{\tilde{x}} R_b(x, \tilde{x}) \\
&= 0
\end{aligned}$$

其中最后一行源于速率矩阵的行和为零这一事实。请注意，任何 $R_t = \beta(t)R_b$ 也将具有这个稳态分布，因为乘以 $\beta(t)$ 可以看作只是时间轴的缩放。从详细平衡方程中，我们得到关于 R_b 的条件，使得我们期望的 p_{ref} 是稳态分布

$$\frac{R_b(\tilde{x}, x)}{R_b(x, \tilde{x})} = \frac{p_{\text{ref}}(x)}{p_{\text{ref}}(\tilde{x})} = \exp \left[\frac{(\tilde{x} - \mu_0)^2}{2\sigma_0^2} - \frac{(x - \mu_0)^2}{2\sigma_0^2} \right]$$

这给出了 R_b 中对角线元素的约束，但并未完全定义整个矩阵。为此，我们首先假设 μ 被选为状态空间中心。然后将率矩阵上半部分对角线右侧的非对角项和下半部分对角线左侧的非对角项设为 1。最后，从率矩阵的顶部和底部开始，我们定义了由详细平衡条件尚未定义的率矩阵值。为清晰起见，我们在此为 8×8 率矩阵提供了该方案的图示表示。

$$\begin{bmatrix} \cdot & 1 & \square & \square & \square & \square & \square & \square \\ \triangle & \cdot & 1 & \square & \square & \square & \square & \triangle \\ \triangle & \triangle & \cdot & 1 & \square & \square & \triangle & \triangle \\ \triangle & \triangle & \triangle & \cdot & 1 & \triangle & \triangle & \triangle \\ \triangle & \triangle & \triangle & \triangle & \cdot & \triangle & \triangle & \triangle \\ \triangle & \triangle & \triangle & \square & 1 & \cdot & \triangle & \triangle \\ \triangle & \triangle & \square & \square & \square & 1 & \cdot & \triangle \\ \triangle & \square & \square & \square & \square & \square & 1 & \cdot \end{bmatrix}$$

$\square$ 表示我们将定义的值， $\triangle$ 表示通过详细平衡条件相对于另一个条目定义的值，而 $\cdot$ 是一个对角线条目，等于负的次对角线行和。我们可以定义 $\square$ 值为 0 以获得稀疏率矩阵，然而，我们在早期实验中发现，允许向更远的态转移可以大大减少混合时间并提高性能。我们类似地定义每行的 $\square$ ，通过将其设置为等于 $\exp[-i^2/\sigma_r^2]$ ，其中 i 是该行中“1”值的距离，而 σ_r 是一个超参数，定义了典型转移在状态空间中的长度尺度。这使我们的前向过程倾向于在长度尺度为 σ_r 的附近态之间进行转移。

F CTMC 仿真

F.1 精确 CTMC 与 Tau-Leaping

在本节中，我们首先描述精确 CTMC 仿真，然后再给出 Tau-Leaping 的算法描述。

当 CTMC 具有齐次速率矩阵时，我们可以使用 Gillespie 算法 [21, 22, 23] 来精确模拟它。该算法基于 CTMC 的跳跃链/持有时间定义。它重复执行以下两个步骤：

- 从均值为 $-1/R(x, x)$ 的指数分布中抽取一个持有时间，并在当前状态 x 中等待相应的时间。
- 从 $r(\tilde{x}|x) = (1 - \delta_{x, \tilde{x}}) \frac{R(x, \tilde{x})}{\sum_{x' \neq x} R(x, x')}$ 中采样下一个状态。

该算法可通过改进的下一步反应方法 [33] 调整以适用于具有时变率矩阵的情况。然而，这两种算法仍会单独遍历 CTMC 中的每个转换，因此不适用于我们的情况，因为在每个模拟步骤中只有一个维度会改变，这使得生成样本的计算成本非常高。相反，我们使用 tau 跳跃法，该方法允许在单个模拟步骤中多个维度发生变化。我们在算法 1 中详细介绍了这种方法。

F.2 预测-校正讨论

在本节中，我们比较预测-校正采样方案在连续状态空间和离散状态空间中的应用。

Algorithm 1: Generative Reverse Process Simulation with Tau-Leaping

```
 $t \leftarrow T$ 
 $\mathbf{x}_t^{1:D} \sim p_{\text{ref}}(\mathbf{x}_T^{1:D})$ 
while  $t > 0$  do
  Compute  $p_{0|t}^\theta(x_0^d | \mathbf{x}_t^{1:D})$ ,  $d = 1, \dots, D$  with one forward pass of the denoising network
  for  $d = 1, \dots, D$  do
    for  $s = 1, \dots, S \setminus x_t^d$  do
       $\hat{R}_t^{\theta d}(\mathbf{x}_t^{1:D}, s) \leftarrow R_t^d(s, x_t^d) \sum_{x_0^d} p_{0|t}^\theta(x_0^d | \mathbf{x}_t^{1:D}) \frac{q_{t|0}(s | x_0^d)}{q_{t|0}(x_t^d | x_0^d)}$ 
       $P_{ds} \leftarrow \text{Poisson}(\tau \hat{R}_t^{\theta d}(\mathbf{x}_t^{1:D}, s))$ 
    end
  end
  for  $d = 1, \dots, D$  do
    if data is categorical AND  $\sum_{s=1}^S P_{ds} > 1$  then
       $x_{t-\tau}^d \leftarrow x_t^d$  // reject change
    else
       $x_{t-\tau}^d \leftarrow x_t^d + \sum_{s=1}^S P_{ds} \times (s - x_t^d)$ 
    end
  end
   $\mathbf{x}_{t-\tau}^{1:D} \leftarrow \text{Clamp}(\mathbf{x}_{t-\tau}^{1:D}, \min = 1, \max = S)$ 
   $t \leftarrow t - \tau$ 
end
```

预测-校正方案在连续状态空间中于 [4] 中被引入。它由在预测步骤和校正步骤之间交替组成：

$$\text{Predictor} \quad \mathbf{x}_i \leftarrow \mathbf{x}_{i+1} + \gamma_i s_\theta(\mathbf{x}_{i+1}, i+1) + \sqrt{\gamma_i} z, \quad z \sim \mathcal{N}(0, I)$$

$$\text{Corrector} \quad \mathbf{x}_i \leftarrow \mathbf{x}_i + \epsilon_i s_\theta(\mathbf{x}_i, i) + \sqrt{2\epsilon_i} z, \quad z \sim \mathcal{N}(0, I)$$

$\mathbf{x}_i$ 在哪里是采样步 i 的状态, s_θ 是近似 $\nabla_{\mathbf{x}} \log q_t(\mathbf{x})$ 和 γ_i 的学习分数模型, ϵ_i 分别是预测器和校正器的步长。我们看到它们的形式相似, 但校正器在更新步骤中会额外添加一个因子 $\sqrt{2}$ 的高斯噪声。

在离散状态空间中, 与连续状态空间情况下的梯度引导随机步采样不同, 我们通过模拟具有定义速率的 CTMC 来采样。当我们进行预测器步时, 我们使用 $\hat{R}_t^\theta$ 进行模拟, 当我们进行校正器步时, 我们使用 $R_t^{\text{c}\theta} = \hat{R}_t^\theta + R_t$ 进行模拟。如果我们精确模拟 CTMC, 正如上一节所述, 这相当于从由归一化对应于当前状态速率矩阵行的分类分布中采样下一个状态。因此, 校正器采样可以看作是从通过 $R_t^{\text{c}\theta}$ 定义的略微更嘈杂的分类分布中采样, 与通过 $\hat{R}_t^\theta$ 定义的预测器分类分布相比。这类似于在连续状态空间中校正器步骤中应用的高斯噪声增加, 具有类似性。

增加校正步骤能使样本的边缘更接近 $q_t(\mathbf{x})$, 并且持续应用校正步骤将进一步探索 $q_t(\mathbf{x})$ 的领域。在之前关于连续状态预测-校正方法的研究中, 校正步骤的数量通常较少 (例如, 每个预测步骤只有 1 或 2 个校正步骤), 或者甚至完全移除了校正步骤。在本工作中, 我们发现对于逆生成过程的某些区域, 每个预测步骤使用多达 10 个校正步骤可能是有益的。此外, 在连续状态空间中, 观察到过多的校正步骤会导致生成数据中出现不希望的噪声 [34]。

我们假设, 在离散状态空间中, 校正步骤比在连续状态空间中更有效地用于探索 $q_t(\mathbf{x})$ 的领域。这是因为, 校正更新主要通过对率本身 $\hat{R}_t^\theta$ 的定义, 并通过添加正向率 R_t 使分类概率略微更接近均匀。这可能是比在连续状态空间情况下简单地添加额外的高斯噪声更有效的更新。此外, 连续状态空间中的去噪模型可以被视为输出维度为 $\mathbf{x}_0$ 的 D 点估计。然而,




图7: 通过重复应用校正步骤, $\mathbf{x}_t$ 对 $t = 0.4$ 的进展。在每一对行中, 顶行是 $\mathbf{x}_t$, 而底行是 $p_{0|t}^\theta(\mathbf{x}_0|\mathbf{x}_t)$ (每个维度中类别概率的argmax预测)。每一列代表额外的100个校正步骤。

在离散状态空间中, 去噪模型在每个维度上输出一个分类分布 (输出维度 $D \times S$) 允许它在 $\mathbf{x}_0$ 预测中表达一些不确定性信息, 尽管维度之间具有条件独立性。在离散状态空间中添加校正步骤将允许信息在当前时间步的维度之间混合, 探索 $q_t(\mathbf{x})$ 的模式。

我们在图7中的图像建模任务上探索这一想法。我们运行逆向生成过程直到时间 $t = 0.4$, 此时我们保持时间恒定并应用1000个校正步骤。我们看到, 生成的 $\mathbf{x}_t$ 状态进展探索了 $q_t(\mathbf{x})$ 在图像空间局部区域中的潜在局部模式。

G 显式维度假设在离散时间中

在离散时间中, 参数化逆向核 $p_{k|k+1}^\theta$ 通常通过去噪模型 $p_{0|k+1}^\theta$ 定义。这里, 我们考察在附录 C.3和之前的离散时间工作中, 当正向过程分解时的多维情况下的此定义。我们首先将真实全维逆向核 $q_{k|k+1}$ 用真实的去噪分布 $q_{0|k+1}$ 表示。

$$\begin{aligned}
 q_{k|k+1}(\mathbf{x}_k^{1:D}|\mathbf{x}_{k+1}^{1:D}) &= \prod_{d=1}^D q_{k|k+1}(x_k^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D}) \\
 &= \prod_{d=1}^D \sum_{\mathbf{x}_0^d} q_{k,0|k+1}(x_k^d, x_0^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D}) \\
 &= \prod_{d=1}^D \sum_{\mathbf{x}_0^d} q_{0|k+1}(x_0^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D}) q_{k|0,k+1}(x_k^d|x_0^d, \mathbf{x}_{k+1}^d)
 \end{aligned}$$

在最后一行中, 我们使用了这样一个事实: 正向过程在各个维度上是独立的。为了创建我们的近似反向核, $p_{k|k+1}^\theta$, 我们用近似 $q_{0|k+1}(x_0^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D})$ 。

$$p_{0|k+1}^\theta(x_0^d | \mathbf{x}_{k+1}^{1:D}),$$

$$p_{k|k+1}^\theta(\mathbf{x}_k^{1:D} | \mathbf{x}_{k+1}^{1:D}) = \prod_{d=1}^D \sum_{x_0^d} p_{0|k+1}^\theta(x_0^d | \mathbf{x}_{k+1}^{1:D}) q_{k|0,k+1}(x_k^d | x_0^d, x_{k+1}^d)$$

我们丢弃了额外的 $\mathbf{x}_k^{1:d-1}$ 条件，因为我们使用的是非自回归模型，该模型接收 $\mathbf{x}_{k+1}^{1:D}$ 并在单次正向传递中给出关于 x_0^d 、 $d = 1 \dots D$ 、的条件独立概率。对于有限的 K ，这个近似永远无法匹配真实的核，因为我们没有对所有相关信息进行条件化。当然，随着 K 的增大，这个近似会变得更加准确。由于我们在连续域中操作 $q_{0|t}(x_0^d | \mathbf{x}^{1:D})$ ，我们不必做这个近似，因为在我们对正向过程进行分解时（参见命题3），条件独立去噪模型，会直接出现在我们的反向率 $\hat{R}_t^{1:D}$ 中。

H 实验细节

在本节中，我们提供了针对将我们的方法应用于实际问题的实验的补充细节。我们的模型代码可在 <https://github.com/andrew-cr/tauLDR> 获取。在描述每个实验的具体细节之前，我们先解释所有实验通用的实现细节。

当我们将训练数据点的每个小批量评估目标 $\mathcal{L}_{CT}$ 时，我们必须从 $t \sim \mathcal{U}(0, T)$ 中为每个采样一个时间，该时间代表正向过程中的点，我们将对其进行添加噪声。如果 t 非常接近 0 时采样，可能会出现训练不稳定性，因为反向率 $\hat{R}_t$ 在该区域变得病态。这种现象在连续状态空间模型中也观察到，因为分数 $\nabla_x \log q_t(x)$ 在接近 $t = 0$ 时变得病态。反向率和分数在正向过程的开始附近变得病态，因为边缘概率 $q_t(x)$ 将在数据流形周围高度集中，而 $\log q_t(x)$ 在远离数据区域的区域会爆炸。为了避免这些问题，一个常见的技巧是设置一个最小时间，使得 $t \sim \mathcal{U}(\epsilon, T)$ 。 ϵ 设置为使得在 $t = \epsilon$ 处的噪声水平非常小，反向采样到该点将产生非常接近 p_{data} 的样本。在我们的实验中，我们设置 $\epsilon = 0.01T$ 。

在逆向采样过程中，我们使用tau-leaping来模拟从 $t = T$ 到 $t = \epsilon$ 的逆向过程，因为逆向速率没有针对 $t < \epsilon$ 进行训练。这会产生一个接近 p_{data} 的样本。我们发现，如果我们再完成一个最终步骤来去除样本中可能仍然存在的小量噪声，FID 等指标的性能会得到提升。具体来说，我们将样本通过去噪模型 $p_{0|t}^\theta(x_0 | x_t)$ 并使用 $t = \epsilon$ 来获得一个形状为 $D \times S$ 的输出，其中 D 是问题的维度。这是一个关于每个维度状态的概率分布。我们将每个维度的值设置为概率最高的状态。这样产生的样本就消除了所有噪声。

我们模型中 T 的具体值是任意的，因为正向过程可以在时间轴上缩放，为任何 T 提供相同的噪声过程。因此，我们简单地设置 $T = 1$ 。

H.1 示例说明

我们的二维数据集是通过从具有像素值与一个 32×32 灰度图像中 τ 字符的 32×32 状态空间中按概率采样 1M 个二维点创建的。

在我们的前向过程中，我们使用高斯速率（参见附录 E），其平稳分布标准差为 $\sigma_0 = 8$ ，速率长度尺度为 $\sigma_r = 1$ 。我们使用 $\beta(t) = 5 \times 5^t \log(5)$ 的速率调度。

为了表示 $p_{0|t}^\theta$ ，我们使用一个残差 MLP。该架构包括一个输入线性层，将输入维度 2 提升到内部网络维度 16。然后，有 2 个残差块，每个块由以下部分组成：一个隐藏维度为 32 的单个隐藏层 MLP，以及一个残差连接到

为了表示 [35]，我们使用一个残差 MLP。该架构包括一个输入线性层，将输入维度 2 提升到内部网络维度 16。然后，有 2 个残差块，每个块由以下内容组成：一个隐藏维度为 32 的单个隐藏层 MLP、一个连接到 MLP 输入的残差连接、一个层归一化，最后是一个由时间嵌入调制的 FiLM 层 [35]。在输出端，有一个输出维度为 $2 \times 32 = 64$ 的单个线性层，表示每个 2 维度中的状态概率。时间通过 Transformer 正弦位置嵌入 [36] 进行嵌入，创建一个大小为 32 的嵌入。然后，该嵌入通过一个隐藏维度为 32、输出维度为 128 的单个隐藏层 MLP 进行进一步处理。为了在每个残差块中创建 FiLM 参数，时间嵌入通过一个输出维度为 32 的线性层进行处理，以提供对 16 维状态维度的乘法和加法调制。我们使用 Adam 优化器，学习率为 0.0001，批量大小为 32，进行 1M 步的优化，以最小化 $\mathcal{L}_{CT}$ 目标函数。

对于精确模拟，我们使用带时间依赖转换率修改的下一步反应方法 [33]。此方法通过计算每种转换类型下次发生的时序，并应用最早发生的转换，逐个处理精确模拟路径中的每个转换。精确算法细节可参见 [33]。要计算转换下次发生的时间，我们需要积分反向速率矩阵（见 [33] 中的公式(13)）。我们使用步长为 0.001 的欧拉积分来完成这一步。

H.2 图像建模

我们在包含 50000 张维度为 $3 \times 32 \times 32$ 图像的 CIFAR10 训练数据集上训练。我们在由 10000 张图像组成的 CIFAR10 测试数据集上评估测试 ELBO。对于正向去噪过程，我们使用高斯速率（参见附录 E），其平稳分布标准差为 $\sigma_0 = 512$ ，速率长度尺度为 $\sigma_r = 6$ 。这实际上定义了一个均匀的平稳分布，因为状态空间大小为 256。我们发现这比更集中的高斯表现更好。我们的 β 调度是 $\beta(t) = 3 \times 100^t \log 100$ 。这是根据 σ_r 选择的，使得 $q_{t|0}$ 方差的总体变化形状大致匹配 [3] 中提出的调度。

我们的 $p_{0|t}^\theta$ 模型采用在 [3] 中引入的标准 U-net [37] 架构进行参数化。该网络遵循 PixelCNN++ 主干 [38] 并带有组归一化层。下采样/上采样堆叠中有四个特征图分辨率（ 32×32 到 4×4 ）。在每个分辨率级别上都有两个卷积残差块。在 16×16 分辨率级别 [39] 的残差块之间有一个自注意力块。时间通过首先使用 Transformer 正弦位置嵌入 [36] 进行嵌入后输入到网络中。该时间嵌入通过 SiLU 激活 [40] 然后一个线性层传递到每个残差块，并在两个卷积操作之间的残差块内的隐藏状态上添加。

[3] 的原始架构输出维度为 $3 \times 32 \times 32$ ，因为它对 x_t 进行了 x_0 的点预测。为了让模型输出关于 x_0 的概率（即输出维度为 $3 \times 32 \times 32 \times 256$ ），我们采用了 [8] 中建议的调整。具体来说，我们使用了它们的截断逻辑分布参数化方法，其中模型输出逻辑分布的均值和对数尺度，即输出维度为 $3 \times 32 \times 32 \times 2$ 。对于一个状态的概率，则是将这个连续分布在实数线上从该状态到下一个状态的积分。为了在输出中引入残差归纳偏差，逻辑分布的均值被取为 $\tanh(x_t + \mu')$ ，其中 x_t 是输入到模型中的归一化输入，而 μ' 是从网络中输出的均值。归一化操作将输入范围从 $0, \dots, 255$ 映射到 $[-1, 1]$ 。总共，我们的网络有大约 3570 万个参数。

我们使用附录 D 中描述的辅助目标函数进行优化，并使用 $\lambda = 0.001$ 。在辅助目标函数中，我们使用连续时间 ELBO 的一步前向传递版本，即 $\mathcal{L}_{CT0}$ 。我们使用 Adam 优化器进行 2M 步优化，学习率为 0.0002，批大小为 128。我们使用标准的训练技巧来提高优化效果，即 [3, 4]。在整个训练过程中，我们使用衰减因子为 0.9999 的参数指数移动平均。这些平均参数在测试时使用。在优化的开始阶段，我们使用线性学习率预热，持续 5000 步。我们将梯度范数裁剪到 1.0 的范数值。我们设置网络的 dropout 率为 0.1。每个残差块的跳过连接通过因子 $\frac{1}{\sqrt{2}}$ 进行重新缩放。输入图像在训练过程中应用随机水平翻转。

对于表1中的采样，我们为 $\tau = 0.001$ LDR-0 设置 τ ，为 $\tau = 0.002$ LDR-10 设置 τ 。对于 τ LDR-10，每 $t < 0.1T$ 个预测步骤引入10个校正步骤。我们发现，在反向采样过程的末尾附近引入校正步骤，在计算成本最小增加的情况下，对样本质量有最佳改进。当使用校正率 R_t^c 进行 tau-leaping 时，我们能够控制使用什么 τ ，因为我们正在采样一个不同的 CTMC（以 q_t 作为其平稳分布），而不是原始的反向 CTMC。我们发现，将校正率 τ 设置为反向 CTMC 原始 τ 的1.5倍，在这个例子中实现了最佳性能。

我们在学术研究集群上使用 4 块 V100 GPU 进行训练。为了计算 Inception 和 FID 值，我们使用 pytorch-fid [41] 以及进一步开发¹。我们通过计算 DDPM [3] 方法发布的图像的 Inception 和 FID 分数，验证了该库产生的值与先前工作相当。

我们在图 8 中展示了来自 τ LDR-10 模型的大量无条件样本。我们现在还展示了使用标准 tau-leaping 的反向采样过程的统计数据 $\tau = 0.001$ 。图 9 显示了在 tau-leaping 的单步过程中发生转换的维度比例。我们看到在初始阶段，每个维度在每个 tau-leaping 步都会发生变化，但在过程接近结束时，更多维度将最终固定在其位置，比例会减少。在图 10 中，我们展示了由于提议超出边界的跳跃而被裁剪的维度比例。总体而言，该比例很小。它在过程的开始时最大，当时我们从近似均匀的 p_{ref} 初始采样，并且会有接近边界的维度。随着像素值最终固定，比例会减少。图 11 展示了反向采样过程中选定维度的进展。一个相似的画面出现，维度最终会固定在状态空间的一个区域。我们还注意到，在反向过程的开始阶段，单次 tau-leaping 步会做出更大的跳跃，而在接近结束时，跳跃会变小。

H.3 单音音乐

我们从 Lakh 钢琴卷数据集 [29, 30] (许可协议 CC By 4.0) 生成我们的训练数据集。该数据集包含 174,154 个多轨钢琴卷。我们遍历所有歌曲以及每首歌曲中的所有轨道，并选择符合以下条件的序列：它们是单音的（一次只播放一个音符），没有超过一拍的没有音符播放的时期，序列中包含多种类型的音符，并且没有任何一个音符在总共 256 个时间步中播放超过 50 个时间步。这去除了数据集中无趣和琐碎的序列。然后我们移除结果中的任何重复项。最终我们得到 6000 个训练样本和 950 个测试样本。每首歌曲包含 256 个时间步（每拍 16 个），每个时间步取 129 个值中的一个，即我们有 $D = 256$ 和 $S = 129$ 。这个状态值代表 128 个选项中的一个音符或一个休止符。当我们映射到 0 到 128 的整数时，会打乱这个状态空间的顺序。当我们输入到去噪网络时，我们输入为 129 维的 one-hot 向量。

对于前向噪声过程，我们使用均匀速率矩阵， $R_b = \mathbb{1}\mathbb{1}^T - S\text{Id}$ 并设置 $\beta(t) = 0.03$ 。我们发现时间常数 $\beta(t)$ 对这个数据集是足够的。在我们的比较中，我们使用了定义如下所示的出生/死亡速率矩阵

$$\begin{bmatrix} -\lambda & \lambda & 0 & 0 & \dots & 0 & 0 \\ \lambda & -2\lambda & \lambda & 0 & \dots & 0 & 0 \\ 0 & \lambda & -2\lambda & \lambda & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & \lambda & -\lambda \end{bmatrix}$$

这是出生/死亡过程的速率矩阵。我们设置 $\lambda = 1$ 和 $\beta(t) = \frac{1}{2} \times 10000^t \log 10000$ 。这些超参数的选择使得前向过程具有稳定的噪声速率，同时 q_T 仍然非常接近 p_{ref} 。我们选择比较这类速率矩阵，因为出生/死亡速率不适用于这种分类数据，因为相邻状态没有意义

¹<https://github.com/w86763777/pytorch-gan-metrics>




图8：来自我们 τ LDR-10模型的无条件CIFAR10样本。




图9：在反向采样过程中，tau-leaping的单步转换过程中发生变化的维度比例。




图 10: 由于在反向采样过程中提议一个超出边界的跳跃, 导致在tau-leaping步骤中剪裁的维度比例。




图 11: 反向采样过程中所选维度的进展。

因为映射到整数是任意的。均匀速率适合这种分类数据, 因为在时间间隔内, 它有均等的机会转移到任何其他状态。D3PM基线也使用时间齐次均匀正向核实现, 使得离散时间和连续时间情况下的噪声速率相匹配。

我们定义了我们的条件去噪网络, $p_{0|t}^\theta(x_0|x, y)$ 采用受 [31] 启发的Transformer架构。它接受一个形状为 (B, D, S) 的输入, 其中 B 是批次大小, D 是维度 (256), S 是状态大小 (129)。这个最终维度包含 one-hot 向量。对初始条目的条件化是通过将条件信息 y 与噪声输入 x 连接来实现的。在网络的开始处, 有一个输出大小为128的输入嵌入线性层, 这是Transformer的模型维度。然后向隐藏状态添加Transformer位置嵌入。接下来应用了6个Transformer编码器层堆栈, 它们由一个自注意力块和一个隐藏层MLP组成。自注意力块使用8个头, MLP的隐藏层大小为2048。在每个内部块的输出处, 我们应用了 dropout, 概率为0.1。最后, 有一个2个残差MLP层的堆栈。每个都由一个隐藏维度为2048的隐藏层MLP组成。在MLP的输入和输出之间有一个残差连接。对块的输出应用了层归一化。为了创建网络的输出, 有一个输出线性层, 输出形状为 (B, D, S) , 其中现在 S 维度有logit概率。为了在网络中引入残差偏差, 我们将one-hot输入添加到输出logits中。所有激活都是ReLU。时间通过FiLM层 [35] 输入到网络中。首先, 使用U-net架构用于图像建模的sinusoidal Transformer位置嵌入将时间嵌入, 以创建128大小的嵌入。然后将其传递到一个隐藏层大小为2048、输出大小为512的单隐藏层MLP。在每个编码器和残差MLP块中, 有一个FiLM线性层, 它接受512大小的512时间嵌入, 并输出两个大小为128的FiLM参数。这些是应用于隐藏状态的缩放和偏移。在编码器块中, 这个FiLM变换在自注意力块之后和全连接块之后应用。在残差MLP块中, 它在层归一化操作之后应用。我们的网络总共有大约700万个参数。




图12：反向采样过程中拒绝跳跃的比例。拒绝率计算为tau跳跃步骤中拒绝跳跃的维度比例。结果在16个批次上取平均值。

2048、输出大小为512。在每个编码器和残差MLP块中，有一个FiLM线性层，它接受512大小的512时间嵌入，并输出两个大小为128的FiLM参数。这些是应用于隐藏状态的缩放和偏移。在编码器块中，这个FiLM变换在自注意力块之后和全连接块之后应用。在残差MLP块中，它在层归一化操作之后应用。我们的网络总共有大约700万个参数。

我们使用Adam优化器进行1M步优化，批大小为64，学习率为0.0002。我们使用条件 $\bar{\mathcal{L}}_{CT}$ 目标函数，并附加直接 $p_{0|t}^\theta$ 监督，如附录D所述，权重为 $\lambda = 0.001$ 。我们还进行与附录C.4中解释的相同的前向传递近似。我们使用标准的训练技巧来改进优化 [3, 4]。在整个训练过程中，我们使用衰减因子0.9999对参数维护指数移动平均值。这些平均参数在测试时使用。优化开始时，我们对前5000步使用线性学习率预热。我们将梯度范数剪裁到1.0的范数值。我们在学术集群的单个V100 GPU上训练。

使用 τ LDR-0 进行采样时，我们使用 $\tau = 0.001$ ；而使用 τ LDR-2 进行采样时，我们在每个预测器步骤后包含 2 个校正步骤，时间点为 $t < 0.9T$ 。校正率使用 $\tau = 0.0001$ 进行模拟，我们发现其表现最佳。我们拒绝任何在 2 个或更多跳跃被提议的维度，因为这是分类数据。我们在图 12 中绘制了拒绝率。大多数情况下，拒绝率为零，并且只有少数步骤的拒绝率略有上升。我们在图 13 中展示了来自测试数据集前 10 首歌曲的大量样本。我们看到采样完成的变异性，并且它们始终遵循歌曲前两个小节的条件风格。模型的音频样本可在 <https://github.com/andrew-cr/tauLDR> 获取。最后，我们检查了在均匀和出生/死亡率矩阵情况下，随机选择的一些维度在反向采样过程中的进展。图 14 显示了均匀情况下的进展，我们看到在整个反向过程中，通过状态空间的大型跳跃被做出。图 15 显示了出生/死亡情况下的进展。在反向采样的开始阶段，没有维度移动，因为在这种情况下拒绝率高，因为速率矩阵不适合分类数据。接近结束时，在相邻状态之间进行小跳跃，但由于此速率矩阵不会在任何类别之间发生大型跳跃，因此整体性能会更差。

一、伦理考量

我们的工作提升了我们对去噪生成模型的理论理解，同时也改进了在某些离散数据集上的生成能力。深度生成模型是通用方法




图13: 测试数据集中前10首歌曲中, 来自 τ LDR-0模型的两个条件样本。




图14：在均匀速率矩阵的逆向采样过程中，一组维度的进展。




图15：在出生/死亡速率矩阵的逆向采样过程中，一组维度的进展。

用于从非结构化数据中学习，但在误用时可能产生负面影响。例如，它们可以通过减少创建逼真虚假内容所需的资源来传播虚假信息。此外，生成模型将产生准确反映其训练数据集统计特性的样本。因此，如果不充分考虑原始数据中存在的偏见的情况下，将这些模型的样本解释为客观真理，那么它们可能会加剧对少数群体的歧视。

在这项工作中，我们在包含较少敏感数据的数据集上训练，例如物体图片和音乐样本。然而，我们提出的方法可以用于建模包含偏见和潜在有害内容的人像图片或互联网文本，模型随后会从中学习并复制这些内容。在用真实世界数据集训练这些模型以及部署它们时，必须格外小心，以减轻和防止它们可能造成的危害。