

离散去噪模型的连续时间框架

安德鲁·坎贝尔¹乔·本顿¹瓦伦丁·德博托利²汤姆·雷福斯¹乔治·德利吉安尼迪
斯¹阿诺·杜塞¹

¹英国牛津大学统计系 ²法国巴黎 CNRS ENS 乌尔姆 {campbell, Benton, rainforth, d
eligion, doucet}@stats.ox.ac.uk valentin.debortoli@gmail.com

抽象的

我们为离散数据的去噪扩散模型提供了第一个完整的连续时间框架。这是通过将前向噪声过程和相应的反向时间生成过程制定为连续时间马尔可夫链（CTMC）来实现的。该模型可以使用连续时间版本的 ELBO 进行有效训练。我们使用化学物理学中开发的技术来模拟高维 CTMC，并利用我们的连续时间框架来派生高性能采样器，我们证明这些采样器可以优于离散数据的离散时间方法。连续时间处理还使我们能够得出新颖的理论结果，限制生成的样本分布与真实数据分布之间的误差。

1 简介

扩散/基于评分/去噪模型 [1,2,3,4] 是一类流行的生成模型，它可以实现最先进的样本质量，并良好地覆盖数据分布 [5]，同时使用稳定、非对抗性、易于实现的训练目标。总体框架是定义一个前向噪声过程，该过程接收数据并逐渐破坏数据，直到数据分布转变为易于采样的简单分布。然后，模型通过学习噪声边缘分布的对数梯度（称为分数）来学习逆转此过程。

之前大多数关于去噪模型的工作都是在连续状态空间上进行的。然而，对于许多问题，我们想要建模的数据是离散的。例如，这种情况发生在文本、分割图、分类特征、离散潜在空间和图像的直接 8 位表示中。先前的工作试图实现去噪框架对离散数据问题的好处，并取得了有希望的初步结果[6,7,8,9,10,11,12,13]。

所有这些先前的方法都以离散 *time* 形式训练和采样模型。不幸的是，在离散时间内工作有明显的缺点。它通常迫使用户在训练时选择过程的一个分区，并且模型仅在这些固定时间点学习去噪。由于固定的划分，我们只能采用简单的祖先抽样策略。在连续时间内，模型会学习对过程中任意时间点进行去噪。反向过程的完整规范使得定义反向采样方案具有更大的灵活性。例如，在连续状态空间中，已经设计了大大减少采样时间的连续时间采样器[14,15,16,17]以及提高样本质量的连续时间采样器[4,18]。连续时间解释还使得能够推导有趣的理论属性，例如连续状态空间中的误差界限[19]。




图 1: 前向噪声过程根据 R_t (时间 t 时的损坏事件发生率) 损坏数据。噪声过程的时间反转给出了通过 $\hat{R}_t^\theta$ 定义的生成过程, 即时间 t 生成事件的速率。 $\hat{R}_t^\theta$ 通过去噪网络 $p_{0|t}^\theta(x_0|x_t)$ 进行参数化, 该网络输出以噪声 x_t 为条件的干净 x_0 值的分类概率。

为了让这些好处也能用于离散状态空间, 我们为离散去噪模型制定了连续时间框架。具体来说, 我们的贡献如下。我们将前向噪声过程表述为连续时间马尔可夫链 (CTMC), 并确定生成 CTMC, 即该过程的时间反转。然后, 我们限制生成的数据分布的对数似然, 给出 ELBO 的连续时间等效项, 可用于有效训练真实生成逆过程的参数逼近。为了有效地模拟参数逆过程, 我们利用 tau-leaping [20] 并提出了一种新颖的预测校正器类型方案, 可用于提高模拟精度。连续时间框架使我们能够得出真实数据分布与通过 tau 跳跃模拟的近似逆过程生成的样本之间的误差范围。最后, 我们展示了我们提出的对 CIFAR-10 数据集和单声道音乐序列的图像生成建模的方法。值得注意的是, 我们发现带有预测校正器采样器的 tau-leaping 可以提供比以前的离散时间离散状态方法更高质量的 CIFAR10 样本, 进一步缩小图像建模为离散数据或连续数据时的性能差距。

所有命题和定理的证明在附录中给出。

2 离散去噪模型背景

在离散时间、离散状态空间的情况下, 我们的目标是对具有有限基数 $S = |\mathcal{X}|$ 的离散数据 $x_0 \in \mathcal{X}$ 进行建模。我们假设某些离散数据分布 $p_{\text{data}}(x_0)$ 为 $x_0 \sim p_{\text{data}}(x_0)$ 。我们定义了一个前向噪声过程, 将 $p_{\text{data}}(x_0)$ 转换为某种分布 $q_K(x_K)$, 该分布非常接近易于采样的分布 $p_{\text{ref}}(x_K)$ 。这是通过定义前向内核 $q_{k+1|k}(x_{k+1}|x_k)$ 来完成的, 所有前向内核都承认 p_{ref} 作为平稳分布并相当快地混合。例如, 可以使用简单的统一内核 [6, 8], $q_{k+1|k}(x_{k+1}|x_k) = \delta_{x_{k+1}, x_k}(1 - \beta) + (1 - \delta_{x_{k+1}, x_k})\beta/(S - 1)$, 其中 δ 是克罗内克增量。相应的 p_{ref} 是所有状态的均匀分布。其他选择包括: 吸收状态核 (其中每个状态都有很小的概率转变为某种吸收状态) 或离散高斯核 (其中只有到附近状态的转变才有显著概率 (对于具有序数结构的空有效) [8])。

定义 $q_{k+1|k}$ 后, 我们进行前向联合分解如下

$$q_{0:K}(x_{0:K}) = p_{\text{data}}(x_0) \prod_{k=0}^{K-1} q_{k+1|k}(x_{k+1}|x_k).$$

联合分布 $q_{0:K}(x_{0:K})$ 也允许逆分解:

$q_{0:K}(x_{0:K}) = q_K(x_K) \prod_{k=0}^{K-1} q_{k|k+1}(x_k|x_{k+1})$ 其中 $q_K(x_K)$ 表示 $q_{0:K}(x_{0:K})$ 在时间 K 的边缘。如果可以访问 $q_{k|k+1}$ 并且可以准确地采样 q_K , 那么可以通过首先采样 $x_K \sim q_K(\cdot)$ 然后对反向内核 (即 $x_k \sim q_{k|k+1}(\cdot|x_{k+1})$) 进行祖先采样来生成 $p_{\text{data}}(x_0)$ 的样本。

然而，在实践中， $q_{k|k+1}$ 很棘手，需要用参数逆核 $p_{k|k+1}^\theta$ 来近似。该内核通常通过解析 $q_{k|k+1,0}$ 分布和参数“去噪”模型 $p_{0|k+1}^\theta$ [6, 8] 来定义，

$$\begin{aligned} p_{k|k+1}^\theta(x_k|x_{k+1}) &\triangleq \sum_{x_0} q_{k|k+1,0}(x_k|x_{k+1}, x_0) p_{0|k+1}^\theta(x_0|x_{k+1}) \\ &= q_{k+1|k}(x_{k+1}|x_k) \sum_{x_0} \frac{q_{k|0}(x_k|x_0)}{q_{k+1|0}(x_{k+1}|x_0)} p_{0|k+1}^\theta(x_0|x_{k+1}). \end{aligned} \quad (1)$$

尽管 $q_K(x_K)$ 也很棘手，但对于较大的 K ，我们可以用 $p_{\text{ref}}(x_K)$ 可靠地近似它。请注意，过渡混合越快，该近似值就越准确。然后可以通过对生成联合分布进行采样来获得来自 $p_{\text{data}}(x_0)$ 的近似样本

$$p_{0:K}^\theta(x_{0:K}) = p_{\text{ref}}(x_K) \prod_{k=0}^{K-1} p_{k|k+1}^\theta(x_k|x_{k+1}),$$

其中 θ 通过最小化负离散时间 (DT) ELBO 进行训练，ELBO 是负模型对数似然的上限

$$\mathbb{E}_{p_{\text{data}}(x_0)} [-\log p_0^\theta(x_0)] \leq \mathbb{E}_{q_{0:K}(x_{0:K})} \left[-\log \frac{p_{0:K}^\theta(x_{0:K})}{q_{1:K|0}(x_{1:K}|x_0)} \right] = \mathcal{L}_{\text{DT}}(\theta).$$

[1]中表明， $\mathcal{L}_{\text{DT}}$ 可以重写为

$$\begin{aligned} \mathcal{L}_{\text{DT}}(\theta) &= \mathbb{E}_{p_{\text{data}}(x_0)} \left[\text{KL}(q_{K|0}(x_K|x_0) || p_{\text{ref}}(x_K)) - \mathbb{E}_{q_{1|0}(x_1|x_0)} \left[\log p_{0|1}^\theta(x_0|x_1) \right] \right. \\ &\quad \left. + \sum_{k=1}^{K-1} \mathbb{E}_{q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0) || p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \right] \end{aligned}$$

其中 KL 是 Kullback-Leibler 散度。选择前向内核 $q_{k+1|k}$ ，以便可以在独立于 k 的时间内有效地计算 $q_{k|0}(x_k|x_0)$ 。这样，可以通过在每个小批量中从 $\mathcal{L}_{\text{DT}}$ 中随机选择项并执行随机梯度步骤来有效地训练 θ 。

3 连续时间框架

3.1 正向过程及其时间反转

我们的方法建立在从 $t = 0$ 到 $t = T$ 的连续时间过程之上。状态转换可以在此过程中的任何时间发生，而不是离散时间情况，在离散时间情况下，只有在应用有限数量的转换内核之一时才会发生转换（参见图 1）。此过程称为连续时间马尔可夫链 (CTMC)，为了完整性，我们在附录 A 中提供了 CTMC 的简短概述。这里直观地介绍一下，我们可以通过初始分布 q_0 和转移率矩阵 $R_t \in \mathbb{R}^{S \times S}$ 来定义 CTMC。如果当前状态为 $\tilde{x}$ ，则转移速率矩阵条目 $R_t(\tilde{x}, x)$ 是状态 $\tilde{x}$ 转移到状态 x 的瞬时速率（每单位时间发生的次数）。宽松地说，该过程中的下一个状态可能是 $R_t(\tilde{x}, x)$ 较高的状态，而且，速率越高，发生此转换所需的时间越少。

事实证明，转移率 R_t 也定义了两个时间点 $t - \Delta t$ 和 t 之间过程的无穷小转移概率

$$q_{t|t-\Delta t}(x|\tilde{x}) = \delta_{x,\tilde{x}} + R_t(\tilde{x}, x)\Delta t + o(\Delta t),$$

其中 $o(\Delta t)$ 表示以比 Δt 更快的速度趋向于零的项。与离散时间情况相比，我们看到 R_t 在我们如何定义前向过程中扮演了与离散时间前向内核 $q_{k+1|k}$ 类似的角色。因此，就像在离散时间中一样，我们设计 R_t ，以便：i) 前向过程快速混合到易于采样的（平稳）分布， p_{ref} ，（例如均匀），ii) 我们可以分析获得 $q_{t|0}(x_t|x_0)$ 分布以实现有效的训练（有关如何完成此操作，请参阅第 4.1 节）。我们在时间 $t = 0$ 处初始化 $q_0(x_0) = p_{\text{data}}(x_0)$ 处的前向 CTMC。我们将时间 $t = T$ 处的边际表示为 $q_T(x_T)$ ，它应该接近于 $p_{\text{ref}}(x_T)$ 。

现在我们考虑前向过程的时间反转，这将通过反向转移率矩阵 $\hat{R}_t \in \mathbb{R}^{S \times S}$ 从边际 $q_T(x_T)$ 回到数据分布 $p_{\text{data}}(x_0)$ ：

$$q_{t|t+\Delta t}(\tilde{x}|x) = \delta_{\tilde{x},x} + \hat{R}_t(x, \tilde{x})\Delta t + o(\Delta t).$$

在离散时间内，使用贝叶斯规则从 $q_{k+1|k}$ 到 $q_{k|k+1}$ 。我们可以使用类似的想法从 R_t 计算 $\hat{R}_t$ ，结果如下。

命题 1. For a forward in time CTMC, $\{x_t\}_{t \in [0, T]}$, with rate matrix R_t , initial distribution $p_{\text{data}}(x_0)$ and terminal distribution $q_T(x_T)$, there exists a CTMC with initial distribution $q_T(x_T)$ at $t = T$, terminal distribution $p_{\text{data}}(x_0)$ at $t = 0$ and transition rate matrix $\hat{R}_t$ that runs backwards in time and is almost everywhere equivalent to the time reversal of the forward CTMC, $\{x_t\}_{t \in [T, 0]}$. Furthermore, $\hat{R}_t$ is related to R_t by the following expression

$$\hat{R}_t(x, \tilde{x}) = R_t(\tilde{x}, x) \sum_{x_0} \frac{q_{t|0}(\tilde{x}|x_0)}{q_{t|0}(x|x_0)} q_{0|t}(x_0|x) \quad \text{for } x \neq \tilde{x},$$

where $q_{t|0}(x|x_0)$ are the conditional marginals of the forward process and $q_{0|t}(x_0|x) = q_{t|0}(x|x_0)p_{\text{data}}(x_0)/q_t(x)$ with $q_t(x)$ being the marginal of the forward process at time t . When $x = \tilde{x}$, $\hat{R}_t(x, x) = -\sum_{x' \neq x} \hat{R}_t(x, x')$ because the rows must sum to zero (see Appendix A).

不幸的是, 由于 $q_t(x)$ 以及 $q_{0|t}(x_0|x)$ 的难以处理, $\hat{R}_t$ 也变得难以处理。因此, 我们通过使用参数去噪模型 $p_{0|t}^\theta(x_0|x)$ 近似 $q_{0|t}(x_0|x)$ 来考虑 $\hat{R}_t$ 的近似 $\hat{R}_t^\theta$:

$$\hat{R}_t^\theta(x, \tilde{x}) = R_t(\tilde{x}, x) \sum_{x_0} \frac{q_{t|0}(\tilde{x}|x_0)}{q_{t|0}(x|x_0)} p_{0|t}^\theta(x_0|x) \quad \text{for } x \neq \tilde{x}$$

和之前一样的 $\hat{R}_t^\theta(x, x) = -\sum_{x' \neq x} \hat{R}_t^\theta(x, x')$ 。作为对离散时间情况的进一步类比, 请注意, 当 $x \neq \tilde{x}$ 时, $\hat{R}_t^\theta$ 具有与方程 (1) 中定义的离散时间参数反向内核 $p_{k|k+1}^\theta$ 相同的形式, 但用前向内核 $q_{k+1|k}$ 替换为前向速率 $R_{t \circ}$ 。

3.2 连续时间 ELBO

在离散时间中, 通过最小化由正向和反向过程形成的离散时间负 ELBO $\mathcal{L}_{\text{DT}}$ 来训练 θ 。我们通过最小化相应的连续时间 (CT) 负 ELBO $\mathcal{L}_{\text{CT}}$, 在连续时间中反映这种方法, 如下推导。

命题 2. For the reverse in time CTMC with initial distribution $p_{\text{ref}}(x_T)$, terminal distribution $p_0^\theta(x_0)$, and reverse rate $\hat{R}_t^\theta$, an upper bound on the negative model log-likelihood, $\mathbb{E}_{p_{\text{data}}(x_0)}[-\log p_0^\theta(x_0)]$, is given by

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x) r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] + C,$$

where C is a constant independent of θ and

$$\mathcal{Z}^t(x) = \sum_{x' \neq x} R_t(x, x') \quad r_t(\tilde{x}|x) = (1 - \delta_{\tilde{x}, x}) R_t(x, \tilde{x}) / \mathcal{Z}^t(x).$$

这里 $r_t(\tilde{x}|x)$ 给出了从 x 转换到 $\tilde{x}$ 的概率, 假设我们知道转换发生在时间 t 。我们可以通过随机梯度下降有效地优化这个目标。对于梯度更新, 我们从 $p_{\text{data}}(x_0)$ 中采样一批数据点, 使用随机时间 $t \sim \mathcal{U}(0, T)$ 、 $x \sim q_{t|0}(x|x_0)$ 对每个数据点进行噪声处理, 最后为每个 x 从 $r_t(\tilde{x}|x)$ 中采样辅助 $\tilde{x}$ 。直观上, $(x, \tilde{x})$ 是跟随时间前向噪声过程的一对状态。最小化 $\mathcal{L}_{\text{CT}}$ 中的第二项会最大化该对的反向速率, 但方向是向后的, 即 $\tilde{x}$ 到 x 。这就是 $\hat{R}_t^\theta$ 学习逆转噪声过程的方式。附录 C.1 给出了对第一项的直觉以及与 $\mathcal{L}_{\text{DT}}$ 的直接比较。

$\hat{R}_t^\theta$ 的第一个参数被输入到 $p_{0|t}^\theta$ 中, 因此我们天真地需要对 x 和 $\tilde{x}$ 进行两次网络前向传递来评估目标。我们可以通过用 $\tilde{x}$ 近似第一项中的 $q_t(x)$ 样本来避免这种情况, 这意味着我们只需要在 $\tilde{x}$ 上评估网络一次。该近似是有效的, 因为如我们在附录 C.4 中所示, 对于非常小的 δt , $\tilde{x}$ 近似根据 $q_{t+\delta t}$ 分布。

4 高效的前向和后向采样

4.1 前向过程的选择

需要选择转移率矩阵 R_t , 以便前向过程: i) 快速混合到 p_{ref} , 并且 ii) 可以通过分析获得 $q_{t|0}(x|x_0)$ 分布。柯尔莫哥洛夫

需要对 CTMC 的微分方程进行积分以获得 $q_{t|0}(x|x_0)$ 。当所有 t, t' 的 R_t 和 $R_{t'}$ 交换时，这可以通过分析完成，请参阅附录 E。满足此条件的一个简单方法是令 $R_t = \beta(t)R_b$ ，其中 $R_b \in \mathbb{R}^{S \times S}$ 是用户指定的与时间无关的基本速率矩阵，而 $\beta(t) \in \mathbb{R}$ 是时间相关标量。然后我们得到解析表达式

$$q_{t|0}(x = j|x_0 = i) = \left(Q \exp \left[\Lambda \int_0^t \beta(s) ds \right] Q^{-1} \right)_{ij}$$

其中 $R_b = Q \Lambda Q^{-1}$ 是矩阵 R_b 的特征分解， $\exp[\cdot]$ 是逐元素指数。

我们对 β 时间表的选择以 [3, 4], $\beta(t) = ab^t \log(b)$ 为指导。选择超参数 a 和 b ，使得最终时间 $t = T$ 处的 $q_T(x) \approx p_{\text{ref}}(x)$ 同时具有稳定的“信息损坏”速度，从而确保 R_t 在短时间内不会快速变化。

我们尝试使用各种 R_b 矩阵，例如统一速率 $R_b = 11^T - S\text{Id}$ ，其中 11^T 是 1 矩阵， Id 是单位矩阵。对于具有严重空间偏差的问题，例如图像，我们可以使用仅鼓励过渡到附近状态的前向速率；详细信息以及相应离散时间过程的链接可以在附录 E 中找到。

4.2 维度因式分解

我们的目标是对 D 维度的数据进行建模，每个维度从 S 可能性中获取一个值。我们现在稍微重新定义符号并说 $\mathbf{x}^{1:D} \in \mathcal{X}^D$ ， $|\mathcal{X}| = S$ 。在此设置中，天真地计算转移概率将需要计算与每个可能的下一个状态相对应的 S^D 速率值。对于任何大小合理的 S 和 D 来说，这都是很棘手的。我们简单地通过分解前向过程以使每个维度独立传播来避免这个问题。由于这是一个连续的时间过程，并且每个维度的前向过程相互独立，因此两个或多个维度同时转变的概率为零。因此，总体而言，在全维度前向 CTMC 中，每次转变仅涉及一个维度的变化。对于时间反转 CTMC，每次转变中也确实有一个维度发生变化。这使得计算变得容易处理，因为 S^D 速率值只有 $D \times (S - 1) + 1$ 是非零的 - 这些值对应于恰好一维发生变化的转换加上无变化转换。最后，我们注意到，尽管维度在正向方向上独立传播，但它们在反向方向上并不独立，因为每个维度的正向过程的起点对于非因式分解的 p_{data} 来说并不独立。下面的命题显示了这种情况下正向和反向利率的确切形式。

命题 3. *If the forward process factorizes as $q_{t|s}(\mathbf{x}_t^{1:D}|\mathbf{x}_s^{1:D}) = \prod_{d=1}^D q_{t|s}(x_t^d|x_s^d)$, $t > s$, then the forward and reverse rates are of the form*

$$R_t^{1:D}(\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}) = \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}},$$

$$\hat{R}_t^{1:D}(\mathbf{x}^{1:D}, \tilde{\mathbf{x}}^{1:D}) = \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \sum_{x_0^d} q_{0|t}(x_0^d|\mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)},$$

where $R_t^d \in \mathbb{R}^{S \times S}$ and $\delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$ is 1 when all dimensions except for d are equal.

为了找到 $\hat{R}_t^{1:D}$ ，我们只需将 $q_{0|t}(x_0^d|\mathbf{x}^{1:D})$ 替换为 $p_{0|t}^\theta(x_0^d|\mathbf{x}^{1:D})$ ，这很容易用神经网络建模，在每个维度上输出条件独立的状态概率。在附录 C.3 中，当我们使用 $R_t^{1:D}$ 和 $\hat{R}_t^{1:D}$ 的因式分解形式时，我们导出了 $\mathcal{L}_{\text{CT}}$ 的形式。

4.3 用 Tau 跳跃模拟生成逆过程

参数生成逆过程是具有速率矩阵 $\hat{R}_t^{1:D}$ 的 CTMC。模拟从时间 $t = T$ 的分布 $p_{\text{ref}}(\mathbf{x}_T^{1:D})$ 回到 $t = 0$ 的过程将产生来自 $p_{\text{data}}(\mathbf{x}_0^{1:D})$ 的近似样本。该过程可以使用 Gillespie 算法 [21,22,23] 进行精确模拟，该算法交替执行 i) 对保持当前状态的保持时间进行采样，以及 ii) 根据当前速率矩阵对新状态进行采样， $\hat{R}_t^{1:D}$ (参见附录 F)。对于大型 D 来说，这是低效的，因为我们需要单独逐步执行每个转换，因此每个模拟步骤只会改变一个维度。

相反，我们使用 tau-leaping [20, 23]，这是化学物理学中开发的一种非常流行的近似模拟方法。不是在时间中倒退一次过渡到下一次，而是跳跃式的跳跃

从 t 到 $t - \tau$ 并同时应用 $[t - \tau, t]$ 中发生的所有转换。为了实现跨越，我们假设 $\hat{R}_t^{\theta 1:D}$ 和 $\mathbf{x}_t^{1:D}$ 在 $[t - \tau, t]$ 中保持不变。当我们从 t 传播到 $t - \tau$ 时，我们会对发生的所有转换进行计数，但会推迟实际应用它们，直到到达 $t - \tau$ ，以便 $\mathbf{x}_t^{1:D}$ 在 $[t - \tau, t]$ 中保持不变。假设 $\hat{R}_t^{\theta 1:D}$ 和 $\mathbf{x}_t^{1:D}$ 保持不变，则 $[t - \tau, t]$ 中从 $\mathbf{x}_t^{1:D}$ 到 $\tilde{\mathbf{x}}_t^{1:D}$ 的转变发生的次数服从均值为 $\tau \hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \tilde{\mathbf{x}}_t^{1:D})$ 的泊松分布。一旦到达 $t - \tau$ ，我们就应用同时发生的所有转换，即 $\mathbf{x}_{t-\tau}^{1:D} = \mathbf{x}_t^{1:D} + \sum_i P_i(\tilde{\mathbf{x}}_i^{1:D} - \mathbf{x}_t^{1:D})$ ，其中 P_i 是平均值为 $\tau \hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \tilde{\mathbf{x}}_i^{1:D})$ 的泊松随机变量。请注意，总和假定从 $\mathcal{X}$ 到 $\mathbb{Z}$ 的映射。




图 2: 从 $x_t^{1:2} = \{S_4, S_1\}$ 到 $x_{t-\tau}^{1:2} = \{S_2, S_3\}$ 的一个 tau 跳跃步骤的 3D 可视化。这里， $D = 2$ 、 $|\mathcal{X}| = 5$ 、 $P_{12} = 1$ 、 $P_{22} = 2$ ，所有其他 $P_{ds} = 0$ 。

利用我们对 $\hat{R}_t^{\theta 1:D}$ 的了解，我们可以进一步解压此更新。即，仅当 $\tilde{\mathbf{x}}_t^{1:D}$ 在一维上具有与 $\mathbf{x}_t^{1:D}$ 不同的值时， $\hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \tilde{\mathbf{x}}_t^{1:D})$ 才可以为非零（多维变化的比率为零）。对这些选项进行显式求和，我们得到 $\mathbf{x}_{t-\tau}^{1:D} = \mathbf{x}_t^{1:D} + \sum_{d=1}^D \sum_{s=1 \setminus x_t^d}^S P_{ds}(s - x_t^d) \mathbf{e}^d$ ，其中 $\mathbf{e}^d$ 是维度为 1 的单热向量 d ，而 P_{ds} 是平均值为 $\tau \hat{R}_t^{\theta 1:D}(\mathbf{x}_t^{1:D}, \mathbf{x}_t^{1:D} + (s - x_t^d) \mathbf{e}^d)$ 的泊松随机变量。由于多个 P_{ds} 可以为非零，因此我们看到 tau 跳跃允许 $\mathbf{x}_t^{1:D}$ 在单个步骤中在多个维度上发生变化。图 2 直观地体现了这一想法。在 $[t - \tau, t]$ 间隔期间，维度 1 中发生一次跳跃，维度 2 中发生两次跳跃。一旦到达 $t - \tau$ ，这些都会同时应用。当我们的离散数据具有序数结构时（例如第 6.2 节），我们到 $\mathbb{Z}$ 的映射不是任意的，并且在同一维度（ $\sum_{s=1 \setminus x_t^d}^S P_{ds} > 1$ ）内进行多次跳跃是有意义的。在非序数/分类情况下（例如第 6.3 节），到 $\mathbb{Z}$ 的映射是任意的，因此，尽管在不同维度中同时进行跳跃是有意义的，但在同一维度内进行多次跳跃则没有意义。对于此类数据，我们拒绝对任何 d （其中 $\sum_{s=1 \setminus x_t^d}^S P_{ds} > 1$ ）对 x_t^d 进行更改。实际上，当 $R_t^{1:D}$ 适用于分类数据（例如统一数据）时，拒绝率非常小，请参见附录 H.3。在第 4.5 节中，我们的错误界限解释了我们在序数情况的实践中观察到的这种低拒绝概率以及低概率的出界跳跃。

tau 跳跃近似随着 τ 的减小而改进，在 $\tau \rightarrow 0$ 的限制下恢复精确模拟。精确模拟类似于自回归模型，因为每一步仅改变一个维度。增加 τ 以及每步变化的平均维度数为我们提供了一种自然的方式来调节模型的“自回归性”并通过计算来交换样本质量（图 4 右）。我们将使用 tau-leaping 模拟反向 CTMC 的方法称为 τ LDR（tau-leaping 去噪反转），我们在附录 F 的算法 1 中将其形式化。

我们注意到，理论上，可以将 $\hat{R}_t^{\theta 1:D}$ 近似为区间 $[t - \tau, t]$ 中的常数，并通过用矩阵指数 $P_{t-\tau|t} \approx \exp(\tau \hat{R}_t^{\theta 1:D})$ 求解前向 Kolmogorov 方程来构造转移概率矩阵。然而，对于学习到的 $\hat{R}_t^{\theta 1:D} \in \mathbb{R}^{S^D \times S^D}$ 矩阵，计算该矩阵指数很困难，因此我们使用 tau-leaping 进行采样。

4.4 预测-校正器

在近似反向采样过程中，我们的目标是 t 时刻样本的边际分布接近真实 CTMC 在 t 时刻的 $q_t(x_t)$ （边际分布。连续时间框架使我们能够利用额外的信息来更准确地跟踪边际值 $\{q_t(x_t)\}_{t \in [0, T]}$ 的反向进展并提高样本质量。也就是说，在使用速率为 $\hat{R}_t^{\theta}$ 的 tau 跳跃“预测器”步骤之后，我们可以应用速率为 R_t^c 的“校正器”步骤，其中 $q_t(x_t)$ 作为其平稳分布。校正器步骤使时间 t 的样本分布更接近所需的 $q_t(x_t)$ 边际。 R_t^c 很容易计算，如下所述

命题 4. For a forward CTMC with marginals $\{q_t(x_t)\}_{t \in [0, T]}$, forward rate, R_t , and corresponding reverse CTMC with rate $\hat{R}_t$, the rate $R_t^c = R_t + \hat{R}_t$ has $q_t(x_t)$ as its stationary distribution.

在实践中，我们通过用 $\hat{R}_t^\theta$ 替换 $\hat{R}_t$ 来近似 R_t^c 。这直接类似于连续状态空间 [4] 中的预测器-校正器采样器，它通过集成反向 SDE 进行预测，并使用基于分数的马尔可夫链蒙特卡罗步骤进行校正，请参阅附录 F.2 进行进一步讨论。

4.5 错误界限

我们的连续时间框架还允许我们根据反向率的近似误差和前向噪声过程的混合，为真实数据分布和通过 tau 跳跃（没有预测校正器步骤）生成的样本分布之间的误差提供新颖的理论界限。

我们假设 $\mathcal{X}$ 上有一个时间同质速率矩阵 R_t ，通过为每个 d 设置 $R_t^d = R_t$ 来构造 $\mathcal{X}^D$ 上的分解速率矩阵 $R_t^{1:D}$ 。请注意，通过将时间重新调整为 $\beta(t)$ 因子，我们可以将第 4.1 节中的速率选择转变为时间同质的。我们将表示 $|R| = \sup_{t \in [0, T], x \in \mathcal{X}} |R_t(x, x)|$ ，并令 t_{mix} 为具有速率 R_t 的 CTMC 的 $(1/4)$ 混合时间 (参见 [24, 第 4.5 章])。

定理 1. *For any $D \geq 1$ and distribution p_{data} on $\mathcal{X}^D$, let $\{x_t\}_{t \in [0, T]}$ be a CTMC starting in p_{data} with rate matrix $R_t^{1:D}$ as above. Suppose that $\hat{R}_t^{\theta 1:D}$ is an approximation to the reverse rate matrix and let $(y_k)_{k=0,1,\dots,N}$ be a tau-leaping approximation to the reverse dynamics with maximum step size τ . Suppose further that there is some constant $M > 0$ independent of D such that*

$$\sum_{y \neq x} \left| \hat{R}_t^{1:D}(x, y) - \hat{R}_t^{\theta 1:D}(x, y) \right| \leq M \quad (2)$$

for all $t \in [0, T]$. Then under the assumptions in Appendix B.5, there are constants $C_1, C_2 > 0$ depending on $\mathcal{X}$ and R_t but not D such that, if $\mathcal{L}(y_0)$ denotes the law of y_0 , we have the total variation bound

$$\|\mathcal{L}(y_0) - p_{\text{data}}\|_{\text{TV}} \leq 3MT + \left\{ (|R|SDC_1)^2 + \frac{1}{2}C_2(M + C_1SD|R|) \right\} \tau T + 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

上述界限的第一项捕获了我们用 $\hat{R}_t^{\theta 1:D}$ 近似反向速率 $\hat{R}_t^{1:D}$ 所引入的误差。第二项反映了 tau 跳跃近似引入的误差，并且在 T 和 τ 中都是线性的，表明当我们将 tau 跳跃步长设为任意小时，tau 跳跃引入的误差将趋于零。最后一项描述了前向链的混合，并捕获了由于 p_{ref} 和 q_T 不完全相等而引入的误差。

我们选择使边界对维度 D 的依赖性明确，因为我们特别有兴趣将 tau 跳跃应用于高维问题，在高维问题中我们在单个时间步中同时进行不同维度的转换。最坏情况下，界限在维度上呈二次方增长，而例如呈指数级增长。因此，该界限有助于向我们表明，在高维度中，我们不需要使 τ 变得不切实际的小。除了获得这些直觉之外，我们并不期望在实践中界限特别严格，而且由于很难找到 M 、 C_1 和 C_2 ，因此计算起来不切实际。

当我们对序数数据使用空间偏差率时，附录 B.5 中列出的假设大致适用于 tau 跳跃，使得跳跃大小很小，或者对于非序数数据使用均匀率，从而维度拒绝率很小。这些假设可能会被削弱，但是定理 1 会变得更加复杂，从而模糊了问题的直觉和结构。

5 相关工作

去噪模型在离散数据上的应用首先在 [1] 中描述，使用二项式扩散过程处理二进制数据集。每个反向内核 $p_{k|k+1}^\theta$ 都直接参数化，而不使用去噪模型 $p_{0|k}^\theta$ 。在 [25] 中，建议使用统一的前向噪声核 $q_{k+1|k}$ 和通过去噪模型参数化的反向核来处理离散分类数据，但没有使用该方法进行实验。然后使用 [6] 中的类似模型对文本和分割图进行实验。[8] 中引入了其他前向内核，它们更适合某些数据类型，例如空间偏置高斯内核。[9, 13] 使用均匀和吸收状态前向将该方法应用于离散潜在空间建模




图 3: 左: 真实训练分布与通过精确模拟或 τ 跳跃生成的样本分布之间的 Hellinger 距离。当 τ 较小时, 我们以与精确模拟相同的保真度来模拟反向 CTMC。右上: 使用 $\tau = 0.004$ 的 τ 跳跃模拟反向生成过程期间边缘的直方图。较暗和较大的钻石代表密度增加。右下: 与 $\tau = 0.1$ 相同, 注意样本质量降低。

内核。虽然[8]中提到了前向过程与连续时间的联系, 但所有这些方法都是在离散时间中训练和采样的。我们在附录 G 中表明, 这涉及对多维数据进行隐式近似。我们通过连续时间的训练和采样来扩展这一工作范围。

其他作品也在离散空间中运作, 但不太严格遵循扩散框架。[12]中提出了一种针对文本的损坏过程, 其中还包含了令牌删除和插入。[26]还关注文本, 创建一个重复应用相同去噪内核的生成反向链。腐败分布也是通过相同的去噪内核定义的, 以减少训练和采样之间的分布偏移。在[7]中, 使用了更标准的基于掩码的前向过程, 但反转是从与顺序无关的自回归角度解释的。他们还描述了如何将他们的模型解释为连续时间吸收状态扩散的逆转, 但在训练或采样中没有利用这种观点。[27]提出了一种可用于二进制数据的去噪类型框架, 其中正向和反向过程共享相同的转换内核。最后, 在[11]中, VQVAE 的离散潜在空间是通过使用概率量化函数量化底层连续状态空间扩散来建模的。

6 实验

6.1 示例

我们首先验证该方法可以从数据分布的整个支持中准确地生成样本, 并且 τ -leaping 可以准确地模拟反向 CTMC。为此, 我们创建一个由 32 个状态空间的 2d 样本组成的数据集, 这些样本经过排列, 使得训练数据集的直方图形成 “ τ ” 形状。我们使用 $\mathcal{L}_{CT}$ 目标训练去噪模型, 其中 $p_{0|t}^\theta$ 通过残差 MLP 进行参数化 (完整细节参见附录 H.1)。然后, 我们使用精确方法 (直到需要对反向速率进行数值积分) 和 τ 跳跃对参数化反向过程进行采样。图 3 右上角显示了使用 $\tau = 0.004$ 进行反向模拟期间的边缘, 我们确实从 p_{data} 的整个支持中生成了样本。此外, 我们发现, 只要 τ 足够小, 我们就可以匹配反向 CTMC 精确模拟的保真度 (图 3 左)。 τ 的值指示根据 $NFE = T/\tau$ 的反向过程中网络评估的数量。在所有实验中, 我们都使用 $T = 1$ 。由于学习的 $\hat{R}_t^\theta$ 模型的缺陷, 精确模拟导致生成分布和训练分布之间的海灵格距离不为零。

6.2 图像建模

我们现在证明, 与离散时间操作相比, 我们的连续时间框架为我们提供了改进的生成建模性能。我们在 CIFAR-10 图像数据集上展示了这一点。图像通常存储为离散数据, 每个像素通道从 256 种可能性中获取一个值。连续状态空间方法必须以某种方式绕过这个事实, 例如, 在生成过程结束时添加离散化函数 [3] 或向数据添加均匀噪声。

表 1: 在离散状态空间中对 CIFAR10 进行建模的扩散方法的样本质量指标和模型可能性。包括在连续空间中建模 CIFAR10 的扩散方法以供参考。按照标准做法, 使用与训练数据集相关的 50000 个生成样本来计算初始分数 (IS) 和 Fréchet 初始距离 (FID)。ELBO 值在测试集上以每维位数的形式报告。

	Method	IS ($\uparrow$)	FID ($\downarrow$)	ELBO ($\uparrow$)
Discrete state	D3PM Absorbing [8]	6.78	30.97	-4.40
	D3PM Gauss [8]	8.56	7.34	-3.44
	τ LDR-0 (ours)	8.74	8.10	-3.59
	τ LDR-10 (ours)	9.49	3.74	-3.59
Continuous state	DDPM [3]	9.46	3.17	-3.75
	NCSN [4]	9.89	2.20	-




图 4: 左: 来自我们的 τ LDR-10 模型的条件 CIFAR10 样本 右: 生成的 CIFAR10 样本的 FID 分数与采样期间 $p_{0|t}^\theta$ 评估的数量 (由变化的 τ 引起的变化)。使用 10k 样本计算, 因此与表 1 [28] 存在差异。

在这里, 我们直接在离散空间中对图像进行建模。我们使用标准 U-net 架构 [3] 参数化 $p_{0|t}^\theta$, 并根据 [8] 建议对离散状态空间进行修改。我们使用空间偏置速率矩阵并使用增强的 $\mathcal{L}_{CT}$ 损失进行训练, 包括直接 $p_{0|t}^\theta$ 监督, 完整的实验细节参见附录 H.2。

图 4 左图显示了从模型中随机生成的无条件 CIFAR10 样本, 我们在表 1 中报告了样本质量指标。我们看到, 我们的方法 (τ LDR-0) 具有 0 个校正步骤, 与 D3PM 离散时间方法相比, 具有更好的 Inception Score, 但 FID 更差。然而, 我们的 τ LDR-10 方法在反向采样过程结束时每个预测步骤有 10 个校正步骤 ($t < 0.1T$) 极大地提高了样本质量, 在两个指标上都击败了离散时间方法, 并进一步缩小了与将图像建模为连续数据的方法的性能差距。为我们提供这种改进性能的校正器率的推导需要我们的连续时间框架。D3PM 实现了最高的 ELBO, 但我们注意到这与样本质量没有很好的相关性。在表 1 中, 调整了 τ , 使得 τ LDR-0 和 τ LDR-10 在反向采样过程中都使用 1000 次 $p_{0|t}^\theta$ 评估。我们在图 4 右侧展示了 FID 分数如何随 τ LDR- $\{0, 3, 10\}$ 的 $p_{0|t}^\theta$ 评估次数变化。校正器步骤的最佳数量取决于采样预算, 对于更严格的预算, 校正器步骤的数量越少是最佳的。这是因为当我们使用更多数量的校正器步骤时, 维持固定预算所需的 τ 会增加。

6.3 单音音乐

在这个实验中, 我们证明了我们的连续时间模型提高了非序数/分类离散数据的生成质量。我们对来自 Lakh 钢琴卷轴数据集的歌曲进行建模 [29, 30]。我们从数据集中选择所有单音序列, 以便在 256 个时间步长中的每一个上, 要么演奏 128 个音符中的一个, 要么休止符。因此, 我们的数据具有状态空间大小 $S = 129$ 和维度 $D = 256$ 。当映射到 $\mathbb{Z}$ 时, 我们会打乱状态空间的顺序以破坏任何序数结构。我们使用 Transformer 架构 [31] 参数化 $p_{0|t}^\theta$, 并使用 $\mathcal{L}_{CT}$ 的条件形式进行训练, 目标是给定歌曲的前 2 个小节, 最后 14 个小节 (224 个时间步长) 的条件分布。我们使用统一的前向速率矩阵, R_t , 完整的实验细节

表 2: 比较生成的条件样本和真实完成情况的指标。我们在测试集上计算这些值, 显示每首测试歌曲的 5 个样本的平均值 $\pm$ std。

Model	Hellinger Distance	Proportion of Outliers
τ LDR-0 Birth/Death	0.3928 ± 0.0010	0.1316 ± 0.0012
τ LDR-0 Uniform	0.3765 ± 0.0013	0.1106 ± 0.0010
τ LDR-2 Uniform	0.3762 ± 0.0015	0.1091 ± 0.0014
D3PM Uniform [8]	0.3839 ± 0.0002	0.1137 ± 0.0010




图 5: 未见过的音乐序列的有条件完成。调节 2 条显示在黑线左侧。更多示例和录音请参见附录 H.3。

附录 H.3 中给出。图 5 显示了未见过的测试歌曲的有条件完成。该模型能够以与条件小节相同的风格忠实地完成这首曲子。

我们在表 2 中量化了样本质量。我们使用两个指标: 生成的直方图和地面实况注释之间的海林格距离, 以及各代中但不在地面实况中的离群值注释的比例。使用我们的方法, 我们比较出生/死亡和统一远期速率矩阵 R_t 。对于相邻状态, 出生/死亡率仅非零, 而统一率允许在任意状态之间进行转换, 这更适合分类情况, 从而提高样本质量。每个预测器步骤添加 2 个校正器步骤可进一步提高样本质量。我们还与离散时间方法 D3PM [8] 及其最适合分类数据的损坏过程进行比较。我们发现它的性能比我们的连续时间方法更差。

7 讨论

我们提出了离散去噪模型的连续时间框架。我们展示了如何使用 tau-leaping 有效地对生成过程进行采样, 并提供了生成样本的误差范围。在离散数据问题上, 我们发现我们的预测校正器采样器比离散时间方法提高了样本质量。关于局限性, 我们的模型需要进行多次模型评估才能生成样本。我们的工作也为将提高连续数据采样速度的工作[14、15、16、17、32]应用于离散数据问题打开了大门。图像上的建模性能也稍微落后于连续状态空间模型, 我们希望通过定制的离散状态架构和损坏过程调整进一步缩小这一差距。最后, 我们注意到 CIFAR10 上离散时间模型的 ELBO 值比我们的方法更好。在这项工作中, 我们关注样本质量, 而不是使用我们的模型来给出数据可能性, 例如用于压缩下游任务。

致谢

Andrew Campbell 和 Joe Benton 感谢 EPSRC CDT 在现代统计和统计机器学习 (EP/S023151/1) 方面的支持。Arnaud Doucet 得到了 EPSRC 拨款 EP/R034710/1 的部分支持。他还感谢英国国防科学技术实验室 (DSTL) 和 EPSRC 在 EP/R013616/1 资助下的支持。这是美国国防部、英国国防部和英国 EPSRC 在多学科大学研究计划下合作的一部分。该项目利用了由 EPSRC (EP/T022205/1) 资助的 Tier 2 HPC 设施 JADE2 上的时间。

参考

- [1] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan 和 Surya Ganguli. 使用非平衡热力学的深度无监督学习。 *International Conference on Machine Learning*, 2015。 [2] 杨松和斯特凡诺·埃尔蒙。通过估计数据分布的梯度进行生成建模。 *Advances in Neural Information Processing Systems*, 2019。
- [3] 乔纳森·何 (Jonathan Ho)、阿杰·贾恩 (Ajay Jain) 和彼得·阿贝尔 (Pieter Abbeel)。去噪扩散概率模型。 *Advances in Neural Information Processing Systems*, 2020。
- [4] 宋杨、Jascha Sohl-Dickstein、Diederik P. Kingma、Abhishek Kumar、Stefano Ermon 和 Ben Poole。通过随机微分方程基于分数的生成模型。 *International Conference on Learning Representations*, 2021 年。 [5] Prafulla Dhariwal 和 Alexander Nichol。扩散模型在图像合成方面击败了 GAN。 *Advances in Neural Information Processing Systems*, 2021 年。 [6] Emiel Hoogeboom、Didrik Nielsen、Priyank Jaini、Patrick Forré 和 Max Welling。Argmax 流和多项式扩散：学习分类分布。 *Advances in Neural Information Processing Systems*, 2021 年。
- [7] Emiel Hoogeboom、Alexey A Gritsenko、Jasmijn Bastings、Ben Poole、Rianne van den Berg 和 Tim Salimans。自回归扩散模型。 *International Conference on Learning Representations*, 2022 年。
- [8] 雅各布·奥斯汀、丹尼尔·约翰逊、乔纳森·何、丹尼尔·塔洛和 Rianne van den Berg。离散状态空间中的结构化去噪扩散模型。 *Advances in Neural Information Processing Systems*, 2021 年。
- [9] 帕特里克·埃瑟、罗宾·隆巴赫、安德烈亚斯·布拉特曼和比约恩·奥默。Imagebart：具有多项扩散的双向上下文，用于自回归图像合成。 *Advances in Neural Information Processing Systems*, 2021 年。
- [10] 埃米尔·胡格博姆、维克多·加西亚·萨托拉斯、克莱门特·维尼亚克和马克斯·韦林。3d 中分子生成的等变扩散。 *International Conference on Machine Learning*, 2022 年。
- [11] 马克斯·科恩、纪尧姆·基斯佩、西尔万·勒考夫、查尔斯·奥利恩和埃里克·穆林斯。扩散桥矢量量化变分自动编码器。 *International Conference on Machine Learning*, 2022 年。
- [12] 丹尼尔·D·约翰逊、雅各布·奥斯汀、Rianne van den Berg 和丹尼尔·塔洛。超越就地腐败：去噪概率模型中的插入和删除。 *ICML Workshop on Invertible Neural Networks, Normalizing Flows, and Explicit Likelihood Models (INNF+)*, 2021 年。
- [13] 顾书阳, 陈东, 包建民, 文方, 张波, 陈东东, 袁璐, 郭百宁。用于文本到图像合成的矢量量化扩散模型。 *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022 年。
- [14] Alexia Jolicoeur-Martineau、Ke Li、Rémi Piché-Taillefer、Tal Kachman 和 Ioannis Mitliagkas。使用基于分数的模型生成数据时必须快速。 *arXiv preprint arXiv:2105.14080*, 2021 年。
- [15] 张勤生, 陈永新。使用指数积分器对扩散模型进行快速采样。 *arXiv preprint arXiv:2204.13902*, 2022 年。
- [16] 蒂姆·萨利曼和乔纳森·何。用于扩散模型快速采样的渐进蒸馏。 *International Conference on Learning Representations*, 2022 年。
- [17] 郑亨镇, 沉秉秀, 叶钟哲。更接近扩散更快：通过随机收缩加速逆问题的条件扩散模型。 *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022 年。

- [18]蒂姆·多克霍恩、阿拉什·瓦达特和卡斯滕·克雷斯。基于分数的生成模型，具有临界阻尼朗之万扩散。 *International Conference on Learning Representations*, 2022 年。
- [19] Valentin De Bortoli、James Thornton、Jeremy Heng 和 Arnaud Doucet。扩散薛定谔桥及其基于分数的生成建模的应用。 *Advances in Neural Information Processing Systems*, 2021 年。
- [20] 丹尼尔·T·吉莱斯皮。化学反应系统的近似加速随机模拟。 *The Journal of Chemical Physics*, 115(4): 1716–1733, 2001。[21]丹尼尔·T·吉莱斯皮。数值模拟耦合化学反应的随机时间演化的通用方法。 *Journal of Computational Physics*, 22(4): 403–434, 1976。[22]丹尼尔·T·吉莱斯皮。耦合化学反应的精确随机模拟。 *The Journal of Physical Chemistry*, 81(25):2340–2361, 1977。[23] 达伦·J·威尔金森。 *Stochastic Modelling for Systems Biology*。查普曼和霍尔/CRC, 2018。[24]大卫·莱文、尤瓦尔·佩雷斯和伊丽莎白·威尔默。 *Markov Chains and Mixing Times*。美国数学会, 2009。
- [25] 宋家明, 孟晨林, Stefano Ermon。去噪扩散隐式模型。 *International Conference on Learning Representations*, 2021 年。
- [26] Nikolay Savinov、Junyoung Chung、Mikolaj Binkowski、Erich Elsen 和 Aaron van den Oord。用于文本生成的逐步展开去噪自动编码器。 *International Conference on Learning Representations*, 2022 年。
- [27] Anirudh Goyal、Nan Rosemary Ke、Surya Ganguli 和 Yoshua Bengio。变分回溯：将转换算子学习为随机循环网络。 *Advances in Neural Information Processing Systems*, 2017 年。
- [28] 冲敏金和大卫·福赛思。有效公正的 fid 和 inception 分数以及在哪里可以找到它们。 *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020。
- [29]科林·拉斐尔。 *Learning-based methods for comparing sequences, with applications to audio-to-midi alignment and matching*。博士论文, 哥伦比亚大学, 2016。
- [30] 董浩文, 萧文一, 杨丽嘉, 杨一轩。Musegan: 用于符号音乐生成和伴奏的多轨顺序生成对抗网络。 *AAAI Conference on Artificial Intelligence*, 2018。
- [31] 高塔姆·米塔尔、杰西·恩格尔、柯蒂斯·霍桑和伊恩·西蒙。使用扩散模型的符号音乐生成。 *International Society for Music Information Retrieval*, 2021 年。
- [32] 包凡, 李崇轩, 朱军, 张波。Analytic-dpm: 扩散概率模型中最优反向方差的分析估计。 *International Conference on Learning Representations*, 2022 年。
- [33] 大卫·F·安德森。一种改进的下一个反应方法, 用于模拟具有时间依赖性倾向和延迟的化学系统。 *The Journal of Chemical Physics*, 127(21): 214107, 2007。
- [34] Chie Furusawa, Shinya Kitaoka, Michael Li, Yuri Odagiri。生成概率图像着色。 *arXiv preprint arXiv:2109.14518*, 2021 年。
- [35] 伊桑·佩雷斯、弗洛里安·斯特鲁布、哈姆·德弗里斯、文森特·杜穆兰和亚伦·库维尔。电影：具有一般调节层的视觉推理。 *AAAI Conference on Artificial Intelligence*, 2018。
- [36] Ashish Vaswani、Noam Shazeer、Niki Parmar、Jakob Uszkoreit、Llion Jones、Aidan N Gomez、Łukasz Kaiser 和 Illia Polosukhin。您所需要的就是关注。 *Advances in Neural Information Processing Systems*, 2017 年。

[37] 奥拉夫·罗纳伯格、菲利普·费舍尔和托马斯·布洛克斯。U-net：用于生物医学图像分割的卷积网络。 *International Conference on Medical Image Computing and Computer-assisted Intervention*, 2015。[38] Tim Salimans、Andrej Karpathy、Xi Chen 和 Diederik P Kingma。Pixelcnn++：通过离散逻辑混合似然和其他修改改进 Pixelcnn。 *International Conference on Learning Representations*, 2017。[39] Xi Chen、Nikhil Mishra、Mostafa Rohaninejad 和 Pieter Abbeel。Pixelsnail：改进的自回归生成模型。 *International Conference on Machine Learning*, 2018。[40] Stefan Elfwing、Eiji Uchibe 和 Kenji Doya。用于强化学习中神经网络函数逼近的 Sigmoid 加权线性单元。 *Neural Networks*, 107: 3-11, 2018。[41] 马克西米利安·塞策。pytorch-fid：PyTorch 的 FID 分数。 <https://github.com/mseitzer/pytorch-fid>, 2020 年 8 月。版本 0.2.1。

附录

内容

连续时间马尔可夫链入门 15

B 样张 16

B.1 命题证明 1.	16
B.2 命题证明2。	17
B.3 命题3的证明。	21
B.4 命题证明 4。	22
B.5 定理证明 1.	22

C 连续时间 ELBO 详细信息 27

C.1 与离散时间 ELBO 的比较。	27
C.2 条件形式。	27
C.3 具有因式分解假设的连续时间 ELBO。	27
C.4 一次向前传球。	29

D 直接去噪模型监督 30

E 正向过程的选择 32

F CTMC 模拟 34

F.1 精确的 CTMC 和 Tau 跳跃。	34
F.2 预测校正器讨论。	34

G 离散时间中的隐式维度假设 36

H 实验细节 37

H.1 示范示例。	37
H.2 图像建模。	38
H.3 单音音乐。	39

I 道德考虑

42

附录的结构如下。在 A 节中，我们对连续时间马尔可夫链进行了简短介绍，包括我们在这项工作中使用的相关结果。正文中所有命题和定理的证明都在 B 节中。然后，我们在 C 节中描述了我们提出的目标 $\mathcal{L}_{CT}$ 的一些额外的直觉和形式。在 D 节中，我们描述了如何将额外的直接去噪模型监督项添加到目标中以提高经验性能。有关我们如何在模型中定义前向过程的详细信息，请参阅 E 部分。F 部分更详细地描述了如何模拟 CTMC，并包括 tau 跳跃的算法描述。我们在 G 节中认为，在对多维数据使用因式分解前向过程时，在离散时间中进行操作会强制执行隐式假设。所有研究的完整实验细节以及我们模型的其他图和结果都可以在 H 部分中找到。最后，在第一节中，我们考虑了我们研究的社会影响。




图 6: 具有 3 个状态的一维 CTMC 的示意图。

连续时间马尔可夫链入门

连续时间马尔可夫链 (CTMC) 是满足马尔可夫性质的右连续随机过程 $\{x_t\}_{t \in [0, T]}$, 其中 x_t 取离散状态空间 $\mathcal{X}$ 中的值。由于 CTMC 是马尔可夫, 因此过程的未来行为仅取决于当前状态, 而不取决于历史。CTMC 路径的示意图如图 6 所示。在前一状态中等待随机确定的时间后, 该过程会重复从一种状态转换到另一种状态。

CTMC 可以完全通过其跳跃和保持时间来表征。具体来说, 每次跳转之间的时间或 *holding time* 呈指数分布, 均值为 $\nu(x)$, 其中 x 是过程所保持的状态。跳转到的下一个状态是从跳转概率分布 $r(\tilde{x}|x)$ 中得出的。然后重复保持和跳跃过程。

我们在主论文中使用了涉及转移率矩阵 $R \in \mathbb{R}^{S \times S}$ 的等效定义。转移率矩阵定义为

$$R(\tilde{x}, x) = \lim_{\Delta t \rightarrow 0} \frac{q_{t|t-\Delta t}(x|\tilde{x}) - \delta_{x,\tilde{x}}}{\Delta t} \quad (3)$$

其中, $R(\tilde{x}, x)$ 是转移率矩阵的 $(\tilde{x}, x)$ 元素, 而 $q_{t|t-\Delta t}(x|\tilde{x})$ 是在假定进程在时间 $t - \Delta t$ 处于状态 $\tilde{x}$ 的情况下, 在时间 t 处于状态 x 的无穷小转移概率。相反, CTMC 本身可以通过这个无穷小转移概率来定义

$$q_{t|t-\Delta t}(x|\tilde{x}) = \delta_{x,\tilde{x}} + R(\tilde{x}, x)\Delta t + o(\Delta t) \quad (4)$$

其中 $o(\Delta t)$ 表示趋向于零的速率比 Δt 更快。根据转移率矩阵的定义, 我们可以推断出以下属性:

$$R(\tilde{x}, x) \geq 0 \quad \text{for } \tilde{x} \neq x, \quad R(x, x) \leq 0, \quad R(x, x) = -\sum_{x' \neq x} R(x, x') \quad (5)$$

$R(\tilde{x}, x)$ 是概率质量从状态 $\tilde{x}$ 移动到 x 的速率。 $R(x, x)$ 是概率质量移出状态 x 的总速率, 因此为负。

在时间齐次的情况下, R 与跳跃时间和保持时间定义具有简单的关系。

$$\nu(x) = -\frac{1}{R(x, x)} \quad r(\tilde{x}|x) = (1 - \delta_{\tilde{x}, x}) \frac{R(x, \tilde{x})}{-R(x, x)}$$

在时间非均匀的情况下, 我们的转移率矩阵现在将取决于时间 R_t , 并且这些与跳跃和保持时间定义的简单关系不成立。然而, R_t 仍遵循方程(3)、(4)和(5)。

CTMC 转移概率满足 Kolmogorov 前向和后向方程。对于 $t > s$,

$$\text{Kolmogorov forward equation} \quad \partial_t q_{t|s}(x|\tilde{x}) = \sum_y q_{t|s}(y|\tilde{x}) R_t(y, x)$$

$$\text{Kolmogorov backward equation} \quad \partial_s q_{t|s}(x|\tilde{x}) = - \sum_y R_s(\tilde{x}, y) q_{t|s}(x|y)$$

柯尔莫哥洛夫前向方程还为我们提供了 CTMC 边缘的微分方程。

$$\partial_t q_t(x) = \sum_y q_t(y) R_t(y, x).$$

指数和泊松随机变量 在时间齐次情况下, 保持时间呈指数分布, 平均值为 $\nu(x) = -1/R(x, x)$ 。tau 跳跃算法依赖于以下事实: 当事件间时间按均值 ν 呈指数分布时, 区间 $[0, t]$ 中的事件数量呈均值 $\frac{1}{\nu}t$ 的泊松分布。

B 证明

B.1 命题1的证明

Proof. 我们记得, 如果一个过程 $\{x_t\}_{t \in [0, T]}$ 在 $\mathcal{X}$ 中取值, 那么它是右连续的并且满足马尔可夫性质, 则称为 CTMC。用 $n \in \mathbb{N}$ 表示 $\{y_t\}_{t \in [0, T]} = \{x_{T-t}\}_{t \in [0, T]}$, 但前向过程 τ_n 的跳转时间除外, 其中 $y_{T-\tau_n} = x_{\tau_n}^- = \lim_{t \leq \tau_n, t \rightarrow \tau_n} x_t$ 。因此, $\{y_t\}_{t \in [0, T]}$ 几乎肯定等于 $\{x_{T-t}\}_{t \in [0, T]}$ 并且是右连续的。由于马尔可夫性质是对称的, 我们得到 $\{y_t\}_{t \in [0, T]}$ 是一个 CTMC。我们现在计算它的转移矩阵。让 $x, \tilde{x} \in \mathcal{X}$ 与 $x \neq \tilde{x}$, 使用柯尔莫哥洛夫前向方程, 我们有

$$\partial_t p_{t|s}(\tilde{x}|x) = \sum_{y \in \mathcal{X}} p_{t|s}(y|x) \hat{R}_{T-t}(y, \tilde{x}),$$

其中 $\{p_{t|s}, s, t \in [0, T], t > s\}$ 是与 $\{y_t\}_{t \in [0, T]}$ 关联的转移概率系统, $\{\hat{R}_{T-t}\}_{t \in [0, T]}$ 是与 $\{y_t\}_{t \in [0, T]}$ 关联的转移率矩阵。注意

$$\begin{aligned} p_{t|s}(x = j|\tilde{x} = i) &= \mathbb{P}(y_t = j \mid y_s = i) \\ &= \mathbb{P}(x_{T-t} = j \mid x_{T-s} = i) \\ &= \mathbb{P}(x_{T-s} = i \mid x_{T-t} = j) \frac{\mathbb{P}(x_{T-t} = j)}{\mathbb{P}(x_{T-s} = i)} \\ &= q_{T-s|T-t}(\tilde{x} = i|x = j) \frac{q_{T-t}(x = j)}{q_{T-s}(\tilde{x} = i)} \end{aligned}$$

其中 $\{q_{t|s}, s, t \in [0, T], t > s\}$ 是与 $\{x_t\}_{t \in [0, T]}$ 相关的转移概率系统, 而 $\{q_t, t \in [0, T]\}$ 是 $\{x_t\}_{t \in [0, T]}$ 的边际。现在, 写出 $\{x_t\}_{t \in [0, T]}$ 的向后柯尔莫哥洛夫方程

$$\partial_s q_{t|s}(\tilde{x}|x) = - \sum_{y \in \mathcal{X}} R_s(x, y) q_{t|s}(\tilde{x}|y)$$

重新标记我们获得的时间指数,

$$\begin{aligned} \partial_{T-t} q_{T-s|T-t}(\tilde{x}|x) &= - \sum_{y \in \mathcal{X}} R_{T-t}(x, y) q_{T-s|T-t}(\tilde{x}|y) \\ \partial_t q_{T-s|T-t}(\tilde{x}|x) &= \sum_{y \in \mathcal{X}} R_{T-t}(x, y) q_{T-s|T-t}(\tilde{x}|y) \end{aligned}$$

令 $s \rightarrow t$ 并使用 $\lim_{s \rightarrow t} q_{T-s|T-t}(x|\tilde{x}) = 0$, 我们得到

$$\begin{aligned}
\hat{R}_{T-t}(x, \tilde{x}) &= \lim_{s \rightarrow t} \partial_t p_{t|s}(\tilde{x}|x) \\
&= \lim_{s \rightarrow t} \partial_t \left(q_{T-s|T-t}(x|\tilde{x}) \frac{q_{T-t}(\tilde{x})}{q_{T-s}(x)} \right) \\
&= \lim_{s \rightarrow t} \left[\partial_t (q_{T-s|T-t}(x|\tilde{x})) \frac{q_{T-t}(\tilde{x})}{q_{T-s}(x)} + q_{T-s|T-t}(x|\tilde{x}) \frac{\partial_t q_{T-t}(\tilde{x})}{q_{T-s}(x)} \right] \\
&= \lim_{s \rightarrow t} \partial_t (q_{T-s|T-t}(x|\tilde{x})) \frac{q_{T-t}(\tilde{x})}{q_{T-s}(x)} \\
&= R_{T-t}(\tilde{x}, x) \frac{q_{T-t}(\tilde{x})}{q_{T-t}(x)}
\end{aligned}$$

重新标记速率矩阵上的时间索引, 我们得到

$$\hat{R}_t(x, \tilde{x}) = R_t(\tilde{x}, x) \frac{q_t(\tilde{x})}{q_t(x)}$$

现在我们以不同的形式写出边际比率 $\frac{q_t(\tilde{x})}{q_t(x)}$

$$\begin{aligned}
\frac{q_t(\tilde{x})}{q_t(x)} &= \sum_{x_0} \frac{p_{\text{data}}(x_0)}{q_t(x)} q_{t|0}(\tilde{x}|x_0) \\
&= \sum_{x_0} \frac{q_{0|t}(x_0|x)}{q_{t|0}(x|x_0)} q_{t|0}(\tilde{x}|x_0).
\end{aligned}$$

用这种形式代替边际比率就得出了证明。 □

B.2 命题2的证明

在本节中, 我们详细介绍命题 2 的两个证明。第一个是使用随机过程结果的形式证明。然后, 我们为相同的结果提供第二个非正式证明, 以获得对仅依赖于 CTMC 基本结果的 $\mathcal{L}_{\text{CT}}$ 目标的直觉。

证明 1 - 随机过程

Proof. 我们将 $\mathbb{Q}$ 写为具有速率矩阵 R_t 的前向 CTMC 的路径度量, 将 $\hat{\mathbb{Q}}$ 写为其精确时间反转的路径度量, 将 $\mathbb{P}^\theta$ 写为具有速率矩阵 $\hat{R}_t^\theta$ 的近似逆过程的路径度量。此外, 我们使用上标来表示起始点的条件, 例如 $\mathbb{Q}^{x_0}$ 表示在 x_0 中开始的前向过程的路径度量。

通过这个记号, 我们有

$$\begin{aligned}
-\log p_0^\theta(x_0) &= -\log \int p_{\text{ref}}(dx_T) \int_{\{\hat{W}_T=x_0\}} \mathbb{P}^{\theta, x_T}(dw) \\
&= -\log \int q_{T|0}(dx_T) \int_{\{\hat{W}_T=x_0\}} \hat{\mathbb{Q}}^{x_T}(dw) \frac{dp_{\text{ref}}}{dq_{T|0}}(x_T) \frac{d\mathbb{P}^{\theta, x_T}}{d\hat{\mathbb{Q}}^{x_T}}(w) \\
&= -\log \int q_{T|0}(dx_T) \int \hat{\mathbb{Q}}(dw|\hat{W}_0 = x_T, \hat{W}_T = x_0) \frac{dp_{\text{ref}}}{dq_{T|0}}(x_T) \frac{d\mathbb{P}^{\theta, x_T}}{d\hat{\mathbb{Q}}^{x_T}}(w) \mathbb{Q}^{x_T}\{\hat{W}_0 = x_0\} \\
&\leq \int q_{T|0}(dx_T) \int \hat{\mathbb{Q}}(dw|\hat{W}_0 = x_T, \hat{W}_T = x_0) \left\{ -\log \frac{d\mathbb{P}^{\theta, x_T}}{d\hat{\mathbb{Q}}^{x_T}}(w) \right\} + C,
\end{aligned}$$

其中 $\mathbb{P}^\theta, \hat{\mathbb{Q}}$ 以相反的时间方向运行。为反向路径编写 $\hat{W}_s$ 并对 $p_{\text{data}}(dx_0)$ 进行积分, 我们有

$$\begin{aligned} \int p_{\text{data}}(x_0)[- \log p_0^\theta(x_0)] &\leq \int p_{\text{data}}(x_0) \int q_{T|0}(\mathrm{d}x_T) \int \hat{\mathbb{Q}}(\mathrm{d}\hat{W}|\hat{W}_0 = x_T, \hat{W}_T = x_0) \\ &\quad \times \left\{ \int_{s=0}^T \hat{R}_{T-s}^\theta(\hat{W}_s) \mathrm{d}s - \sum_{s: \hat{W}_{s-} \neq \hat{W}_s} \log \mathbb{P}_{T-s}^\theta(\hat{W}_s|\hat{W}_{s-}) \hat{R}_{T-s}^\theta(\hat{W}_{s-}) \right\} + C, \end{aligned}$$

其中 $\hat{R}_t^\theta(x)$ 是 $-\hat{R}_t^\theta(x, x)$ 的简写。

当 $x_0 \sim p_{\text{data}}, x_T \sim q_{T|0}(\cdot|x_0), \hat{W} \sim \hat{\mathbb{Q}}(\mathrm{d}W|\hat{W}_0 = x_T, \hat{W}_T = x_0)$ 时, 反向路径根据 $p_{\text{data}}(\mathrm{d}x_0)\mathbb{Q}_{x_0}(\mathrm{d}W)$ 分布, 因此 $(\hat{W}_{s-}, \hat{W}_s)$ 的分布类似于 $(W_{T-s}, W_{(T-s)-})$, 因此我们有

$$\begin{aligned} &\int p_{\text{data}}(x_0)[- \log p_0^\theta(x_0)] \\ &\leq \int p_{\text{data}}(x_0)\mathbb{Q}_{x_0}(\mathrm{d}W) \left\{ \int_{s=0}^T \hat{R}_{T-s}^\theta(W_{(T-s)-}) \mathrm{d}s - \sum_{s: W_{(T-s)-} \neq W_{T-s}} \log \mathbb{P}_{T-s}^\theta(W_{(T-s)-}|W_{T-s}) \hat{R}_{T-s}^\theta(W_{T-s}) \right\} + C \end{aligned}$$

使用 Dynkin 引理和 $\mathbb{P}_t^\theta(x|y)\hat{R}_t^\theta(y) = \hat{R}_t^\theta(y, x)$ 我们可以将最后一行重新表达为

$$\begin{aligned} &= \iint_{s=0}^T q_{T-s}(\mathrm{d}x) \left\{ \sum_{z \neq x} \hat{R}_{T-s}^\theta(x, z) - \sum_{z \neq x} R_{T-s}(x, z) \frac{\sum_{y \neq x} R_{T-s}(x, y)}{\sum_{z \neq x} R_{T-s}(x, z)} \log \hat{R}_{T-s}^\theta(y, x) \right\} \\ &= \iint_{s=0}^T q_{T-s}(\mathrm{d}x) r_{T-s}(\mathrm{d}y|x) \left\{ \sum_{z \neq x} \hat{R}_{T-s}^\theta(x, z) - \sum_{z \neq x} R_{T-s}(x, z) \log \hat{R}_{T-s}^\theta(y, x) \right\} \\ &= \iint_{s=0}^T q_s(\mathrm{d}x) r_s(\mathrm{d}y|x) \left\{ \sum_{z \neq x} \hat{R}_s^\theta(x, z) - \sum_{z \neq x} R_s(x, z) \log \hat{R}_s^\theta(y, x) \right\} \end{aligned}$$

重新排列以命题 2 的形式给出连续时间 ELBO。

□

证明2——离散时间ELBO的极限

Proof. 考虑 $[0, T]$, $0 = t_0 < t_1 < \dots < t_{k-1} < t_k < t_{k+1} < \dots < t_{K-1} < t_K = T$ 的分区。让 $t_k - t_{k-1} = \Delta t$ 代表所有 k 。在下标中, 当不引起混淆时, 我们使用 k 作为 t_k 的简写。考虑具有这种时间划分的 CTMC, 将问题转换为具有前向转移内核 $q_{k+1|k}(x_{k+1}|x_k)$ 和参数化反向内核 $p_{k|k+1}^\theta(x_k|x_{k+1})$ 的离散时间马尔可夫链。因此, 我们可以将负 ELBO 写成离散时间形式, $\mathcal{L}_{\text{DT}}$

$$\begin{aligned} \mathcal{L}_{\text{DT}}(\theta) &= \mathbb{E}_{p_{\text{data}}(x_0)} \left[\text{KL}(q_{K|0}(x_K|x_0)||p_{\text{ref}}(x_K)) - \mathbb{E}_{q_{1|0}(x_1|x_0)} \left[\log p_{0|1}^\theta(x_0|x_1) \right] \right. \\ &\quad \left. + \sum_{k=1}^{K-1} \mathbb{E}_{q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0)||p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \right] \end{aligned}$$

接下来, 我们将根据 CTMC 速率矩阵编写转换内核, 并以 $\Delta t \rightarrow 0$ 为极限, 以获得连续时间负 ELBO。

首先, 考虑 $\mathcal{L}_{\text{DT}}$ 的内部总和中的一项

$$\begin{aligned} L_k &= \mathbb{E}_{p_{\text{data}}(x_0)q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0)||p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \\ &= -\mathbb{E}_{p_{\text{data}}(x_0)q_{k+1|0}(x_{k+1}|x_0)q_{k|k+1,0}(x_k|x_{k+1}, x_0)} \left[\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] + C \\ &= -\mathbb{E}_{q_k(x_k)q_{k+1|k}(x_{k+1}|x_k)} \left[\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] + C \end{aligned}$$

我们将不依赖于 θ 的项吸收到 C 中。我们现在用 $\hat{R}_k^\theta$ 来写 $p_{k|k+1}^\theta(x_k|x_{k+1})$ 。

$$\begin{aligned}
p_{k|k+1}^\theta(x_k|x_{k+1}) &= \delta_{x_k, x_{k+1}} + \hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \\
\log p_{k|k+1}^\theta(x_k|x_{k+1}) &= \log \left(\delta_{x_k, x_{k+1}} + \hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \\
&= \delta_{x_k, x_{k+1}} \log \left(1 + \hat{R}_k^\theta(x_k, x_k)\Delta t + o(\Delta t) \right) \\
&\quad + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \\
&= \delta_{x_k, x_{k+1}} \left(\hat{R}_k^\theta(x_k, x_k)\Delta t + o(\Delta t) \right) \\
&\quad + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \tag{6}
\end{aligned}$$

在最后一行，我们使用了 $\log(1+z) = z - \frac{z^2}{2} + o(z^2)$ 的级数展开，对于 $|z| \leq 1, z \neq -1$ 有效。对于任何有限的 $R_k^\theta(x_k, x_k)$ ， Δt 可以取足够小，使得级数展开式成立。现在，我们将这种形式的 $\log p_{k|k+1}^\theta$ 替换为 L_k ，并进一步将

$q_{k+1|k}(x_{k+1}|x_k) = \delta_{x_k, x_{k+1}} + R_k(x_k, x_{k+1})\Delta t + o(\Delta t)$ 的期望写为显式和。

$$\begin{aligned}
L_k &= -\mathbb{E}_{q_k(x_k)} \left[\sum_{x_{k+1}} \left\{ \left[\delta_{x_k, x_{k+1}} + R_k(x_k, x_{k+1})\Delta t + o(\Delta t) \right] \times \right. \right. \\
&\quad \left. \left[\delta_{x_k, x_{k+1}} \left(\hat{R}_k^\theta(x_k, x_k)\Delta t + o(\Delta t) \right) \right. \right. \\
&\quad \left. \left. + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \right] \right\} \right] + C \\
L_k &= -\mathbb{E}_{q_k(x_k)} \left[\sum_{x_{k+1}} \left\{ \delta_{x_k, x_{k+1}} \hat{R}_k^\theta(x_k, x_k)\Delta t \right. \right. \\
&\quad \left. \left. + (1 - \delta_{x_k, x_{k+1}}) R_k(x_k, x_{k+1})\Delta t \times \right. \right. \\
&\quad \left. \left. \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) + o(\Delta t) \right\} \right] + C
\end{aligned}$$

我们可以通过以下重新排列来隔离日志中的 $\hat{R}_k^\theta$

$$\begin{aligned}
&\Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k)\Delta t + o(\Delta t) \right) \\
&= \Delta t \log \Delta t + \Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) + o(1) \right) \\
&= \Delta t \log \Delta t + \Delta t \log(1 + o(1)) + \Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) \right)
\end{aligned}$$

其中前两项与 θ 无关，并且趋向于 0 作为 $\Delta t \rightarrow 0$ 。请注意，对于具有 $R_k(x_k, x_{k+1}) > 0$ 的 $x_{k+1} \neq x_k$ 对，我们假设 $\hat{R}_k^\theta(x_{k+1}, x_k) > 0$ 。这个假设是有效的，因为对于 $x_{k+1} \neq x_k$ ，我们有

$$\hat{R}_k^\theta(x_{k+1}, x_k) = R_k(x_k, x_{k+1}) \sum_{x_0} \frac{q_{k|0}(x_k|x_0)}{q_{k|0}(x_{k+1}|x_0)} p_{0|k}^\theta(x_0|x_{k+1})$$

我们假设 $p_{0|k}^\theta(x_0|x_{k+1}) > 0$ 当我们使用 softmax 输出参数化 $p_{0|k}^\theta$ 时有效。我们假设一个不可约马尔可夫链，因此 $q_{k|0} > 0$ 对应 $t_k > 0$ 。

通过这种重新排列，并将常数项吸收到 C 中，我们得到

$$L_k = -\mathbb{E}_{q_k(x_k)} \left[\sum_{x_{k+1}} \left\{ \delta_{x_k, x_{k+1}} \hat{R}_k^\theta(x_k, x_k) \Delta t \right. \right. \\ \left. \left. + (1 - \delta_{x_k, x_{k+1}}) R_k(x_k, x_{k+1}) \Delta t \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) \right) \right. \right. \\ \left. \left. + o(\Delta t) \right\} \right] + C$$

$$L_k = -\mathbb{E}_{q_k(x_k)} \left[\hat{R}_k^\theta(x_k, x_k) \Delta t + \sum_{x_{k+1} \neq x_k} R_k(x_k, x_{k+1}) \Delta t \log \hat{R}_k^\theta(x_{k+1}, x_k) + o(\Delta t) \right]$$

第二项可以重写，以便更有效地使用蒙特卡洛进行近似。目前，必须针对总和 $\sum_{x_{k+1} \neq x_k}$ 中的每一项评估去噪模型 $p_{0|k}^\theta$ ，这将需要神经网络的多次前向传递。我们可以创建一个新的概率分布来进行采样，如下所示。定义

$$r_k(x_{k+1}|x_k) = (1 - \delta_{x_k, x_{k+1}}) \frac{R_k(x_k, x_{k+1})}{\mathcal{Z}^k(x_k)}$$

在哪里

$$\mathcal{Z}^k(x_k) = \sum_{x'_{k+1} \neq x_k} R_k(x_k, x'_{k+1})$$

所以我们现在有

$$L_k = -\mathbb{E}_{q_k(x_k) r_k(x_{k+1}|x_k)} \left[\hat{R}_k^\theta(x_k, x_k) \Delta t + \mathcal{Z}^k(x_k) \Delta t \log \hat{R}_k^\theta(x_{k+1}, x_k) + o(\Delta t) \right]$$

检查 $\mathcal{L}_{\text{DT}}$ 中的其他项，我们有 $\mathbb{E}_{p_{\text{data}}(x_0)} [\text{KL}(q_{K|0}(x_K|x_0) || p_{\text{ref}}(x_K))]$ ，它不依赖于 θ 和 $\mathbb{E}_{q_{1|0}(x_1|x_0)} [\log p_{0|1}^\theta(x_0|x_1)]$ ，我们在此展开

$$\begin{aligned} & \mathbb{E}_{q_{1|0}(x_1|x_0)} [\log p_{0|1}^\theta(x_0|x_1)] \\ &= \sum_{x_1} \{ \delta_{x_1, x_0} + \Delta t R_1(x_0, x_1) + o(\Delta t) \} \log p_{0|1}^\theta(x_0|x_1) \\ &= \log p_{0|1}^\theta(x_0|x_0) + \Delta t \sum_{x_1} R_1(x_0, x_1) \log p_{0|1}^\theta(x_0|x_1) + o(\Delta t) \\ &= \Delta t \hat{R}_1^\theta(x_0, x_0) + \Delta t \sum_{x_1} R_1(x_0, x_1) \log p_{0|1}^\theta(x_0|x_1) + o(\Delta t) \end{aligned}$$

在最后一行我们使用了等式 6。总而言之，

$$\begin{aligned} \mathcal{L}_{\text{DT}} &= \Delta t \mathbb{E}_{p_{\text{data}}(x_0) q_{1|0}(x_1|x_0)} \left[-\hat{R}_1^\theta(x_0, x_0) + \sum_{x_1} R_1(x_0, x_1) \log p_{0|1}^\theta(x_0|x_1) \right] \\ &\quad - \Delta t \sum_{k=1}^{K-1} \mathbb{E}_{q_k(x_k) r_k(x_{k+1}|x_k)} \left[\hat{R}_k^\theta(x_k, x_k) + \mathcal{Z}^k(x_k) \log \hat{R}_k^\theta(x_{k+1}, x_k) \right] \\ &\quad + o(\Delta t) + C \end{aligned}$$

我们现在将 $\mathcal{L}_{\text{DT}}$ 的极限取为 $\Delta t \rightarrow 0$ 和 $K \rightarrow \infty$ 。

$$\lim_{\Delta t \rightarrow 0} \mathcal{L}_{\text{DT}} = \mathcal{L}_{\text{CT}} = - \int_0^T \mathbb{E}_{q_t(x) r_t(\tilde{x}|x)} \left[\hat{R}_t^\theta(x, x) + \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] dt + C$$

如果我们认为积分是关于时间上均匀分布 $(0, T)$ 的期望，我们可以使用蒙特卡罗来估计积分。我们还明确地将 $\hat{R}_t^\theta(x, x)$ 写为负的非对角行总和以获得

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x) r_t(\tilde{x}|x)} \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] + C.$$

□

B.3 命题3的证明

Proof. 我们假设 $q_{t|s}(\mathbf{x}_t^{1:D}|\mathbf{x}_s^{1:D})$ 因式分解为 $\prod_{d=1}^D q_{t|s}(x_t^d|x_s^d)$, 其中 $q_{t|s}(x_t^d|x_s^d)$, $d = 1, \dots, D$ 是每个具有前向速率 $R_t^d(\tilde{x}^d, x^d)$ 的独立奇异维 CTMC 的转移概率。接下来, 我们将删除 x 参数上的时间下标。为了找到 $R_t^{1:D}$ 和 R_t^d 之间的对应关系, 我们使用 Kolmogorov 前向方程

$$\partial_t q_{t|s}(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}) = \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) R_t^{1:D}(\mathbf{y}^{1:D}, \mathbf{x}^{1:D})$$

将 $q_{t|s}$ 以分解形式代入 LHS

$$\begin{aligned} \partial_t q_{t|s}(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}) &= \partial_t \left\{ \prod_{d=1}^D q_{t|s}(x^d|\tilde{x}^d) \right\} \\ &= \sum_{d=1}^D q_{t|s}(\mathbf{x}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) \partial_t q_{t|s}(x^d|\tilde{x}^d) \\ &= \sum_{d=1}^D q_{t|s}(\mathbf{x}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) \sum_{y^d} q_{t|s}(y^d|\tilde{x}^d) R_t^d(y^d, x^d) \\ &= \sum_{d=1}^D \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{x}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) q_{t|s}(y^d|\tilde{x}^d) R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}} \\ &= \sum_{d=1}^D \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D \setminus d}|\tilde{\mathbf{x}}^{1:D \setminus d}) q_{t|s}(y^d|\tilde{x}^d) R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}} \\ &= \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) \sum_{d=1}^D R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}} \end{aligned}$$

因此我们得到

$$\sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) R_t^{1:D}(\mathbf{y}^{1:D}, \mathbf{x}^{1:D}) = \sum_{\mathbf{y}^{1:D}} q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) \sum_{d=1}^D R_t^d(y^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{y}^{1:D \setminus d}}$$

对于所有可能的可分解前向过程转换 $q_{t|s}$, 包括 $q_{t|s}(\mathbf{y}^{1:D}|\tilde{\mathbf{x}}^{1:D}) = \delta_{\mathbf{y}^{1:D}, \tilde{\mathbf{x}}^{1:D}}$, 这都必须成立。这个选择给了我们远期利率关系

$$R_t^{1:D}(\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}) = \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$$

将其代入命题 1 的反向利率表达式中, 我们得到

$$\begin{aligned} \hat{R}_t^{1:D}(\mathbf{x}^{1:D}, \tilde{\mathbf{x}}^{1:D}) &= \sum_{\mathbf{x}_0^{1:D}} \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \frac{q_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}_0^{1:D})}{q_t(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D})} q_{0|t}(\mathbf{x}_0^{1:D}|\mathbf{x}^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \\ &= \sum_{\mathbf{x}_0^{1:D}} \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)} q_{0|t}(\mathbf{x}_0^{1:D}|\mathbf{x}^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \\ &= \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \sum_{x_0^d} q_{0|t}(x_0^d|\mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)} \sum_{\mathbf{x}_0^{1:D \setminus d}} q_{0|t}(\mathbf{x}_0^{1:D \setminus d}|x_0^d, \mathbf{x}^{1:D}) \\ &= \sum_{d=1}^D R_t^d(\tilde{x}^d, x^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} \sum_{x_0^d} q_{0|t}(x_0^d|\mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d|x_0^d)}{q_{t|0}(x^d|x_0^d)} \end{aligned}$$

□

B.4 命题 4 的证明

Proof. 由K 应用于前向过程的奥尔莫戈洛夫前向方程,

我们有

$$\partial_t q_t(x_t) = \sum_y R_t(y, x_t) q_t(y)$$

此外, 将柯尔莫哥洛夫前向方程应用于逆向过程, 其与前向过程具有相同的边际但时间反转, 我们得到

$$-\partial_t q_t(x_t) = \sum_y \hat{R}_t(y, x_t) q_t(y)$$

将这两个方程相加得出

$$\sum_y \left\{ R_t(y, x_t) + \hat{R}_t(y, x_t) \right\} q_t(y) = 0$$

因此, 与Kolmogorov方程相比, $R_t + \hat{R}_t$ 是具有不变分布 q_t 的CTMC的速率矩阵。

□

B.5 定理 1 的证明

在本节中, 我们推导出 tau 跳跃扩散模型的误差界限。因为 τ 跳跃近似仅在一歩中沿着不同维度进行多次跳跃的情况下才有意义, 所以我们选择明确边界对模型维度的依赖性, 而不是简单地考虑固定 D 和 $\tau \rightarrow 0$ 的情况。

回想一下正文, 我们在 $\mathcal{X}$ 上有一个时间同质速率矩阵 R_t , 通过为每个 d 设置 $R_t^d = R_t$ 来构造 $\mathcal{X}^D$ 上的因式分解速率矩阵 $R_t^{1:D}$, 并将表示 $|R| = \sup_{t \in [0, T], x \in \mathcal{X}} |R_t(x, x)|$, 并令 t_{mix} 为具有速率 R_t 的 CTMC 的 $(1/4)$ 混合时间。我们还使用从 $\mathcal{X}$ 到 $\mathbb{Z}$ 的映射在状态空间 $\mathcal{X}^D$ 上定义加法, 如第 4.3 节和按组件加法。

定理 1. *For any $D \geq 1$ and distribution p_{data} on $\mathcal{X}^D$, let $\{x_t\}_{t \in [0, T]}$ be a CTMC starting in p_{data} with rate matrix $R_t^{1:D}$ as above. Suppose that $\hat{R}_t^{\theta 1:D}$ is an approximation to the reverse rate matrix and let $(y_k)_{k=0,1,\dots,N}$ be a tau-leaping approximation to the reverse dynamics with maximum step size τ . Suppose further that there is some constant $M > 0$ independent of D such that*

$$\sum_{y \neq x} \left| \hat{R}_t^{1:D}(x, y) - \hat{R}_t^{\theta 1:D}(x, y) \right| \leq M$$

for all $t \in [0, T]$. Then under the assumptions listed below, there are constants $C_1, C_2 > 0$ depending

on $\mathcal{X}$ and R_t but not D such that, if $\mathcal{L}(y_0)$ denotes the law of y_0 , we have the total variation bound

$$\|\mathcal{L}(y_0) - p_{\text{data}}\|_{\text{TV}} \leq 3MT + \left\{ (|R|SDC_1)^2 + \frac{1}{2}C_2(M + C_1SD|R|) \right\} \tau T + 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

上述定理在以下假设下成立, 如果 $x, y \in S^D$ 最多有一个坐标不同, 我们将 $x \sim y$ 写为 $x, y \in S^D$ 。

假设 1. *The data distribution p_{data} is strictly positive.*

假设 2. *There exists a constant $C_1 > 0$, depending on S and R_t but not D , such that for all $t \in [0, T]$ and $x, y \in S^D$ such that $x \sim y$, we have*

$$\frac{q_t(x)}{q_t(y)} \leq C_1.$$

假设 3. *There exists a constant $C_2 > 0$, depending on S and R_t but not D , such that for all $t \in [0, T]$ and all $x, y \in S^D$ such that $x \sim y$, we have*

$$\sum_z \left| \hat{R}_t(x, x+z) - \hat{R}_t(y, y+z) \right| \leq C_2.$$

相反，如果我们允许 C_1 和 C_2 取决于维度 D ，则假设 2 和 3 可以简单地从假设 1 和状态空间的有限性得出。然而，如前所述，我们选择上面更强的公式，以便明确误差界限对维度的依赖性。

正如正文中所述，在大多数具有实际意义的情况下（包括第 6 节中探讨的两个例子），假设 3 仅近似成立。然而，我们仍然期望只要另外选择 x, y ，使得逆过程的 τ 跳跃近似以相当高的概率在它们之间跳跃，假设 3 中的界限就成立。例如，在我们的数据是序数的情况下，我们期望对于任何 $x \sim y$ ，从 x 到 y 的跳转仅在 x 接近 y 时才常见，因此每当发生从 x 到 y 的跳转时， $\hat{R}_t(x, x+z)$ 和 $\hat{R}_t(y, y+z)$ 应该相当接近。在这种形式的较弱假设下，定理 1 的证明可以按照类似的思路进行调整，但代价是技术性的显着增加。因此，我们选择关注假设 3 成立的更简单的情况，因为它说明了关键思想。

为了证明定理 1，我们需要以下引理

作为。

命题 5. *Let $(x_t)_{t \in [0, T]}$ and $(y_t)_{t \in [0, T]}$ be continuous time Markov chains on a finite state space S with generators G_t and H_t respectively which are both bounded and continuous in t . Let the Markov kernels associated to X and Y be K and L respectively. Then for any probability distribution ν on S we have*

$$\|\nu K - \nu L\|_{\text{TV}} \leq \int_0^T \sup_{x \in S} \left\{ \sum_{y \neq x} |G_t(x, y) - H_t(x, y)| \right\} dt$$

Proof. 基于[24]第20.1章的构造，我们定义 $(x_t)_{t \in [0, T]}$ 和 $(y_t)_{t \in [0, T]}$ 的耦合如下。首先取 $Z \sim \nu$ 并设置 $x_0 = y_0 = Z$ 。还定义变量 $\tilde{x}_0 = \tilde{y}_0 = Z_0$ 。

接下来，固定 λ 使得 $|G_t(x, x)|, |H_t(x, x)| \leq \lambda$ 对于所有 $x \in S, t \in [0, T]$ ，令 $(N_s)_{1 \leq s \leq T}$ 为速率 λ 的 $[0, T]$ 上的泊松过程，并将 N_0 设置为 0。我们将到达时间写为 $N = N_T$ 和 $S_1, S_2, \dots, S_N$ 并设置 $S_{N+1} = T$ 。我们对 $t > 0$ 归纳构造 x_t 和 y_t ，如下所示。对于 $t \in [0, S_1)$ 令 $x_t = y_t = x_0$ 。让 $1 \leq j \leq N$ 。给定 $(x_r : r < S_j)$ 、 $(y_r : r < S_j)$ 和 $\tilde{x}_j, \tilde{y}_j$ ，定义以下概率度量

$$\begin{aligned} \rho_j(\tilde{x}_j, w) &:= \begin{cases} G_{S_j}(\tilde{x}_j, w)/\lambda, & w \neq \tilde{x}_j \\ 1 - G_{S_j}(\tilde{x}_j, w)/\lambda, & w = \tilde{x}_j, \end{cases} \\ \rho'_j(\tilde{y}_j, w) &:= \begin{cases} H_{S_j}(\tilde{y}_j, w)/\lambda, & w \neq \tilde{y}_j \\ 1 - H_{S_j}(\tilde{y}_j, w)/\lambda, & w = \tilde{y}_j. \end{cases} \end{aligned}$$

从 (ρ_j, ρ'_j) 的最大耦合中采样 $(\tilde{x}_{j+1}, \tilde{y}_{j+1})$ ，并且对于 $t \in [S_j, S_{j+1})$ 集合 $x_t = \tilde{x}_{j+1}$ 、 $y_t = \tilde{y}_{j+1}$ 。最后设置 $x_T = x_{S_N}$ 和 $y_T = y_{S_N}$ 。

现在，观察以这种方式定义的 $(x_t, y_t)_{t \in [0, T]}$ 是给定马尔可夫链的耦合。而且，

$$\begin{aligned} \|\nu K - \nu L\|_{\text{TV}} &\leq \mathbb{P}(x_T \neq y_T) \\ &= \mathbb{E} \left[\sum_{j=1}^N \mathbb{I}\{x_{S_j} \neq y_{S_j}\} \right] \\ &= \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \sum_{j=0}^n \mathbb{E} [\mathbb{I}\{x_{S_j} \neq y_{S_j}\}] \end{aligned}$$

并利用跳跃最大耦合的事实

$$\begin{aligned}
&= \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \sum_{j=0}^n \mathbb{E} \left[\mathbb{I} \{x_s = y_s, s < S_j\} \times \|\rho_j(X_{S_{j-1}}, \cdot) - \tilde{\rho}_j(X_{S_{j-1}}, \cdot)\|_{\text{TV}} \right] \\
&= \sum_{n=0}^{\infty} \frac{\lambda^n e^{-\lambda}}{n!} \sum_{j=0}^n \mathbb{E} \left[\mathbb{I} \{x_s = y_s, s < S_j\} \frac{1}{\lambda} \sum_z |G_{S_j}(x_{S_{j-1}}, z) - H_{S_j}(x_{S_{j-1}}, z)| \right] \\
&= \frac{1}{\lambda} \mathbb{E} \left[\sum_{s: x_s \neq x_{s-}} \sum_z |G_s(x_{s-}, z) - H_s(x_{s-}, z)| \right] \\
&= \frac{1}{\lambda} \int_{s=0}^T \mathbb{E} \left[\lambda \sum_z |G_s(x_{s-}, z) - H_s(x_{s-}, z)| \right] \\
&= \int_{s=0}^T \mathbb{E} \left[\sum_z |G_s(x_{s-}, z) - H_s(x_{s-}, z)| \right] ds
\end{aligned}$$

根据需要。 $\square$

命题 6. For all $t \in [0, T]$ and $x, y \in \mathcal{X}^D$ such that $x \sim y$, we have

$$|\partial_t \hat{R}_t(x, y)| \leq 2|R|^2 SDC_1^2$$

Moreover, it follows that $\hat{R}_t$ is bounded and continuous in t .

Proof. 为了简洁起见，在符号清晰的情况下省略上标，我们有

$$\begin{aligned}
\left| \partial_t \hat{R}_t^{1:D}(x^{1:D}, y^{1:D}) \right| &= \left| R_t(y, x) \partial_t \left\{ \frac{q_t(y)}{q_t(x)} \right\} \right| \\
&= \left| R_t(y, x) \left\{ \frac{q_t(y)}{q_t(x)} \frac{\sum_z R_t(z, y) q_t(z)}{q_t(y)} - \frac{q_t(y)}{q_t(x)} \frac{\sum_z R_t(z, x) q_t(z)}{q_t(x)} \right\} \right| \\
&\leq 2|R|^2 SDC_1^2
\end{aligned}$$

其中第二行来自柯尔莫哥洛夫的前向方程，最终的不等式来自假设 2 以及 $R_t(z, x)$ (resp 的事实。仅当 $x \sim z$ (resp 时， $R_t(z, y)$) 才非零。 $y \sim z$)，并且 x (最多有 $|S||D|$ 个值。 y) 这适用。 $\square$

现在我们给出定理1的证明。

Proof of Theorem 1. 让我们将 τ 跳跃中使用的时间步标记为 $0 = t_0 < t_1 < \dots < t_N = T$ ，表示 $\tau_k = t_k - t_{k-1}$ ，并用 $\pi^D(x^{1:D}) = \prod_{d=1}^D \pi(x^d)$ 表示目标平稳分布，其中 π 是单维转移矩阵 R_t^1 的不变分布。

另外，令 $\mathcal{R}_k^{\theta, (\tau)}$ 为马尔可夫核，对应于应用速率矩阵 $\hat{R}_{t_k}^{\theta}$ 的 τ 跳跃近似从 t_k 移动到 t_{k-1} ，并表示 $\mathcal{R}^{\theta, (\tau)} = \mathcal{R}_N^{\theta, (\tau)} \mathcal{R}_{N-1}^{\theta, (\tau)} \dots \mathcal{R}_1^{\theta, (\tau)}$ ，以便 $\mathcal{R}^{\theta, (\tau)}$ 表达 τ 跳跃过程的完整动态，我们有 $\mathcal{L}(\hat{y}_0) = \pi^D \mathcal{R}^{\theta, (\tau)}$ 。

然后，如[19]所示，我们可以分解

$$\|\pi^D \mathcal{R}^{\theta, (\tau)} - p_d\|_{\text{TV}} \leq \|\pi^D \mathcal{R}^{\theta, (\tau)} - \pi^D(\mathbb{P}^R)_{T|0}\|_{\text{TV}} + \|\pi^D - q_T\|_{\text{TV}}$$

其中 $\mathbb{P}^R$ 是精确逆过程的路径度量。

我们首先处理第二项。令 t_{mix} 为具有速率矩阵 R_t^1 的一维CTMC的(1/4)混合时间，即

$$t_{\text{mix}} = \inf \left\{ t \geq 0 : \sup_{x_0^1 \in S} \|q_t|_0(\cdot | x_0^1) - \pi\|_{\text{TV}} \leq \frac{1}{4} \right\}$$

然后从

$$\|q_{t|0}(\cdot | x_0^{1:D}) - \pi^D\|_{\text{TV}} \leq \sum_{d=1}^D \|q_{t|0}(\cdot | x_0^d) - \pi\|_{\text{TV}}$$

t_{mix}^D , 即具有速率矩阵 $R_t^{1:D}$ 的完整 CTMC 的 $(1/4)$ 混合时间, 满足不等式 $t_{\text{mix}}^D \leq \{1 + \lceil \log_2 D \rceil\} t_{\text{mix}}$. 如果我们将 $(x_{mt_{\text{mix}}^D})_{m \in \mathbb{N}}$ 视为离散时间马尔可夫链, 则马尔可夫链混合的标准结果 (例如, 参见[24]的第 4.5 章) 表明:

$$\|q_{mt_{\text{mix}}^D|0}(\cdot | x_0^{1:D}) - \pi^D\|_{\text{TV}} \leq 2^{-m}$$

那么对于任何 $T \geq 0$ 我们有

$$\|\pi^D - q_T\|_{\text{TV}} \leq 2 \exp \left\{ -\frac{T \log 2}{t_{\text{mix}}^D} \right\} \leq 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

完成第二学期的界限。

为了限制第一项, 我们定义 $\mathcal{P}_k = (\mathbb{P}^R)_{T-t_{k-1}|T-t_k}$ 并将其分解为

$$\begin{aligned} \|\pi \mathcal{R}^{\theta,(\tau)} - \pi(\mathbb{P}^R)_{T|0}\|_{\text{TV}} &\leq \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} \dots \mathcal{R}_1^{\theta,(\tau)} - \nu \mathcal{P}_N \dots \mathcal{P}_1\|_{\text{TV}} \\ &\leq \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} \mathcal{R}_{N-1}^{\theta,(\tau)} \dots \mathcal{R}_1^{\theta,(\tau)} - \nu \mathcal{R}_N^{\theta,(\tau)} \mathcal{P}_{N-1} \dots \mathcal{P}_1\|_{\text{TV}} \\ &\quad + \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} \mathcal{P}_{N-1} \dots \mathcal{P}_1 - \nu \mathcal{P}_N \mathcal{P}_{N-1} \dots \mathcal{P}_1\|_{\text{TV}} \\ &\leq \sup_{\nu} \|\nu \mathcal{R}_{N-1}^{\theta,(\tau)} \dots \mathcal{R}_1^{\theta,(\tau)} - \nu \mathcal{P}_{N-1} \dots \mathcal{P}_1\|_{\text{TV}} + \sup_{\nu} \|\nu \mathcal{R}_N^{\theta,(\tau)} - \nu \mathcal{P}_N\|_{\text{TV}} \\ &\leq \sum_{k=1}^N \sup_{\nu} \|\nu \mathcal{R}_k^{\theta,(\tau)} - \nu \mathcal{P}_k\|_{\text{TV}} \end{aligned}$$

通过归纳进行。因此, 只要找到每个区间 $[t_{k-1}, t_k]$ 上累积的总变异距离的界限就足够了。

令 $\mathcal{R}_k^{\theta}$ 为对应于以恒定速率矩阵 $\hat{R}_{t_k}^{\theta}$ 运行从 t_k 到 t_{k-1} 的链的马尔可夫核。由于根据命题 6, 反向速率矩阵 $\hat{R}_t$ 在 t 中是有界且连续的, 因此使用命题 5, 我们推断出对于 S 上的任何分布 ν , 我们有

$$\begin{aligned} \|\nu \mathcal{P}_k - \nu \mathcal{R}_k^{\theta}\|_{\text{TV}} &\leq \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_t(x, y) - \hat{R}_{t_k}^{\theta}(x, y)| \right\} dt \\ &\leq \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_t(x, y) - \hat{R}_{t_k}(x, y)| \right\} dt \\ &\quad + \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_{t_k}(x, y) - \hat{R}_{t_k}^{\theta}(x, y)| \right\} dt \end{aligned}$$

这个的前半部分 表达式可以使用均值定理 ac 来限制

共指向

$$\begin{aligned} \int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_t(x, y) - \hat{R}_{t_k}(x, y)| \right\} dt &\leq \int_{t_{k-1}}^{t_k} |t - t_k| \cdot 2|R|^2 S^2 D^2 C_1^2 dt \\ &\leq (|R| S D C_1 \tau_k)^2 \end{aligned}$$

在第一行中, 我们使用了被加数仅在 $y \sim x$ 时才非零, 并且 y 最多有 $|S||D|$ 个值。第二项可以使用条件 (2) 来限制, 得到

$$\int_{t_{k-1}}^{t_k} \sup_{x \in S} \left\{ \sum_{y \neq x} |\hat{R}_{t_k}(x, y) - \hat{R}_{t_k}^{\theta}(x, y)| \right\} dt \leq M \tau_k$$

结合这两个表达式，我们得到了 $\|\nu\mathcal{P}_k - \nu\mathcal{R}_k^\theta\|_{\text{TV}}$ 的界限。

$$\|\nu\mathcal{P}_k - \nu\mathcal{R}_k^\theta\|_{\text{TV}} \leq (|R|SDC_1\tau_k)^2 + M\tau_k$$

它仍然受约束 $\|\nu\mathcal{R}_k^\theta - \nu\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}}$ 。请注意，从 x_{t_k} 开始使用速率矩阵 $\hat{R}_{t_k}^\theta$ 执行 τ 跳跃等效于使用由下式给出的恒定速率矩阵 $\hat{R}_{t_k}^{\theta,(\tau)}$ 运行从时间 t_k 到 t_{k-1} 的连续时间马尔可夫链

$$\hat{R}_{t_k}^{\theta,(\tau)}(x, y) = \hat{R}_{t_k}^\theta(x_{t_k}, y - x + x_{t_k})$$

(接下来可能会进行钳位操作以使我们保持在 $\mathcal{X}^D$ 之内。通过与命题 5 的证明类似的论证，

$$\|\delta_{x_{t_k}}\mathcal{R}_k^\theta - \delta_{x_{t_k}}\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} \leq \int_{t_{k-1}}^{t_k} \mathbb{E} \left[\sum_{y \neq x_t} |\hat{R}_{t_k}^\theta(x_t, y) - \hat{R}_{t_k}^\theta(x_{t_k}, y - x_t + x_{t_k})| \right] dt$$

其中期望被接管 $(x_t)_{t \in [t_{k-1}, t_k]}$ 根据具有速率矩阵 $\hat{R}_{t_k}^\theta$ 的精确 CTMC 分布。（请注意，我们忽略了夹紧操作，因为这只能减少最终的总变化距离。）

我们可以使用条件 (2) 根据精确的逆过程重写这个界限，得到

$$\|\delta_{x_{t_k}}\mathcal{R}_k^\theta - \delta_{x_{t_k}}\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} \leq \int_{t_{k-1}}^{t_k} \mathbb{E} \left[2M + \sum_{y \neq x_t} |\hat{R}_{t_k}(x_t, y) - \hat{R}_{t_k}(x_{t_k}, y - x_t + x_{t_k})| \right] dt$$

令 J_t 为 (x_t) 在 t_k 和 t 之间进行的跳跃次数，为方便起见，将这些跳跃的次数标记为 $s_1, \dots, s_j$ ，其中 $t \leq s_1 \leq \dots \leq s_j \leq t_k$ 和 $j = J_t$ 。那么根据假设 3，我们有

$$\begin{aligned} \sum_{y \neq x_t} |\hat{R}_{t_k}(x_t, y) - \hat{R}_{t_k}(x_{t_k}, y - x_t + x_{t_k})| &\leq \sum_z |\hat{R}_{t_k}(x_t, x_t + z) - \hat{R}_{t_k}(x_{s_1}, x_{s_1} + z)| + \dots \\ &\quad + \sum_z |\hat{R}_{t_k}(x_{s_j}, x_{s_j} + z) - \hat{R}_{t_k}(x_{t_k}, x_{t_k} + z)| \\ &\leq C_2 J_t \end{aligned}$$

我们进行了替换 $z = y - x_{t_k}$ 。我们的结论是

$$\begin{aligned} \|\delta_{x_{t_k}}\mathcal{R}_k^\theta - \delta_{x_{t_k}}\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} &\leq \int_{t_{k-1}}^{t_k} \mathbb{E} [2M + C_2 J_t] dt \\ &\leq 2M|t_k - t_{k-1}| + C_2 \int_{t_{k-1}}^{t_k} |t_k - t| \cdot \sup_x |\hat{R}_{t_k}^\theta(x, x)| dt \\ &\leq 2M\gamma_k + \frac{1}{2}C_2 |\hat{R}_{t_k}^\theta| \tau_k^2 \\ &\leq 2M\tau_k + \frac{1}{2}C_2 (M + C_1 SD |R|) \tau_k^2 \end{aligned}$$

在哪里绑定 $\mathbb{E}[J_t]$ 我们观察到 (x_t) 的跳跃发生的速率以上面由 $\sup_x |\hat{R}_{t_k}^\theta(x, x)|$ 为界，并且在最后一行中我们使用了条件 (2) 和假设 2。由于上述内容适用于 x_{t_k} 的任何选择，因此可以得出以下结论：

$$\sup_\nu \|\nu\mathcal{R}_k^\theta - \nu\mathcal{R}_k^{\theta,(\tau)}\|_{\text{TV}} \leq 2M\tau_k + \frac{1}{2}C_2 (M + C_1 SD |R|) \tau_k^2$$

总结 k 并将所有界限放在一起，我们得到

$$\|\mathcal{L}(y_0) - p_{\text{data}}\|_{\text{TV}} \leq 3MT + \left\{ (|R|SDC_1)^2 + \frac{1}{2}C_2 (M + C_1 SD |R|) \right\} \tau T + 2 \exp \left\{ -\frac{T \log^2 2}{t_{\text{mix}} \log 4D} \right\}$$

根据需要。 $\square$

C 连续时间 ELBO 详细信息

C.1 与离散时间 ELBO 的比较

通过将 $\mathcal{L}_{\text{CT}}$ 目标与其离散时间对应物 $\mathcal{L}_{\text{DT}}$ 进行比较，并检查当时间步长非常小时，极限中的 $\mathcal{L}_{\text{DT}}$ 变为 $\mathcal{L}_{\text{CT}}$ 的方式，最容易获得对 $\mathcal{L}_{\text{CT}}$ 目标的直觉。为了方便起见，我们在这里重复 $\mathcal{L}_{\text{CT}}$ 的定义

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x) r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x) \right) \right] + C.$$

回想一下，从 $\mathcal{L}_{\text{DT}}$ 中的 KL 和到独立于 θ 的加法常数的单个项是

$$-\mathbb{E}_{q_k(x_k) q_{k+1|k}(x_{k+1}|x_k)} \left[\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right].$$

最小化此项是从前向动态中采样 (x_k, x_{k+1}) ，然后最大化反向配对的分配模型概率。类似的想法可以用来理解 $\mathcal{L}_{\text{CT}}$ 。首先，我们根据 $\hat{R}_k^\theta$ 将日志 $p_{k|k+1}^\theta(x_k|x_{k+1})$ 写为

$$\begin{aligned} \log p_{k|k+1}^\theta(x_k|x_{k+1}) &= \delta_{x_k, x_{k+1}} \left(\hat{R}_k^\theta(x_k, x_k) \Delta t + o(\Delta t) \right) \\ &\quad + (1 - \delta_{x_k, x_{k+1}}) \log \left(\hat{R}_k^\theta(x_{k+1}, x_k) \Delta t + o(\Delta t) \right) \end{aligned}$$

我们将 $x_k = x_{k+1}$ 和 $x_k \neq x_{k+1}$ (查看 $\mathcal{L}_{\text{CT}}$ 的证明以获取完整详细信息) 时的情况分开。第一项将成为 $\mathcal{L}_{\text{CT}}$ 中的 $\sum_{x' \neq x} \hat{R}_t^\theta(x, x')$ 项，而第二项将成为 $\mathcal{Z}^t(x) \log(\hat{R}_t^\theta(\tilde{x}, x))$ 项。现在，当我们最小化 $\mathcal{L}_{\text{CT}}$ 时，我们从前向过程中采样 $(x, \tilde{x})$ ，然后最大化反向配对的分配模型概率，就像 $\mathcal{L}_{\text{DT}}$ 中一样。稍微额外的复杂性来自于我们分别考虑 $x_k = x_{k+1}$ 时的情况和 $x_k \neq x_{k+1}$ 时的情况。当 $x_k = x_{k+1}$ 时，这对应于 $\mathcal{L}_{\text{CT}}$ 中的第一项，我们可以看到它最小化了 x 中的反向率，这恰好最大化了不发生转换的模型概率。当 $x_k \neq x_{k+1}$ 时，这对应于 $\mathcal{L}_{\text{CT}}$ 中的第二项，它最大化从 $\tilde{x}$ 到 x 的反向速率，从而最大化发生 $\tilde{x}$ 到 x 转换的模型概率。

C.2 条件形式

对于 $\mathcal{L}_{\text{CT}}$ 的条件形式 (表示为 $\bar{\mathcal{L}}_{\text{CT}}$)，我们取而代之的是负条件模型对数似然的上限， $\mathbb{E}_{p_{\text{data}}(x_0, y)}[-\log p_0^\theta(x_0|y)]$ ，其中 y 是我们的条件。 $\bar{\mathcal{L}}_{\text{CT}}$ 具有以下形式

$$\begin{aligned} \bar{\mathcal{L}}_{\text{CT}}(\theta) &= T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(x_0, y) q_{t|0}(x|x_0) r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^\theta(x, x'|y) \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^\theta(\tilde{x}, x|y) \right) \right] + C, \text{ 其中} \\ \hat{R}_t^\theta(x, \tilde{x}|y) &= R_t(\tilde{x}, x) \sum_{x_0} \frac{q_{t|0}(\tilde{x}|x_0)}{q_{t|0}(x|x_0)} p_{0|t}^\theta(x_0|x, y) \quad \text{for } x \neq \tilde{x}. \\ &= - \sum_{x' \neq x} \hat{R}_t^\theta(x, x'|y) \quad \text{for } x = \tilde{x} \end{aligned}$$

通过考虑离散时间 ELBO, $\bar{\mathcal{L}}_{\text{DT}}$ 的条件形式并使用与之前相同的参数从离散时间到连续时间，可以轻松得出此结论。

$$\mathbb{E}_{p_{\text{data}}(x_0, y)}[-\log p_0^\theta(x_0|y)] \leq \mathbb{E}_{p_{\text{data}}(x_0, y) q_{1:K|0}(x_{1:K}|x_0)} \left[-\log \frac{p_{0:K}^\theta(x_{0:K}|y)}{q_{1:K|0}(x_{1:K}|x_0)} \right] = \bar{\mathcal{L}}_{\text{DT}}$$

C.3 具有因式分解假设的连续时间 ELBO

在下面的命题中，我们展示了使用因式分解前向过程时 $\mathcal{L}_{\text{CT}}$ 的形式。我们注意到，在证明中我们将采样分布从 $p_{\text{data}}(\mathbf{x}_0^{1:D}) q_{t|0}(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D}) r_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}^{1:D})$ 重新排列为 $p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}_0^{1:D}) \phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D})$ 。这并不是绝对必要的，但它允许我们对中间 $\mathbf{x}^{1:D}$ 变量进行分析求和，从而大大减少最终目标的方差。

命题 7. The $\mathcal{L}_{\text{CT}}$ objective when we substitute in the factorized forms for the forward and reverse process given in Proposition 3 is

$$\begin{aligned}\mathcal{L}_{\text{CT}} = & T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(\mathbf{x}_0^{1:D}) q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) \left[\sum_{d=1}^D \sum_{x^d \neq x^d} \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x^d) \right] \\ & - T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D}) \left[\sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \phi_t(x^d | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D/d} \circ x^d) \log \left(\hat{R}_t^{\theta d}(\tilde{\mathbf{x}}^{1:D}, x^d) \right) \right] \\ & + C\end{aligned}$$

with

$$\begin{aligned}\hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, \tilde{x}^d) &= R_t^d(\tilde{x}^d, x^d) \sum_{x_0^d} p_{0|t}^{\theta}(x_0^d | \mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d | x_0^d)}{q_{t|0}(x^d | x_0^d)} \\ \mathcal{Z}^t(\mathbf{x}^{1:D}) &= \sum_{d=1}^D \sum_{\tilde{x}^d \neq x^d} R_t^d(x^d, \tilde{x}^d) \\ \phi_t(x^d | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) &= \frac{R_t^d(x^d, \tilde{x}^d) q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d | \mathbf{x}_0^{1:D})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d) \sum_{d'=1}^D \sum_{x'^{d'} \neq \tilde{x}^{d'}} \frac{R_t^{d'}(x'^{d'}, \tilde{x}^{d'})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x'^{d'})} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x'^{d'} | \mathbf{x}_0^{1:D})}\end{aligned}$$

where $\circ$ represents the concatenation of a $D-1$ dimensional vector, $\mathbf{x}^1$

$^{1:D \setminus d}$ with a scalar x^d such that the resultant D dimensional vector has x^d at its d^{th} dimension. $\psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D})$ is defined as the marginal of the forward noising process joint, $\int q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) r_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}^{1:D}) d\mathbf{x}^{1:D}$.

Proof. 我们首先在这里重写 $\mathcal{L}_{\text{CT}}$ 的一般形式

$$\mathcal{L}_{\text{CT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x) r_t(\tilde{x} | x) \left[\left\{ \sum_{x' \neq x} \hat{R}_t^{\theta}(x, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^{\theta}(\tilde{x}, x) \right) \right] + C$$

在哪里

$$\mathcal{Z}^t(x) = \sum_{x' \neq x} R_t(x, x') \quad r_t(\tilde{x} | x) = (1 - \delta_{\tilde{x}, x}) R_t(x, \tilde{x}) / \mathcal{Z}^t(x).$$

通过因式分解的前向过程, $\hat{R}_t^{\theta}$ 变为

$$\hat{R}_t^{\theta 1:D}(\mathbf{x}^{1:D}, \tilde{\mathbf{x}}^{1:D}) = \sum_{d=1}^D \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, \tilde{x}^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$$

在哪里

$$\hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, \tilde{x}^d) = R_t^d(\tilde{x}^d, x^d) \sum_{x_0^d} p_{0|t}^{\theta}(x_0^d | \mathbf{x}^{1:D}) \frac{q_{t|0}(\tilde{x}^d | x_0^d)}{q_{t|0}(x^d | x_0^d)}$$

将 $\hat{R}_t^{\theta 1:D}$ 的这种形式代入 $\mathcal{L}_{\text{CT}}$ 中的第一项, 我们得到

$$\begin{aligned}& \sum_{\mathbf{x}'^{1:D} \neq \mathbf{x}^{1:D}} \sum_{d=1}^D \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x'^d) \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{x}'^{1:D \setminus d}} \\ &= \sum_{d=1}^D \sum_{x'^d} \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x'^d) \sum_{\mathbf{x}'^{1:D \setminus d}} \delta_{\mathbf{x}^{1:D \setminus d}, \mathbf{x}'^{1:D \setminus d}} (1 - \delta_{\mathbf{x}'^{1:D}, \mathbf{x}^{1:D}}) \\ &= \sum_{d=1}^D \sum_{x'^d \neq x^d} \hat{R}_t^{\theta d}(\mathbf{x}^{1:D}, x'^d)\end{aligned}$$

现在我们处理 $\mathcal{L}_{\text{CT}}$ 中的第二项。我们首先重新排列我们的期望分布:

$$p_{\text{data}}(\mathbf{x}_0^{1:D}) q_{t|0}(\mathbf{x}^{1:D} | \mathbf{x}_0^{1:D}) r_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}^{1:D}) = p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D} | \mathbf{x}_0^{1:D}) \phi_t(\mathbf{x}^{1:D} | \tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D})$$

我们有,

$$\begin{aligned}
\phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) &\propto q_{t|0}(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D})r_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}^{1:D}) \\
&= q_{t|0}(\mathbf{x}^{1:D}|\mathbf{x}_0^{1:D})(1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}}) \frac{\sum_{d=1}^D R_t^d(x^d, \tilde{x}^d) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}}{\mathcal{Z}^t(\mathbf{x}^{1:D})} \\
&= \sum_{d=1}^D \frac{R_t^d(x^d, \tilde{x}^d)}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d)} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d|\mathbf{x}_0^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} (1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}})
\end{aligned}$$

为了找到归一化常数, 我们可以对 $\mathbf{x}^{1:D}$ 上的比例项求和

$$\begin{aligned}
&\sum_{\mathbf{x}^{1:D}} \sum_{d=1}^D \frac{R_t^d(x^d, \tilde{x}^d)}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d)} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d|\mathbf{x}_0^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}} (1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}}) \\
&= \sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \frac{R_t^d(x^d, \tilde{x}^d)}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d)} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d|\mathbf{x}_0^{1:D})
\end{aligned}$$

所以,

$$\phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) = (1 - \delta_{\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}}) \sum_{d=1}^D \phi_t(x^d|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \delta_{\mathbf{x}^{1:D \setminus d}, \tilde{\mathbf{x}}^{1:D \setminus d}}$$

在哪里

$$\phi_t(x^d|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) = \frac{R_t^d(x^d, \tilde{x}^d) q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d|\mathbf{x}_0^{1:D})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d) \sum_{d'=1}^D \sum_{x^{d'} \neq \tilde{x}^{d'}} \frac{R_t^{d'}(x^{d'}, \tilde{x}^{d'})}{\mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x^{d'})} q_{t|0}(\tilde{\mathbf{x}}^{1:D \setminus d'} \circ x^{d'}|\mathbf{x}_0^{1:D})}$$

现在我们将第二项写为

$$\begin{aligned}
&T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}_0^{1:D})} \left[- \sum_{\mathbf{x}^{1:D}} \phi_t(\mathbf{x}^{1:D}|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \mathcal{Z}^t(\mathbf{x}^{1:D}) \log \hat{R}_t^{\theta 1:D}(\tilde{\mathbf{x}}^{1:D}, \mathbf{x}^{1:D}) \right] \\
&= -T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(\mathbf{x}_0^{1:D}) \psi_t(\tilde{\mathbf{x}}^{1:D}|\mathbf{x}_0^{1:D})} \left[\sum_{d=1}^D \sum_{x^d \neq \tilde{x}^d} \phi_t(x^d|\tilde{\mathbf{x}}^{1:D}, \mathbf{x}_0^{1:D}) \mathcal{Z}^t(\tilde{\mathbf{x}}^{1:D \setminus d} \circ x^d) \log \left(\hat{R}_t^{\theta d}(\tilde{\mathbf{x}}^{1:D}, x^d) \right) \right]
\end{aligned}$$

□

C.4 一次前向传球

为了评估 $\mathcal{L}_{\text{CT}}$ 目标, 我们天真地需要执行去噪网络的两次前向传递: $p_{0|t}^{\theta}(x_0|x)$ 计算 $\hat{R}_t^{\theta}(x, x')$ 和 $p_{0|t}^{\theta}(x_0|\tilde{x})$ 计算 $\hat{R}_t^{\theta}(\tilde{x}, x)$ 。这是浪费的, 因为 $\tilde{x}$ 是通过应用单个前向转换从 x 创建的, 这在多维问题上意味着 $\tilde{x}$ 仅在单个维度上与 x 不同。为了利用 $\tilde{x}$ 和 x 非常相似的事实, 我们用样本 $\tilde{x} \sim \sum_x q_t(x) r_t(\tilde{x}|x)$ 近似样本 $x \sim q_t(x)$ 。这给出了更有效的目标,

$$\mathcal{L}_{\text{eCT}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x) r_t(\tilde{x}|x)} \left[\left\{ \sum_{x' \neq \tilde{x}} \hat{R}_t^{\theta}(\tilde{x}, x') \right\} - \mathcal{Z}^t(x) \log \left(\hat{R}_t^{\theta}(\tilde{x}, x) \right) \right] + C$$

表 3: 单音音乐数据集的指标, 比较使用有效 $\mathcal{L}_{\text{eCT}}$ 目标与原始 $\mathcal{L}_{\text{CT}}$ 目标的训练。我们在测试集上计算这些值, 显示每首测试歌曲的 5 个样本的平均值 $\pm \text{std}$ 。

Model	Hellinger Distance	Proportion of Outliers
$\tau\text{LDR-0 Uniform } \mathcal{L}_{\text{eCT}}$	0.3765 ± 0.0013	0.1106 ± 0.0010
$\tau\text{LDR-0 Uniform } \mathcal{L}_{\text{CT}}$	0.3797 ± 0.0009	0.1128 ± 0.0007

正如我们现在所示, 该近似是有效的, 因为 $q_t(x)$ 和 $\sum_x q_t(x)r_t(\tilde{x}|x)$ 是非常相似的分布。

$$\begin{aligned}
\sum_x q_t(x)r_t(\tilde{x}|x) &= \sum_x q_t(x)(1 - \delta_{x,\tilde{x}}) \frac{R_t(x, \tilde{x})}{\sum_{x' \neq x} R_t(x, x')} \\
&\propto -q_t(\tilde{x})R_t(\tilde{x}, \tilde{x}) + \sum_x q_t(x)R_t(x, \tilde{x}) \\
&= q_t(\tilde{x}) \sum_{x' \neq \tilde{x}} R_t(\tilde{x}, x') + \partial_t q_t(\tilde{x}) \\
&\propto q_t(\tilde{x}) + \frac{1}{\sum_{x' \neq x} R_t(\tilde{x}, x')} \partial_t q_t(\tilde{x}) \\
&= q_t(\tilde{x}) + \delta t \partial_t q_t(\tilde{x})
\end{aligned}$$

其中第三行我们使用了 Kolmogorov 前向方程并定义了 $\delta_t = 1/\sum_{x' \neq x} R_t(\tilde{x}, x')$ 。因此, 分布 $\sum_x q_t(x)r_t(\tilde{x}|x)$ 是使用围绕 $q_t(\tilde{x})$ 的一阶泰勒展开来近似的 $q_{t+\delta t}(\tilde{x})$ 。我们注意到 δt 是到时间 t 的下一转换的平均时间。 δt 可以根据我们考虑的实际设置进行计算, 在图像建模任务中它在 $2 \times 10^{-6}T$ 和 $2 \times 10^{-8}T$ 之间变化, 在单声道音乐任务中为 $1 \times 10^{-3}T$ 。

我们进行了消融实验, 比较了单声道音乐数据集上的 $\mathcal{L}_{\text{eCT}}$ 和 $\mathcal{L}_{\text{CT}}$ 训练, 结果如表 3 所示。我们发现, 当使用更高效的 $\mathcal{L}_{\text{eCT}}$ 目标以及提高效率时, 我们获得了性能上的小幅提升。我们假设这是因为当 $\tilde{x}$ 共享时, 目标中的两项之间的负相关性增加, 导致 $\mathcal{L}_{\text{eCT}}$ 目标的方差略有减少。

D 直接去噪模型监督

按照[8], 我们可以将直接的 $p_{0|t}^\theta$ 监督引入优化目标中, 根据经验发现, 这可以提高性能。我们首先通过表达 $\mathcal{L}_{\text{CT}}$ 并明确对 $p_{0|t}^\theta$ 的依赖来将更改置于上下文中。

$$\begin{aligned}
\mathcal{L}_{\text{CT}} &= T \mathbb{E}_{t \sim \mathcal{U}(0, T)} q_t(x)r_t(\tilde{x}|x) \left[\left\{ \sum_{x' \neq x} R_t(x', x) \sum_{x_0} \frac{q_{t|0}(x'|x_0)}{q_{t|0}(x|x_0)} p_{0|t}^\theta(x_0|x) \right\} \right. \\
&\quad \left. - \mathcal{Z}^t(x) \log \left(R_t(x, \tilde{x}) \sum_{x_0} \frac{q_{t|0}(x|x_0)}{q_{t|0}(\tilde{x}|x_0)} p_{0|t}^\theta(x_0|\tilde{x}) \right) \right] + C
\end{aligned}$$

$p_{0|t}^\theta(x_0|x)$ 的信号来自 x_0 的总和, 并按比率 $\frac{q_{t|0}(x|x_0)}{q_{t|0}(\tilde{x}|x_0)}$ 加权。我们还可以通过从损坏的版本 x 预测干净的数据点 x_0 并使用负对数似然损失来提供直接去噪信号。

$$L_{\text{ll}}(\theta) = T \mathbb{E}_{t \sim \mathcal{U}(0, T)} p_{\text{data}}(x_0) q_{t|0}(x|x_0) \left[-\log p_{0|t}^\theta(x_0|x) \right]$$

命题 8. *The true denoising distribution, $q_{0|t}$, minimizes L_{ll}*

Proof.

$$\begin{aligned} & T \mathbb{E}_{t \sim \mathcal{U}(0, T) q_t(x)} \left[\text{KL} \left(q_{0|t}(x_0|x) \parallel p_{0|t}^\theta(x_0|x) \right) \right] \\ &= T \mathbb{E}_{t \sim \mathcal{U}(0, T) p_{\text{data}}(x_0) q_{t|0}(x|x_0)} \left[-\log p_{0|t}^\theta(x_0|x) \right] + C \end{aligned}$$

其中 C 是独立于 θ 的常数。因此，最小化 L_{ll} 相当于最小化 $q_{0|t}$ 和 $p_{0|t}^\theta$ 之间的KL散度，其在 $p_{0|t}^\theta = q_{0|t}$ 时最小化。 $\square$

如果我们获得真实的去噪分布 $p_{0|t}^\theta = q_{0|t}$ ，那么我们将得到真实的反向率 $\hat{R}_t$ 。[8] 发现结合 L_{ll} 和 $\mathcal{L}_{\text{DT}}$ 的目标进行优化效果最好，我们也可以在连续时间内做到这一点

$$\min_{\theta} \mathcal{L}_{\text{CT}}(\theta) + \lambda L_{ll}(\theta)$$

其中 λ 是超参数。在[8]中，发现单独使用 L_{ll} 进行训练导致的性能比将 ELBO 包含在损失中的性能更差。我们提供了一个理论假设来解释为什么会出现这种情况。我们证明，最小化 L_{ll} 相当于最小化离散时间内负 ELBO 的上限，因此通过使用 L_{ll} 进行训练，我们只是最小化负模型对数似然上比直接使用负 ELBO 更宽松的界限。

命题 9. *Minimizing the sum of negative log-likelihoods*

$$\sum_{k=0}^{K-1} \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0)} \left[-\log p_{0|k+1}^\theta(x_0|x_{k+1}) \right]$$

is equivalent to minimizing an upper bound on the negative ELBO.

Proof.

$$\begin{aligned} \mathcal{L}_{\text{DT}}(\theta) &= \mathbb{E}_{p_{\text{data}}(x_0)} \left[\text{KL}(q_{K|0}(x_K|x_0) \parallel p_{\text{ref}}(x_K)) - \mathbb{E}_{q_{1|0}(x_1|x_0)} \left[\log p_{0|1}^\theta(x_0|x_1) \right] \right. \\ &\quad \left. + \sum_{k=1}^{K-1} \mathbb{E}_{q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0) \parallel p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \right] \end{aligned}$$

考虑总和中的一项

$$\begin{aligned} L_k &= \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0)} \left[\text{KL}(q_{k|k+1,0}(x_k|x_{k+1}, x_0) \parallel p_{k|k+1}^\theta(x_k|x_{k+1})) \right] \\ &= \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] \\ &\quad + \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0) q_{k|k+1,0}(x_k|x_{k+1}, x_0)} \left[\log q_{k|k+1,0}(x_k|x_{k+1}, x_0) \right] \end{aligned}$$

现在,

$$\begin{aligned} & \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log p_{k|k+1}^\theta(x_k|x_{k+1}) \right] \\ &= \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log \sum_{\tilde{x}_0} q(x_k|\tilde{x}_0, x_{k+1}) p_{0|k+1}^\theta(\tilde{x}_0|x_{k+1}) \right] \\ &= \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1})} \left[-\log \sum_{\tilde{x}_0} \frac{q_{0|k}(\tilde{x}_0|x_k) q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(\tilde{x}_0|x_{k+1})} p_{0|k+1}^\theta(\tilde{x}_0|x_{k+1}) \right] \\ &\leq \mathbb{E}_{q_{k+1}(x_{k+1}) q_{k|k+1}(x_k|x_{k+1}) q_{0|k}(\tilde{x}_0|x_k)} \left[-\log \frac{q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(\tilde{x}_0|x_{k+1})} p_{0|k+1}^\theta(\tilde{x}_0|x_{k+1}) \right] \\ &= \mathbb{E}_{p_{\text{data}}(x_0) q_{k+1|0}(x_{k+1}|x_0)} \left[-\log p_{0|k+1}^\theta(x_0|x_{k+1}) \right] \\ &\quad + \mathbb{E}_{p_{\text{data}}(x_0) q_{k|0}(x_k|x_0) q_{k+1|k}(x_{k+1}|x_k)} \left[-\log \frac{q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(x_0|x_{k+1})} \right] \end{aligned}$$

所以,

$$\begin{aligned}
\mathcal{L}_{\text{DT}} \leq & \sum_{k=0}^{K-1} \left\{ \mathbb{E}_{p_{\text{data}}(x_0)q_{k+1|0}(x_{k+1}|x_0)} \left[-\log p_{0|k+1}^\theta(x_0|x_{k+1}) \right] \right\} \\
& + \mathbb{E}_{p_{\text{data}}(x_0)} [\text{KL}(q_{K|0}(x_K|x_0) || p_K(x_K))] \\
& + \sum_{k=1}^{K-1} \left\{ \mathbb{E}_{p_{\text{data}}(x_0)q_{k+1|0}(x_{k+1}|x_0)q_{k|k+1,0}(x_k|x_{k+1},x_0)} [\log q_{k|k+1,0}(x_k|x_{k+1},x_0)] \right. \\
& \left. + \mathbb{E}_{p_{\text{data}}(x_0)q_{k|0}(x_k|x_0)q_{k+1|k}(x_{k+1}|x_k)} \left[-\log \frac{q_{k|k+1}(x_k|x_{k+1})}{q_{0|k+1}(x_0|x_{k+1})} \right] \right\}
\end{aligned}$$

我们可以看到只有第一项依赖于 θ 。

□

E 前向过程的选择

我们需要选择 R_t 的结构, 以便我们可以通过分析获得 $q_{t|0}$ 边际, 从而实现有效的训练。

命题 10. *If R_t and $R_{t'}$ commute for all t, t' then $q_{t|0}(x = j|x_0 = i) = (\exp[\int_0^t R_s ds])_{ij}$ where exp here is understood to be the matrix exponential function.*

Proof. 让 $(P_t)_{ij} = q_{t|0}(x = j|x_0 = i)$ 。我们证明 $P_t = \exp\left(\int_0^t R_s ds\right)$ 是 Kolmogorov 前向方程的解, 其矩阵形式为 $\partial_t P_t = P_t R_t$ 。将矩阵指数写成求和形式

$$\begin{aligned}
P_t &= \sum_{k=0}^{\infty} \frac{1}{k!} \left(\int_0^t R_s ds \right)^k \\
&= \text{Id} + \int_0^t R_s ds + \frac{1}{2!} \left(\int_0^t R_s ds \right)^2 + \frac{1}{3!} \left(\int_0^t R_s ds \right)^3 + \dots
\end{aligned}$$

现在, 区分并利用 R_t 、 $R_{t'}$ 通勤这一事实。

$$\begin{aligned}
\partial_t P_t &= R_t + \int_0^t R_s ds R_t + \frac{1}{2!} \left(\int_0^t R_s ds \right)^2 R_t + \dots \\
&= \left\{ \sum_{k=0}^{\infty} \frac{1}{k!} \left(\int_0^t R_s ds \right)^k \right\} R_t \\
&= P_t R_t
\end{aligned}$$

□

正如正文中所述, 我们通过选择 $R_t = \beta(t)R_b$ 来实现交换律, 其中 $\beta(t)$ 是时间相关标量, R_b 是常数基矩阵。我们可以利用特征分解

$R_b = Q\Lambda Q^{-1}$ 来有效计算 P_t ,

$$\begin{aligned}
P_t &= \exp \left(\int_0^t \beta(s) R_b ds \right) \\
&= \sum_{k=0}^{\infty} \frac{1}{k!} \left(\int_0^t \beta(s) R_b ds \right)^k \\
&= \sum_{k=0}^{\infty} \frac{1}{k!} \left(Q\Lambda Q^{-1} \int_0^t \beta(s) ds \right)^k \\
&= \sum_{k=0}^{\infty} \frac{1}{k!} Q \left(\Lambda \int_0^t \beta(s) ds \right)^k Q^{-1} \\
&= Q \left\{ \sum_{k=0}^{\infty} \frac{1}{k!} \left(\Lambda \int_0^t \beta(s) ds \right)^k \right\} Q^{-1} \\
&= Q \exp \left[\Lambda \int_0^t \beta(s) ds \right] Q^{-1}
\end{aligned}$$

由于 Λ 是对角矩阵, 因此矩阵指数与元素指数一致, 使得最终表达式易于计算。我们选择 $\beta(t) = ab^t \log b$, 因为这使得指示 $q_{t|0}$ 方差的积分具有简单的形式 $\int_0^t \beta(s) ds = ab^t - a_0$ 。

对于分类问题, 我们发现统一的速率矩阵效果很好, $R_t = \beta 11^T - \beta S \text{Id}$ 。这直接类似于离散时间均匀转移矩阵: $P = \alpha 11^T + (1 - S\alpha) \text{Id}$ 和 α , 具体取决于所使用的时间离散化。事实上, 如果通过矩阵指数计算均匀 R_t 速率对应的离散转移矩阵, 就可以得到均匀转移矩阵。另一个绝对的腐败过程是吸收性的国家过程。在离散时间中, 转移矩阵由 $P = \alpha 1e_*^T + (1 - \alpha) \text{Id}$ 给出, 其中 e_* 是吸收状态的 one-hot 编码。相应的吸收态连续时间过程有转移率矩阵: $R_t = \beta 1e_*^T - \beta \text{Id}$ 。更复杂的转换矩阵的对应关系, 例如[8] 中的离散高斯矩阵更难通过分析找到, 特别是考虑到时间非齐次情况。对于具有序数结构的数据集, 我们构建了一个新的速率矩阵, 该矩阵使用与[8]构建离散高斯矩阵类似的方法来保持对附近状态的偏差。

我们通过首先选择所需的平稳分布 p_{ref} , 然后填充矩阵条目来构建此矩阵, 以便我们鼓励过渡到附近的状态, 同时保持 p_{ref} 作为我们的平稳分布。具体来说, 我们让 p_{ref} 是状态空间上的离散高斯分布, 即

$$p_{\text{ref}}(x) \propto \exp \left[-\frac{(x - \mu_0)^2}{2\sigma_0^2} \right]$$

要找到这种情况下的速率条件, 请回忆一下边际的柯尔莫哥洛夫微分方程

$$\partial_t q_t(x) = \sum_{\tilde{x}} q_t(\tilde{x}) R_b(\tilde{x}, x)$$

现在, 考虑与 p_{ref} 详细平衡的汇率

$$p_{\text{ref}}(\tilde{x}) R_b(\tilde{x}, x) = p_{\text{ref}}(x) R_b(x, \tilde{x})$$

将此速率代入柯尔莫哥洛夫方程, 我们看到 p_{ref} 是平稳分布

$$\begin{aligned}
\partial_t p_{\text{ref}}(x) &= \sum_{\tilde{x}} p_{\text{ref}}(\tilde{x}) R_b(\tilde{x}, x) \\
&= \sum_{\tilde{x}} p_{\text{ref}}(x) R_b(x, \tilde{x}) \\
&= p_{\text{ref}}(x) \sum_{\tilde{x}} R_b(x, \tilde{x}) \\
&= 0
\end{aligned}$$

其中最后一行是根据速率矩阵的行和为零这一事实得出的。请注意，任何 $R_t = \beta(t)R_b$ 也将具有这种平稳分布，因为乘以 $\beta(t)$ 可以被视为只是时间轴的缩放。从详细的平衡方程中，我们获得了 R_b 的条件，使得我们期望的 p_{ref} 是平稳分布

$$\frac{R_b(\tilde{x}, x)}{R_b(x, \tilde{x})} = \frac{p_{\text{ref}}(x)}{p_{\text{ref}}(\tilde{x})} = \exp \left[\frac{(\tilde{x} - \mu_0)^2}{2\sigma_0^2} - \frac{(x - \mu_0)^2}{2\sigma_0^2} \right]$$

这给出了对 R_b 内对角线元素的约束，但没有完全定义整个矩阵。为此，我们首先假设 μ 被选为状态空间的中心。然后，我们将速率矩阵上半部分对角线右侧的对角项和下半部分对角线左侧的对角项设置为 1。最后，从速率矩阵的顶部和底部开始，我们对尚未由详细平衡条件定义的速率矩阵值进行定义。为了清楚起见，我们在下面提供了该方案针对 8×8 速率矩阵的图示

$$\begin{bmatrix} \cdot & 1 & \square & \square & \square & \square & \square & \square \\ \triangle & \cdot & 1 & \square & \square & \square & \square & \triangle \\ \triangle & \triangle & \cdot & 1 & \square & \square & \triangle & \triangle \\ \triangle & \triangle & \triangle & \cdot & 1 & \triangle & \triangle & \triangle \\ \triangle & \triangle & \triangle & \triangle & \cdot & \triangle & \triangle & \triangle \\ \triangle & \triangle & \triangle & \square & 1 & \cdot & \triangle & \triangle \\ \triangle & \triangle & \square & \square & \square & 1 & \cdot & \triangle \\ \triangle & \square & \square & \square & \square & \square & 1 & \cdot \end{bmatrix}$$

其中 $\square$ 表示我们将定义的值， $\triangle$ 表示通过详细平衡条件相对于另一个条目定义的值，而 $\cdot$ 是一个对角线条目，等于负的非对角线行总和。我们可以将 $\square$ 值定义为 0 以获得稀疏速率矩阵，但是，我们在早期实验中发现，允许转换到更远的状态大大减少了混合时间并提供了更好的性能。我们以类似的方式在每一行中定义 $\square$ ，将其设置为等于 $\exp[-i^2/\sigma_r^2]$ ，其中 i 是距该行中“1”值的距离，而 σ_r 是定义典型转换状态空间中的长度尺度的超参数。这使我们的前向过程产生偏差，以 σ_r 的长度在附近状态之间进行转换。

F CTMC 模拟

F.1 精确 CTMC 和 Tau 跳跃

在本节中，我们首先描述精确的 CTMC 模拟，然后再给出 tau 跳跃的算法描述。

当 CTMC 具有时间同质速率矩阵时，我们可以使用 Gillespie 算法 [21,22,23] 来精确模拟它。该算法基于 CTMC 的跳跃链/保持时间定义。它重复以下两个步骤：

- Draw a holding time from an exponential distribution with mean $-1/R(x, x)$ and wait in the current state x for that amount of time.
- Sample the next state from $r(\tilde{x}|x) = (1 - \delta_{x, \tilde{x}}) \frac{R(x, \tilde{x})}{\sum_{x' \neq x} R(x, x')}$

当我们使用改进的下一个反应方法 [33] 具有时间非均匀速率矩阵时，可以对该算法进行调整。然而，这两种算法仍然单独逐步执行 CTMC 中的每个转换，因此不适合我们的情况，因为每个模拟步骤只会改变一个维度，从而导致生成样本的计算成本非常高。相反，我们使用 tau-leaping 来允许在单个模拟步骤中改变多个维度。我们在算法 1 中详细介绍了该方法。

F.2 预测-校正讨论

在本节中，我们比较应用于连续状态空间和离散状态空间的预测校正器采样方案。

算法 1: 使用 Tau-Leaping 进行生成逆向过程模拟

```

 $t \leftarrow T$ 
 $\mathbf{x}_{1:D}^1 \sim \text{pref}(\mathbf{x}_T^{1:D})$  while  $t > 0$  do 使用去噪网络的一次前向传递计算
   $p_{0|t}^\theta(x_0^d | \mathbf{x}_t^{1:D}), d = 1, \dots, D$  for  $d = 1, \dots, D$  do for  $s = 1, \dots, S \setminus x_t^d$  do
     $\hat{R}_t^{\theta d}(\mathbf{x}_t^{1:D}, s) \leftarrow R_t^d(s, x_t^d) \sum_{x_0^d} p_{0|t}^\theta(x_0^d | \mathbf{x}_t^{1:D}) \frac{q_{t|0}(s | x_0^d)}{q_{t|0}(x_t^d | x_0^d)}$   $P_{ds} \leftarrow \text{Poisson}(\tau \hat{R}_t^{\theta d}(\mathbf{x}_t^{1:D}, s))$ 
  end end for  $d = 1, \dots, D$  do if data is categorical AND  $\sum_{s=1}^S P_{ds} > 1$  then  $x_{t-\tau}^d \leftarrow x_t^d //$ 
  拒绝更改 else end end  $\mathbf{x}_{t-\tau}^{1:D} \leftarrow \text{Clamp}(\mathbf{x}_{t-\tau}^{1:D}, \min =$ 
  1,  $\max = S)$   $t \leftarrow t - \tau$   $\mathbf{x}_t^d \leftarrow \mathbf{x}_{t-\tau}^d + \sum_{s=1}^S P_{ds} \times (s - x_t^d)$ 

```

连续状态空间中的预测校正方案在[4]中介绍。它包括预测器步骤和校正器步骤之间的交替：

$$\begin{aligned} \text{Predictor} \quad \mathbf{x}_i &\leftarrow \mathbf{x}_{i+1} + \gamma_i s_\theta(\mathbf{x}_{i+1}, i+1) + \sqrt{\gamma_i} z, \quad z \sim \mathcal{N}(0, I) \\ \text{Corrector} \quad \mathbf{x}_i &\leftarrow \mathbf{x}_i + \epsilon_i s_\theta(\mathbf{x}_i, i) + \sqrt{2\epsilon_i} z, \quad z \sim \mathcal{N}(0, I) \end{aligned}$$

其中 $\mathbf{x}_i$ 是采样步骤 i 的状态， s_θ 是近似于 $\nabla_{\mathbf{x}} \log q_t(\mathbf{x})$ 和 γ_i 的学习得分模型， ϵ_i 分别是预测器和校正器的步长。我们看到两者都采用相似的形式，只是校正器在更新步骤中添加了 $\sqrt{2}$ 倍的高斯噪声。

在离散状态空间中，我们不像连续状态空间情况那样使用梯度引导随机步骤进行采样，而是通过以定义的速率模拟 CTMC 进行采样。当我们采取预测步骤时，我们使用 $\hat{R}_t^\theta$ 进行模拟，当我们采取校正步骤时，我们使用 $R_t^{c\theta} = \hat{R}_t^\theta + R_t$ 进行模拟。如果我们精确地模拟 CTMC，我们在上一节中已经看到，这相当于从通过标准化对应于当前状态的速率矩阵的行定义的分类分布中采样下一个状态。因此，与通过 $\hat{R}_t^\theta$ 定义的预测器分类分布相比，校正器采样可以视为从通过 $R_t^{c\theta}$ 定义的噪声稍大的分类分布中进行采样。这类似于在连续状态空间中的校正器步骤期间应用的增加的高斯噪声。

添加校正器步骤使样本的边缘更接近 $q_t(\mathbf{x})$ ，并且校正器的继续应用将进一步探索 $q_t(\mathbf{x})$ 的域。在之前关于连续状态预测器-校正器方法的工作中，校正器步骤的数量很小（例如每个预测器步骤 1 或 2 个校正器步骤），或者实际上校正器步骤已被完全删除。在这项工作中，我们发现，在反向生成过程的某些区域，每个预测步骤使用最多 10 个校正步骤可能是有益的。此外，在连续状态空间中，据观察，太多的校正步骤可能会导致生成的数据中出现不需要的噪声[34]。

我们假设校正器步骤在离散状态空间中比在连续状态空间中更好地利用来探索 $q_t(\mathbf{x})$ 的域。这是因为，校正器更新主要是通过反向速率本身 $\hat{R}_t^\theta$ 来定义的，只是通过添加前向速率 R_t 将分类概率稍微退火到均匀。这可能是比在连续状态空间情况下简单添加额外高斯噪声更有效的更新。此外，连续状态空间中的去噪模型可以看作是输出维度 D 的 $\mathbf{x}_0$ 的点估计。然而，




图 7: 通过重复应用校正器步骤, 将 $\mathbf{x}_t$ 进展为 $t = 0.4$ 。在每对行中, 顶行是 $\mathbf{x}_t$, 底行是每个维度) 中分类概率的 $p_{0|t}^\theta(\mathbf{x}_0|\mathbf{x}_t)$ (argmax 做出的 $\mathbf{x}_0$ 预测。每列代表额外的 100 个校正器步骤。

在离散状态空间中, 去噪模型在每个维度 (输出维度 $D \times S$) 上输出分类分布, 使其能够在 $\mathbf{x}_0$ 预测中表达一些不确定性信息, 尽管维度之间存在条件独立性。在离散状态空间添加校正器步骤将允许信息在当前时间步骤的维度之间混合, 从而探索 $q_t(\mathbf{x})$ 的模式。

我们在图 7 中的图像建模任务中探索了这个想法。我们运行反向生成过程直到时间 $t = 0.4$, 此时我们保持时间常数并应用 1000 个校正器步骤。我们看到, $\mathbf{x}_t$ 状态的进展探索了图像空间局部区域中 $q_t(\mathbf{x})$ 的潜在局部模式。

G 离散时间的隐式维度假设

在离散时间中, 参数逆核 $p_{k|k+1}^\theta$ 通常通过去噪模型 $p_{0|k+1}^\theta$ 定义。在这里, 我们在前向过程因式分解的多维情况下检查这个定义, 如附录 C.3 和之前的离散时间工作 [8]。我们首先根据真实的去噪分布 $q_{0|k+1}$ 编写真实的全维反向内核 $q_{k|k+1}$ 。

$$\begin{aligned}
 q_{k|k+1}(\mathbf{x}_k^{1:D}|\mathbf{x}_{k+1}^{1:D}) &= \prod_{d=1}^D q_{k|k+1}(x_k^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D}) \\
 &= \prod_{d=1}^D \sum_{\mathbf{x}_0^d} q_{k,0|k+1}(x_k^d, x_0^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D}) \\
 &= \prod_{d=1}^D \sum_{\mathbf{x}_0^d} q_{0|k+1}(x_0^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D}) q_{k|0,k+1}(x_k^d|x_0^d, \mathbf{x}_{k+1}^d)
 \end{aligned}$$

在最后一行中, 我们利用了前向过程在各个维度上是独立的这一事实。为了创建我们的近似反向内核 $p_{k|k+1}^\theta$, 我们将 $q_{0|k+1}(x_0^d|\mathbf{x}_k^{1:d-1}, \mathbf{x}_{k+1}^{1:D})$ 近似为

$$p_{0|k+1}^\theta(x_0^d | \mathbf{x}_{k+1}^{1:D}),$$

$$p_{k|k+1}^\theta(\mathbf{x}_k^{1:D} | \mathbf{x}_{k+1}^{1:D}) = \prod_{d=1}^D \sum_{x_0^d} p_{0|k+1}^\theta(x_0^d | \mathbf{x}_{k+1}^{1:D}) q_{k|0,k+1}(x_k^d | x_0^d, x_{k+1}^d)$$

我们抛弃了额外的 $\mathbf{x}_k^{1:d-1}$ 条件，因为我们使用了非自回归模型，该模型接受 $\mathbf{x}_{k+1}^{1:D}$ 并在单个前向传递中给出了 x_0^d 、 $d = 1, \dots, D$ 上的条件独立概率。对于有限的 K ，这种近似永远无法匹配真实的内核，因为我们没有以所有相关信息为条件。当然，随着 K 变大，这种近似变得更加准确。由于我们在连续状态下操作，因此我们不必进行这种近似，因为当我们对前向过程进行因式分解时，条件独立的去噪模型 $q_{0|t}(x_0^d | \mathbf{x}^{1:D})$ 直接出现在我们的反向率 $\hat{R}_t^{1:D}$ 中（参见命题 3）。

H 实验细节

在本节中，我们提供了将我们的方法应用于实际问题的实验的更多细节。我们模型的代码可在 <https://github.com/andrew-cr/tauLDR> 获取。在描述每个实验的具体细节之前，我们首先解释所有实验共有的实现细节。

当我们评估每个小批量训练数据点的目标 $\mathcal{L}_{CT}$ 时，我们必须从 $t \sim \mathcal{U}(0, T)$ 中对每个数据点采样一个时间，它代表我们将对其进行噪声处理的前向过程中的点。如果 t 采样非常接近 0，则可以发现训练不稳定，因为反向速率 $\hat{R}_t$ 在该区域变得病态。在连续状态空间模型中也观察到这种现象，因为分数 $\nabla_x \log q_t(x)$ 在接近 $t = 0$ 时变得病态。反向速率和分数在接近正向过程开始时变得病态，因为边际概率 $q_t(x)$ 将在数据流形周围达到高度峰值，而 $\log q_t(x)$ 将在不靠近数据的区域中爆炸。为了避免这些问题，一个常见的技巧是设置一个最小时间，例如 $t \sim \mathcal{U}(\epsilon, T)$ 。 ϵ 被设置为使得 $t = \epsilon$ 处的噪声水平非常小，并且到此点的反向采样将产生非常接近 p_{data} 的样本。在我们的实验中，我们设置 $\epsilon = 0.01T$ 。

在反向采样过程中，我们使用 tau-leaping 来模拟从 $t = T$ 到 $t = \epsilon$ 的反向过程，因为反向速率没有针对 $t < \epsilon$ 进行训练。这会产生接近 p_{data} 的样本。我们发现，如果我们完成最后一步以消除样品中可能仍然存在的少量噪音，FID 等指标的性能会得到改善。具体来说，我们将样本通过带有 $t = \epsilon$ 的去噪模型 $p_{0|t}^\theta(x_0 | x_t)$ ，以获得形状为 $D \times S$ 的输出，其中 D 是问题的维度。这是每个维度的状态概率分布。我们将每个维度的值设置为概率最高的状态。然后生成一个已消除所有噪声的样本。

我们模型中 T 的具体值是任意的，因为前向过程可以在时间轴上缩放，以为任何 T 提供相同的噪声过程。因此，我们只需将 T 设置为 1 即可。

H.1 示范例子

我们的 2d 数据集是通过从 32×32 状态空间采样 1M 2d 点来创建的，其概率与 τ 字符的 32×32 灰度图像的像素值成正比。

对于我们的前向过程，我们使用具有平稳分布标准偏差 $\sigma_0 = 8$ 和速率长度尺度 $\sigma_r = 1$ 的高斯速率（参见附录 E）。我们使用 $\beta(t) = 5 \times 5^t \log(5)$ 的速率表。

为了表示 $p_{0|t}^\theta$ ，我们使用残差 MLP。该架构由一个输入线性层组成，用于将输入维度 2 提升到内部网络维度 16。然后，有 2 个残差块，每个残差块由：隐藏维度为 32 的单个隐藏层 MLP、到

MLP 的输入，层范数，最后是由时间嵌入调制的 FiLM 层 [35]。在输出处，有一个输出大小为 $2 \times 32 = 64$ 的单个线性层，表示每个 2 维中的状态概率。使用 Transformer 正弦位置嵌入 [36] 嵌入时间，创建大小为 32 的嵌入。然后，嵌入由隐藏层大小为 32 和输出大小为 128 的单个隐藏层 MLP 进一步处理。为了在每个残差块中创建 FiLM 参数，时间嵌入通过输出大小为 32 的线性层，以提供对状态维度 16 的乘法和加法调制。我们最小化 $\mathcal{L}_{\text{CT}}$ 目标使用 Adam，学习率为 0.0001，批量大小为 32，步长为 1M。

为了进行精确模拟，我们使用下一个反应方法，并对时间相关的转变速率进行修改[33]。该方法通过计算每种转换类型下一次发生的时间并应用最快发生的转换，单独逐步执行精确模拟路径中的每个转换。确切的算法细节可以在[33]中找到。为了计算下一次转换发生的时间，我们需要对反向速率矩阵进行积分（[33]中的等式（13））。我们通过步长为 0.001 的欧拉积分来实现这一点。

H.2 图像建模

我们在包含 50000 张维度为 $3 \times 32 \times 32$ 的图像的 CIFAR10 训练数据集上进行训练。我们在包含 10000 张图像的 CIFAR10 测试数据集上评估测试 ELBO。对于前向噪声过程，我们使用高斯速率（参见附录 E），其平稳分布标准差为 $\sigma_0 = 512$ ，速率长度尺度 $\sigma_r = 6$ 。这有效地定义了均匀的平稳分布，因为状态空间的大小为 256。我们发现这比更集中的高斯表现更好。我们的 β 时间表是 $\beta(t) = 3 \times 100^t \log 100$ 。这是根据 σ_r 选择的，以便 $q_{t|0}$ 方差的总体进展形状与 [3] 中提出的时间表大致匹配。

我们的 $p_{0|t}^\theta$ 模型使用 [3] 中引入的标准 U-net [37] 架构进行参数化。该网络遵循带有组归一化层的 PixelCNN++ 主干网 [38]。下采样/上采样堆栈中有四种特征图分辨率（ 32×32 到 4×4 ）。在每个分辨率下都有两个卷积残差块。在 16×16 分辨率级别 [39] 的残差块之间有一个自注意力块。首先通过 Transformer 正弦位置嵌入将时间输入到网络中[36]。这次，嵌入通过 SiLU 激活 [40] 传递到每个残差块中，然后通过线性层，然后将其添加到两个卷积操作之间的残差块内的隐藏状态上。

[3] 的原始架构具有维度 $3 \times 32 \times 32$ 的输出，因为它在给定 x_t 的情况下对 x_0 进行点预测。为了使模型输出超过 x_0 （的概率，即输出维度为 $3 \times 32 \times 32 \times 256$ ）我们进行[8]中建议的调整。具体来说，我们使用截断的逻辑分布参数化，其中模型输出逻辑分布的均值和对数尺度，即输出维度为 $3 \times 32 \times 32 \times 2$ 。状态的概率是映射到实数线上时该状态与下一个状态之间的连续分布的积分。为了对输出施加残余归纳偏差，逻辑分布的平均值被取为 $\tanh(x_t + \mu')$ ，其中 x_t 是模型的归一化输入， μ' 是从网络输出的平均值。标准化操作采用 $0, \dots, 255$ 范围内的输入并将其映射到 $[-1, 1]$ 。我们的网络总共有大约 35.700 万个参数。

我们使用附录 D 中描述的辅助目标（ $\lambda = 0.001$ ）进行优化。在辅助目标中，我们使用连续时间 ELBO 的单前向传递版本， $\mathcal{L}_{\text{CT}}$ 。我们使用 Adam 优化 2M 步骤，学习率为 0.0002，批量大小为 128。我们使用标准的训练技巧集来改进优化 [3, 4]。在整个训练过程中，我们保持参数的指数移动平均值，衰减因子为 0.9999。这些平均参数在测试期间使用。在优化开始时，我们对前 5000 个步骤使用线性学习率预热。我们将梯度范数剪裁为范数值 1.0。我们将网络的 dropout 率设置为 0.1。每个残差块的跳过连接按因子重新缩放 $\frac{1}{\sqrt{2}}$ 。输入图像在训练期间应用了随机水平翻转。

对于表 1 中的采样，我们为 τ LDR-0 设置 $\tau = 0.001$ ，为 τ LDR-10 设置 $\tau = 0.002$ 。 τ LDR-10 的每个预测器步骤有 10 个校正器步骤在 $t < 0.1T$ 之后引入。我们发现，在反向采样过程接近结束时引入校正器步骤可以最大程度地提高样本质量，同时计算成本的增加最小。当使用校正率 R_t^c 执行 tau 跳跃时，我们可以控制我们使用的 τ ，因为我们正在对原始反向 CTMC 采样不同的 CTMC（以 q_t 作为其平稳分布）。我们发现，在本例中，将反向 CTMC 的校正器速率 τ 设置为原始 τ 的 1.5 倍可实现最佳性能。

我们在学术研究集群上使用 4 个 V100 GPU 进行训练。为了计算 Inception 和 FID 值，我们使用 pytorch-fid [41] 和进一步的开发¹。我们通过 DDPM [3] 方法计算已发布图像的 Inception 和 FID 分数，验证了该库产生的值与之前的工作相当。

我们在图 8 中展示了来自 τ LDR-10 模型的大量无条件样本。我们现在还提供了使用 $\tau = 0.001$ 进行标准 tau 跳跃的反向采样过程的统计数据。图 9 显示了单步 tau 跳跃过程中转变的维度比例。我们看到，在初始阶段，每个 tau 跳跃步骤中每个维度都会发生变化，但在接近过程结束时，更多的维度将定居在其最终位置，并且比例会变小。在图 10 中，我们显示了由于提出越界跳跃而被剪裁的维度比例。总体而言，所占比例较小。当我们最初从近似均匀的 p_{ref} 进行采样时，它在过程开始时最大，并且会有接近边界的维度。当像素值稳定到最终值时，该比例会减小。图 11 显示了反向采样过程中维度选择的进展。类似的情况出现了，维度最终定居在状态空间的一个区域中。我们还注意到，较大的跳跃是在接近反向过程开始时的单个 tau 跳跃步骤中进行的，而较小的跳跃是在接近结束时进行的。

H.3 单音音乐

我们从 Lakh 钢琴卷轴数据集 [29, 30] 生成训练数据集（许可证 CC By 4.0）。该数据集包含 174,154 个多轨钢琴卷轴。我们遍历所有歌曲和每首歌曲中的所有曲目，并选择符合以下条件的序列：它们是单音的（一次仅演奏一个音符），没有一个长于一个小节的时间段没有演奏任何音符，序列中演奏的音符类型不只一种，最后在总共 256 个时间步长中，没有一个音符演奏的时间步数超过 50 个时间步长。这会删除数据集中存在的无趣且琐碎的序列。然后我们删除结果中的所有重复项。这给我们留下了 6000 个训练示例和 950 个测试示例。每首歌曲由 256 个时间步长（每小节 16 个）组成，每个时间步长从 129 个值中选取一个，即我们有 $D = 256$ 和 $S = 129$ 。此状态值表示 128 个选项中的一个音符或休止符。当映射到 0 到 128 的整数时，我们会打乱该状态空间的顺序。当我们输入到去噪网络时，我们输入的是 one-hot 129 维向量。

对于前向噪声过程，我们使用统一速率矩阵 $R_b = 11^T - S\text{Id}$ 并设置 $\beta(t) = 0.03$ 。我们发现时间常数 $\beta(t)$ 对于该数据集来说就足够了。在我们的比较中，我们使用定义的出生/死亡率矩阵

$$\begin{bmatrix} -\lambda & \lambda & 0 & 0 & \dots & 0 & 0 \\ \lambda & -2\lambda & \lambda & 0 & \dots & 0 & 0 \\ 0 & \lambda & -2\lambda & \lambda & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & \lambda & -\lambda \end{bmatrix}$$

这是出生/死亡过程的速率矩阵。我们设置 $\lambda = 1$ 和 $\beta(t) = \frac{1}{2} \times 10000^t \log 10000$ 。选择这些超参数是为了使前向过程具有稳定的噪声率，同时仍然使 q_T 非常接近 p_{ref} 。我们选择比较这些类型的比率矩阵，因为出生/死亡率不适合此分类数据，因为相邻状态没有意义

¹<https://github.com/w86763777/pytorch-gan-metrics>




图 8: 来自我们的 τ LDR-10 模型的无条件 CIFAR10 样本。




图 9: 在反向采样过程中, 单步 τ 跳跃过程中发生转变的维度比例。




图 10: 由于在反向采样过程中提出越界跳跃, 在 tau 跳跃步骤中被剪裁的维度比例。




图 11: 反向采样过程中维度选择的进展。

因为到整数的映射是任意的。统一速率适用于此类分类数据, 因为在一个时间间隔内, 它具有统一的概率转换到任何其他状态。D3PM 基线还使用时间同质均匀前向内核集来实现, 以便噪声率在离散和连续时间情况下匹配。

我们使用受[31]启发的变压器架构定义条件去噪网络 $p_{0|t}^\theta(x_0|x, y)$ 。它采用形状 (B, D, S) 的输入, 其中 B 是批量大小, D 是维度 (256), S 是状态大小 (129)。这一最终维度包含独热向量。对初始条的调节是通过将调节信息 y 与噪声输入 x 连接来实现的。在网络的开始处, 有一个输入嵌入线性层, 其输出大小为 128, 这是我们变压器的模型尺寸。然后将变压器位置嵌入添加到隐藏状态。接下来应用 6 个 Transformer 编码器层的堆栈, 其中包含一个自注意力块和一个隐藏层 MLP。自注意力块使用 8 个头, MLP 的隐藏层大小为 2048。在每个内部块的输出处, 我们应用速率为 0.1 的 dropout。最后, 有 2 个剩余 MLP 层的堆栈。每个由一个隐藏层 MLP 组成, 隐藏维度为 2048。MLP 的输入和输出之间存在残差连接。层范数应用于块的输出。为了创建网络的输出, 有一个输出形状为 (B, D, S) 的输出线性层, 其中现在 S 维度具有 logit 概率。为了向网络注入残余偏差, 我们将 one-hot 输入添加到输出 logits 中。所有激活都是 ReLU。时间通过 FiLM 层输入到网络中 [35]。首先, 使用正弦变换器位置嵌入来嵌入时间, 就像用于图像建模的 U-net 架构中一样, 以创建 128 的嵌入大小。然后将其传递到具有隐藏大小的单个隐藏层 MLP




图 12: 反向采样期间拒绝的跳跃比例。拒绝率计算为 τ 跳跃步骤中跳跃被拒绝的维度比例。结果取 16 个批次的平均值。

2048 和输出大小 512。在每个编码器和残差 MLP 块内，有一个 FiLM 线性层，它接受 512 次嵌入并输出两个 FiLM 参数，每个参数的大小为 128。这些是应用于隐藏状态的比例和偏移。在编码器块中，该 FiLM 变换在自注意力块之后应用，并在全连接块之后再次应用。在残差 MLP 块中，它在层范数操作之后应用。我们的网络总共有大约 700 万个参数。

我们使用 Adam 优化 1M 步，批量大小为 64，学习率为 0.0002。我们使用条件 $\bar{\mathcal{L}}_{CT}$ 目标和额外的直接 $p_{0|t}^o$ 监督，如附录 D 中所述，权重为 $\lambda = 0.001$ 。我们还进行了与附录 C.4 中解释的相同的一次前向传递近似。我们使用标准的训练技巧集来改进优化 [3, 4]。在整个训练过程中，我们保持参数的指数移动平均值，衰减因子为 0.9999。这些平均参数在测试期间使用。在优化开始时，我们对前 5000 个步骤使用线性学习率预热。我们将梯度范数剪裁为范数值 1.0。我们在学术集群上的单个 V100 GPU 上进行训练。

对于使用 τ LDR-0 进行采样，我们使用 $\tau = 0.001$ ；对于使用 τ LDR-2 进行采样，我们在 $t < 0.9T$ 之后为每个预测器步骤包含 2 个校正器步骤。校正率是用 $\tau = 0.0001$ 模拟的，我们发现它的性能最佳。我们拒绝提出 2 个或更多跳跃的任何维度，因为这是分类数据。我们在图 12 中绘制了拒绝率。大多数时候，拒绝率为零，并且在少数步骤中拒绝率略有增加。我们在图 13 中展示了测试数据集中前 10 首歌曲的大量样本。我们看到采样的完成之间存在差异，并且它们始终遵循歌曲的前两个小节的调节风格。该模型的音频样本可在 <https://github.com/andrew-cr/tauLDR> 上获取。最后，我们检查在统一和出生/死亡率矩阵情况的逆向抽样过程中随机选择维度的进展。图 14 显示了统一情况的进展，我们看到在整个相反过程中，状态空间发生了大的跳跃。图 15 显示了出生/死亡案件的进展情况。在反向采样开始时，没有维度移动，因为在这种情况下拒绝率很高，因为比率矩阵不适合分类数据。接近尾声时，相邻状态之间会发生小跳跃，但由于此速率矩阵不会发生任何类别之间的大跳跃，因此总体性能会更差。

I 道德考虑

我们的工作增加了我们对去噪生成模型的理论理解，并提高了一些离散数据集的生成能力。深度生成模型是通用方法




图 13: 测试数据集中前 10 首歌曲中每首歌曲的 τ LDR-0 模型的两个条件样本。




图 14：统一速率矩阵的反向采样过程中维度选择的进展。




图 15：出生/死亡率矩阵反向采样过程中维度选择的进展。

用于从非结构化数据中学习，滥用时可能会产生负面社会影响。例如，它们可以通过减少创建真实虚假内容所需的资源来传播错误信息。此外，生成模型将生成准确反映训练数据集统计数据的样本。因此，如果将这些模型中的样本解释为客观事实，而没有充分考虑原始数据中存在的偏见，那么它们可能会延续对少数群体的歧视。

在这项工作中，我们对包含不太敏感数据的数据集进行训练，例如物体图片和音乐样本。然而，我们提出的方法可用于对来自互联网的人物图像或文本进行建模，这些图像或文本将包含偏见和潜在有害的内容，然后模型将从中学习和重现。在现实世界数据集上训练这些模型以及部署它们时必须非常小心，以减轻和防止它们可能造成的危害。