

梦想 7B：扩散大型语言模型

叶家成¹*谢志辉¹*郑林¹*高家辉²*吴自瑞¹蒋欣²李振国²孔令鹏¹ ¹香港大学²华为诺亚方舟实验室DreamLM/Dream Dream-7B



2025 年 4 月 2 日

抽象的

我们介绍 Dream 7B，迄今为止最强大的开放扩散大型语言模型。与顺序生成标记的自回归 (AR) 模型不同，Dream 7B 采用离散扩散模型，通过迭代去噪并行细化序列。我们的模型在一般、数学和编码任务上始终优于现有的扩散语言模型。Dream 7B 展示了卓越的规划能力和推理灵活性，包括任意订单生成、填充功能和可调的质量速度权衡。这些结果是通过简单而有效的训练技术实现的，包括基于 AR 的 LLM 初始化和上下文自适应令牌级噪声重新调度。我们发布了 Dream-Base 和 Dream-Instruct，以促进基于扩散的语言建模的进一步研究。




图 1：扩散和自回归语言模型在各种任务上的性能比较。

1 简介

大语言模型 (LLM) 的快速发展从根本上改变了人工智能，推动了不同应用和行业的突破。当前的格局以自回归 (AR) 模型为主，该模型通过顺序从左到右的标记预测生成文本，几乎所有领先的系统都包括 GPT-4 (OpenAI 等人，2024 年) 和 DeepSeek R1 (Guo 等人，2025 年)。虽然这些模型展示了卓越的功能，但出现了一个基本问题：什么样的架构范式可以定义下一代法学硕士？由于 AR 模型在复杂推理、长期规划和跨扩展上下文保持一致性方面表现出固有的局限性，这个问题变得越来越重要 (Bubek 等人，2023; Dziri 等人，2023; Bachmann 和 Nagarajan，2024; Ye 等人，2025a)。这些限制尤其重要

*Equal Contribution

对于嵌入式人工智能、自主代理和长期决策系统等新兴应用来说，对整个序列进行整体推理而不是增量推理的能力变得至关重要。

离散扩散模型（DM）自从被引入文本领域以来，作为一种有前途的序列生成替代方案而受到关注（Austin 等人，2021a；Hoogeboom 等人，2021；Campbell 等人，2022）。扩散模型不是从左到右逐个构建文本标记，而是从完全损坏的序列开始，并通过多个细化步骤逐渐对它们进行去噪，从而实现双向上下文集成和更灵活的生成模式。这种架构转变释放了几个直接解决自回归限制的理论优势。扩散的并行性质可以通过同时合并来自所有位置的信息来实现更丰富的上下文建模，从而可能导致更加连贯和全局一致的输出（Li et al., 2022）。此外，迭代细化过程自然支持可控生成（Gulrajani 和 Hashimoto, 2023b；Li 等人，2022），并通过可调整的推理步骤提供灵活的质量速度权衡，为测试时间扩展的优化提供新的维度（Snell 等人，2024；Muennighoff 等人，2025；Geiping 等人，2025），补充现有技术，例如长期思想链式推理（Jaech et al., 2024；Guo et al., 2025）。

最近的发展已经开始证明缩放扩散语言模型的实际可行性。DiffuLLaMA (Gong et al., 2025)、LLaD A (Nie et al., 2025b) 等工作已成功地将离散扩散扩展到十亿参数范围。而Mercury Coder (Inception Labs, 2025) 作为一种商业实现，在代码生成方面表现出了卓越的推理效率。这种快速的进展，加上扩散语言建模固有的架构优势，使这些模型成为克服自回归方法基本局限性的有希望的方向。然而，在各种一般任务中，与 Qwen2.5 (Qwen 等人，2025) 等最先进的自回归模型实现性能相当方面仍存在显著差距（Clark 等人，2018 年；Hendrycks 等人，2020 年）。

在这项工作中，我们提出了 Dream 7B，这是一个 70 亿参数的扩散语言模型，它弥补了这一性能差距，同时展示了扩散范式固有的独特功能。我们引入了一个综合训练框架，该框架利用基于 AR 的 LLM 初始化和上下文自适应噪声调度来扩展扩散语言模型。通过广泛的评估，我们确定扩散模型可以在一般语言任务上与基于 AR 的 LLM 性能相匹配，同时在规划密集型场景中提供明显的优势，并通过任意顺序生成和动态质量速度优化提供前所未有的推理灵活性。我们发布了 Dream-Base 和 Dream-Instruct，以促进这一有希望的方向的进一步研究。

- 我们发布了 Dream 7B，它在各种基准测试中始终明显优于现有的扩散语言模型。
- Dream 7B 在标准基准测试（通用语言理解、数学推理和代码生成）上实现了与 Qwen 2.5 的竞争性能，同时展示了从扩散建模范式自然产生的卓越规划能力和新颖的推理灵活性功能。

2 相关工作

2.1 文本的扩散模型

扩散模型最初是为图像生成等连续领域开发的（Song 等人，2021；Ho 等人，2020）。在取得巨大成功的基础上，许多作品通过在连续嵌入空间中对文本进行建模、构建连续扩散语言模型，将扩散技术扩展到文本生成任务（Li et al., 2022；Gong et al., 2023b,a；Dieleman et al., 2022）。在这些方法中，Lin 等人。（2023）证明了在小型变压器的预训练和微调框架内应用扩散模型的可行性。

为了适应文本的离散性质，Austin 等人。（2021a）；霍格布姆等人。（2021）；坎贝尔等人。（2022）引入了离散扩散，它在离散词汇空间上运行，建立了

离散扩散方法的基础。在此公式中，扩散向前逐步使用 [MASK] 标记（导致吸收状态）或随机标记（导致统一状态），而反向过程则从这些噪声序列中重建原始文本。在此基础上，一些研究改进了离散扩散的训练目标（Zheng et al., 2024b; Lou et al., 2024; Shi et al., 2024; Ou et al., 2025; Zhao et al., 2024; Sahoo et al., 2024）。此外，何等人。（2023）；叶等人。（2025c）已经展示了通过使用预训练的掩码语言模型（MLM，例如 BERT; Devlin 等人，2019）初始化离散扩散模型的好处。最近的研究强调了扩散语言模型在复杂推理和规划任务中的优势（Ye et al., 2024, 2025a,b）。此外，通过块生成将扩散和自回归方法相结合已成为一种有前途的方法，证明了并行性和顺序一致性之间的灵活权衡（Ye 等人，2024; Arriola 等人，2025）。

2.2 扩散大语言模型

Gulrajani 和 Hashimoto (2023a) 分析了连续扩散语言模型的缩放定律，强调与自回归 (AR) 模型相比，连续扩散模型需要更长的训练时间才能获得最佳计算效率。在离散域中，Lou 等人。（2024）表明，掩蔽扩散模型 (MDM) 可以实现与 GPT-2 级 AR 模型相当或超过的困惑度。受这些结果的鼓舞，最近的努力已将扩散语言模型扩展到数十亿个参数。聂等人。（2025a）证明了 1.1B 规模的 MDM 在问答等语言任务中的适用性。龚等人没有从头开始训练。（2025）提议将现有的 AR 语言模型（GPT-2 和 LLaMA，从 127M 到 7B 参数）调整为基于扩散的对应模型，称为 DiffuGPT 和 DiffuLLaMA。同时，聂等人。（2025b）提出了 LLaDA，这是一种从头开始训练的 8B 参数扩散语言模型，其性能可与 LLaMA3-8B 相媲美 (Grattafiori 等人，2024)。此外，Mercury Coder (Inception Labs, 2025) 最近在代码生成任务中展示了商业适用性和效率。总的来说，我们的工作建立在掩模扩散范式的基础上，并引入了新的训练技术来进一步提高性能，突出了基于扩散的模型作为自回归法学硕士替代方案的潜力。

3 初步

3.1 自回归建模

考虑从数据分布 $q(\mathbf{x})$ 采样的长度为 N 的序列 $\mathbf{x} := (\mathbf{x}^1, \dots, \mathbf{x}^N)$ 。序列建模的基本方法将标记的联合概率分解为条件概率的乘积 (Jelinek, 1980; Bengio 等人，2000)：

$$p_{\theta}(\mathbf{x}) = p_{\theta}(\mathbf{x}^1) \underbrace{\prod_{n=2}^N p_{\theta}(\mathbf{x}^n | \mathbf{x}^{1:n-1})}_{\text{progressive left-context prediction}}, \quad (1)$$

其中 θ 表示模型参数，而 $\mathbf{x}^{1:n-1} := \mathbf{x}^1, \dots, \mathbf{x}^{n-1}$ 表示前面的标记。

3.2 离散扩散建模

离散扩散模型 (Sohl-Dickstein et al., 2015; Hoogeboom et al., 2021; Austin et al., 2021a) 是一类潜变量模型，其特征是前向噪声过程和学习反向去噪过程。令 $\mathbf{x}_t$ 表示时间步 t 处的噪声序列，并采用 [MASK] 噪声。前向过程 $q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$ 逐渐将原始数据 $\mathbf{x}_0 := \mathbf{x}$ 破坏为一系列噪声越来越大的标记（用 [MASK] 标记替换） $\mathbf{x}_{1:T} := \mathbf{x}_1, \dots, \mathbf{x}_T$ 。继续前向过程，直到序列在 $t = T$ 处完全去噪。对于 $t \in (0, T)$ ，序列 $\mathbf{x}_t$ 使用噪声调度 α_t （进行部分噪声处理，其中对于每个标记，保持未屏蔽的概率为 α_t ）。当 t 从 T 移动到 0 时，后向过程通过迭代预测屏蔽标记，学习将屏蔽序列逐渐去噪回到原始数据分布。这个去噪过程可以

建模为：

$$p_{\theta}(\mathbf{x}) = \sum_{\mathbf{x}_{1:T} \sim q} p(\mathbf{x}_T) \underbrace{\prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)}_{\text{progressive full-context prediction}}. \quad (2)$$

可以通过最小化干净数据 $\mathbf{x}_0$ 的负对数似然来优化模型参数 θ 。

离散时间公式 $t \in (0, T)$ 将 $\mathbf{x}_t$ 限制为预定的噪声水平，这可能会引入偏差。为了减轻这一限制并实现跨任意噪声水平的灵活采样，我们采用连续时间参数化，其中 t 的范围连续超过 $[0, 1]$ （Kingma 等人，2021；Campbell 等人，2022；Shi 等人，2024；Ou 等人，2025）。对于任何 $0 \leq s < t \leq 1$ ，这种连续公式允许前向过程表示为 $q(\mathbf{x}_t | \mathbf{x}_s)$ 。我们采用具有吸收态的离散扩散，并将目标简化为加权交叉熵损失：

$$L(\theta) = -\mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}), t \sim \mathcal{U}(0,1), \mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0)} w(t) \sum_{n=1}^N \mathbf{1}_{[\mathbf{x}_t^n = \text{MASK}]} \log p_{\theta}(\mathbf{x}_0^n | \mathbf{x}_t), \quad (3)$$

其中指示函数 $\mathbf{1}_{[\mathbf{x}_t^n = \text{MASK}]}$ 确保仅在屏蔽标记位置上计算损失，而 $w(t) \in (0, 1]$ 是由 α_t 的变换确定的时间相关的重新加权项。例如，当前向过程采用噪声调度 $\alpha_t = 1 - t$ 时，相应的权重变为 $w(t) = \frac{1}{t}$ （Austin et al., 2021a；Cheng 等人，2024b），它更加重视更接近干净数据的去噪步骤（即，如 $t \rightarrow 0$ ）。如 Shi 等人（2024）；Gong 等人（2025）所示，这个加权交叉熵目标方程。（3）代表了 ELBO 的有效重新表述，可以优化掩模预测器 $p_{\theta}(\cdot | \mathbf{x}_t)$ 通过提供负对数似然的易处理的变分上限。

4 方法




图 2：Dream 中自回归建模和扩散建模的比较。Dream 以转移的方式预测所有屏蔽标记，从而允许与 AR 模型进行最大程度的架构对齐和权重初始化。

4.1 基于AR的LLM初始化

在 DiffuLLaMA（Gong 等人，2025）的基础上，我们发现利用现有自回归（AR）模型的预训练权重为扩散语言模型提供了一种重要的初始化策略。在 Dream 中，我们采用了 Gong 等人的“转移操作”策略。（2025）在向基于扩散的训练过渡期间保持 AR 模型固有的移位操作特征。具体来说，训练自回归模型，以便位置 i 处的隐藏表示对预测位置 $i + 1$ 处的标记所需的信息进行编码。我们的方法不是破坏这种学习的位置关系，而是在整个扩散训练过程中保留了这种移位机制。该模型继续利用隐藏状态 h_i 来生成位置 $i + 1$ 的预测，这与尝试在其原始位置预测屏蔽标记的传统扩散模型形成对比。这种设计选择确保扩散学习过程与预训练表示保持一致，防止从自回归到扩散建模的过渡破坏预训练权重中嵌入的基本序列理解。




图 3: 上下文自适应令牌级噪声重新调度机制的图示。Dream 通过测量其上下文信息来重新确定每个掩码标记的噪声级别。

AR 初始化策略通过构建已建立的序列建模功能而不是从头开始学习这些表示来提供计算优势，正如我们在第 5.4 节中的实验结果所证明的那样。此外，这种方法最大化了现有预训练 AR 语言模型的效用。一旦高级 AR LLM 可用，我们的框架就可以快速迭代改进扩散模型，而无需昂贵的从头开始培训，从而有效地利用研究社区在自回归模型开发方面的集体努力。

4.2 上下文自适应令牌级噪声重新调度

文本的标准扩散训练应用统一的句子级时间步长，它忽略了各个标记的不同上下文依赖性。在传统的离散扩散训练中，对单个时间步长 t 进行采样以确定整个序列的总体噪声水平，之后模型对所有屏蔽位置均匀地执行去噪。例如，当采用噪声调度 $\alpha_t = 1 - t$ 时，等式(3)中的加权项 $w(t)$ 变为 $\frac{1}{t}$ 。然而，由于学习发生在令牌级别，因此每个令牌经历的实际噪声可能会偏离全局时间步长 t 。图 3 中显示了一个示例，共享句子级 t 被分配给标准离散扩散模型中的三个掩码标记，而第一个标记本质上应该与比后续标记更低的噪声水平相关联，因为它受益于更丰富的上下文调节。这种差异会导致学习效果不佳，特别是对于具有不同程度上下文信息的标记。

为了解决这个限制，我们从序列级噪声调度转向令牌级噪声调度。我们引入了 CART（令牌级别的上下文自适应噪声重新调度），它单独测量每个令牌的上下文信息，并根据当前上下文动态地重新分配适当的噪声级别。这种方法提供了细粒度的、特定于令牌的指导，可以更好地反映序列中不同位置的不同难度和上下文依赖性。具体来说，CART 的目标表示如下：

$$L(\theta) = -\mathbb{E}_{\mathbf{x}_0 \sim q(\mathbf{x}), t \sim \mathcal{U}(0,1), \mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0)} \sum_{n=1}^N \mathbf{1}_{[\mathbf{x}_t^n = \text{MASK}]} w(t, \mathbf{x}_t, n) \log p_{\theta}(\mathbf{x}_0^n | \mathbf{x}_t), \quad (4)$$

其中 $w(t, \mathbf{x}_t, n)$ 是 $w(t)$ 的泛化项，可以灵活设计。在实践中，我们采用几何分布的混合来量化每个干净标记相对于噪声标记的信息贡献，其定义为：

$$w(t, \mathbf{x}_t, n) = \frac{1}{2} \sum_{i=1}^N \mathbf{1}_{[\mathbf{x}_i^t \neq \text{MASK}]} \text{Geo}(p, |n - i| - 1), \quad (5)$$

其中 $p \in (0, 1]$ 控制几何分布的锐度。较小的 p 会导致干净的令牌倾向于对序列中的所有屏蔽令牌做出均匀的贡献，而较大的 p 会迫使干净的令牌对附近的屏蔽令牌产生更大的影响。

4.3 培训

模型架构 Dream 模型建立在 Transformer 架构之上 (Vaswani et al., 2017)，保持与现有自回归语言模型的完全兼容性，同时实现基于扩散的训练。具体来说，Dream-7B 采用与 Qwen2.5-7B 相同的模型配置 (Qwen et al., 2025)。

预训练 训练目标是对数据分布 $p_{\theta}(\mathbf{x}_0)$ 进行建模。我们通过随机梯度下降训练的蒙特卡罗方法估计方程 (3)。我们的训练语料库包含 5800 亿个令牌，涵盖文本、数学和代码领域。数据来源于三个主要存储库：用于通用领域文本的 Dolma v1.7 (Soldaini 等人, 2024)、用于编程和代码数据集的 OpenCoder (Huang 等人, 2025) 以及用于精选高质量文本和数学内容的 DCLM-Baseline (Li 等人, 2024)。我们专门利用开源数据集来证明我们范例的有效性并确保可重复性。

有监督微调 SFT 训练目标是对条件分布 $p_{\theta}(r_0|p_0)$ 进行建模，其中 p_0 是提示， r_0 表示响应。在微调期间，噪声仅应用于序列的响应部分，保持提示完整以保留指令跟随能力。为了使 Dream 与用户指令保持一致，我们整理了一个数据集，其中包含来自 Tulu 3 (Lambert 等人, 2025) 和 SmolLM 2 (Allal 等人, 2025) 的 180 万个指令响应对。

5 实验

5.1 设置

评估任务 我们根据一套全面的基准对 Dream 进行了评估，这些基准旨在评估其跨多个领域的功能。对于一般语言理解，我们采用了 MMLU (Hendrycks et al., 2020)、BBH (Suzgun et al., 2022)、ARC-E (Clark et al., 2018)、ARC-C (Clark et al., 2018)、HellaSwag (Zellers et al., 2019)、WinoGrande (Sakaguchi et al., 2019) 等任务。2021)、PIQA (Bisk 等人, 2020) 和 RACE (Lai 等人, 2017) 来测试知识、推理和常识能力。对于数学和科学推理，我们使用 GSM8K (Cobbe et al., 2021) 和 MATH (Hendrycks et al., 2020) 进行数值计算和问题解决，并使用 GPQA (Rein et al., 2023) 进行科学理解。通过 HumanEval (Chen et al., 2021) 和 MBPP (Austin et al., 2021b) 评估代码生成能力，以衡量编程能力。IFEval 基准专门衡量模型遵循给定指令进行评估的能力。对于规划任务，我们评估了 Ye 等人的倒计时和数独任务的性能。(2025a)，以及郑等人的旅行规划任务。(2024a)，评估具有特定目标的规划能力。

5.2 梦想基地成果

扩散语言模型优于自回归模型的规划性能如表1所示，与Qwen2.5 7B相比，Dream 7B在保持有竞争力的通用语言能力的同时，在复杂推理场景中表现出色，展现了扩散模型优越的推理和规划能力。例如，在一般任务上，Dream 7B 在 MMLU 和 HellaSwag 上实现了可比的性能，仅略有差距，而在推理任务（ARC-E、ARC-C）上表现优于。最显著的优势出现在规划任务中，其中 Dream 7B 在倒计时（16.0 比 6.2）、数独（81.0 比 21.0）和旅行规划（17.8 比 3.6）方面明显优于 Qwen2.5。此外，我们观察到其他扩散模型 (LLaDA) 在这些任务上也始终优于 Qwen2.5，这为扩散建模在规划能力方面的固有优势提供了额外的证据。

Dream 训练方法的有效性与之前最先进的扩散模型 (LLaDA 8B，从头开始训练) 相比，Dream 7B 在仅使用 1/4 的训练数据 (0.6T 与 2.3T 令牌) 的情况下在所有评估领域实现了显著的性能改进。Dream 7B 在一般任务上表现出了显著的进步，在推理任务上的优势更为明显。值得注意的是，Dream 7B 在推理任务上取得了实质性的改进（例如，ARC-C 从 47.5 提高到 59.8，GSM8K 从 70.9 提高到 77.2）。此外，Dream 7B 在规划任务方面表现出色，与 LLaDA 相比有很大优势：倒计时从 13.2 提高到 16.0，数独从 46.0 提高到 81.0。这些结果验证了我们的自回归模型初始化策略和上下文自适应噪声重新调度机制的有效性。值得注意的是，由于 Dream 7B 是从 Qwen2.5 权重初始化的，我们预计通过更强大的自回归基础模型，我们的方法将能够开发出功能更强大的扩散语言模型。

表 1: 基本模型在标准评估基准上的比较。* 表示 Dream 7B、LLaDA 8B、Qwen2.5 7B 和 LLaMA3 8B 在相同协议下进行评估。最好的结果加粗，次好的结果加下划线。我们的结果以蓝色突出显示。

Model	Dream 7B*	LLaDA 8B*	Qwen2.5 7B*	LLAMA3 8B*	Mistral 7B	DeepSeek 7B
Type	Diffusion	Diffusion	AR	AR	AR	AR
Training Tokens	0.6T	2.3T	18T	15T	-	2T
General Tasks						
MMLU	69.5 (5)	65.9 (5)	71.9 (5)	63.5 (5)	60.1 (5)	48.2 (5)
BBH	57.9 (3)	47.4 (3)	63.9 (3)	62.7 (3)	-	39.5 (3)
ARC-E	83.9 (0)	71.8 (0)	77.4 (0)	81.1 (0)	80.0 (0)	67.9 (0)
ARC-C	59.8 (0)	47.5 (0)	51.5 (0)	53.6 (0)	55.5 (0)	48.1 (0)
Hellaswag	73.3 (0)	72.7 (0)	79.0 (0)	78.9 (0)	81.3 (0)	75.4 (0)
WinoGrande	74.5 (5)	73.5 (5)	76.4 (5)	76.9 (5)	75.3 (0)	70.5 (0)
PIQA	75.8 (0)	74.8 (0)	79.8 (0)	81.3 (0)	83.0 (0)	79.2 (0)
RACE	44.7 (0)	38.7 (0)	41.9 (0)	39.2 (0)	-	46.5 (5)
Mathematics & Science						
GSM8K	77.2 (8)	70.9 (8)	78.9 (8)	55.3 (8)	52.1 (8)	17.4 (8)
MATH	39.6 (4)	30.7 (4)	41.1 (4)	18.0 (4)	13.1 (4)	6.0 (4)
GPQA	36.6 (5)	30.4 (5)	35.5 (5)	30.6 (5)	-	-
Code						
HumanEval	57.9 (0)	32.9 (0)	56.7 (0)	35.4 (0)	30.5 (0)	26.2 (0)
MBPP	56.2 (4)	39.0 (4)	63.6 (4)	49.2 (4)	47.5 (3)	39.0 (3)
Planning Tasks						
Countdown	16.0 (8)	13.2 (8)	6.2 (8)	3.7 (8)	-	-
Sudoku	81.0 (8)	46.0 (8)	21.0 (8)	0.0 (8)	-	-
Trip planning	17.8 (2)	16.4 (2)	3.6 (2)	8.7 (2)	-	-

5.3 梦授的结果

作为扩散 LLM 后期训练的早期探索，我们进行轻量级监督微调，以使 Dream 与用户指令保持一致。具体来说，我们策划了 180 万个指令响应对，并对 Dream 进行了 3 个时期的微调。表 2 中 Dream-Instruct 的结果证明了 DLLM 在指令跟踪任务中与基于 AR 的 LLM 相匹配的潜力，为未来高级 DLLM 后训练方法奠定了基础。

表 2: 在标准评估基准上进行监督微调后的性能比较。

Model	Dream 7B	LLaDA 8B	Qwen2.5 7B	LLaMA3 8B
Type	Diffusion	Diffusion	AR	AR
Post-training	SFT	SFT	SFT+RL	SFT+RL
Alignment pairs	1.8M	4.5M	1M/0.15M	-
MMLU	67.0	65.5	76.6	68.4
MMLU-pro	43.3	37	56.3	41.9
GSM8K	81.0	78.6	91.6	78.3
Math	39.2	26.6	75.5	29.6
GPQA	33.0	31.8	36.4	31.9
HumanEval	55.5	47.6	84.8	59.8
MBPP	58.8	34.2	79.2	57.6
IFEval	62.5	59.9	74.7	49.7

5.4 AR初始化的效果

为了验证自回归 (AR) 初始化的有效性，我们采用 LLaMA3.2-1B 中的 Dream-1B 进行了初步实验。如图 4 所示，事实证明，AR 初始化策略在训练的早期阶段特别有效，与从头开始训练相比具有显著优势。这一观察结果表明，AR 模型中现有的从左到右的知识为加速扩散模型任意阶生成能力的发展提供了坚实的基础。这种加速显著减少了预训练所需的标记数量和计算资源，使我们的方法比从头开始训练扩散语言模型更加高效。

此外，我们的分析表明，学习率在保留从 AR 初始化继承的有益属性方面起着至关重要的作用。过高的学习率会迅速降低初始权重中嵌入的从左到右的语言知识，从而削弱 AR 初始化的优势。相反，过于保守的学习率可能会阻碍模型有效学习扩散过程的能力。通过系统的超参数调整，我们仔细校准了学习率以及其他训练参数，以实现最佳性能。




图 4：从头开始和 AR 初始化与 LLaMA3.2 1B 训练在具有 200B 代币的 Dream 1B 模型上的损失比较。由于从因果注意力到完全注意力的转变，AR 初始化在开始时也会经历很高的损失；然而，与整个训练期间从头开始训练相比，这种损失仍然较低。

5.5 讨论

5.5.1 规划能力分析

叶等人。2025a,b 证明文本传播模型在小规模、特定任务的环境中表现出卓越的规划能力。然而，目前尚不清楚这些优势是否可以扩展到通用的、按比例缩放的扩散模型。在这项工作中，我们扩展了扩散语言模型，并使用 Dream 7B 系统地评估了它们基于约束的规划能力。我们对 Ye 等人的倒计时和数独任务中的 Dream 进行了评估。（2025a）。我们的实验比较包括 Dream 7B 以及 LLaDA 8B、Qwen2.5 7B 和 LLaMA3 8B，并以 DeepSeek V3-671B (0324) 作为参考点。所有模型均在几次设置中进行评估，无需进行特定任务的训练。

图 5 中显示的结果表明，Dream 在这两项任务中始终优于其他类似大小的基线模型。值得注意的是，Dream 7B 显著超过了同等大小的自回归模型（LLaMA3 8B 和 Qwen2.5 7B）的性能，并且在某些情况下（例如 Countdown3），甚至超过了更大的 DeepSeek-V3-671B (0324)，尽管后者具有




图 5：不同计划难度时倒计时和数独的结果。

更多数量级的参数。这种巨大的性能优势表明，扩散语言模型本质上在解决涉及多个约束或特定目标优化的问题时更有效。有关说明 Qwen2.5 7B 和 Dream 7B 在各种规划场景中的性能差异的详细定性示例，请参阅图 6。

Task	Question (In-context examples are omitted)	Answer from Qwen2.5 7B (AR)	Answer from Dream 7B (Diffusion)
Trip Planning	You plan to visit 3 European cities for 12 days in total. You only take direct flights to commute between cities. You would like to visit Istanbul for 5 days. You would like to visit Budapest for 6 days. You would like to visit Dubrovnik for 3 days.	Here is the trip plan for visiting the 3 European cities for 12 days: **Day 1-5:** Arriving in Istanbul and visit Istanbul for 5 days. **Day 5-11:** Fly from Istanbul to Budapest. Visit Budapest for 6 days. **Day 11-12:** Fly from Budapest to Dubrovnik. **Day 11-12:** Visit Dubrovnik for 3 days.	Here is the trip plan for visiting the 3 European cities for 12 days: **Day 1-3:** Arriving in Dubrovnik and visit Dubrovnik for 3 days. **Day 3-7:** Fly from Dubrovnik to Istanbul. Visit Istanbul for 5 days. **Day 7-12:** Fly from Istanbul to Budapest. Visit Budapest for 6 days.
	Here are the cities that have direct flights: Istanbul and Budapest, from Dubrovnik to Istanbul.		
	Find a trip plan of visiting the cities for 12 days by taking direct flights to commute between them.		
Countdown	Given 5 numbers, use +-* / to operate over the first four numbers to achieve the fifth number. Input: 81,84,82,42,41		
	Output:	84-81=3,82-42=40,40/3=13.3333333	82-81=1,84-1=83,83-42=41
Sudoku	Fill the position where the values are 0 in a 4x4 grid with digits 1-4 so that each column, each row, and each of the four 2x2 subgrids that compose the grid contains all of the digits from 1 to 4.		
	Input:		
	4001	4312	4231
	3124	2134	3124
	1302	1342	1342
	0400	3241	2413
	Output:		

图 6：Qwen2.5 7B 和 Dream 7B 生成的示例。

5.5.2 质量与速度的权衡

扩散语言模型通过其可调整的推理过程提供了独特的优势，其中可以修改扩散时间步数以平衡计算速度和输出质量。减少时间步数可以加快推理速度，但可能会降低生成质量，而增加时间步数可以提高输出质量，但会增加额外计算的成本。

为了证明这种灵活性，我们对 Countdown 任务进行了系统的质量-速度分析，在不同的时间步配置下将 Dream 7B 与 Qwen2.5 7B 进行了比较，如图 7 所示。实验结果表明，Dream 的性能通过时间步调整在计算效率和生成质量之间呈现出可控的权衡，为用户提供了对推理过程的细粒度控制。值得注意的是，当扩散步数设置在 5-20 之间时，与 Qwen2.5 7B 相比，Dream 在速度和质量上都取得了优异的性能。

这种基于时间步长的方法引入了推理时间缩放的额外维度（Snell 等人，2024；Muennighoff 等人，2025；Geiping 等人，2025），它与现有技术一起工作，例如 OpenAI o1（Jaech 等人，2024）和 Deep Seek R1（Guo 等人，2025）等大型语言模型中使用的思想链推理。这种可调整的计算质量权衡代表了扩散模型与传统自回归模型的区别的关键优势。




图 7: Dream 7B 和 Qwen2.5 7B 倒计时任务的质量速度比较。通过调整扩散时间步长，Dream 的性能可以灵活调整速度或质量。

5.5.3 任意订单生成

扩散模型表现出显著的推理灵活性，这使得它们与传统的自回归（AR）模型不同，后者通常以固定的从左到右的顺序生成序列。这种灵活性源于它们以任意顺序合成输出的固有能力，从而开辟了更广泛的多样化用户查询和交互模式。

Dream 7B 支持自然完成和填充任务，无需专门培训。这种灵活性的主要例子包括：

- 完成：用户可以提供一段初始文本，模型可以无缝地继续或完成它。
- 填充：扩散模型可以填充给定文本中缺失的片段。这可以不受特定要求的限制或指导，例如确保生成的填充导致精确的结束句子。
- 可配置的解码顺序：除了这些特定于任务的灵活性之外，用户还可以对解码行为本身进行控制。通过调整解码超参数，可以定制生成过程以模仿 AR 模型更结构化、从左到右的生成特征，或者相反，它可以在解码顺序中引入不同程度的随机性，从而朝着部分甚至完全随机顺序合成的方向发展。

这种输出构建方式（而不仅仅是生成内容）的适应性，使扩散模型能够满足不同的偏好和任务要求，使其成为适用于广泛生成场景的多功能工具。我们在 <https://hkunlp.github.io/blog/2025/dream/> 上提供这些功能的动态演示。

6 结论

Dream 7B 代表了基于扩散的语言建模向前迈出的重要一步，实现了与最先进的自回归模型的竞争性能，同时为灵活的文本生成提供了独特的功能。我们的实验表明，扩散语言模型尤其在约束满足和规划任务中表现出色，其双向性质和迭代细化过程比传统的从左到右生成方法具有明显的优势。

该模型执行任意顺序生成的能力使得完成和填充任务中的新颖应用成为可能，而可调节的时间步长配置为用户提供了对推理期间质量与速度权衡的细粒度控制。这些功能与预先训练的自回归模型初始化的已证明的有效性相结合，为开发更灵活和更强大的语言模型建立了一条实用途径。未来的工作将探索先进的训练后方法、更长的上下文功能以及在需要增强规划和推理能力的专业领域的应用。

致谢

我们感谢蔡成武的支持和有益的讨论。我们还感谢开源社区提供高质量的数据集和评估框架。这项研究得到了中国国家自然科学基金委员会 (NSFC) 和研究资助局 (RGC) 联合研究计划的部分支持，资助号为 N_HKU714/21。

参考

Loubna Ben Allal、Anton Lozhkov、Elie Bakouch、Gabriel Martín Blázquez、Guilherme Penedo、Lewis Tunstall、Andrés Marafioti、Hynek Kydlíček、Agustín Piqueres Lajarín、Vaibhav Srivastav、Joshua Lochner、Caleb Fahlgren、Xuan-Son Nguyen、Clémentine Fourier、Ben 布滕肖、雨果·拉彻、赵浩军、西里尔·扎卡、马蒂厄·莫伦、科林·拉菲尔、莱安德罗·冯·韦拉和托马斯·沃尔夫。 SmolLM2: 当 smol 变大时——以数据为中心的小型语言模型训练，2025 年。URL <https://arxiv.org/abs/2502.02737>。

Marianne Arriola、Aaron Gokaslan、Justin T. Chiu、Zhihan Yang、Zhixuan Qi、Jiaqi Han、Subham Sekhar Sahoo 和 Volodymyr Kuleshov。块扩散：自回归和扩散语言模型之间的插值，2025。URL <https://arxiv.org/abs/2503.09573>。

雅各布·奥斯汀、丹尼尔·D 约翰逊、乔纳森·何、丹尼尔·塔洛和瑞安·范登伯格。离散状态空间中的结构化去噪扩散模型。神经信息处理系统的进展，34: 17981–17993, 2021a。

Jacob Austin、Augustus Odena、Maxwell Nye、Maarten Bosma、Henryk Michalewski、David Dohan、Ellen Jiang、Carrie Cai、Michael Terry、Quoc Le 等。使用大型语言模型进行程序综合。arXiv 预印本 arXiv:2108.07732, 2021b。

格雷戈尔·巴赫曼 (Gregor Bachmann) 和瓦什纳夫·纳加拉詹 (Vaishnavh Nagarajan)。下一个令牌预测的陷阱。arXiv 预印本 arXiv:2403.06963, 2024。

约舒亚·本吉奥、雷让·杜查姆和帕斯卡·文森特。神经概率语言模型。神经信息处理系统的进展，2000 年 13 月。

Yonatan Bisk、Rowan Zellers、高剑峰、Yejin Choi 等。Piqa: 用自然语言推理物理常识。2020 年 AAAI 人工智能会议论文集。

Sébastien Bubeck、Varun Chandrasekaran、Ronen Eldan、Johannes Gehrke、Eric Horvitz、Ece Kamar、Peter Lee、Yin Tat Lee、Yuanzhi Li、Scott Lundberg 等。通用人工智能的火花：gpt-4 的早期实验，2023 年。

安德鲁·坎贝尔、乔·本顿、瓦伦丁·德·博尔托利、托马斯·雷恩福斯、乔治·德利吉安尼迪斯和阿诺·杜塞。离散去噪模型的连续时间框架。神经信息处理系统进展, 35: 28266–28279, 2022。Mark Chen、Jerry Tworek、Heewoo Jun、Qiming Yuan、Henrique Ponde De Oliveira Pinto、Jared Kaplan、Harri Edwards、Yuri Burda、Nicholas Joseph、Greg Brockman 等。评估在代码上训练的大型语言模型。arXiv 预印本 arXiv: 2107.03374, 2021。Peter Clark、Isaac Cowhey、Oren Etzioni、Tushar Khot、Ashish Sabharwal、Carissa Schoenick 和 Oyvind Tafjord。您认为您已经解决了问答问题吗? 尝试 arc, ai2 推理挑战赛。arXiv 预印本 arXiv:1803.05457, 2018。Karl Cobbe、Vineet Kosaraju、Mohammad Bavarian、Mark Chen、Heewoo Jun、Lukasz Kaiser、Matthias Plappert、Jerry Tworek、Jacob Hilton、Reiichiro Nakano 等。培训验证员解决数学应用题。arXiv 预印本 arXiv: 2110.14168, 2021。Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。BERT: 用于语言理解的深度双向转换器的预训练。在过程中。NAA CL-HLT, 第 4171–4186 页。计算语言学协会, 2019。Sander Dieleman、Laurent Sartran、Arman Roshannai、Nikolay Savinov、Yaroslav Ganin、Pierre H Richemond、Arnaud Doucet、Robin Strudel、Chris Dyer、Conor Durkan 等。分类数据的连续扩散。arXiv 预印本 arXiv:2211.15089, 2022。Nouha Dziri、Ximing Lu、Melanie Sclar、Xiang Lorraine Li、Liwei Jiang、Bill Yuchen Lin、Sean Welleck、Peter West、Chandra Bhagavatula、Ronan Le Bras 等。信仰与命运: 变形金刚对组合性的限制。神经信息处理系统进展, 36: 70293–70332, 2023。Jonas Geiping、Sean McLeish、Neel Jain、John Kirchenbauer、Siddharth Singh、Brian R Bartoldson、Bhavya Kailkhura、Abhinav Bhatele 和 Tom Goldstein。通过潜在推理扩展测试时计算: 一种循环深度方法。arXiv 预印本 arXiv:2502.05171, 2025。龚山三、李木凯、冯江涛、吴志勇和孔令鹏。DiffuSeq-v2: 桥接离散和连续文本空间, 以加速 Seq2Seq 扩散模型。Houda Bouamor、Juan Pino 和 Kalika Bali 编辑, 计算语言学协会的调查结果: EMNLP 2023, 第 9868–9875 页。计算语言学协会, 2023a。龚山三, 李木凯, 冯江涛, 吴志勇, 孔令鹏。DiffuSeq: 使用扩散模型生成序列到序列文本。国际学习表征会议, ICLR, 2023b。龚珊珊、Shivam Agarwal、张一哲、叶家成、郑林、李穆凯、安晨鑫、赵培林、毕伟、韩家伟、彭浩和孔令鹏。通过适应自回归模型来扩展扩散语言模型。国际学习代表会议, 2025 年。Aaron Grattafiori、Abhimanyu Dubey、Abhinav Jauhri、Abhinav Pandey、Abhishek Kadian、Ahmad Al-Dahle、Aiesha Letman、Akhil Mathur、Alan Schelten、Alex Vaughan、Amy Yang、Angela Fan、Anirudh Goyal、Anthony Hartshorn、Aobo Yang、Archi Mitra、阿奇·斯拉万库玛尔、阿尔乔姆·科热涅夫、阿瑟·辛斯瓦克、阿伦·饶、阿斯顿·张、奥瑞连·罗德里格斯、奥斯汀·格雷格森、艾娃·斯帕塔鲁、巴蒂斯特·罗齐尔、贝瑟尼·拜伦、平·唐、鲍比·陈、夏洛特·考切特、查亚·纳亚克、Chloe Bi、克里斯·马拉、克里斯·麦康奈尔、克里斯蒂安·凯勒、克里斯托弗·图雷、吴春阳、科琳娜黄、克里斯蒂安·坎顿·费雷尔、赛勒斯·尼古拉迪斯、达米安·阿隆修斯、丹尼尔·宋、丹妮尔·平茨、丹尼·利夫希茨、丹尼·怀亚特、大卫·埃西奥布、德鲁夫·乔杜里、德鲁夫·马哈詹、迭戈·加西亚·奥拉诺、迭戈·佩里诺、迪乌克·哈普克斯、叶戈尔·拉科姆金、埃哈布·阿尔巴达维、埃琳娜·洛巴诺娃、艾米丽·迪南、埃里克·迈克尔·史密斯、菲利普·拉德诺维奇、弗朗西斯科·古兹曼、弗兰克·张、加布里埃尔·辛奈夫、加布里埃尔·李、乔治亚·刘易斯·安德森、戈文德·塔泰、格雷姆·内尔、格雷瓜尔·米隆、关庞、吉列姆·库雷尔、海莉·阮、汉娜·科雷瓦尔、胡旭、雨果·图夫龙、伊利扬·扎罗夫、伊曼诺尔·阿列塔·伊瓦拉、伊莎贝尔·克鲁曼、伊山·米斯拉、伊万 Evtimov、Jack 张、Jade Copet、Jaewon Lee、Jan Geffert、Jana Vranes、Jason Park、Jay Mahadeokar、Jeet Shah、Jelmer van der Linde、Jennifer Billock、Jenny Hong、Jenya Lee、Jeremy Fu、Jianfeng Chi、Jianyu Huang、Jiawen Liu、Jie Wang、

于杰曹、乔安娜·比顿、乔·斯皮萨克、朴钟洙、约瑟夫·罗卡、约书亚·约翰斯顿、约书亚·萨克斯、贾俊腾、卡扬·瓦苏登·阿尔瓦拉、卡蒂克·普拉萨德、卡蒂凯亚·乌帕萨尼、凯特·普拉维亚克、李柯、肯尼思·希菲尔德、凯文·斯通、哈立德·埃尔·阿里尼、克里西卡·艾耶、克什蒂兹·马利克、Kuenley Chiu、库纳尔·巴拉、库沙尔·拉科蒂亚、劳伦·兰塔拉·耶里、劳伦斯·范德马滕、劳伦斯·陈、梁谭、利兹·詹金斯、路易斯·马丁、洛维什·马达安、卢博·马洛、卢卡斯·布莱彻、卢卡斯·兰扎特、卢克·德·奥利维拉、马德琳·穆齐、马赫什·帕苏普莱蒂、曼纳特·辛格、马诺哈尔·帕鲁里、马辛·卡达斯、玛丽亚Tsi mpoukelli、Mathew Oldham、Mathieu Rita、Maya Pavlova、Melanie Kambadur、Mike Lewis、Min Si、Mitesh Kumar Singh、Mona Hassan、Naman Goyal、Narjes Torabi、Nikolay Bashlykov、Nikolay Bogoychev、Niladri Chatterji、Ning Chang、Olivier Duchenne、Onur Çelebi、Patrick Alrassy、Pengchuan 张、李鹏伟、Petar Vasic、Peter Weng、Prajjwal Bhargava、Pratik Dubal、Praveen Krishnan、Punit Singh Koura、徐朴新、何清、董清晓、Ragavan Srinivasan、Raj Ganapathy、Ramon Calderer、Ricardo Silveira Cabral、Robert Stojnic、Roberta Raileanu、Rohan Maheswari、Rohit Girdhar、Rohit Patel、Roma in Sauvestre、Ronnie Polidoro、Roshan Sumbaly、Ross Taylor、Ruan Silva、侯锐、Rui Wang、Saghar Hosseini、Sahana Chennabasappa、Sanjay Singh、Sean Bell、Seohyun Sonia Kim、Sergey Edunov、少良聂、Sharan Narang、Sharath Raparthy、Sheng Shen、Shengye Wan、Shruti Bhosale、Shun Zhang、Simon范登亨德、苏米亚·巴特拉、斯宾塞·惠特曼、斯滕·苏特拉、斯蒂芬·科洛、苏钦·古鲁兰甘、西德尼·博罗金斯基、塔玛尔·赫尔曼、塔拉·福勒、塔里克·谢沙、托马斯·乔治欧、托马斯·夏洛姆、托比亚斯·斯佩克巴赫、托多尔·米哈伊洛夫、童晓、乌杰瓦尔·卡恩、维达努·戈斯瓦米、维博·古普塔、维涅什·拉马纳坦、Viktor Kerkez、文森特·贡格特、Virginie Do、Vish Vogeti、Vítor Albiero、Vladan Petrovic、Weiwei Chu、熊文汉、傅文音、Whitney Meers、Xavier Martinet、王晓东、王晓芳、谭小青、夏希德、谢新峰、贾旭超、王雪薇、Yaelle Goldschlag、Yashesh Gaur、Yasmine Babaei、文怡、宋伊文、张雨辰、李悦、毛雨宁、扎查里·德尔皮尔·考德特、严征、陈正兴、佐伊·帕帕基波斯、阿迪亚·辛格、阿尤什·斯里瓦斯塔瓦、阿卜哈·贾因、亚当·凯尔西、亚当·沙恩菲尔德、阿迪西亚·甘迪迪、阿道夫·维多利亚、阿胡瓦·金斯坦德、阿杰·梅农、阿杰·夏尔马、亚历克斯·博森伯格、阿列克谢·巴耶夫斯基、艾莉·范斯坦、阿曼达·卡莱特、阿米特·桑加尼、阿莫斯·泰奥、阿南·尤努斯、安德烈·卢普、安德烈斯·阿尔瓦拉多、安德鲁·卡普尔斯、安德鲁·顾、安德鲁·何、安德鲁·波尔顿、安德鲁·瑞安、安基特·拉姆昌达尼、安妮·东、安妮·弗兰科、阿努吉·戈亚尔、阿帕拉吉塔·萨拉夫、阿卡班杜·乔杜里、阿什利·加布里埃尔、阿什温·巴兰贝、阿萨夫·艾森曼、阿扎德亚兹丹、博·詹姆斯、本·毛雷尔、本杰明·莱昂哈迪、伯尼·黄、贝丝·洛伊德、贝托·德·保拉、巴加维·帕兰贾普、刘兵、吴波、倪博宇、布雷登·汉考克、布拉姆·瓦斯蒂、布兰登·斯彭斯、布拉尼·斯托伊科维奇、布莱恩·加米多、布里特·蒙塔尔沃、卡尔·帕克、卡莉·伯顿、卡特琳娜·梅希亚、刘策、王长瀚、金昌奎、周潮、Chester Hu、Ching-Hsiang Chu、Chris Cai、Chris Tindal、Christoph Feichtenhofer、Cynthia Gau、Damon Civin、Dana Beaty、Daniel Kreymer、Daniel Li、David Adkins、David Xu、Davide Testuggine、Delia David、Devi Parikh、Diana Liskovich、Didem Foss、Dingkang Wang、Duc Le、Dustin Holland、Edward Dowling、Eissa Jamil、伊莲·蒙哥马利、埃莱奥诺拉·普雷萨尼、艾米丽·哈恩、艾米丽·伍德、埃里克·图安·乐、埃里克·布林克曼、埃斯特班·阿科特、埃文·邓巴、埃文·斯莫瑟斯、孙飞、菲利克斯·克鲁克、田丰、菲利波斯·科基诺斯、菲拉特·奥兹格内尔、弗朗西斯科·卡吉奥尼、弗兰克·卡纳耶特、弗兰克·塞德、加布里埃拉·梅迪纳·弗洛雷斯、加布里埃拉·施瓦茨、Gada Badeer、Georgia Swee、Gil Halpern、Grant Herman、Grigory Sizov、Guangyi、Zhang、Guna Lakshminarayanan、Hakan Inan、Hamid Shojanazeri、Han Zou、Hannah Wang、Hanwen Zha、Haroun Habeeb、Harrison Rudolph、Helen Suk、Henry Aspegren、Hunter Goldman、詹宏源、Ibrahim Damla、Igor Molybog、Igor图法诺夫、伊利亚斯·莱昂蒂亚迪斯、伊琳娜·埃琳娜·维利切、伊泰·盖特、杰克·韦斯曼、詹姆斯·格博斯基、詹姆斯·科利、珍妮丝·林、贾菲特·阿舍、让-巴蒂斯特·加亚、杰夫·马库斯、杰夫·唐、詹妮弗·陈、珍妮·珍、杰里米·雷森斯坦、杰里米·特博尔、杰西卡·钟、金健、杨静怡、乔·卡明斯、乔恩·卡维尔、乔恩Shepard、乔纳森·麦克菲、乔纳森·托雷斯、乔什·金斯伯格、王俊杰、吴凯、Kam Hou U、Karan Saxena、Kartikay Khandelwal、Katayoun Zand、Kathy Matosich、Kaushik Veeraraghavan、Kelly Michelena、李克谦、Kiran Jagadeesh、Kun Huang、Kunal Chawla、Kyle Huang、Lailin Chen、Lakshya Garg、Lavender A、莱安德罗·席尔瓦、李·贝尔、张磊、郭良鹏、于立成、利隆·莫什科维奇、卢卡·韦尔斯特、马迪安·卡布萨、马纳夫·阿瓦拉尼、曼尼什·巴特、马丁纳斯·曼库斯、马坦·哈森、马修·伦尼、马蒂亚斯·雷索、马克西姆·格罗舍夫、马克西姆·纳乌莫夫、玛雅·拉蒂、梅根·肯尼利、刘苗、迈克尔·L塞尔策、米哈尔·瓦尔科、米歇尔·雷斯特雷波、米希尔·帕特尔、米克·维亚茨科夫、米卡耶尔·萨姆韦利安、迈克·克拉克、迈克·梅西、迈克·王、米克尔·朱伯特·赫尔莫索、莫·梅塔纳特、穆罕默德·拉斯特加里、穆尼什·班萨尔、南迪尼·桑萨

Salpekar, Ozlem Kalinli, Parkin Kent, Parth Parekh, Paul Saab, Pavan Balaji, Pedro Rittner, Philip Bontrager, Pierre Roux, Piotr Dollar, Polina Zvyagina, Prashant Ratanchandani, Pritish Yuvraj, 钱亮, Rachad Alao, Rachel Rodriguez, Rafi Ayub, Raghotham Murthy, Raghu Nayani, 拉胡尔·米特拉, Rangaprabhu Parthasarathy, Raymond Li, Rebekkah Hogan, Robin Battey, Rocky Wang, Russ Howes, Ruty Rinott, Sachin Mehta, Sachin Siby, Sai Jayesh Bondu, Samyak Datta, Sara Chugh, Sara Hunt, Sargun Dhillon, Sasha Sidorov, Satadru Pan, Saurabh Mahajan, Saurabh Verma, Seiji Yamamoto, Sharadh Ramaswamy, Shaun Lindsay, Shaun Lindsay, 盛峰, Shenghao Lin, Shengxin Cindy Zha, Shishir Patil, Shiva Shankar, 张书强, 张书强, 王思农, Sneha Agarwal, Soji Sajuyigbe, Soumith Chintala, Stephanie Max, Stephen Chen, Steve Kehoe, Steve Satterfield, Sudarshan Govindaprasad, Sumit Gupta, Summer Deng, 赵成民, 桑尼·维克, 苏拉吉·萨勃拉曼尼亚, Sy Choudhury, Sydney Goldman, Tal Remez, Tamar Glaser, Tamara Best, Thilo Koehler, Thomas Robinson, 李天河, 张天军, 蒂姆·马修斯, 周蒂莫西, Tzook Shaked, Varun Vontimitta, Victoria Ajayi, Victoria Montanez, Vijai Mohan, Vinay Satish Kumar, Vishal Mangla, Vlad Ionescu, Vlad Poenaru, Vlad Tiberiu Mihailescu, Vladimir Ivanov, 李伟, Wenchen Wang, Wenwen Jiang, Wes Bouaziz, Will Constable, Xiao Cheng Tang, Xiaojian Wu, Xiaolan Wang, Xilun Wu, Xinbo Gau, Yaniv Kleinman, Yanjun Chen, Ye Hu, Ye Jia, Ye Qi, Yenda Li, Yilin Zhang, Ying Zhu, Yossi Adi, Youngjin Nam, Yu, 王, 赵宇, 郝雨辰, 钱云迪, 李云禄, 何雨子, Zach Rait, Zachary DeVito, Zef Rosnbrick, 赵多文, 杨振宇, 赵志伟和马志宇。美洲驼 3 群模型, 2024 年。URL <https://arxiv.org/abs/2407.21783>。

伊沙安·古尔拉贾尼 (Ishaan Gulrajani) 和桥本龙典 (Tatsunori Hashimoto)。基于可能性的扩散语言模型。第三十七届神经信息处理系统会议, 2023a。

Ishaan Gulrajani 和 Tatsunori B Hashimoto。基于可能性的扩散语言模型。神经信息处理系统的进展, 36: 16693–16715, 2023b。

郭大亚, 杨德建, 张浩伟, 宋俊晓, 张若宇, 徐润新, 朱启豪, 马世荣, 王培毅, 毕晓, 等。Deepseek-r1: 通过强化学习激励 llms 的推理能力。arXiv 预印本 arXiv:2501.12948, 2025。

何正福、孙天祥、唐琼、王宽宁、黄玄静、邱西鹏。DiffusionBERT: 使用扩散模型改进生成屏蔽语言模型。载于 Anna Rogers, Jordan Boyd-Graber 和 Naoaki Okazaki, 编辑, 计算语言学协会第 61 届年会论文集 (第一卷: 长论文), 第 4521-4534 页, 加拿大多伦多, 2023 年 7 月。计算语言学协会。doi: 10.18653/v1/2023.acl-long.248。

丹·亨德里克斯、科林·伯恩斯、史蒂文·巴沙特、安迪·邹、曼塔斯·马泽卡、道恩·宋和雅各布·斯坦哈特。测量大规模多任务语言理解。arXiv 预印本 arXiv:2009.03300, 2020。

乔纳森·何 (Jonathan Ho)、阿杰·贾恩 (Ajay Jain) 和彼得·阿贝尔 (Pieter Abbeel)。去噪扩散概率模型。Hugo Larochelle, Marc’ Aurelio Ranzato, Raia Hadsell, Maria-Florina Balcan 和 Hsuan-Tien Lin, 编辑, 神经信息处理系统进展 33: 2020 年神经信息处理系统年会, NeurIPS 2020, 2020 年 12 月 6-12 日, 虚拟, 2020 年。

埃米尔·胡格布姆、迪德里克·尼尔森、普里扬克·贾尼、帕特里克·弗雷和马克斯·威灵。Argmax 流和多项式扩散: 学习分类分布。神经信息处理系统的进展, 34: 12454–12465, 2021。

黄思明、程天浩、J.K.刘、郝嘉然、宋刘一涵、徐阳、J.杨、刘家恒、张晨晨、柴林正、袁瑞峰、张兆祥、付杰、刘谦、张戈、王自力、齐元、徐英辉和楚伟。Opencoder: 顶级代码大语言模型的开放食谱, 2025 年。URL <https://arxiv.org/abs/2411.04905>。

初始实验室。Mercury: 基于扩散的超快速语言模型。https://www.inceptionlabs.ai/introducing-mercury, 2025。访问时间: 2025 年 6 月 16 日。

Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney 等。Openai o1 系统卡。arXiv 预印本 arXiv:2412.16720, 2024。

弗雷德里克·耶利内克.从稀疏数据中插值估计马尔可夫源参数。在过程中。模式识别实践研讨会, 1980, 1980。

迪德里克·金马、蒂姆·萨利曼斯、本·普尔和乔纳森·何。变分扩散模型。神经信息处理系统的进展, 34: 21696–21707, 2021。

赖国坤、谢启哲、刘汉晓、杨一鸣、Eduard Hovy。Race: 来自考试的大规模阅读理解数据集。arXiv 预印本 arXiv:1704.04683, 2017。

Nathan Lambert、Jacob Morrison、Valentina Pyatkin、黄圣依、Hamish Ivison、Faeze Brahman、Lester James V. Miranda、Alisa Liu、Nouha Dziri、Shane Lyu、Yuling Gu、Saumya Malik、Victoria Graf、Jena D. Hwang、江江杨、Ronan Le Bras、Oyvind Tafjord、Chris Wilhelm、Luca Soldaini、Noah A. Smith、一中王、Pradeep Dasigi 和 Hannaneh Hajishirzi。Tulu 3: 推动开放语言模型训练后的前沿, 2025 年。URL <https://arxiv.org/abs/2411.15124>。

Jeffrey Li, Alex Fang, Georgios Smyrnis, Maor Ivgi, Matt Jordan, Samir Gadre, Hritik Bansal, Etash Guha, Se drick Keh, Kushal Arora, Saurabh Garg, Rui Xin, Niklas Muennighoff, Reinhard Heckel, Jean Mercat, Mayee Chen, Suchin Gururangan, Mitchell Wortsman, Alon Albalak, Yonatan Bitton, Marianna Nezhurina, Amro Abbas, Cheng-Yu Hsieh, Dhruva Ghosh, Josh Gardner, Maciej Kilian, Hanlin 张、邵儒林、莎拉·普拉特、Sunny Sanyal、Gabriel Ilharco、Giannis Daras、Kalyani Marathe、Aaron Gokaslan、Jieyu 张、Khyathi Chandu、Thao Nguyen、Igor Vasiljevic、Sham Kakade、Shuran Song、Sujay Sanghavi、Fartash Faghri、Sewoong Oh、Luke Zettlemoyer、Kyle Lo、Alaaeldin El-Nouby、Hadi Pouransari、Alexander Toshev、Stephanie Wang、Dirk Groeneveld、Luca Soldaini、Pang Wei Koh、Jenia Jitsev、Thomas Kollar、Alexandros G. Dimakis、Yair Carmon、Achal Dave、Ludwig Schmidt、和维沙尔·香卡。Datacomp-lm: 寻找下一代语言模型训练集。神经信息处理系统的进展, 2024 年。

李翔、John Thickstun、Ishaan Gulrajani、Percy Liang 和 Tatsunori B Hashimoto。Diffusion-lm 改进了可控文本生成。神经信息处理系统会议, NeurIPS, 2022 年。

林正浩、龚业云、沉业龙、吴童、范志浩、林陈、段南和陈伟珠。使用扩散语言模型生成文本: 一种具有连续段落降噪的预训练方法。第 40 届国际机器学习会议记录, ICML' 23。JMLR.org, 2023 年。

楼亚伦、孟晨林和斯特凡诺·埃尔蒙。通过估计数据分布的比率进行离散扩散语言建模。国际机器学习会议, ICML, 2024 年。

Niklas Muennighoff、杨子潼、石维嘉、李翔丽莎、李飞飞、Hannaneh Hajishirzi、Luke Zettlemoyer、Percy Liang、Emmanuel Candès 和 Tatsunori Hashimoto。s1: 简单的测试时间缩放。arXiv 预印本 arXiv:2501.19393, 2025。

聂沉、朱凤起、杜超、庞天宇、刘谦、曾光涛、林敏、李崇轩。扩大文本上的蒙版扩散模型, 2025a。网址 <https://arxiv.org/abs/2410.18514>。

聂沉、朱凤起、游泽斌、张晓鹿、欧景阳、胡军、周军、林彦凯、文继荣和李崇轩。大型语言扩散模型。arXiv 预印本 arXiv:2502.09992, 2025b。

OpenAI、Josh Achiam、Steven Adler、Sandhini Agarwal、Lama Ahmad、Ilge Akkaya、Florencia Leoni Aleman、Diogo Almeida、Janko Altmenschmidt、Sam Altman、Shyamal Anadkat、Red Avila、Igor Babuschkin、Suchir Balaji、Valerie Balcom、Paul Baltescu、Haiming Bao、Mohammad Bavarian、Jeff Bel gum、Irwan Bello、杰克·伯丁、加布里埃尔·伯纳戴特·夏皮罗、克里斯托弗·伯纳、兰尼·博格多诺夫、奥列格·博伊科、玛德琳·博伊德、安娜·路易莎·布拉克曼、格雷格·布罗克曼、蒂姆·布鲁克斯、迈尔斯·布伦戴奇、凯文·巴顿、特雷弗·蔡、罗茜·坎贝尔、安德鲁·卡恩、布列塔尼·凯里、切尔西·卡尔森、罗里·卡迈克尔、陈波姬、张彻、福蒂斯·尚齐斯、德里克·陈、陈苏利、Ruby Chen、Jason Chen、Mark Chen、Ben Chess、Chester Cho、Casey Chu、Hung Won Chung、Dave Cummings、Jeremiah Currier、戴云星、Cory Decareaux、Thomas Degry、Noah Deutsch、Damien Deville、Arka Dhar、David Dohan、Steve Dowling、Sheila Dunning、Adrien Ecoffet、Atty Eleti、Tyna Eloundou、David Farhi、Liam Fedus、Niko 菲利克斯、西蒙·波萨达·菲什曼、贾斯顿·福特、伊莎贝拉·富尔福德、利奥

高、埃利·乔治、克里斯蒂安·吉布森、维克·戈尔、塔伦·戈吉内尼、加布里埃尔·吴、拉斐尔·贡蒂霍-洛佩斯、乔纳森·戈登、摩根·格拉夫斯坦、斯科特·格雷、瑞安·格林、约书亚·格罗斯、顾世翔、郭宇飞、克里斯·哈拉西、杰西·韩、杰夫·哈里斯、何雨辰、迈克·希顿、约翰内斯·海德克、克里斯·赫塞、艾伦·希基、韦德·希基、Peter Hoeschele、Brandon Houghton、Kenny Hsu、胡胜利、胡欣、Joost Huijzinga、Shantanu Jain、Shawn Jain、Joanne Jang、Angela Jiang、Roger Jiang、金浩准、Denny Jin、Shino Jomoto、Billie Jonn、Heewoo Jun、Tomer Kaftan、ukasz Kaiser、Ali Kamali、Ingmar Kanitscheider、Nitish Shirish Keskar、Tabarak Khan、洛根·基尔帕特里克、金钟旭、克里斯蒂娜·金、Yongjik Kim、简·亨德里克·基什内尔、杰米·基罗斯、马特·奈特、丹尼尔·科科塔洛、ukasz Kondraciuk、安德鲁·康德里奇、阿里斯·康斯坦丁尼迪斯、凯尔·科西奇、格雷琴·克鲁格、维沙尔·郭、迈克尔·兰佩、伊凯·兰、泰迪·李、简·雷克、杰德·梁、丹尼尔·利维、李泽明、Rachel Lim、Molly Lin、Stephanie Lin、Mateusz Litwin、Theresa Lopez、Ryan Lowe、Patricia Lue、Anna Makanju、Kim Malfacini、Sam Manning、Todor Markov、Yaniv Markovski、Bianca Martin、Katie Mayer、Andrew Mayne、Bob McGrew、Scott Mayer McKinney、Christine McLeavey、Paul McMillan、Jake McNeil、David Medina、阿洛克·梅塔、雅各布·梅尼克、卢克·梅斯、安德烈·米什琴科、帕梅拉·米什金、维尼·摩纳哥、埃文·森川、丹尼尔·莫辛、童木、米拉·穆拉蒂、奥列格·默克、大卫·梅利、阿什文·奈尔、中野礼一郎、拉吉夫·纳亚克、阿尔文德·尼拉坎坦、理查德·吴、卢贤宇、欧阳龙、卡伦·奥基夫、雅库布·帕乔基、亚历克斯·帕诺、乔·巴勒莫、阿什利·潘图利亚诺、詹巴蒂斯塔·帕拉斯坎多洛、乔尔·帕里什、艾米·帕帕里塔、亚历克斯·帕索斯、米哈伊尔·巴甫洛夫、安德鲁·彭、亚当·佩雷尔曼、菲利普·德·阿维拉·贝尔布特·佩雷斯、迈克尔·彼得罗夫、恩里克·庞德·德·奥利维拉·平托、迈克尔·波科尼、米歇尔·波克拉斯、Vitchy r H. Pong、托利·鲍威尔、阿丽西娅·鲍尔、鲍里斯·鲍尔、伊丽莎白·普罗尔、劳尔·普里、亚历克·雷德福、杰克·雷、阿迪亚·拉梅什、卡梅隆·雷蒙德、弗朗西斯·瑞尔、肯德拉·里姆巴赫、卡尔·罗斯、鲍勃·罗斯特德、亨利·鲁塞斯、尼克·莱德、马里奥·萨尔塔雷利、特德·桑德斯、希巴尼·桑图卡、吉里什·萨斯特里、希瑟·施密特、大卫·施努尔、约翰·舒尔曼、丹尼尔·塞尔萨姆、凯拉·谢泼德、托基·谢尔巴科夫、杰西卡·谢、莎拉·肖克、普拉纳夫·希亚姆、西蒙·西多、埃里克·西格勒、麦迪·西蒙斯、乔丹·席特金、卡塔琳娜·斯拉马、伊恩·索尔、本杰明·索科洛斯基、杨松、娜塔莉·施陶达赫、费利佩·彼得罗斯基、娜塔莉·萨默斯、伊利亚·苏茨克夫、唐杰、尼古拉斯·特扎克、玛德琳B. Thompson、Phil Tillet、Amin Tootoonchian、Elizabeth Tseng、Preston Tuggle、Nick Turley、Jerry Tworek、Juan Felipe Cerón Uribe、Andrea Vallone、Arun Vijayvergiya、Chelsea Voss、Carroll Wainwright、Justin Jay Wang、Alvin Wang、Ben Wang、Jonathan Ward、Jason Wei、CJ Weinmann、Akila Welihinda、Peter Welinder、Jiayi Weng、Lilian Weng、Matt Wiethoff、Dave Willner、Clemens Winter、Samuel Wolrich、Hannah Wong、Lauren Workman、Sherwin Wu、Jeff Wu、Michael Wu、Kai Shaw、Tao Xu、Sarah Yoo、Kevin Yu、Qiming Yuan、Wojciech Zaremba、Rowan Zellers、Chong Chang、Marvin 张、Shengjia Chao、郑天浩、Juntang Zhang、William Zhuk 和 Barret Zoph。Gpt-4 技术报告，2024 年。URL <https://arxiv.org/abs/2303.08774>。

欧景阳、聂沉、薛凯文、朱凤起、孙家成、李振国、李崇轩。您的吸收离散扩散秘密地模拟了干净数据的条件分布。国际学习表征会议，2025 年。

问wen, :, 安阳, 杨宝松, 张北辰, 惠斌源, 郑波, 于博文, 李成远, 刘大一恒, 黄飞, 魏浩然, 林煥, 杨健, 涂建红, 张建伟, 杨建新, 杨家喜, 周静仁, 林俊阳, 党凯, 卢克明, 包克勤, 杨克新, 余乐, 李梅, 薛明峰, 张培, 朱勤, 门锐, 润吉林天浩、唐天一、夏廷宇、任兴章、任宣成、杨帆、苏杨、张益昌、万宇、刘玉琼、崔泽宇、张振如和邱子涵。Qwen2.5 技术报告，2025 年。URL <https://arxiv.org/abs/2412.15115>。

David Rein、Betty Li Hou、Asa Cooper Stickland、Jackson Petty、Richard Yuanzhe Pang、Julien Dirani、Julian Michael 和 Samuel R Bowman。Gpqa：研究生级别的谷歌验证问答基准。arXiv 预印本 arXiv:2311.12022, 2023。

Subham Sekhar Sahoo、Marianne Arriola、Aaron Gokaslan、Edgar Mariano Marroquin、Alexander M Rush、Yair Schiff、Justin T Chiu 和 Volodymyr Kuleshov。简单有效的掩蔽扩散语言模型。2024 年第三十八届神经信息处理系统年会。网址 <https://openreview.net/forum?id=L4uaAR4ArM>。

坂口圭介、罗南·勒·布拉斯、钱德拉·巴加瓦图拉和崔艺珍。Winogrande：大规模的对抗性 winograd 模式挑战。ACM 通讯，64(9):99–106，2021 年。

施嘉欣、韩克航、王哲、Arnaud Doucet 和 Michalis K. Titsias。离散数据的简化和广义掩蔽扩散。神经网络信息处理系统, 2024 年。Charlie Snell, Jaehoon Lee, Kelvin Xu 和 Aviral Kumar。以最佳方式缩放 llm 测试时间计算比缩放模型参数更有效。arXiv 预印本 arXiv: 2408.03314, 2024。Jascha Sohl-Dickstein、Eric Weiss、Niru Maheswaranathan 和 Surya Ganguli。使用非平衡热力学的深度无监督学习。国际机器学习会议, 第 2256-2265 页。PMLR, 2015。Luca Soldaini、Rodney Kinney、Akshita Bhagia、Dustin Schwenk、David Atkinson、Russell Authur、Ben Bogin、Khyathi Chandu、Jennifer Dumas、Yanai Elazar、Valentin Hofmann、Ananya Jha、Sachin Kumar、Li Lucy、Xinxi Lyu、Nathan Lambert、Ian Magnusson、Jacob Morrison、Niklas Muennighoff、Aakanksha Naik、Crystal Nam、Matthew Peters、Abhilasha Ravichander、Kyle Richardson、Zejian Shen、Emma Strubell、Nishant Subramani、Oyvind Tafjord、Evan Walsh、Luke Zettlemoyer、Noah Smith、Hannaneh Hajishirzi、Iz Beltagy、Dirk Groeneveld、Jesse Dodge 和 Kyle Lo。Dolma: 一个包含 3 万亿个 token 的开放语料库, 用于语言模型预训练研究。载于 Lun-Wei Ku、Andre Martins 和 Vivek Srikumar, 编辑, 计算语言学协会第 62 届年会论文集 (第一卷: 长论文), 2024 年 8 月。宋嘉明、孟晨林和 Stefano Ermon。去噪扩散隐式模型。在过程中。ICLR 的。OpenReview.net, 2021 年。Mirac Suzgun、Nathan Scales、Nathanael Schärli、Sebastian Gehrmann、Yi Tay、Hyung Won Chung、Aakanksha Chowdhery、Quoc V Le、Ed H Chi、Denny Zhou 等。具有挑战性的大工作目标任务以及思维链是否可以解决它们。arXiv 预印本 arXiv: 2210.09261, 2022。Ashish Vaswani、Noam Shazeer、Niki Parmar、Jakob Uszkoreit、Llion Jones、Aidan N Gomez、Łukasz Kaiser 和 Illia Polosukhin。您所需要的就是关注。神经网络信息处理系统进展, 30, 2017。叶家成、龚善三、陈立恒、林郑、高家辉、石韩、吴川、蒋欣、李振国、毕伟, 等。思想扩散: 扩散语言模型中的思想链推理。神经网络信息处理系统进展, 37: 105345–105374, 2024。叶家成、高家辉、宫山三、郑林、蒋欣、李振国和孔令鹏。超越自回归: 复杂推理和规划的离散扩散。国际学习表征会议, 2025a。叶家成、吴振宇、高家辉、吴志勇、蒋欣、李振国和孔令鹏。通过离散扩散进行隐式搜索: 国际象棋研究。国际学习表征会议, 2025b。叶家胜、郑再祥、余宝、钱丽华、顾泉泉。扩散语言模型可以通过缩放和指令微调来执行许多任务, 2025c。网址 <https://arxiv.org/abs/2308.12219>。罗温·泽勒斯、阿里·霍尔兹曼、尤纳坦·比斯克、阿里·法哈迪和 Yejin Choi。Hellaswag: 机器真的能完成你的句子吗? arXiv 预印本 arXiv:1905.07830, 2019。Lingxiao Zhao、Xueying Ding、Lijun Yu 和 Leman Akoglu。改进和统一离散和连续时间离散去噪扩散。arXiv 预印本 arXiv: 2402.03701, 2024。怀秀 Steven Cheng、Swaroop Mishra、Hugh 张、Xinyun Chen、Minmin Chen、Azade Nova、Le Hou、Heng-Tze Cheng、Quoc V. Le、Ed H. Chi 和 Denny Zhou。自然计划: 自然语言规划的 LLMS 基准测试, 2024a。网址 <https://arxiv.org/abs/2406.04520>。林正、袁剑波、雷宇、孔令鹏。用于文本生成的重新参数化离散扩散模型。语言建模会议, COLM, 2024 年 10 月 7-9 日, 宾夕法尼亚州费城, 2024b。