

大语言扩散模型

聂沉^{1,2,3*}朱凤起^{1,2,3*}尤泽斌^{1,2,3†}张晓路^{4‡}欧景阳^{1,2,3}胡军^{4‡}周军^{4‡}林彦凯^{1,2,3‡}温继荣^{1,2,3}李崇轩^{1,2,3‡§} ¹中国人民大学高瓴人工智能学院²大模型与智能治理研究北京市重点实验室

³ 教育部下一代智能搜索与推荐工程研究中心⁴蚂蚁集团{nieshen,fengqizhu,chongxuanli}@ruc.edu.cn

抽象的

人们广泛认为大型语言模型 (LLM) 的功能依赖于自回归模型 (ARM)。我们通过引入 *LLaDA* 来挑战这个概念，这是一种在预训练和监督微调 (SFT) 范式下从头开始训练的扩散模型。*LLaDA* 采用正向数据屏蔽过程和反向生成过程，由 Transformer 参数化来预测屏蔽标记。它通过优化似然下限为概率推理提供了一种有原则的生成方法。在一般任务、数学、代码等方面的广泛基准测试中，*LLaDA* 表现出强大的 *scalability*，并且性能与我们自行构建的 ARM 基准相当。值得注意的是，*LLaDA* 8B 在 *in-context learning* 方面与 *LLaMA3* 8B 等强大的 LLM 具有竞争力，并且在 SFT 之后，在多轮对话等案例研究中表现出令人印象深刻的 *instruction-following* 能力。此外，*LLaDA* 解决了逆转诅咒，在逆转诗完成任务中超越了 GPT-4o。我们的研究结果表明了扩散模型在大规模语言建模方面的前景，并挑战了上述讨论的核心 LLM 功能本质上依赖于 ARM 的普遍假设。项目页面和代码：[https://ml-
gsai.github.io/LLaDA-demo/](https://ml-
gsai.github.io/LLaDA-demo/)。

1 简介

大型语言模型 (LLM) [1] 完全属于生成建模的框架。具体来说，法学硕士旨在通过最大似然估计或等效的两个分布之间的 KL 散度最小化来优化模型分布 $p_\theta(\cdot)$ ，从而捕获真实但未知的语言分布 $p_{\text{data}}(\cdot)$ ：

$$\underbrace{\max_{\theta} \mathbb{E}_{p_{\text{data}}(x)} \log p_{\theta}(x) \Leftrightarrow \min_{\theta} \text{KL}(p_{\text{data}}(x) || p_{\theta}(x))}_{\text{Generative modeling principles}}. \quad (1)$$

主要方法依赖于自回归建模 (ARM) (通常称为“下一个标记预测”范式) 来定义模型分布：

$$\underbrace{p_{\theta}(x) = p_{\theta}(x^1) \prod_{i=2}^L p_{\theta}(x^i | x^1, \dots, x^{i-1})}_{\text{Autoregressive formulation}}, \quad (2)$$

*Equal contribution.

†Work done during an internship at Ant Group.

‡Project leaders.

§Correspondence to Chongxuan Li.




图 1: 零/少样本基准。我们从头开始将 LLaDA 扩展到 8B 参数, 并观察与强自回归 LLM 相比具有竞争力的零/少样本性能 [6]。

其中 x 是长度为 L 的序列, x^i 是第 i 个标记。这种范式已被证明非常有效[2-5], 并已成为当前法学硕士的基础。尽管它被广泛采用, 但一个基本问题仍未得到解答:

Is the autoregressive paradigm the only path to achieving the core capabilities of LLMs, such as scalability, in-context learning, and instruction-following?

我们认为答案是 *not* 一个简单的“是”。之前被忽视的关键见解是: 它是 *generative modeling principles* (, 即等式 (1)), *rather than the autoregressive formulation* (即等式(2)) 本身, 从根本上支撑了法学硕士的基本属性。

特别是, 我们认为 *scalability* 主要是 Transformer [7]、模型大小、数据大小和由等式 1 中的生成原理引起的 *Fisher consistency*⁵ [8] 之间相互作用的结果。(1), 而不是等式中 ARM 的唯一结果。(2)。扩散变换器 [9, 10] 在视觉数据 [11] 上的成功支持了这一说法。此外, *instruction-following* 和 *in-context learning* [4] 功能似乎是结构一致的语言任务上所有条件生成模型的固有属性, 而不是 ARM 的独有优势。此外, 虽然 ARM 可以解释为 *lossless data compressor* [12, 13], 但任何具有足够表达能力的概率模型都可以实现类似的功能 [14]。

然而, 法学硕士的某些固有局限性可直接归因于其自回归性质。例如, 从左到右的生成过程限制了它们处理逆向推理任务的能力[15], 凸显了当前模型泛化能力的典型失败。

受这些见解的激励, 我们引入 *LLaDA (Large Language Diffusion with mAsking)* 来研究 LLM 所展示的功能是否可以从 ARM 之外的生成建模原理中产生, 从而解决之前提出的基本问题。与传统的 ARM 相比, LLaDA 利用掩码扩散模型 (MDM) [16-20], 该模型包含前向数据掩码过程并训练 *mask predictor* 来近似其反向过程。这种设计使 LLaDA 能够构建具有双向依赖性的模型分布, 并优化其对数似然的变分下界, 从而为上述 LLM 的核心功能提供了原则性的、以前未探索过的视角。

我们采用数据准备、预训练、监督微调 (SFT) 和评估的标准流程, 将 LLaDA 扩展到前所未有的 8B 大小的语言扩散。特别是, LLaDA 8B 使用 13 万个 H800 GPU 小时从头开始对 2.3 万亿个代币进行了预训练, 随后对 450 万对进行了 SFT 训练。在语言理解、数学、代码和中文等不同任务中, LLaDA 展示了以下贡献:

- LLaDA 可有效扩展至 10^{23} FLOP 的计算预算, 实现与跨六个任务 (例如 MMLU 和 GSM8K) 的相同数据训练的 ARM 基线相当的结果。

⁵It suggests the ability to recover the true data distribution with infinite data, a sufficiently large network and optimal training.




图 2: LLaDA 概述。(一)预训练。LLaDA 在文本上进行训练，随机掩码以相同的比率 $t \sim U[0, 1]$ 独立应用于所有标记。(b) SFT。只有响应令牌可能被屏蔽。(c) 抽样。LLaDA 模拟从 $t = 1$ （完全屏蔽）到 $t = 0$ （未屏蔽）的扩散过程，通过灵活的重新屏蔽策略在每一步同时预测所有屏蔽。

- 预训练的 LLaDA 8B Base 在几乎所有 15 个标准零/少样本学习任务上都超越了 LLaMA2 7 B Base [21]，同时与 LLaMA3 8B Base [6] 表现相当，展示了有效的上下文学习能力。
- LLaDA 显著增强了 SFT 后遵循指令的能力，如多轮对话等案例研究所示。
- LLaDA 在正向和反向任务中具有一致的性能，有效地打破了反向诅咒 [15]。值得注意的是，它在逆转诗完成任务中优于 GPT-4o。

2 方法

在本节中，我们介绍 LLaDA 的概率公式⁶，以及预训练、监督微调和推理过程，如图 2 所示。

2.1 概率表述

与等式中的 ARM 不同。(2)，LLaDA 通过 *forward process* 和 *reverse process* 定义模型分布 $p_\theta(x_0)$ [16-20]。前向过程逐渐在 x_0 中独立地屏蔽标记，直到序列在 $t = 1$ 处被完全屏蔽。对于 $t \in (0, 1)$ ，序列 x_t 被部分屏蔽，每个序列都以概率 t 被屏蔽，或者以概率 $1 - t$ 保持未屏蔽。当 t 从 1 移动到 0 时，逆过程通过迭代预测屏蔽标记来恢复数据分布。

LLaDA 的核心是一个 *mask predictor*，一个参数模型 $p_\theta(\cdot|x_t)$ ，它以 x_t 作为输入并同时预测所有屏蔽标记（表示为 $\mathbf{M}$ ）。它使用仅在屏蔽标记上计算的交叉熵损失进行训练[18-20]：

$$\mathcal{L}(\theta) \triangleq -\mathbb{E}_{t, x_0, x_t} \left[\frac{1}{t} \sum_{i=1}^L \mathbf{1}[x_t^i = \mathbf{M}] \log p_\theta(x_0^i | x_t) \right], \quad (3)$$

其中 x_0 是训练样本， t 是从 $[0, 1]$ 均匀抽取的连续随机变量， x_t 是从前向过程中采样的， L 是序列长度。指示函数 $\mathbf{1}[\cdot]$ 确保仅针对屏蔽标记计算损失。

训练完成后，我们可以模拟由掩模预测器参数化的反向过程（详细信息请参见第 2.4 节），并将模型分布 $p_\theta(x_0)$ 定义为在 $t = 0$ 处引入的边缘分布。(3) 已被证明是模型分布负对数似然的上限，使其成为生成建模的原则目标：

$$-\mathbb{E}_{p_{\text{data}}(x_0)} [\log p_\theta(x_0)] \leq \mathcal{L}(\theta). \quad (4)$$

值得注意的是，LLaDA 采用在 0 和 1 之间随机变化的掩蔽比，而 BERT [22] 使用固定比率。细微的差异具有重大意义，尤其是在规模上：如图所示

⁶Here, we focus on the approach of LLaDA. A rigorous formulation of MDM is provided in Appendix A for interested readers.

等式。(4)、LLaDA 是一种有原则的生成模型，有可能自然地执行上下文学习和指令遵循，类似于法学硕士。此外，它的生成视角意味着大数据和模型的强大可扩展性，如第 2 节中所讨论的。1. 此外，MaskGIT [23] 采用启发式训练目标，与等式 1 相比，它错过了 $\frac{1}{t}$ 项。(3)，并且缺乏与最大似然的理论联系。我们强调，正是最大似然估计的理论基础促使我们扩展离散扩散模型以进行语言建模。

2.2 预训练

LLaDA 采用 Transformer [7] 作为掩模预测器，类似于现有的 LLM。然而，LLaDA 不使用因果掩码，因为它的公式允许它查看整个输入以进行预测。

我们训练了两种不同大小的 LLaDA 变体：1B 和 8B。我们在这里总结了 LLaDA 8B 和 LLaMA3 8B [6] 的模型架构，详细信息在附录 B.2 中提供。我们确保了大多数超参数的一致性，同时进行了一些必要的修改。为了简单起见，我们使用普通的多头注意力而不是分组查询注意力[24]，因为 LLaDA 与 KV 缓存不兼容，导致键和值头的数量不同。因此，注意力层有更多的参数，我们减少 FFN 维度以保持可比较的模型大小。此外，由于分词器 [4] 根据我们的数据进行了调整，因此词汇量大小有所不同。

LLaDA 模型在包含 2.3 万亿 (T) 代币的数据集上进行预训练，遵循与现有 LLM [25, 26] 紧密结合的数据协议，无需结合任何特殊技术。这些数据来自在线语料库，通过手动设计的规则和基于法学硕士的方法过滤低质量的内容。除了一般文本之外，该数据集还包含高质量代码、数学和多语言数据。有关数据集的更多详细信息，请参阅附录 B.1。数据源和域的混合由缩小的 ARM 引导。预训练过程使用 4096 个 token 的固定序列长度，总计算成本为 13 万 H800 GPU 小时，与相同规模和数据集大小的 ARM 类似。

对于训练序列 x_0 ，我们随机采样 $t \in [0, 1]$ ，以相同的概率 t 独立地屏蔽每个标记，以获得 x_t (见图 2 (a)) 并估计方程 1。(3)通过蒙特卡罗方法进行随机梯度下降训练。此外，继 Nie 等人之后。[27]，为了增强 LLaDA 处理变长数据的能力，我们将 1% 的预训练数据设置为从范围 [1, 4096] 中均匀采样的随机长度。

我们采用 Warmup-Stable-Decay [28] 学习率调度器来监控训练进度而不中断连续训练。具体来说，我们在前 2000 次迭代中将学习率从 0 线性增加到 4×10^{-4} ，并将其保持在 4×10^{-4} 。处理完 1.2T 令牌后，我们将学习率衰减到 1×10^{-4} 并在接下来的 0.8T 令牌中保持不变，以确保稳定的训练。最后，我们将最后 0.3T 令牌的学习率从 1×10^{-4} 线性降低到 1×10^{-5} 。此外，我们使用了 AdamW 优化器 [29]，其权重衰减为 0.1，批量大小为 1280，每个 GPU 的本地批量大小为 4。8B 实验执行一次，没有任何超参数调整。

2.3 有监督微调

我们通过使用配对数据 (p_0, r_0) 进行监督微调 (SFT) 来增强 LLaDA 遵循指令的能力，其中 p_0 是提示， r_0 表示响应。这是 LLM 最简单、最基本的后期培训方法。从技术上讲，这需要在预训练中对条件分布 $p_\theta(r_0|p_0)$ 而不是 $p_\theta(x_0)$ 进行建模。

实现与预训练类似。如图 2 (b) 所示，我们保留提示不变，并独立屏蔽响应中的标记，就像对 x_0 所做的那样。然后，我们将提示和屏蔽响应 r_t 提供给预先训练的屏蔽预测器，以计算 SFT 的损失：

$$-\mathbb{E}_{t, p_0, r_0, r_t} \left[\frac{1}{t} \sum_{i=1}^{L'} \mathbf{1}[r_t^i = M] \log p_\theta(r_0^i | p_0, r_t) \right], \quad (5)$$

其中 L' 表示稍后指定的动态长度，所有其他符号与之前相同。

请注意，这种方法与预训练完全兼容。本质上， p_0 和 r_0 的串联可以视为干净的预训练数据 x_0 ，而 p_0 和 r_t 的串联充当

屏蔽版本 x_t 。该过程与预训练相同，唯一的区别是所有屏蔽标记恰好出现在 r_0 部分。

LLaDA 8B 模型在包含 450 万对的数据集上进行 SFT。与预训练过程一致，数据准备和训练都遵循现有 LLM 中使用的 SFT 协议 [25, 26]，无需引入任何额外的技术来优化 LLaDA 的性能。该数据集跨越多个领域，包括代码、数学和指令跟踪。我们将 |EOS| 令牌附加到每个小批量中的短对末尾，以确保所有数据的长度相等。我们在训练期间将 |EOS| 视为普通令牌，并在采样期间将其删除，使 LLaDA 能够自动控制响应长度。详细信息请参见附录 B.1。

我们使用与预训练阶段类似的时间表在 SFT 数据上训练 3 个 epoch。在前 50 次迭代中，学习率从 0 线性增加到 2.5×10^{-5} ，然后保持恒定。在最后 10% 的迭代中，它线性减少到 2.5×10^{-6} 。此外，我们将每个 GPU 的权重衰减设置为 0.1，全局批量大小设置为 256，本地批量大小设置为 2。SFT 实验执行一次，没有任何超参数调整。

2.4 推论

作为生成模型，LLaDA 可以对新文本进行采样并评估候选文本 *in a diffusion manner instead of the left-to-right autoregressive fashion* 的可能性。

我们从反向生成过程开始。如图 2 (c) 所示，给定提示 p_0 ，我们从完全屏蔽的响应开始，离散化反向过程，从模型分布 $p_\theta(r_0|p_0)$ 中进行采样。采样步骤总数是一个超参数，它自然地为 LLaDA 提供了效率和样本质量之间的权衡，如第 2 节中分析的那样。3.3. 我们默认采用均匀分布的时间步长。此外，生成长度也被视为超参数，指定采样过程开始时完全屏蔽句子的长度。生成后，出现在 |EOS| 令牌之后的令牌将被丢弃。如附录 B.5 中详述，由于预训练和 SFT 都是使用可变长度的数据集进行的，因此最终结果对该长度超参数不敏感。

在从时间 $t \in (0, 1]$ 到 $s \in [0, t)$ 的中间步骤，我们将 p_0 和 r_t 输入到掩码预测器中，并同时预测所有掩码标记。随后，我们重新屏蔽预测标记的 s_t ，期望获得 r_s ，确保反向过程的转换与正向过程保持一致，以实现准确采样 [18-20]。原则上，重新屏蔽策略应该是纯粹随机的。然而，受到 LLM [4, 30] 中采样退火技巧的启发，我们采用了低置信度重新屏蔽策略，其中基于预测对具有最低置信度的预测标记的 s_t 进行标记，与 Chang 等人的方法相同。[23]。

我们提到 LLaDA 可以实现灵活的采样。特别是，它支持在上述预训练或 SFT 过程之后直接进行自回归和块扩散 [31] 采样，而不需要任何进一步的修改或训练。我们在附录 B.4 中提供了详细的分析。尽管如此，扩散采样（即反向生成过程）产生了最佳性能，并在本文中被采用为默认值，特别是对于第 2 节中介绍的所有实验。3.

对于条件似然评估，我们自然可以利用式 (1) 中的上限。 (5)。然而，我们发现以下等效形式 [20] 表现出更低的方差并且更稳定：

$$-\mathbb{E}_{l, r_0, r_l} \left[\frac{L}{l} \sum_{i=1}^L \mathbf{1}[r_l^i = \mathbf{M}] \log p_\theta(r_0^i | p_0, r_l) \right], \quad (6)$$

其中， L 是 r_0 的序列长度， l 是从 $\{1, 2, \dots, L\}$ 中均匀采样的， r_l 是通过从 r_0 中均匀采样 l 令牌获得的，无需替换掩码。

我们在附录 A 中介绍了训练和推理算法以及理论细节。

3 实验

我们在标准基准上评估 LLaDA 的可扩展性、指令跟踪和上下文学习能力，然后通过分析和案例研究来提供全面的评估。




图 3: LLaDA 的可扩展性。我们评估了 LLaDA 和我们的 ARM 基线的性能，这些基线在相同的数据上通过增加预训练计算 FLOP 进行训练。LLaDA 表现出强大的可扩展性，在六项任务上的整体性能与 ARM 相匹配。

3.1 LLaDA 在语言任务上的可扩展性

我们首先研究 LLaDA 在下游任务上的 *scalability* 并与我们构建的 ARM 基线进行比较。具体来说，在 1B 规模上，我们确保 LLaDA 和 ARM 共享相同的架构、数据和所有其他配置。在更大的规模上，我们还报告了由于资源限制而在相同数据上训练的大小略有不同的 LLaDA 和 ARM 模型的结果。详细内容请参见附录 B.2。我们使用预训练计算成本作为统一的缩放指标。为了进行评估，我们重点关注六项标准且多样化的任务。

图3显示LLaDA展现出令人印象深刻的可扩展性，其整体趋势与ARM具有很强的竞争力。值得注意的是，在MMLU和GSM8K等任务上，LLaDA表现出更强的可扩展性。即使在 PIQA 等相对较弱的任务上，与 ARM 的性能差距也会随着规模的增加而缩小。为了考虑异常值的影响，我们选择不拟合定量曲线，以避免潜在的误解。尽管如此，结果清楚地证明了 LLaDA 的可扩展性。

考虑到 LLaDA 在某些基准上的优势，我们假设这种性能增益源于一个关键的架构差异：虽然自回归模型仅优化从左到右的条件概率，但 LLaDA 经过训练可以考虑多个条件方向，如附录 A.2 中详述，这可能会提供更大的灵活性并导致更好的泛化。这一假设是由 LLaDA 在第 2 节逆向推理上的出色表现所激发的。3.3 和附录 B.4 中抽样策略的消融研究。

聂等人。[27] 表明 MDM 需要比 ARM 多 16 倍的计算才能实现相同的可能性。然而，关键的差异使我们的研究结果具有更广泛的适用性。特别是，似然度是下游任务性能的一个相对间接的指标，而扩散优化了似然度的界限，使其无法与 ARM 直接比较。此外，我们将缩放范围从 Nie 等人的 $10^{18} \sim 10^{20}$ FLOPs 扩展到了 $10^{18} \sim 10^{23}$ FLOPs in this work.

3.2 基准测试结果

为了全面评估 LLaDA 8B 的 *in-context learning* 和 *instruction-following* 能力，我们与类似规模的现有 LLM [6,21,25,26,32,33] 进行了详细比较。任务选择和评估协议遵循现有研究，涵盖一般任务、数学、代码和中文的流行基准。附录 B.6 提供了更多详细信息。为了进行更直接的比较，我们在实施中重新评估了代表性的法学硕士 [6, 21]。

如表所示。如图 1 所示，在 2.3T 代币上进行预训练后，LLaDA 8B Base 表现出了出色的性能，几乎在所有任务上都超越了 LLaMA2 7B Base，总体上与 LLaMA3 8B Base 具有竞争力。LLaDA 在数学和语文任务中显示出优势。我们推测

表 1: 预培训法学硕士的基准结果。* 表示模型在相同协议下评估, 详见附录 B.6。†和¶所示的结果来自Yang等人。[25, 26] 和 Bi 等人。[32] 分别。括号中的数字表示用于上下文学习的镜头数量。“-”表示未知数据。

	LLaDA 8B*	LLaMA3 8B*	LLaMA2 7B*	Qwen2 7B†	Qwen2.5 7B†	Mistral 7B†	Deepseek 7B¶
Model	Diffusion	AR	AR	AR	AR	AR	AR
Training tokens	2.3T	15T	2T	7T	18T	-	2T
General Tasks							
MMLU	65.9 (5)	65.4 (5)	45.9 (5)	70.3 (5)	74.2 (5)	64.2 (5)	48.2 (5)
BBH	49.7 (3)	62.1 (3)	39.4 (3)	62.3 (3)	70.4 (3)	56.1 (3)	39.5 (3)
ARC-C	45.9 (0)	53.1 (0)	46.3 (0)	60.6 (25)	63.7 (25)	60.0 (25)	48.1 (0)
Hellaswag	70.5 (0)	79.1 (0)	76.0 (0)	80.7 (10)	80.2 (10)	83.3 (10)	75.4 (0)
TruthfulQA	46.1 (0)	44.0 (0)	39.0 (0)	54.2 (0)	56.4 (0)	42.2 (0)	-
WinoGrande	74.8 (5)	77.3 (5)	72.5 (5)	77.0 (5)	75.9 (5)	78.4 (5)	70.5 (0)
PIQA	73.6 (0)	80.6 (0)	79.1 (0)	-	-	-	79.2 (0)
Mathematics & Science							
GSM8K	70.3 (4)	48.7 (4)	13.1 (4)	80.2 (4)	85.4 (4)	36.2 (4)	17.4 (8)
Math	31.4 (4)	16.0 (4)	4.3 (4)	43.5 (4)	49.8 (4)	10.2 (4)	6.0 (4)
GPQA	25.2 (5)	25.9 (5)	25.7 (5)	30.8 (5)	36.4 (5)	24.7 (5)	-
Code							
HumanEval	35.4 (0)	34.8 (0)	12.8 (0)	51.2 (0)	57.9 (0)	29.3 (0)	26.2 (0)
HumanEval-FIM	73.8 (2)	73.3 (2)	26.9 (2)	-	-	-	-
MBPP	40.0 (4)	48.8 (4)	23.2 (4)	64.2 (0)	74.9 (0)	51.1 (0)	39.0 (3)
Chinese							
CMMLU	69.9 (5)	50.7 (5)	32.5 (5)	83.9 (5)	-	-	47.2 (5)
C-Eval	70.5 (5)	51.7 (5)	34.0 (5)	83.2 (5)	-	-	45.0 (5)

表 2: 经过培训的法学硕士的基准结果。LLaDA 仅采用 SFT 过程, 而其他模型则具有额外的强化学习 (RL) 对齐。* 表示模型在相同协议下评估, 详见附录 B.6。†和¶所示的结果来自Yang等人。[26] 和毕等人。[32] 分别。括号中的数字表示用于上下文学习的镜头数量。“-”表示未知数据。

	LLaDA 8B*	LLaMA3 8B*	LLaMA2 7B*	Qwen2 7B†	Qwen2.5 7B†	Gemma2 9B†	Deepseek 7B¶
Model	Diffusion	AR	AR	AR	AR	AR	AR
Training tokens	2.3T	15T	2T	7T	18T	8T	2T
Post-training Alignment pairs	SFT 4.5M	SFT+RL -	SFT+RL -	SFT+RL 0.5M +-	SFT+RL 1M + 0.15M	SFT+RL -	SFT+RL 1.5M +-
General Tasks							
MMLU	65.5 (5)	68.4 (5)	44.1 (5)	-	-	-	49.4 (0)
MMLU-pro	37.0 (0)	41.9 (0)	4.6 (0)	44.1 (5)	56.3 (5)	52.1 (5)	-
Hellaswag	74.6 (0)	75.5 (0)	51.5 (0)	-	-	-	68.5 (-)
ARC-C	88.5 (0)	82.4 (0)	57.3 (0)	-	-	-	49.4 (-)
Mathematics & Science							
GSM8K	69.4 (4)	78.3 (4)	29.0 (4)	85.7 (0)	91.6 (0)	76.7 (0)	63.0 (0)
Math	31.9 (0)	29.6 (0)	3.8 (0)	52.9 (0)	75.5 (0)	44.3 (0)	15.8 (0)
GPQA	33.3 (5)	31.9 (5)	28.4 (5)	34.3 (0)	36.4 (0)	32.8 (0)	-
Code							
HumanEval	49.4 (0)	59.8 (0)	16.5 (0)	79.9 (0)	84.8 (0)	68.9 (0)	48.2 (-)
MBPP	41.0 (4)	57.6 (4)	20.6 (4)	67.2 (0)	79.2 (0)	74.9 (0)	35.2 (-)

LLM 数据集的优势与其在某些任务中相对较弱的性能源于相同的因素——数据质量和分布的差异, 这很大程度上是由于 LLM 数据集的闭源情况。

值得注意的是, 我们以GSM8K为例, 仔细排除了数据泄露的可能性。首先, 如图 3 所示, LLaDA 在 GSM8K 方面的性能优于 ARM 基线。此外, 结论仍然是附录 B.8 中完全未见过的类似 GSM8K 的任务 [34]。

此外, 选项卡。图 2 比较了 LLaDA 8B Instruct 与现有法学硕士的性能。SFT 提高了 LLaDA 在大多数下游任务上的性能。MMLU 等一些指标出现下降, 可能是由于 SFT 数据质量欠佳。总的来说, 由于我们没有进行对齐

表 3: 采样过程的可视化和生成的多轮对话。在 LLaDA 的响应中，较深的颜色表示在采样后期预测的标记，而较浅的颜色对应于早期的预测。

<i>Sampling Process</i>	
User	Lily can run 12 kilometers per hour for 4 hours. After that, she runs 6 kilometers per hour. How many kilometers can she run in 8 hours?
LLaDA	
<i>Multi-round Dialogue Case</i>	
User	Could you please share with me what the initial two lines of the renowned poem ‘The Road Not Taken’?
LLaDA	Certainly! The initial two lines of the renowned poem “The Road Not Taken” by Robert Frost are: “Two roads diverged in a yellow wood, And sorry I could not travel both.” These lines set the stage for the poem, introducing the idea of a speaker facing a choice between two paths.
User	Please help me translate into Chinese.
LLaDA	Sure! The first two lines of “The Road Not Taken” by Robert Frost can be translated into Chinese as: “两条路分岔在黄色的树林中，遗憾我不能同时走”
User	Please translate into German.
LLaDA	Sure! The first two lines of “The Road Not Taken” by Robert Frost can be translated into German as: “Zwei Wege trennten sich im gelben Wald, und leider konnte ich nicht beide tun.”
User	Please also write a poem about life choices. I require 5 sentences, and the first word of each sentence starts with C as the first letter.
LLaDA	Certainly! Here’s a poem about life choices, with each sentence starting with the letter “C”: Choices cascade through life’s journey, Creating connections with each decision, Careful consideration leads to better paths, Courageous choices shape our destiny, Choosing wisely guides us through the years.

通过强化学习 (RL)，我们的结果略落后于 LLaMA3 8B Instruct，尽管许多指标的差距仍然很小。值得注意的是，即使只有 SFT，LLaDA 也表现出了令人印象深刻的指令跟踪能力，如第 2 节所述。3.4.我们将基于强化学习的对齐留到未来的工作中。

所有结果都在秒中。3 基于纯扩散方法，因为它们比结合自回归组件的方法实现了更好的整体性能。具体来说，我们使用等式。(6) 用于条件似然估计并应用低置信度重掩蔽进行采样。对于 LLaDA 8B Instruct，块扩散式采样在 GSM8K 和 Math 上表现更好，得分为 78.6 和 42.2，而表 2 中的得分为 69.4 和 31.9。2. 这一增益是由于 SFT 数据中大量的 |EOS| 令牌填充造成的，导致低置信度重屏蔽提前终止。详细内容请参见附录B.4。

总体而言，尽管缺乏数据透明度，但我们已尽一切努力采用标准化程序并引入多样化的任务，我们相信它们充分展示了 LLaDA 的非凡能力，这是据我们所知唯一有竞争力的非自回归模型。

3.3 逆向推理与分析

为了量化模型的逆向推理 [15] 能力，我们遵循 Allen-Zhu 和 Li [35] 中建立的协议。具体来说，我们构建了 496 个中国著名诗歌句子对的数据集。给定一首诗中的一个句子，模型的任务是生成后续行（向前）或前一行（反向），而无需额外的微调。示例可以在 B.9 节中找到。与之前的研究相比，这种设置提供了直接且更现实的评估 [27, 36]。

如表所示。如图 4 所示，LLaDA 有效地解决了 *reversal curse* [15]，在正向和反向任务中展示了一致的零样本性能。相比之下，Qwen 2.5 和 GPT-4o 都表现出两者之间的显著差距。前向生成的结果证实，两种 ARM 都很强大，受益于比 LLaDA 更大的数据集和更大的计算资源。然而，LLaDA 在逆转任务中远远优于两者。

我们没有为逆转任务设计任何特殊的東西。直观上，LLaDA 统一对待代币，没有归纳偏差，从而实现平衡的性能。详细信息参见附录A.2。

我们还分析了 LLaDA 不同采样策略的效果，包括自回归采样、块扩散[31]采样和纯扩散采样，表明纯扩散采样实现了最佳的整体性能，详见附录 B.4。

表 4: 诗歌完成任务的比较。

	Forward	Reversal
GPT-4o (2024-08-06)	82.7	34.3
Qwen2.5-7B Instruct	75.9	38.0
LLaDA-8B Instruct	51.8	45.6

此外，我们还检查了 LLaDA 的采样速度和内存消耗，表明它可以在生成质量和速度之间进行灵活的权衡。更多详细信息，请参见附录 B.7。

无分类器引导 (CFG) [37, 27] 是扩散模型中广泛使用的一种技术，用于提高生成质量。为了确保与 ARM 的公平比较，我们在正文中没有将 CFG 应用于 LLaDA。然而，我们表明 LLaDA 与 CFG 兼容，并且始终受益于其应用。更多详细信息，请参见附录 B.3。

3.4 案例研究

我们在选项卡中展示了由 LLaDA 8B Instruct 生成的示例。3、展示其指令跟随能力。首先，该表说明了 LLaDA 以非自回归方式生成连贯、流畅和扩展文本的能力。其次，它突出了模型的多轮对话能力，有效保留对话历史并跨多种语言生成适合上下文的响应。据我们所知，LLaDA 的这种 *chat* 功能令人印象深刻，因为它首次区别于传统的 ARM。更多案例研究请参见附录 B.10。

4 相关工作

扩散模型 [38-40] 在视觉领域取得了显著的成功，但在大规模（例如，使用超过 10^{23} FLOP 训练的模型）语言建模方面仍未得到验证，尽管人们的兴趣日益浓厚，研究工作也越来越广泛。

一种简单的方法是连续化文本数据并直接应用连续扩散模型[41-51]。或者，一些方法对离散分布的连续参数进行建模[52-56]。然而，可扩展性仍然是这些方法的重大挑战。例如，1B 模型可能需要 ARM 的 64 倍计算才能实现相当的性能 [57]。

另一种方法用具有新的正向和反向动力学的离散过程代替连续扩散，从而产生许多变体[58-71]。原始扩散模型论文[38]在统一扩散框架下引入了连续状态和离散状态转换内核。奥斯汀等人。[16]是将离散扩散模型引入语言建模的开创性工作之一，证明了这种方法的可行性。卢等人。[17]表明，掩蔽扩散作为离散扩散的一种特例，在 GPT-2 规模上实现了与 ARM 相当或超过 ARM 的困惑度。施等人。[18]，萨胡等人。[19]，欧等人。[20]建立了基础理论成果，激发了我们的模型设计、训练和推理（详细信息请参见附录A）。聂等人。[27]介绍了语言建模中 MDM 的缩放法则，并探讨了如何利用 MDM 来完成语言任务，例如 GPT-2 规模的问答。龚等人。[72]展示了在 MDM 框架内微调 ARM 的潜力。然而，Gong 等人观察到的改进。[72]仅限于特定的指标，并且他们的方法没有解决通过纯粹的基于扩散的训练可实现的性能。并行工作[73]展示了扩散语言模型在代码生成中的潜力，并强调了它们在推理效率方面的优势。尽管如此，由于它是一个闭源产品，训练程序和采样方法等具体细节仍然未知。

相比之下，这项研究从头开始将 MDM 扩展到前所未有的 8B 参数大小，实现了与 LLaMA 3 等领先的法学硕士相当的性能。

此外，图像生成 [23, 74, 75] 的并行工作与 MDM 在文本数据上的应用非常吻合。此外，MDM 在蛋白质等其他领域也显示出了前景

一代 [76, 77], 他们取得了有希望的成果。值得注意的是, 一系列研究 [31, 78–87] 探索了架构优化、蒸馏和采样算法设计等技术来加速 MDM 采样。

5 结论与讨论

我们引入了 LLaDA, 这是一种从头开始训练的扩散语言模型, 具有前所未有的 8B 参数规模。LLaDA 在可扩展性、上下文学习和指令遵循方面表现出强大的能力, 其性能可与 LLaMA3 等强大的法学硕士相媲美。此外, LLaDA 还具有双向建模、增强鲁棒性等独特优势, 有效解决了现有法学硕士的相关局限性。我们的研究结果表明了扩散模型在大规模语言建模方面的前景, 并挑战了这些基本功能本质上与 ARM 相关的普遍假设。这些结果代表了语言建模的新范式, 并揭示了新颖的见解, 展示了高度的科学创新。

局限性。尽管前景广阔, 但扩散模型的全部潜力仍有待充分探索。这项工作的一些局限性为未来的研究提供了重要的机会。生成长度是用户指定的超参数。尽管 LLaDA 对附录 B.5 中详述的超参数不敏感, 但我们相信采用自适应生成长度将提供更有效的解决方案。由于计算限制, LLaDA 和 ARM 之间的直接比较 (例如在相同数据集上进行训练) 仅限于小于 10^{23} FLOP 的计算预算。为了分配资源来训练尽可能大的 LLaDA 模型并展示其潜力, 我们无法将 ARM 基线扩展到相同的程度。此外, LLaDA 没有设计专门的注意力机制或位置嵌入, 也没有应用任何系统级架构优化, 例如 KV 缓存。在推理方面, 更高效、更可控的 [37, 88, 89] 采样算法仍处于初步阶段。此外, LLaDA 尚未与强化学习保持一致 [90, 91], 这对于提高其性能并与人类意图保持一致至关重要。

展望未来, LLaDA 的模型规模和训练数据量仍然小于领先的 ARM 同类产品 [6, 26, 92–95], 这凸显了需要进一步扩展以充分评估其能力。此外, LLaDA 处理多模式数据的能力仍有待探索。它对即时调整技术 [96] 和集成到基于代理的系统 [97, 98] 的影响仍未完全了解。最后, 需要对 LLaDA (例如 O1 类系统 [99, 100]) 的后训练进行系统研究, 以进一步释放扩散语言模型的潜力。

致谢

该工作得到国家自然科学基金项目 (No. 92470118) 的资助; 北京市自然科学基金 (No. L247030); 北京新星计划 (No. 20220484044); 和蚂蚁集团研究基金。

参考

- [1] 赵鑫、周昆、李俊毅、唐天一、王小雷、侯宇鹏、敏前、张北辰、张俊杰、董子灿等。大型语言模型的调查。 *arXiv preprint arXiv:2303.18223*, 2023。
- [2] 亚历克·雷德福。通过生成预训练提高语言理解, 2018。
- [3] Alec Radford、Jeffrey Wu、Rewon Child、David Lu an、Dario Amodei、Ilya Sutskever 等人。语言模型是无监督的多任务学习者。 *OpenAI blog*, 1(8):9, 2019。
- [4] 汤姆·B·布朗。语言模型是小样本学习者。 *arXiv preprint arXiv:2005.14165*, 2020。
- [5] OpenAI。ChatGPT: 优化对话语言模型。 *OpenAI blog*, 2022 年 11 月。URL <https://openai.com/blog/chatgpt/>。

- [6] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan 等。骆驼 3 群模型。 *arXiv preprint arXiv:2407.21783*, 2024 年。
- [7] 阿什什·瓦斯瓦尼。您所需要的就是关注。 *arXiv preprint arXiv:1706.03762*, 2017 年。
- [8] 罗纳德·费舍尔。理论统计的数学基础。 *Philosophical transactions of the Royal Society of London. Series A, containing papers of a mathematical or physical character*, 222(594-604): 309–368, 1922。
- [9] 鲍凡, 聂沉, 薛凯文, 曹悦, 李崇轩, 苏航, 朱军。所有这些都值得一提: 扩散模型的 vit 骨干。 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第 22669–22679 页, 2023 年。
- [10] 威廉·皮布尔斯, 谢赛宁。具有变压器的可扩展扩散模型。 *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 第 4195–4205 页, 2023 年。
- [11] 蒂姆·布鲁克斯、比尔·皮布尔斯、康纳·霍姆斯、威尔·德普、郭宇飞、李静、大卫·施努尔、乔·泰勒、特洛伊·卢曼、埃里克·卢曼、克拉伦斯·吴、瑞奇·王和阿迪亚·拉梅什。视频生成模型作为世界模拟器。 2024。URL <https://openai.com/research/video-generation-models-as-world-simulators>。
- [12] Gregoire Deletang, Anian Ruoss, Paul-Ambroise Duquenne, Elliot Catt, Tim Genewein, Christopher Mattern, Jordi Grau-Moya, Li Kevin Wenliang, Matthew Aitchison, Laurent Orseau 等。语言建模是压缩。在 *The Twelfth International Conference on Learning Representations* 中。
- [13] 黄玉珍, 张静涵, 单子飞, 何俊贤。压缩以线性方式表示智能。 *arXiv preprint arXiv:2404.09937*, 2024 年。
- [14] 克劳德·埃尔伍德·香农。通信的数学理论。 *The Bell system technical journal*, 27(3): 379–423, 1948。
- [15] Lukas Berglund, Meg Tong, Max Kaufmann, Mikita Balesni, Asa Cooper Stickland, Tomasz Korbak 和 Owain Evans。逆转诅咒: 受过 “a is b” 训练的 LLMs 无法学习 “b is a”。 *arXiv preprint arXiv:2309.12288*, 2023 年。
- [16] 雅各布·奥斯汀、丹尼尔·D·约翰逊、乔纳森·何、丹尼尔·塔洛和瑞安·范登伯格。离散状态空间中的结构化去噪扩散模型。 *Advances in Neural Information Processing Systems*, 34: 17981–17993, 2021。
- [17] 楼亚伦, 孟晨林, 斯特凡诺·埃尔蒙。通过估计数据分布的比率进行离散扩散语言建模。 *arXiv preprint arXiv:2310.16834*, 2023 年。
- [18] 施家新, 韩克航, 王哲, Arnaud Doucet, Michalis K Titsias。离散数据的简化和广义掩蔽扩散。 *arXiv preprint arXiv:2406.04329*, 2024 年。
- [19] Subham Sekhar Sahoo, Marianne Arriola, Yair Schiff, Aaron Gokaslan, Edgar Marroquin, Justin T Chiu, Alexander Rush 和 Volodymyr Kuleshov。简单有效的掩蔽扩散语言模型。 *arXiv preprint arXiv:2406.07524*, 2024 年。
- [20] 欧景阳, 聂沉, 薛凯文, 朱凤起, 孙家成, 李振国, 李崇轩。您的吸收离散扩散秘密地模拟了干净数据的条件分布。 *arXiv preprint arXiv:2406.03736*, 2024 年。
- [21] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale 等。Llama 2: 开放基础和微调的聊天模型。 *arXiv preprint arXiv:2307.09288*, 2023 年。
- [22] 雅各布·德夫林。Bert: 用于语言理解的深度双向转换器的预训练。 *arXiv preprint arXiv:1810.04805*, 2018。
- [23] 张慧文, 张涵, 蒋璐, 刘策, 威廉·T·弗里曼。Maskgit: 蒙版生成图像转换器。 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第 11315–11325 页, 2022 年。

[24] Joshua Ainslie, James Lee-Thorp, Michiel de Jong, Yury Zemlyanskiy, Federico Lebron and Sumit Sanghai. Gqa: 从多头检查点训练广义多查询变压器模型。

Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 第 4895-4901页, 2023年。[25] An Yang, Baosong Yang, Binyuan Hui, Bo Cheng, Bowen Yu, Chang Zhou, Chengpeng Li, Chengyuan Li, Dayiheng Liu, Fei Huang, Guanting Dong, Haoran Wei, Huan Lin, Jialong Tang, Jialin Wang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Ma, Jianxin Yang, Jin Xu, Jingren Zhou, 白金泽、何金正、林俊阳、党凯、陆克明、陈克勤、杨可欣、李梅、薛明峰、倪娜、张培、王鹏、彭茹、门瑞、高瑞泽、林润吉、王世杰、白帅、谭思南、朱天行、李天浩、刘天宇、葛文斌、邓晓东、周小欢、任兴章、张新宇、魏西品、任宣成、刘雪静、范阳、姚洋、张益昌、万宇、褚云飞、刘玉琼、崔泽宇、张振如、郭志芳和范志浩。Qwen2 技术报告, 2024 年。URL <https://arxiv.org/abs/2407.10671>。[26] 杨安、杨宝松、张北辰、惠斌源、郑波、余博文、李成远、刘大一恒、黄飞、魏浩然、林焕、杨建、屠建宏、张建伟、杨建新、杨家喜、周静仁、林俊阳、党凯、卢克明、包克勤、杨可欣、余乐、李美、薛明峰、张培、朱勤、门锐、林润吉、李天浩、夏廷宇、任兴章、任宣成、杨帆、杨苏、张宜昌、万宇、刘玉琼、崔泽宇、张振如和邱子涵。Qwen2.5技术报告。 *arXiv preprint arXiv:2412.15115*, 2024。[27] 聂沉, 朱凤起, 杜超, 庞天宇, 刘谦, 曾光涛, 林敏, 李崇轩。放大文本上的蒙版扩散模型。 *arXiv preprint arXiv:2410.18514*, 2024。[28] 胡胜定, 涂玉革, 韩旭, 何超群, 崔甘曲, 龙翔, 郑志, 方业伟, 黄宇翔, 赵伟林, 等。Minicpm: 通过可扩展的训练策略揭示小语言模型的潜力。 *arXiv preprint arXiv:2404.06395*, 2024 年。

[29]我洛希洛夫。解耦权重衰减正则化。 *arXiv preprint arXiv:1711.05101*, 2017。

[30] Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes 和 Yejin Choi。神经文本退化的奇怪案例。 *arXiv preprint arXiv:1904.09751*, 2019。[31] Marianne Arriola, Aaron Gokaslan, Justin T Chiu, Zhihan Yang, Zhixuan Qi, Jiaqi Han, Subham Sekhar Sahoo 和 Volodymyr Kuleshov。块扩散: 在自回归和扩散语言模型之间进行插值。 *arXiv preprint arXiv:2503.09573*, 2025 年。

[32] 毕晓, 陈德利, 陈冠廷, 陈善皇, 戴大麦, 邓成奇, 丁宏辉, 董凯, 杜秋实, 付哲, 等。Deepseek llm: 以长期主义扩展开源语言模型。 *arXiv preprint arXiv:2401.02954*, 2024 年。

[33] Albert Q Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier 等。米斯特拉尔 7b。 *arXiv preprint arXiv:2310.06825*, 2023 年。

[34] 叶天, 徐子成, 李远志, 朱泽远。语言模型物理学: 第 2.1 部分, 小学数学和隐藏的推理过程。 *ArXiv e-prints*, abs/2407.20311, 2024 年 7 月。完整版本可在 <http://arxiv.org/abs/2407.20311> 获取。

[35] 朱泽元, 李元志。语言模型物理学: 第 3.2 部分, 知识操纵。 *ArXiv e-prints*, abs/2309.14402, 2023 年 9 月。完整版本可在 <http://arxiv.org/abs/2309.14402> 获取。

[36] Ouail Kitouni, Niklas Nolte, Diane Bouchacourt, Adina Williams, Mike Rabbat 和 Mark Ibrahim。因子分解诅咒: 您预测的哪些标记是逆转诅咒等的基础。 *arXiv preprint arXiv:2406.05183*, 2024 年。

[37] 乔纳森·何和蒂姆·萨利曼。无分类器的扩散指导。 *arXiv preprint arXiv:2207.12598*, 2022 年。

- [38] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan 和 Surya Ganguli。使用非平衡热力学的深度无监督学习。在 *International conference on machine learning* 中, 第 2256-2265 页。PMLR, 2015。
- [39] 乔纳森·何 (Jonathan Ho)、阿杰·贾恩 (Ajay Jain) 和彼得·阿贝尔 (Pieter Abbeel)。去噪扩散概率模型。 *Advances in neural information processing systems*, 33: 6840–6851, 2020。
- [40] 宋杨、Jascha Sohl-Dickstein、Diederik P Kingma、Abhishek Kumar、Stefano Ermon 和 Ben Poole。通过随机微分方程基于分数的生成模型。 *arXiv preprint arXiv:2011.13456*, 2020。
- [41] 李翔, John Thickstun, Ishaan Gulrajani, Percy S Liang, Tatsunori B Hashimoto。Diffusion-lm 改进了可控文本生成。 *Advances in Neural Information Processing Systems*, 35: 4328–4343, 2022。
- [42] 龚善三, 李木凯, 冯江涛, 吴志勇, 孔令鹏。Diffuseq: 使用扩散模型生成序列到序列文本。 *arXiv preprint arXiv:2210.08933*, 2022 年。
- [43] 韩晓创, Sachin Kumar, Yulia Tsvetkov。Ssd-lm: 用于文本生成和模块化控制的半自回归单纯形扩散语言模型。 *arXiv preprint arXiv:2210.17432*, 2022 年。
- [44] Robin Strudel, Corentin Tallec, Florent Althé, Yilun Du, Yaroslav Ganin, Arthur Mensch, Will Grathwohl, Nikolay Savinov, Sander Dieleman, Laurent Sifre 等。用于文本生成的自调节嵌入扩散。 *arXiv preprint arXiv:2211.04236*, 2022 年。
- [45] 陈婷, 张瑞祥, 杰弗里·辛顿。模拟位: 使用具有自调节功能的扩散模型生成离散数据。 *arXiv preprint arXiv:2208.04202*, 2022 年。
- [46] Sander Dieleman, Laurent Sartran, Arman Roshannai, Nikolay Savinov, Yaroslav Ganin, Pierre H Richemond, Arnaud Doucet, Robin Strudel, Chris Dyer, Conor Durkan 等。分类数据的连续扩散。 *arXiv preprint arXiv:2211.15089*, 2022 年。
- [47] 皮埃尔·H·里奇蒙德、桑德·迪勒曼和阿诺·杜塞。具有单纯形扩散的分类 sdes, 2022。
- [48] 吴童, 范志浩, 刘晓, 宫业云, 沉业龙, 焦健, 郑海涛, 李俊涛, 魏中字, 郭建, 段南, 陈伟珠。Ar-扩散: 用于文本生成的自回归扩散模型, 2023。
- [49] Rabeeh Karimi Mahabadi, Hamish Ivison, Jaesung Tae, James Henderson, Iz Beltagy, Matthew E. Peters 和 Arman Cohan。Tess: 文本到文本自条件单纯形扩散, 2024。
- [50] 叶家胜, 郑再祥, 鲍玉, 钱丽华, 王明轩。Dinoiser: 通过操纵噪声进行扩散条件序列学习。 *arXiv preprint arXiv:2302.10025*, 2023 年。
- [51] 张一哲, 顾家涛, 吴卓峰, 翟双飞, Joshua Susskind, Navdeep Jaitly。Planner: 通过潜在语言扩散模型生成多样化的段落。 *Advances in Neural Information Processing Systems*, 36: 80178–80190, 2023。
- [52] 亚伦·卢和斯特凡诺·埃尔蒙。反射扩散模型, 2023。
- [53] 亚历克斯·格雷夫斯、鲁佩什·库马尔·斯里瓦斯塔瓦、蒂莫西·阿特金森和福斯蒂诺·戈麦斯。贝叶斯流网络。 *arXiv preprint arXiv:2308.07037*, 2023 年。
- [54] 林正浩, 宫业云, 沉业龙, 吴童, 范志浩, 林陈, 端南, 陈伟珠。使用扩散语言模型生成文本: 一种具有连续段落降噪的预训练方法。在 *International Conference on Machine Learning* 中, 第 21051-21064 页。PMLR, 2023。
- [55] 薛凯文, 周宇豪, 聂沉, 徐敏, 张晓璐, 周军, 李崇轩。通过随机微分方程统一贝叶斯流网络和扩散模型。 *arXiv preprint arXiv:2404.15766*, 2024 年。

- [56] 张瑞祥, 翟双飞, 张一哲, 詹姆斯·桑顿, 欧紫晶, Joshua Susskind, Navdeep Jaitly。目标具体分数匹配: 离散扩散的整体框架。 *arXiv preprint arXiv:2504.16431*, 2025 年。
- [57] Ishaan Gulrajani 和 Tatsunori B Hashimoto。基于可能性的扩散语言模型。 *Advances in Neural Information Processing Systems*, 2024 年 36 日。
- [58] Emiel Hoogetboom, Didrik Nielsen, Priyank Jaini, Patrick Forré 和 Max Welling。Argmax 流和多项式扩散: 学习分类分布。 *Advances in Neural Information Processing Systems*, 34: 12454–12465, 2021。
- [59] Emiel Hoogetboom, Alexey A Gritsenko, Jasmijn Bastings, Ben Poole, Rianne van den Berg 和 Tim Salimans。自回归扩散模型。 *arXiv preprint arXiv:2110.02037*, 2021 年。
- [60] 何正福, 孙天祥, 王宽宁, 黄宣景, 邱西鹏。Diffusion-bert: 用扩散模型改进生成屏蔽语言模型。 *arXiv preprint arXiv:2211.15029*, 2022 年。
- [61] 安德鲁·坎贝尔, 乔·本顿, 瓦伦丁·德博托利, 托马斯·雷恩福斯, 乔治·德利吉安尼迪和阿尔诺·杜塞特。离散去噪模型的连续时间框架。 *Advances in Neural Information Processing Systems*, 35: 28266–28279, 2022。
- [62] 孟晨琳, 崔克里斯蒂, 宋家明, 斯特凡诺·埃尔蒙。具体分数匹配: 离散数据的广义分数匹配。 *Advances in Neural Information Processing Systems*, 35: 34532–34545, 2022。
- [63] Machel Reid, Vincent J. Hellendoorn 和 Graham Neubig。扩散器: 通过基于编辑的重建实现离散扩散, 2022 年。
- [64] 孙浩然, 于立军, 戴波, Dale Schuurmans, 戴汉军。基于分数的连续时间离散扩散模型。 *arXiv preprint arXiv:2211.16750*, 2022 年。
- [65] Ouail Kitouni, Niklas Nolte, James Hensman 和 Bhaskar Mitra。磁盘: 结构化知识的扩散模型。 *arXiv preprint arXiv:2312.05253*, 2023 年。
- [66] 林正, 袁建波, 雷宇, 孔令鹏。用于文本生成的重新参数化离散扩散模型。 *ArXiv*, abs/2302.05737, 2023。
- [67] 陈子祥, 袁慧卓, 李永谦, 寇一文, 张俊凯, 谷泉泉。通过离散扩散模型的去随机化进行快速采样。 *arXiv preprint arXiv:2312.09193*, 2023 年。
- [68] 叶家胜, 郑再祥, 鲍玉, 钱丽华, 谷泉泉。扩散语言模型可以通过缩放和指令微调来执行许多任务。 *arXiv preprint arXiv:2308.12219*, 2023 年。
- [69] Itai Gat, Tal Remez, Neta Shaul, Felix Kreuk, Ricky TQ Chen, Gabriel Synnaeve, Yossi Adi 和 Yaron Lipman。离散流匹配。 *arXiv preprint arXiv:2407.15595*, 2024 年。
- [70] 郑凯文, 陈永新, 毛涵子, 刘明宇, 朱军, 张勤生。掩蔽扩散模型是秘密的与时间无关的掩蔽模型, 并利用不准确的分类采样, 2024 年。URL <https://arxiv.org/abs/2409.02908>。
- [71] 什里亚斯·卡普尔, 埃里克·詹纳和斯图尔特·拉塞尔。用于程序综合的语法树的扩散。 *arXiv preprint arXiv:2405.20519*, 2024 年。
- [72] 龚珊珊, Shivam Agarwal, 张一哲, 叶家成, 郑林, 李木凯, 安晨欣, 赵培林, 毕伟, 韩家伟, 等。通过适应自回归模型来扩展扩散语言模型。 *arXiv preprint arXiv:2410.17891*, 2024 年。
- [73] Samar Khanna, Siddhant Kharbanda, Shufan Li, Harshit Varma, Eric Wang, Sawyer Birnbaum, Ziyang Luo, Yanis Miraoui, Akash Palrecha, Stefano Ermon 等。Mercury: 基于扩散的超快速语言模型。 *arXiv preprint arXiv:2506.17298*, 2025 年。

- [74] 张慧文、张涵、Jarred Barber、AJ Maschinot、Jose Lezama、Lu Jiang、Ming-Hsuan Yang、Kevin Murphy、William T Freeman、Michael Rubinstein 等。Muse：通过屏蔽生成转换器生成文本到图像。 *arXiv preprint arXiv:2301.00704*, 2023 年。
- [75] 尤泽斌, 欧景阳, 张小鲁, 胡军, 周军, 李崇轩。有效且高效的蒙版图像生成模型。 *arXiv preprint arXiv:2503.07197*, 2025 年。
- [76] 王新友, 郑再祥, 叶飞, 薛冬雨, 黄书建, 谷泉泉。扩散语言模型是多功能的蛋白质学习器。 *arXiv preprint arXiv:2402.18567*, 2024 年。
- [77] 王新友, 郑再祥, 叶飞, 薛东宇, 黄书剑, 谷泉泉。Dplm-2: 多模式扩散蛋白质语言模型。 *arXiv preprint arXiv:2410.13782*, 2024 年。
- [78] 寇思琪, 胡兰翔, 何哲智, 邓志杰, 张浩。Cllms: 一致性大语言模型。 *arXiv preprint arXiv:2403.00835*, 2024 年。
- [79] 徐晨凯, 王旭, 廖振毅, 李义顺, 侯天奇, 邓志杰。Show-o Turbo: 加速统一多模式理解和生成。 *arXiv preprint arXiv:2502.05415*, 2025 年。
- [80] Sulin Liu、Juno Nam、Andrew Campbell、Hannes Stärk、Yilun Xu、Tommi Jaakkola 和 Rafael Gómez-Bombarelli。边生成边思考: 离散扩散和计划去噪。 *arXiv preprint arXiv:2410.06264*, 2024 年。
- [81] 朱远志, 王曦, Stéphane Lathuilière, Vicky Kalogeiton。Dimo: 将掩模扩散模型提炼为一步生成器。 *arXiv preprint arXiv:2503.15457*, 2025 年。
- [82] 任一诺, 陈浩轩, 朱雨辰, 郭伟, 陈永新, Grant M Rotskoff, 陶莫雷, 应乐兴。离散扩散模型的快速求解器: 高阶算法的理论和应用。 *arXiv preprint arXiv:2502.00234*, 2025 年。
- [83] Satoshi Hayakawa、Yuhta Takida、Masaaki Imaizumi、Hiromi Wakaki 和 Yuki Mitsufuji。通过维度相关性进行离散扩散的蒸馏。 *arXiv preprint arXiv:2410.08709*, 2024 年。
- [84] 赵一秀, 施家新, 陈锋, Shaul Druckmann, Lester Mackey, Scott Linderman。离散扩散模型的知情校正器。 *arXiv preprint arXiv:2407.21243*, 2024 年。
- [85] 郑凯文, 陈永新, 毛涵子, 刘明宇, 朱军, 张勤生。掩蔽扩散模型是秘密的与时间无关的掩蔽模型, 并利用不准确的分类采样。 *arXiv preprint arXiv:2409.02908*, 2024 年。
- [86] Yong-Hyun Park、Chieh-Hsin Lai、Satoshi Hayakawa、Yuhta Takida 和 Yuki Mitsufuji。跳跃你的步骤: 优化离散扩散模型的采样计划。在 *The Thirteenth International Conference on Learning Representations*, 2024 年。
- [87] 贾斯汀·德斯切诺和卡格拉·古尔切雷。超越自回归: 通过时间自蒸馏实现快速 llms。 *arXiv preprint arXiv:2410.21035*, 2024 年。
- [88] 普拉富拉·达里瓦尔和亚历山大·尼科尔。扩散模型在图像合成方面击败了甘斯。 *Advances in neural information processing systems*, 34: 8780–8794, 2021。
- [89] Yair Schiff、Subham Sekhar Sahoo、Hao Phung、Guanghan Wang、Sam Boshar、Hugo Dallatorre、Bernardo P de Almeida、Alexander Rush、Thomas Pierrot 和 Volodymyr Kuleshov。离散扩散模型的简单引导机制。 *arXiv preprint arXiv:2412.10193*, 2024 年。
- [90] 欧阳龙, 吴杰弗里, 江旭, 迪奥戈·阿尔梅达, 卡罗尔·温赖特, 帕梅拉·米什金, 张冲, 桑迪尼·阿加瓦尔, 卡塔琳娜·斯拉马, 亚历克斯·雷, 等。训练语言模型遵循人类反馈的指令。 *Advances in neural information processing systems*, 35: 27730–27744, 2022。

- [91]拉斐尔·拉法洛夫、阿奇特·夏尔马、埃里克·米切尔、克里斯托弗·D·曼宁、斯特凡诺·埃尔蒙和切尔西·芬恩。直接偏好优化：你的语言模型实际上是一个奖励模型。*Advances in Neural Information Processing Systems*, 2024 年 36 日。
- [92] Josh Achiam、Steven Adler、Sandhini Agarwal、Lama Ahmad、Ilge Akkaya、Florescia Leoni Aleman、Diogo Almeida、Janko Altmenschmidt、Sam Altman、Shyamal Anadkat 等。Gpt-4 技术报告。 *arXiv preprint arXiv:2303.08774*, 2023 年。
- [93] 谷歌。我们的下一代模型：Gemini 1.5, 2024 年。URL <https://blog.google/technology/ai/google-gemini-next-Generation-model-february-2024>。
- [94] 人择。克劳德 3.5 十四行诗, 2024 年。URL <https://www.anthropic.com/news/claude-3-5-sonnet>。
- [95] 刘爱新, 冯北, 薛冰, 王秉轩, 吴伯超, 陆成达, 赵成刚, 邓成启, 张晨宇, 阮冲, 等。Deepseek-v3 技术报告。 *arXiv preprint arXiv:2412.19437*, 2024 年。
- [96] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, 等。思维链提示引发大型语言模型中的推理。*Advances in neural information processing systems*, 35: 24824–24837, 2022。
- [97] Joon Sung Park, Joseph O’ Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang 和 Michael S Bernstein。生成代理：人类行为的交互式拟像。在 *Proceedings of the 36th annual acm symposium on user interface software and technology*, 第 1-22 页, 2023 年。
- [98] 王雷, 马陈, 冯雪阳, 张泽宇, 杨浩, 张景森, 陈志远, 唐家凯, 陈旭, 林彦凯, 等。基于大语言模型的自治代理的调查。 *Frontiers of Computer Science*, 18(6): 186345, 2024。
- [99] 开放人工智能。使用 llms 学习推理, 2024 年。URL <https://openai.com/index/learning-to-reason-with-llms/>。
- [100] 郭大亚, 杨德建, 张浩伟, 宋俊晓, 张若宇, 徐润鑫, 朱启浩, 马世荣, 王培毅, 毕晓, 等。Deepseek-r1: 通过强化学习激励 llms 的推理能力。*arXiv preprint arXiv:2501.12948*, 2025 年。
- [101] 贝尼尼奥·乌里亚、伊恩·默里和雨果·拉罗谢尔。一个深入且易于处理的密度估计器。在 *Proceedings of the 31th International Conference on Machine Learning*, 2014 年。
- [102] Andy Shih、Dorsa Sadigh 和 Stefano Ermon。以正确的方式对任意阶自回归模型进行训练和推理。在 *Proceedings of the 31th International Conference on Machine Learning*, 2022 年。
- [103] 徐章辰, 江凤庆, 牛路瑶, 邓云天, Radha Poovendran, Yejin Choi, Bill Yuchen Lin。Magpie: 通过提示对齐 llms, 从头开始对齐数据合成。 *arXiv preprint arXiv:2406.08464*, 2024 年。
- [104] 魏宇翔, 王哲, 刘家伟, 丁一峰, 张令明。Magicoder: 使用 oss-instruct 增强代码生成能力。 *arXiv preprint arXiv:2312.02120*, 2023 年。
- [105] 张彪, Rico Sennrich。均方根层归一化。 *Advances in Neural Information Processing Systems*, 2019 年 32 日。
- [106] 诺姆·沙泽尔。Glu 变体改进了变压器。 *arXiv preprint arXiv:2002.05202*, 2020。[107] 苏建林, Murtadha Ahmed, 陆宇, 潘胜峰, 波文, 刘云峰。Roformer: 具有旋转位置嵌入的增强型变压器。 *Neurocomputing*, 568: 127063, 2024。
- [108] 贾里德·卡普兰、萨姆·麦坎德利什、汤姆·赫尼汉、汤姆·B·布朗、本杰明·切斯、雷旺·柴尔德、斯科特·格雷、亚历克·雷德福德、杰弗里·吴和达里奥·阿莫迪。神经语言模型的缩放定律。 *arXiv preprint arXiv:2001.08361*, 2020。

- [109] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark 等。训练计算优化的大型语言模型。 *arXiv preprint arXiv:2203.15556*, 2022 年。
- [110] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song 和 Jacob Steinhardt。测量大规模多任务语言理解。 *arXiv preprint arXiv:2009.03300*, 2020。
- [111] Mirac Suzgun, Nathan Scales, Nathanael Schärli, Sebastian Gehrmann, Yi Tay, Hyung Won Chung, Aakanksha Chowdhery, Quoc V Le, Ed H Chi, Denny Zhou 等。具有挑战性的大工作台任务以及思维链是否可以解决它们。 *arXiv preprint arXiv:2210.09261*, 2022 年。
- [112] Peter Clark, Isaac Cowhey, Oren Etzioni, Tushar Khot, Ashish Sabharwal, Carissa Schoenick 和 Oyvind Tafjord。您认为您已经解决了问答问题吗？尝试 arc, ai2 推理挑战赛。 *arXiv preprint arXiv:1803.05457*, 2018。
- [113] Rowan Zellers, Ari Holtzman, Yonatan Bisk, Ali Farhadi 和 Yejin Choi。Hellaswag: 机器真的能完成你的句子吗？ *arXiv preprint arXiv:1905.07830*, 2019。
- [114] 斯蒂芬妮·林、雅各布·希尔顿和欧文·埃文斯。Truthfulqa: 衡量模型如何模仿人类的谎言。 *arXiv preprint arXiv:2109.07958*, 2021 年。
- [115] Keisuke Sakaguchi, Ronan Le Bras, Chandra Bhagavatula 和 Yejin Choi。Winogrande: 大规模的对抗性 winograd 模式挑战。 *Communications of the ACM*, 64(9): 99–106, 2021。
- [116] Yonatan Bisk, Rowan Zellers, 高剑峰, Yejin Choi, 等。Piqa: 用自然语言推理物理常识。在 *Proceedings of the AAAI conference on artificial intelligence*, 2020 年。
- [117] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano 等。培训验证员解决数学应用题。 *arXiv preprint arXiv:2110.14168*, 2021 年。
- [118] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song 和 Jacob Steinhardt。使用数学数据集衡量数学问题的解决能力。 *arXiv preprint arXiv:2103.03874*, 2021 年。
- [119] David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael 和 Samuel R Bowman。Gpqa: 研究生级别的谷歌验证问答基准。 *arXiv preprint arXiv:2311.12022*, 2023 年。
- [120] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde De Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman 等。评估在代码上训练的大型语言模型。 *arXiv preprint arXiv:2107.03374*, 2021 年。
- [121] Mohammad Bavarian, Heewoo Jun, Nikolas Tezak, John Schulman, Christine McLeavey, Jerry Tworek 和 Mark Chen。高效训练语言模型来填补这中间的空缺。 *arXiv preprint arXiv:2207.14255*, 2022 年。
- [122] Jacob Austin, Augustus Odena, Maxwell Nye, Maarten Bosma, Henryk Michalewski, David Dohan, Ellen Jiang, Carrie Cai, Michael Terry, Quoc Le 等。使用大型语言模型进行程序综合。 *arXiv preprint arXiv:2108.07732*, 2021 年。
- [123] 李浩南, 张逸轩, Fajri Koto, 杨一飞, 赵海, 宫业云, 段楠, 蒂莫西·鲍德温。Cmmlu: 测量中文的大规模多任务语言理解。 *arXiv preprint arXiv:2306.09212*, 2023 年。
- [124] 黄玉珍, 白玉琢, 朱志豪, 张俊雷, 张静涵, 苏唐军, 刘俊腾, 吕传成, 张一凯, 付耀, 等。C-eval: 针对基础模型的多层次多学科中文评估套件。 *Advances in Neural Information Processing Systems*, 2024 年 36 日。

[125] Leo Gau、Jonathan Tow、Baber Abbasi、Stella Biderman、Sid Black、Anthony DiPofi、Charles Foster、Laurence Golding、Jeffrey Hsu、Alain Le Noac’h、Haonan Li、Kyle McDonnell、Niklas Muennighoff、Chris Ociepa、Jason Phang、Laria Reynolds、Hailey Schoelkopf、Aviya Skowron、Lintang Sutawika、Eric唐、安尼什·蒂特、本·王、凯文·王和安迪·邹。少量语言模型评估框架，2024 年 7 月。URL <https://zenodo.org/records/12608602>。

Algorithm 1 Pre-training of LLaDA

Require: mask predictor p_θ , data distribution p_{data}

- 1: **repeat**
 - 2: $x_0 \sim p_{\text{data}}$ # with a probability of 1%, the sequence length of x_0 follows $\text{U}[1, 4096]$
 - 3: $t \sim \text{U}(0, 1]$
 - 4: $x_t \sim q_{t|0}(x_t|x_0)$ # $q_{t|0}$ is defined in Eq. (7)
 - 5: Calculate $\mathcal{L} = -\frac{1}{t \cdot L} \sum_{i=1}^L \mathbf{1}[x_t^i = \text{M}] \log p_\theta(x_0^i|x_t)$ # L is the sequence length of x_0
 - 6: Calculate $\nabla_\theta \mathcal{L}$ and run optimizer.
 - 7: **until** Converged
 - 8: **Return** p_θ
-

Algorithm 2 Supervised Fine-Tuning of LLaDA

Require: mask predictor p_θ , pair data distribution p_{data}

- 1: **repeat**
 - 2: $p_0, r_0 \sim p_{\text{data}}$ # please refer to Appendix B.1 for details about the SFT dat
 - 3: $t \sim \text{U}(0, 1]$
 - 4: $r_t \sim q_{t|0}(r_t|r_0)$ # $q_{t|0}$ is defined in Eq. (7)
 - 5: Calculate $\mathcal{L} = -\frac{1}{t \cdot L'} \sum_{i=1}^{L'} \mathbf{1}[r_t^i = \text{M}] \log p_\theta(r_0^i|p_0, r_t)$ # L' is the sequence length of r_0
 - 6: Calculate $\nabla_\theta \mathcal{L}$ and run optimizer.
 - 7: **until** Converged
 - 8: **Return** p_θ
-

Algorithm 3 Conditional Log-likelihood Evaluation of LLaDA

Require: mask predictor p_θ , prompt p_0 , response r_0 , the number of Monte Carlo estimations n_{mc}

- 1: $\log_likelihood = 0$
 - 2: **for** $i \leftarrow 1$ to n_{mc} **do**
 - 3: $l \sim \{1, 2, \dots, L\}$ # L is the sequence length of r_0
 - 4: Obtain r_l by uniformly sampling l tokens from r_0 without replacement for masking
 - 5: $\log_likelihood = \log_likelihood + \frac{L}{l} \sum_{i=1}^L \mathbf{1}[r_l^i = \text{M}] \log p_\theta(r_0^i|p_0, r_l)$
 - 6: **end for**
 - 7: $\log_likelihood = \log_likelihood / n_{mc}$
 - 8: **Return** $\log_likelihood$
-

掩蔽扩散模型的制定

A.1 培训

MDM [16-20] 以不同于自回归模型的方式定义模型分布 $p_\theta(x_0)$ 。

这些模型引入了由时间 $t \in [0, 1]$ 索引的前向过程 $\{x_t\}$ 。此过程逐渐且独立地屏蔽序列 x_0 中的所有标记。在时间 $t = 0$ 时，数据点 x_0 在没有掩模的情况下被完全观察到，而对于 $t \in (0, 1]$ ， x_t 表示期望中具有不同掩模比率的潜在变量。

形式上，给定 x_0 的 x_t 的条件分布由完全因式分解的形式定义：

$$q_{t|0}(x_t|x_0) = \prod_{i=1}^L q_{t|0}(x_t^i|x_0^i), \quad (7)$$

其中每个标记的条件分布由下式给出：

$$q_{t|0}(x_t^i|x_0^i) = \begin{cases} 1 - t, & x_t^i = x_0^i, \\ t, & x_t^i = \text{M}. \end{cases} \quad (8)$$

这里，M表示掩码标记。直观上，每个标记要么保持不变，要么被屏蔽，被屏蔽的概率随着 t 从 0 到 1 线性增加。在 $t = 1$ 时，所有

Algorithm 4 Random Remasking Strategy of LLaDA

Require: mask predictor p_θ , prompt p_0 , answer length L , sampling steps N

```

1: Set  $r_1$  is a fully masked sequence of length  $L$ .
2: for  $t \leftarrow 1$  down to  $\frac{1}{N}$  step  $\frac{1}{N}$  do
3:    $s = t - \frac{1}{N}$ 
4:    $r_0 = \arg \max_{r_0} p_\theta(r_0 | p_0, r_t)$  # we employ greedy sampling when predicting masked tokens
5:   for  $i \leftarrow 1$  to  $L$  do
6:     if  $r_t^i \neq \mathbf{M}$  then
7:        $r_0^i = r_t^i$ 
8:     else
9:       with probability  $\frac{s}{t}$ ,  $r_0^i$  is set to  $\mathbf{M}$ 
10:    end if
11:  end for
12:   $r_s = r_0$ 
13: end for
14: Return  $r_0$ 
  
```

令牌保证被屏蔽，这意味着 x_1 遵循集中于完全屏蔽令牌序列的狄拉克分布。值得注意的是，线性掩蔽概率与连续扩散模型中的噪声表类似但又不同[38-40]。这种线性性的动机是假设文本中的信息与平均标记数量成正比，因此在前向过程中线性丢失信息是合理的。

前向过程不仅是可逆的，而且还对应于在所有令牌上完全因式分解的反向过程。相反的过程，从时间 $t = 1$ 到 0 ，从完全屏蔽的标记序列生成新数据。对于 $0 \leq s < t \leq 1$ ，逆过程的条件分布可分解为：

$$q_{s|t}(x_s | x_t) = \prod_{i=1}^L q_{s|t}(x_s^i | x_t^i), \quad (9)$$

其中每个标记的条件分布为：

$$q_{s|t}(x_s^i | x_t^i) = \begin{cases} 1, & x_t^i \neq \mathbf{M}, x_s^i = x_t^i, \\ \frac{s}{t}, & x_t^i = \mathbf{M}, x_s^i = \mathbf{M}, \\ \frac{t-s}{t} q_{0|t}(x_s^i | x_t^i), & x_t^i = \mathbf{M}, x_s^i \neq \mathbf{M}, \\ 0, & \text{otherwise.} \end{cases} \quad (10)$$

因此，要估计的关键函数是条件分布 $q_{0|t}(x_s^i | x_t^i)$ ，它可以预测原始标记（如果它在输入 x_t 中被屏蔽）。这类似于连续扩散模型中的 *data prediction* 形式。

事实证明我 [20]，一个等效的 *time-free* 参数化可以是 $q_{0|t}(x_s^i | x_t^i)$ 为：

$$q_{0|t}(x_s^i | x_t^i) = p_{\text{data}}(x_0^i | x_t^{\text{UM}}), \quad \forall i \text{ such that } x_t^i = \mathbf{M}, \quad (11)$$

其中 x_t^{UM} 表示 x_t 中未屏蔽标记的集合，它与原始数据 x_0 中的相应标记相同，因为未屏蔽标记仅由 x_0 确定并且与时间 t 无关。直观上，这意味着估计数据预测函数相当于估计干净数据的条件分布，这是时不变的。因此，不需要提供时间 t 作为参数模型的输入。

尽管掩蔽扩散的开发并不平凡，但实现起来却很简单。我们首先介绍 *mask predictor*，一个参数模型 $p_\theta(\cdot | x_t)$ （例如没有因果掩码的 Transformer），它将任何 t 的 x_t 作为输入，并同时预测所有掩码令牌。然后，我们将模型分布 $p_\theta(x_0)$ 定义如下：从 x_1 作为完全屏蔽标记的序列开始，我们模拟由 $p_\theta(\cdot | x_t)$ 参数化的从 $t = 1$ 到 0 的近似反向过程。在 $t = 0$ 处引入的边际分布代表模型分布 $p_\theta(x_0)$ 。

算法5 LLaDA 的低置信度重屏蔽策略 要求：屏蔽预测器 p_θ 、提示 p_0 、答案长度 L 、采样步骤 N 1: 集合 r_1 是长度为 L 的完全屏蔽序列。 2: 对于 $t \leftarrow 1$ 向下到 $\frac{1}{N}$ 步骤 $\frac{1}{N}$ do 3: $s = t - \frac{1}{N}$ 4: 对于 $i \leftarrow 1$ 到 L do 5: if $r_t^i \neq \mathbf{M}$ then 6: $r_0^i = r_t^i, c^i = 1$ 7: else 8: $r_0^i = \arg \max_{r_0^i} p_\theta(r_0^i | p_0, r_t)$ 9: $c^i = p_\theta(r_0^i | p_0, r_t)_{r_0^i}$ 10: 结束 if 11: 结束 for 12: $n_{un} = \lfloor L(1 - s) \rfloor$ # 时间步长 s 中未屏蔽的标记数量为 n_{un} 13: 对于 $i \leftarrow 1$ 到 L 执行 14: if $c^i \in \text{Lowest} - n_{un} (\{c^i\}_1^L)$ then 15: $r_0^i = \mathbf{M}$ # 选择置信度最低的 n_{un} 位置进行重新屏蔽。 16: 结束 if 17: 结束 for 18: $r_s = r_0$ 19: 结束 for 20: 返回 r_0

正式地，掩模预测器是使用带有掩模的交叉熵损失来训练的：

$$\mathcal{L}(\theta) \triangleq -\mathbb{E}_{t, x_0, x_t} \left[\frac{1}{t} \sum_{i=1}^L \mathbf{1}[x_t^i = \mathbf{M}] \log p_\theta(x_0^i | x_t) \right], \quad (12)$$

其中 x_0 是从训练数据中采样的， t 是从 $[0, 1]$ 中均匀采样的， x_t 是从 $q_{t|0}(x_t | x_0)$ 中采样的。指示函数 $\mathbf{1}[\cdot]$ 确保仅针对屏蔽标记计算交叉熵损失。在石等人。[18]，萨胡等人。[19]，欧等人。[20]，已经证明损失函数 $\mathcal{L}(\theta)$ 是模型分布的负对数似然的上限：

$$-\mathbb{E}_{x_0 \sim p_{\text{data}}(x_0)} [\log p_\theta(x_0)] \leq \mathcal{L}(\theta). \quad (13)$$

总之，这种原则方法通过在正向过程中逐步屏蔽标记并在反向过程中学习恢复数据分布来训练生成模型，所有这些都在（近似）最大似然估计框架下进行。

A.2 推论

方程中的交叉熵损失。(12)有几种等价形式[20]。第一个由下式给出

$$-\mathbb{E}_{l \sim \{1, 2, \dots, L\}, x_0, x_l} \left[\frac{L}{l} \sum_{i=1}^L \mathbf{1}[x_l^i = \mathbf{M}] \log p_\theta(x_0^i | x_l) \right], \quad (14)$$

其中， l 是从 $\{1, 2, \dots, L\}$ 中均匀采样的，而 x_l 是通过从 x_0 中均匀采样 l 标记获得的，无需替换掩码。尽管精确屏蔽 l 标记与以概率 t 独立屏蔽每个标记不同，但这两种屏蔽方法会产生与预期相同的结果[20]。

而方程。(12)和等式。(14)期望相同，方差不同。直观地说，在等式中。(12)，我们期望 x_t 有一部分 t 标记被屏蔽。然而，前向过程（即式(7)）的随机性常常会导致偏差，特别是当 x_t 包含很少的标记时。相反，在等式中。(14)， x_l 中屏蔽标记的比例是确定性的 $\frac{l}{L}$ 。虽然理论分析取决于数据分布，但实证结果表明，方程：(12)需要超过1000次蒙特卡罗估计才能获得稳定的结果，而方程(12)需要超过1000次蒙特卡罗估计才能获得稳定的结果。(14)仅用128个估计就达到了稳定性。此外，我们可以简单地修改方程：(14)基于等式(14)到其条件版本（即等式(6)）(5)。

任意阶自回归模型（AO-ARM）[59,101,102]以自回归方式描述了 L 变量的所有可能阶数 π 的联合分布。为了学习这样的分布，AO-ARM 使用权重共享神经网络对所有单变量条件进行建模，并使用掩码标记来表示不存在的变量。在训练期间，所有阶 U_π 均匀分布的预期负对数似然被最小化：

$$-\mathbb{E}_{x_0, \pi \sim U_\pi} \left[\sum_{i=1}^L \log p_\theta(x_0^{\pi(i)} | x_0^{\pi(<i)}; \pi) \right]. \quad (15)$$

直观上， $x_0^{\pi(<i)}$ 可以理解为屏蔽标记 x_t ，其中 $\pi(\geq i)$ 中的索引被屏蔽。可以进一步证明Eq. (15) 等价于式(15)。(12)。这种联系解释了 LLaDA 的双向推理功能，尽管它从未在推理过程中明确使用过。

此外，聂等人。[27]引入了无监督无分类器指导（CFG），这是一种平衡提示对齐和文本多样性的即插即用技术。具体来说，无监督 CFG 采用以下修改后的掩模预测器进行推理：

$$\tilde{p}_\theta(r_0 | p_0, r_t) \propto \frac{p_\theta(r_0 | p_0, r_t)^{1+w}}{p_\theta(r_0 | m, r_t)^w}, \quad (16)$$

其中 m 是与 p_0 长度相同的掩码序列， w 是控制 p_0 强度的可调超参数。为了确保与 ARM 的公平比较，我们在正文中没有将 CFG 应用于 LLaDA。然而，如附录 B.3 所示，LLaDA 与 CFG 完全兼容，并且在应用时始终表现出改进的性能。

A.3 算法

在本节中，我们介绍训练和推理算法。具体来说，我们分别在算法1和算法2中介绍预训练和监督微调算法。此外，算法3中提供了似然评估算法。最后，我们在算法4和算法5中提出了反向生成过程，分别对应于随机重新屏蔽和低置信度[23]重新屏蔽策略。

B 实验

B.1 数据收集和预处理

在本节中，我们首先介绍预训练和 SFT 的数据收集和过滤过程。然后我们描述 LLaDA 在训练期间如何利用这些数据集。

我们的预训练语料库是根据各种公开来源构建的，包括网络数据、书籍、学术论文、社交媒体、百科全书、数学和代码，其中大约 11% 中文、61% 英文和 28% 代码。数据清理过程涉及 PDF 文本提取、重复数据删除和有害内容过滤。为了进一步确保质量，我们对 BERT [22] 模型进行了微调，用于自动数据质量注释，从而能够选择更高质量的样本。我们的 SFT 数据集由 100 万个人工注释样本和 350 万个合成样本组成，这些样本是使用类似于 Xu 等人提出的方法生成的。[103]，魏等人。[104]。

我们将预训练语料库中收集的文档连接起来，并根据预定义的序列长度将文本分割成固定长度的序列。

对于 SFT，采用动态序列长度策略，其中 $|\text{EOS}|$ 令牌被附加到较短对的末尾，以确保每个小批量内所有样本的序列长度一致。值得注意的是，填充 $|\text{EOS}|$ 令牌被视为响应的一部分，即被屏蔽并包含在训练目标中。在采样期间， $|\text{EOS}|$ 令牌将从生成的输出中删除。此策略确保模型通过生成 $|\text{EOS}|$ 学习控制其响应的长度，从而使响应长度能够与给定的提示有效地保持一致。

此外，对于 n 轮对话 $(p_0^0, r_0^0, p_0^1, r_0^1, \dots, p_0^{n-1}, r_0^{n-1})$ ，我们将其视为 n 单轮对话对，即 $(p_0^0, r_0^0), (p_0^0 r_0^0 p_0^1, r_0^1), \dots, (p_0^0 r_0^0 p_0^1 \dots p_0^{n-1}, r_0^{n-1})$ 并随机采样一个。这种数据划分策略不仅使 LLaDA 具备多轮对话能力，而且与上述 $|\text{EOS}|$ 填充策略保持一致。

表 5: 模型架构。我们报告了 1B 和 7B ARM 基准、1B 和 8B LLaDA 模型以及 8B LLaMA3 模型的架构配置。

	Our ARM Baseline 1B	LLaDA 1B	Our ARM Baseline 7B	LLaDA 8B	LLaMA3 8B
Layers	22	22	28	32	32
Model dimension	2048	2048	4096	4096	4096
Attention heads	32	32	32	32	32
Vocabulary size	126,464	126,464	126,464	126,464	128,000
FFN dimension	5634	5634	13,440	12,288	14,336
Key/Value heads	4	4	8	32	8
Total parameters	1.49 B	1.49 B	6.83 B	8.02 B	8.03 B
Non-embedding parameters	0.97 B	0.97 B	5.80 B	6.98 B	6.98 B

表 6: CFG 上的消融。CFG 不断提高 LLaDA 的性能。

	ARC-C	Hellaswag	TruthfulQA	WinoGrande	GPQA	PIQA
w/o CFG	45.9	70.5	46.1	74.8	25.2	73.6
w/ CFG	47.9	72.5	46.4	74.8	26.1	74.4

B.2 模型训练细节

本节提供 LLaDA 和相应 ARM 基线的训练详细信息。

首先，为了提高效率，我们训练了 ARM 和 MDM，两者都具有 1.5B 参数和相同的架构。此外，我们将 MDM 扩展到 8B 参数。由于计算资源限制，我们没有训练具有相同架构的 8B 自回归模型。相反，我们利用之前训练的 7B 自回归模型进行比较。这四个模型用于第二节的可扩展性分析。3.1.

我们为我们训练的 ARM 和 MDM 采用了类似于 LLaMA [6, 21] 的 Transformer 架构。具体来说，我们采用 RMSNorm [105] 来稳定训练，使用 SwiGLU [106] 作为激活函数来增强非线性，并集成 RoPE [107] 以获得更具表现力的位置编码。标签。图 5 提供了模型架构的概述。

对于 1B 和 7B ARM 基线以及 1B 和 8B LLaDA 模型，我们使用权重衰减为 0.1 的 AdamW 优化器 [29]，并采用 Warmup-Stable-Decay [28] 学习率调度器。在前 2000 次迭代中，学习率从 0 线性增加到最大值，然后保持恒定。对于 LLaDA 8B，为了确保稳定的训练，在预训练期间降低了一次学习率，如第 2 节所述。2.2. 对于 1B ARM 基线以及 1B 和 8B LLaDA 模型，最大学习率设置为 4×10^{-4} ，批量大小为 1280，无需任何超参数调整。对于 7B ARM 基线，最大学习率设置为 4.2×10^{-4} ，批量大小为 4224，两者都是通过网格搜索选择的。

此外，我们采用广泛使用的 $6ND$ 公式 [108, 109] 来计算图 3 中的训练 FLOP，其中 N 表示非嵌入参数的数量， D 表示训练令牌的总数。表 3 中提供了对应于图 3 的详细结果。18 和选项卡。19.

B.3 无分类器指导的消融

本节介绍了无分类器引导 (CFG) 的消融研究。关于 CFG 的理论细节可以在附录 A.2 中找到。

为简单起见，我们选择了六个代表性基准测试，包括 ARC-C、HellaSwag、TruthfulQA、WinoGrande、PIQA 和 GPQA，并使用 LLaDA 8B Base 进行实验。我们在 {0.5, 1, 1.5, 2} 中搜索每个任务的 CFG 尺度，并报告最佳结果。如表所示。6、CFG 持续改进 LLaDA 的性能。我们强调，为了确保与 ARM 的公平比较，论文报告的主要结果中没有使用 CFG。




图 4: LLaDA 支持的灵活采样策略。彩色方块表示未屏蔽的标记，而标有 $\times$ 的方块表示屏蔽的标记。在此图中，块扩散和块扩散 LLaDA 采样的块长度均为 4。

表 7: LLaDA 8B Base 采样策略的消融。 L' 是块长度。纯扩散采样实现了最佳的整体性能。

		BBH	GSM8K	Math	HumanEval	MBPP
Autoregressive		38.1	63.1	23.6	18.3	33.4
Block Diffusion	$L' = 2$	37.3	62.6	25.2	14.6	33.6
	$L' = 4$	40.0	65.7	26.6	15.9	36.0
	$L' = 8$	42.0	68.2	27.7	19.5	39.2
	$L' = 32$	45.7	68.6	29.7	29.9	37.4
Block Diffusion LLaDA	$L' = 2$	48.0	70.0	30.8	26.2	40.0
	$L' = 4$	48.5	70.3	31.3	27.4	38.8
	$L' = 8$	48.6	70.2	30.9	31.1	39.0
	$L' = 32$	48.3	70.3	31.2	32.3	40.0
Pure Diffusion		49.7	70.3	31.4	35.4	40.0

表 8: LLaDA 8B 指令采样策略的消融。为了提高效率，块长度设置为 32。纯扩散采样实现了最佳的整体性能。

	GSM8K	Math	HumanEval	MBPP	GPQA	MMLU-Pro	ARC-C
Autoregressive	0	9.5	0	0	0	0	84.4
Block Diffusion	24.6	23.5	17.1	21.2	29.3	32.5	88.1
Block Diffusion LLaDA	77.5	42.2	46.3	34.2	31.3	34.8	85.4
Pure Diffusion	69.4	31.9	49.4	41.0	33.3	37.0	88.5

B.4 抽样策略的细节和简化

在本节中，我们首先介绍LLaDA支持的不同采样策略。然后，我们提出消融研究来评估这些采样策略的性能。

灵活的抽样策略。在秒。2.4、图2(c)说明了LLaDA的逆向生成过程。如图4所示，除了反向生成过程之外，LLaDA还支持在预训练或SFT阶段之后直接进行自回归和块扩散[31]采样，而不需要任何进一步的修改或重新训练。块扩散采样在每个块内应用原点逆过程以及跨块的自回归采样。在原始的块扩散过程中，序列长度是动态变化的。如图4 (c) 所示，LLaDA还可以采用固定长度的块扩散策略，我们将其称为块扩散LLaDA，也称为半自回归重掩蔽。

实验设置。我们使用 LLaDA 8B Base 和 LLaDA 8B Instruct 评估不同的采样策略进行综合分析。对于 LLaDA 8B Base，我们使用表 1 中的五个基准测试。1 基于抽样而不是似然估计进行评估。对于 LLaDA 8B Instruct，我们使用表 1 中的七个指标。2，不包括 MMLU 和 Hella Swag，因为这两个任务只需要模型生成单个令牌（即 A、B、C 或 D）。在所有设置中，都会生成一个令牌。

表 9: 随机和低置信度重新屏蔽策略的分析。低置信度重新屏蔽始终优于随机重新屏蔽。

Length	BBH	GSM8K	Math	HumanEval	MBPP
Random Remasking	32.1	21.3	9.2	11.6	21.0
Low-confidence Remasking	45.0	70.0	30.3	32.9	40.2

表 10: 世代长度的消融。结果对长度超参数不敏感。

Length	BBH	GSM8K	Math	HumanEval	MBPP
256	45.0	70.0	30.3	32.9	40.2
512	50.4	70.8	30.9	32.9	39.2
1024	49.7	70.3	31.4	35.4	40.0

每个采样步骤。对于自回归和块扩散采样，生成在生成 |EOS| 代币时终止。对于块扩散 LLaDA（即半自回归重新掩码）和纯扩散采样，LLaDA 8B Base 的生成长度固定为 1024，而对于 LLaDA 8B Instruct，它从 {64, 256, 512} 调整以平衡效率和性能。低置信度重掩蔽适用于块扩散和块扩散 LLaDA 中的块内扩散采样，以及纯扩散采样。我们还测试了 LLaDA 8B Base 的不同块长度。对于 LLaDA 8B Instruct，我们仅评估块长度 32 的效率，因为它在 LLaDA 8B Base 上产生最佳结果。

此外，对于 LLaDA 8B Instruct，由于 SFT 数据中 |EOS| 令牌的大量填充（如第 B.1 节中详述），我们观察到在纯扩散采样下，模型输出中 |EOS| 令牌的比例变得非常高。这会导致代数极短并降低模型性能。为了缓解这个问题，对于 HumanEval、MBPP、GSM8K、Math 和 GPQA，我们在纯扩散采样期间将 |EOS| 令牌的置信度分数设置为零。此调整有助于在生成过程中保持适当的 |EOS| 代币比例。

最后，我们进行消融研究，以分析使用纯扩散采样的随机和低置信度重新掩蔽策略的效果。为了提高效率，我们在此分析中使用 LLaDA 8B Base，其生成长度和采样步长设置为 256。

结果。如表所示。7、对于块扩散采样，整体性能随着块长度的增加而提高。此外，两个选项卡。7 和选项卡。图 8 显示块扩散采样始终优于自回归采样，并且块扩散 LLaDA 采样进一步改进了标准块扩散采样。最后，纯扩散采样实现了最佳的整体性能。

此外，选项卡。图 9 显示，低置信度重新屏蔽策略始终优于随机重新屏蔽策略。我们假设低置信度重掩码的功能类似于 ARM 中默认使用的退火采样方法，通过减少生成句子的多样性来提高准确性。

我们发现自回归采样会导致 LLaDA 8B Instruct 的性能非常差。这是因为每个 SFT 数据都是一个完整的句子，因此给定序列长度，LLaDA 8B Instruct 倾向于在该长度内生成完整的句子。相比之下，LLaDA 8B Base 不会遇到这个问题，因为预训练数据由截断的文档组成（如附录 B.1 中详述），并且模型是使用随机序列长度进行训练的（如第 2.2 节中详述）。因此，当给定较短的序列长度时，LLaDA 8B Base 往往只生成句子的一部分，然后可以将其用作前缀继续生成。

在选项卡中将块长度设置为 8。8 进一步将 GSM8K 分数从 77.5 提高到 78.6。

B.5 生成长度的消融

在本节中，我们对生成的长度进行消融研究。




图 5: 采样效率分析。LLaDA 的生成长度设置为 256, 图中采样步长设置为 32、64、128 和 256。这对应于每次前向传递分别解码 8、4、2 和 1 个令牌。LLaDA 可以在生成质量和采样速度之间进行灵活的权衡。

为了确保公平性, 对于每个设置, 我们将采样步骤数设置为等于生成的长度, 确保在每个采样步骤中, 只有一个标记从掩码传输到文本。我们使用 LLaDA 8B Base 进行实验。

正如表中报道的那样。10、结果对长度超参数不敏感。

B.6 标准基准和评估细节

在本节中, 我们介绍我们使用的基准并介绍我们评估过程的详细信息。

遵循标准 LLM [25, 26] 评估实践, 我们从四个维度评估 LLaDA:

一般能力: MMLU [110]、BBH [111]、ARC-C [112]、Hellaswag [113]、TruthfulQA [114]、WinoGrande [115] 和 PIQA [116]。

数学和科学能力: GSM8K [117]、数学 [118] 和 GPQA [119]。

代码生成: HumanEval [120]、HumanEval-FIM [121] 和 MBPP [122]。

中文理解: CMMLU[123]和C-Eval[124]。

对于所有上述基准, 我们遵循 LLM 评估中广泛采用的评估流程 [125], 主要采用条件似然估计和条件生成。具体来说, 对于某些基准, 提供了提示和多个候选答案, 并且需要模型来计算每个候选的条件可能性。然后选择可能性最高的候选作为模型的最终答案, 并将准确性用作评估指标。对于其余的基准, 模型根据给定的提示生成响应, 并使用精确匹配和其他相关标准等指标来评估性能。

对于基础模型, 我们使用 MMLU、CMMLU、C-Eval、ARC-C、Hellaswag、TruthfulQA、WinoGrande、PIQA 和 GPQA 的条件似然估计, 而其余基准则使用条件生成进行评估。对于指令模型, 我们使用条件生成来评估所有基准。

表 11: 内存消耗分析。内存以 GB 为单位。在没有任何推理优化技术（例如 KV Cache）的情况下，LLaDA 的内存使用量与 LLaMA3 相当，并且当后者使用 KV Cache 时略高于 LLaMA3。

Input Length	Output Length	LLaDA 8B	LLaMA3 8B w/o KV-Cache	LLaMA3 8B w/ KV-Cache
512	512	17.03	16.70	16.32
	1024	17.53	17.49	16.43
	2048	18.52	20.00	16.73
1024	512	17.53	17.16	16.36
	1024	18.01	18.26	16.41
	2048	19.02	21.39	16.74

对于基本模型，我们使用广泛采用的开源评估框架 lm-evaluation-harness [125]，但该框架不支持 HumanEval-FIM 指标。For HumanEval-FIM on the base model and all evaluation metrics on the instruct model, we use an internal evaluation library. We choose the internal library as lm-evaluation-harness shows greater deviation from the LLaMA3 results reported by Yang et al. [25]，相对于我们的内部评估。

For benchmarks evaluated via conditional likelihood estimation, we use Monte Carlo estimation to approximate Eq. (6) 对于 LLaDA。Since MMLU, CMMLU, and C-EVAL only require the likelihood of a single token, a single Monte Carlo estimate is sufficient for these benchmarks. For all other benchmarks, we find that 128 Monte Carlo samples are adequate to produce stable results.

对于使用条件生成评估的基准，我们对 LLaDA Base 和 LLaDA Instruct 应用具有低置信度重掩蔽策略的纯扩散采样。对于 LLaDA Base，我们将生成长度和采样步数设置为 1024。对于 LLaDA Instruct，采样步数设置为等于答案长度，配置如下：MMLU 和 HellaSwag 为 3，GPQA 为 64，MBPP 和 MMLU-Pro 为 256，HumanEval、GSM8K、Math 和 ARC-C 为 512。如附录 B.4 中详述，对于 HumanEval、MBPP、GSM8K、Math 和 GPQA，我们在 LLaDA Instruct 采样期间将 |EOS| 令牌的置信度设置为零。

B.7 采样效率分析

本节我们首先分析 LLaDA 的采样效率，包括采样速度和内存消耗。然后我们讨论潜在的优化以进一步提高其效率。

我们使用四个具有代表性的开放式生成基准进行采样速度分析：GSM8K、Math、HumanEval 和 MBPP。我们使用广泛采用的吞吐量指标来衡量生成速度，定义为每秒生成的代币数量。我们比较 LLaDA 8B Base 和 LLaMA3 8B Base，两者都使用 bfloat16 精度。本节中的所有实验均在单个 A100-80GB GPU 上进行，批量大小为 1。对于 LLaDA，在所有四个基准测试中，输出长度都固定为 256 个标记。

Fig. 5 shows that LLaDA enables a flexible trade-off between generation quality and speed by adjusting the number of sampling steps. 具体来说，在 GSM8K 和数学数据集上，LLaDA 8B Base 实现了与 LLaMA3 8B Base 相当的性能，同时吞吐量提高了 1.5 倍和 1.8 倍，尽管 LLaMA3 使用 KV 缓存并且 LLaDA 在没有任何推理优化技术的情况下运行。For the HumanEval benchmark, LLaDA 8B Base performs comparably to LLaMA3 8B Base when the throughput is matched. On the MBPP benchmark, LLaDA 8B Base lags behind LLaMA3 8B Base.

对于 LLaMA3，KV 缓存提供的加速优势在 HumanEval 数据集上明显较弱，这可以归因于其相对较短的提示长度。具体来说，GSM8K、Math、MBPP 和 HumanEval 的平均提示长度分别为 894、680、628 和 132 个令牌。

标签。图 11 LLaDA 8B Base 和 LLaMA3 8B Base 之间的内存消耗比较。为了避免由于训练数据的差异而导致生成长度的变化，我们在内存分析期间固定了输入和输出令牌长度。对于 LLaDA，无论采样步骤数有多少，内存使用量都保持不变。其内存消耗与不带 KV 缓存的 LLaMA3 8B Base 相当，但略高于带 KV 缓存的内存消耗。

表 12: iGSM 数据集的比较。

	4 steps	5 steps	6 steps
LLaMA3 8B Base	38.0	35.0	34.0
LLaDA 8B Base	64.0	41.0	44.0

我们强调，这项研究的目标不是提出一个比 ARM 更快的模型。相反，我们的目标是展示大规模语言建模扩散模型的前景，并挑战可扩展性、上下文学习和指令跟踪等核心 LLM 功能本质上依赖于 ARM 的普遍假设。大量研究 [31, 79–87] 重点关注通过算法或架构创新来提高 MDM 的生成效率。我们将 LLaDA 类似的以效率为导向的探索留给未来的工作。

B.8 iGSM 数据集评估

为了进一步评估 LLaDA 的数学能力，我们在 iGSM [34]（一个无限的、类似 GSM8K 的合成数据集）上测试了它的性能。iGSM 是通过特定规则生成的，具有控制问题难度的参数（即解决步骤的数量）。为了评估的一致性，我们将“#### \$answer”附加到最终解决方案中，遵循 GSM8K 格式。以下是解决方案步骤设置为 4 的示例：

（问题）每个北极星小学的文化研究教室的数量等于1。每个韦斯特里奇小学的舞蹈室的数量等于每个北极星小学的教室和每个北极星小学的文化研究教室的总和的3倍。Westridge 小学有多少个舞蹈室？（解）定义北极星小学文化研究教室为 x ； so $x = 1$. 定义北极星小学教室为 m ； so $m = x = 1$. 定义 Westridge 小学的舞蹈室为 n ； $w = m + x = 1 + 1 = 2$; 所以 $n = 3 * w = 3 * 2 = 6$ #### 6

由于 GSM8K 和 iGSM 之间存在细微差别（例如，使用 mod 5 算法系统），我们遵循 [34] 并为每个问题提供系统提示以及四镜头问答对。

（提示）您是解决涉及加法、减法和乘法的基本数学问题的专家。您以统一的格式解决所有问题。所有计算均以模 5 进行。例如， $4 + 4$ 等于 3、 $2 + 4$ 等于 1、 $3 + 3 + 3$ 等于 4、 $3 * 3$ 等于 4、 $2 * 2$ 等于 4。在提供解决方案时，请以“#### x”结尾。其中 x 是您的最终答案，是 0 到 4 之间的整数。您必须求解所有问题都使用相同的解决方案格式。我们的场景最多涉及四类对象：学校、教室、背包和文具。每个学校可以包含教室，每个教室可以包含背包，并且每个背包可以包含文具。我们可以指定数量，例如每个 Lakeshore High 的舞蹈工作室的数量。假设每个具有相同名称的实体都具有相同的配置；例如，每所 Lakeshore High 都包含相同数量的舞蹈室。另一个指导原则是，没有提到的就不存在：当我们提到 Lakeshore High 的教室时，我们只是在讨论场景中明确提到的教室。此外，如果甚至没有提及 Lakeshore High，则其中的任何教室都会自动被视为不存在（即 0）。

对于 4 到 6 个解决步骤，我们为每种情况生成 100 个问题，并在表 12 中报告相应的准确性。如表所示，LLaDA 8B Base 在未见过的数学问题上表现出比 LLaMA3 8B Base 显著且一致的优势，与表 1 中的结果一致。

表 13: 块扩散 LLaDA 采样过程的可视化。在 LLaDA 的响应中，较深的颜色表示在采样后期预测的标记，而较浅的颜色对应于早期的预测。

User	What are the benefits of regular exercise for physical and mental health?																			
LLaDA	Regular	exercise	can	improve	physical	health	by	strengthening	muscles	and	bones	,								
	improving	cardiovascular	health	,	and	reducing	the	risk	of	chronic	diseases	such	as							
	diabetes	and	heart	disease	.	It	can	also	improve	mental	health	by	reducing	stress						
	and	anxiety	,	improving	mood	,	and	enhancing	cognitive	function	.	Additionally	,							
	exercise	can	improve	sleep	quality	and	increase	energy	levels	.										

B.9 诗歌完成任务

在本节中，我们将介绍诗歌完成数据集中的示例，如下所示。

示例1:

提示：窈窕淑女的下一句是什么？直接输出句子即可。

答案：君子好逑。

示例2:

提示：不束缚一格降人才的上一句是什么？直接输出句子即可。

。答：我劝天公重抖擞。

B.10 更多案例研究

在本节中，我们将介绍 LLaDA 8B Instruct 的其他案例研究。首先，选项卡。图 13 显示了块扩散 LLaDA 采样的采样过程，而 Tab. 13 显示了块扩散 LLaDA 采样的采样过程。图14描绘了具有随机重新掩码的多轮对话的采样过程。此外，选项卡。15 和选项卡。图16提供了单轮和多轮对话的进一步示例。最后，标签。图 17 展示了 LLaDA 8B Instruct 模型成功完成诗歌反转的示例，而 GPT-4o 则失败了。

C 影响报告

我们的工作展示了扩散模型在大规模语言建模方面的前景，并挑战了一种常见的假设，即可扩展性、上下文学习和指令遵循等核心 LLM 功能本质上依赖于 ARM。我们的研究结果为探索自然语言处理中的替代概率范式开辟了新途径，并在对话式人工智能、代码生成和复杂推理任务中具有潜在的应用。

然而，与传统的法学硕士一样，扩散模式也引起了类似的社会担忧。其中包括大规模培训对环境的影响、生成有害内容的潜在滥用以及培训数据中存在的偏见的放大。应对这些挑战对于确保负责任地开发和部署扩散语言模型至关重要。

表 14: 多轮对话的可视化。我们采用随机重新屏蔽策略。在 LLaDA 的响应中，较深的颜色表示在采样后期预测的标记，而较浅的颜色对应于早期的预测。

User	I want to have a pet, but I don't know whether to get a cat or a dog. Do you have any suggestions?
LLaDA	It really depends on your preferences , lifestyle , and the type of pet you want . If you want an independent pet and have a busy schedule , a cat is a good choice . If you prefer a companion and have a more active lifestyle , a dog might be a better fit . Have you considered your options ?
User	I'm very busy at work, so it seems like a cat would be a more suitable option. Do you have any suggestions for getting a cat?
LLaDA	Sure ! First , make sure you have enough space in your home and provide food , water , and toys for your cat . Also , research different breeds and personalities , and choose cats that are suitable for your lifestyle . Lastly , make sure you have the necessary vaccinations and insurance in place before you get a pet .

表 15: LLaDA 8B 指令的单轮对话案例。

<i>Daily life</i>	
User	What's a piece of advice you've received that you've found helpful?
LLaDA	One helpful piece of advice I've received is to always be open to learning and growth. I've found that being willing to explore new ideas and experiences has helped me become more resilient and adaptable. By embracing a growth mindset, I've been able to identify opportunities for improvement and development, both personally and professionally.
<i>Daily life</i>	
User	Please recommend me three famous movies
LLaDA	Certainly! Here are three famous movies that have achieved widespread popularity and critical acclaim: 1. The Shawshank Redemption (1994) - Inspired by a novella and directed by Frank Darabont, this film tells the story of Andy Dufresne, a man convicted of murdering his wife, dealing with his harsh life in Shawshank Prison and forming an unlikely friendship with a fellow inmate. 2. The Godfather (1972) - Directed by Francis Ford Coppola, this film is based on Mario Puzo's novel of the same name. It follows the story of the Corleone family, particularly Michael Corleone, who rises to power and takes over the family's criminal empire. 3. The Empire Strikes Back (1980) - Directed by George Lucas, this film continues the story of a young Skywalker in the Star Wars saga. It follows Luke Skywalker as he helps the Rebel Alliance fight against the Galactic Empire and destroy the powerful weapon, the Death Star. All of these films are celebrated for their cinematic achievements, powerful storytelling, and memorable characters.
<i>Translation</i>	
User	Please help me translate into Chinese: 'What is now proved was once only imagined'
LLaDA	现在被证明的曾经只是想象
<i>Translation</i>	
User	Please help me translate into German: 'What is now proved was once only imagined'
LLaDA	Wer heute bestätigt ist, war einst nur imaginiert.
<i>Math</i>	
User	Emma decides to run 4 sprints 5 times a week. She runs 75 meters each sprint. How many total meters does she run a week?
LLaDA	Emma runs 4 sprints each time, so she runs a total of $4 \times 5 = 20$ sprints a week. Each sprint is 75 meters long, so Emma runs a total of $20 \times 75 = 1500$ meters a week. The final result is 1500
<i>Code</i>	
User	I am writing python code, I have an array, please help me sort it from largest to smallest
LLaDA	Certainly! You can sort an array from the largest to smallest in Python using the 'sort()' method or the 'sorted()' function. Here's an example: <pre> ### Using 'sort()' method: my_array = [3, 1, 4, 1, 5, 2] my_array.sort(reverse=True) print(my_array) </pre>

表 16: LLaDA 8B 指令的多轮对话案例。

<i>Daily life</i>	
User	How do I prepare for a job interview?
LLaDA	To prepare for a job interview, you should research the company and the job, practice common interview questions, and dress appropriately.
User	What are some common interview questions?
LLaDA	Some common interview questions include “Tell me about yourself” and “Why do you want to work for us”?
<i>Daily life</i>	
User	How do I start learning programming?
LLaDA	To learn programming, you can start by choosing a programming language that you are interested in. Some popular languages include Python, Java, and C++.
User	Which programming language should I learn first?
LLaDA	It depends on your interests and goals. Python is a great language for beginners for its simplicity and versatility.
User	How long does it take to learn Python?
LLaDA	It can take anywhere from a few weeks to several months to learn Python.
User	What are some good Python projects for beginners?
LLaDA	Some good Python projects for beginners include building a simple calculator, a game, and a web application.
<i>Math</i>	
User	Natalia sold clips to 48 of her friends in April, and then she sold half as many clips in May. How many clips did Natalia sell altogether in April and May?
LLaDA	Natalia sold clips to 48 friends in April. She sold half as many clips in May, so she sold $48/2 = 24$ clips in May. Altogether, Natalia sold $48 + 24 = 72$ clips in April and May. The final result is 72.
User	Natalia sold three times as many items in June as she did in May. How many clips did Natalia sell altogether in these three months?
LLaDA	Natalia sold clips to 48 friends in April. She sold half as many clips in May, so she sold $48/2 = 24$ clips in May. Natalia sold three times as many items in June as she did in May, so she sold $24 * 3 = 72$ clips in June. Altogether, Natalia sold $48 + 24 + 72 = 144$ clips in these three months. The final result is 144.

表 17: LLaDA 8B 指令成功但 GPT-4o 失败的诗歌反转完成案例。

<i>Question1</i>	
User	‘但闻人语响’的上一句是什么？
GPT-4o	“但闻人语响”的上一句是“无可奈何花落去”，这两句出自唐代词人李清照的（武陵春，春晚：无可奈何花落去，但闻人语响。这首词表达了作者在春天时节的孤独与感伤，借花落和人语声的描写，反映出词人内心的无亲与失落。
LLaDA	“但闻人语响”的上一句是“空山不见人”
<i>Question2</i>	
User	‘夜静春山空’的上一句是什么？
GPT-4o	“夜静春山空”的上一句是“空山新雨后”，这两句出自唐代诗人王维的（山居秋暝）：空山新雨后，夜静春山空。这首诗描绘了春天山中雨后的寂静与空灵，表现出自然的宁静与和谐美。
LLaDA	“夜静春山空”的上一句是“人闲桂花落”

表18: 图3中LLaDA的详细结果。“-”表示缺失值, 这不影响关于LLaDA可扩展性的观察。这些缺失值是由于硬件故障造成的。

Model	Training Tokens	FLOPs	MMLU	CMMLU	ARC-C	PIQA	GSM8K	HumanEval
LLaDA 1B	37.75B	2.20e20	25.52	25.95	25.17	59.41	1.82	0.00
LLaDA 1B	88.08B	5.13e20	27.11	26.52	26.96	61.86	3.03	1.83
LLaDA 1B	138.41B	8.06e20	29.32	27.13	30.20	63.38	2.35	0.00
LLaDA 1B	239.08B	1.39e21	31.48	30.77	27.99	63.11	3.26	1.22
LLaDA 1B	352.32B	2.05e21	35.86	34.35	31.31	65.34	3.64	3.05
LLaDA 1B	461.37B	2.69e21	31.86	30.98	30.12	65.51	2.35	0.61
LLaDA 8B	62.91B	2.63e21	32.22	28.5	30.20	63.82	3.87	2.44
LLaDA 8B	125.83B	5.27e21	33.39	33.9	34.64	66.54	8.72	3.66
LLaDA 8B	251.66B	1.05e22	42.84	40.59	40.10	69.04	15.31	3.66
LLaDA 8B	377.49B	1.58e22	45.11	43.99	39.25	68.61	25.40	9.76
LLaDA 8B	503.32B	2.11e22	43.57	41.38	42.06	70.24	27.52	9.76
LLaDA 8B	629.14B	2.63e22	48.80	47.13	42.24	72.09	30.10	12.80
LLaDA 8B	679.48B	2.85e22	49.61	48.19	41.30	70.84	26.31	8.54
LLaDA 8B	792.72B	3.31e22	50.88	49.01	42.58	70.51	31.99	6.10
LLaDA 8B	981.47B	4.11e22	49.47	48.10	40.27	71.38	-	6.10
LLaDA 8B	1107.30B	4.64e22	51.13	47.57	41.13	69.26	36.69	10.37
LLaDA 8B	1233.13B	5.16e22	50.52	49.72	45.05	71.49	38.97	9.76
LLaDA 8B	1358.95B	5.69e22	54.61	53.97	49.40	74.05	48.14	17.68
LLaDA 8B	1547.70B	6.48e22	57.38	56.04	49.49	74.59	53.30	20.73
LLaDA 8B	1975.52B	8.27e22	58.52	57.87	50.68	75.35	-	19.51

表 19: 图 3 中自回归基线的详细结果。

Model	Training Tokens	FLOPs	MMLU	CMMLU	ARC-C	PIQA	GSM8K	HumanEval
ARM 1B	37.75B	2.20e20	25.47	25.38	30.20	67.36	2.20	4.88
ARM 1B	88.08B	5.13e20	24.67	25.23	33.96	70.02	7.51	10.37
ARM 1B	138.41B	8.06e20	29.25	27.48	33.45	70.29	8.34	9.76
ARM 7B	17.30B	6.02e20	26.92	25.18	21.02	57.18	1.29	1.22
ARM 7B	34.60B	1.20e21	25.83	25.38	24.07	62.84	1.59	2.44
ARM 7B	86.50B	3.01e21	24.41	24.90	25.42	71.11	2.88	7.93
ARM 7B	173.02B	6.02e21	26.20	24.78	26.10	74.27	6.67	9.15
ARM 7B	207.62B	7.23e21	30.36	28.86	31.86	74.48	8.57	12.80
ARM 7B	224.92B	7.83e21	29.49	32.26	31.19	74.37	8.95	8.54
ARM 7B	242.22B	8.43e21	33.62	31.38	34.92	75.41	10.84	9.15
ARM 7B	259.52B	9.03e21	34.11	34.20	32.88	75.19	9.33	10.98
ARM 7B	311.43B	1.08e22	35.66	35.49	36.61	75.14	11.30	10.37
ARM 7B	363.33B	1.26e22	34.54	37.67	34.58	76.55	12.28	14.02
ARM 7B	415.24B	1.45e22	35.37	38.37	35.25	76.39	14.40	12.80
ARM 7B	449.84B	1.57e22	39.51	39.24	34.92	76.82	14.94	14.63
ARM 7B	519.09B	1.81e22	40.30	40.69	37.29	77.15	14.03	14.63
ARM 7B	778.57B	2.71e22	43.33	43.50	38.31	77.53	17.59	14.63
ARM 7B	1038.09B	3.61e22	45.06	46.12	41.69	77.86	20.02	15.85
ARM 7B	1384.12B	4.82e22	47.63	48.18	47.80	76.93	22.82	15.24
ARM 7B	2076.18B	7.23e22	47.68	50.85	44.07	77.37	24.79	14.63
ARM 7B	2214.59B	7.71e22	49.26	52.08	53.56	77.69	27.37	17.07