

项目 1 - 离散扩散模型

讲师：赵伟辰

2026 年春季

1.1 项目介绍

为主动应对智能时代对高等教育人才培养提出的新挑战，推进人工智能与教育教学的深度融合，聚焦课程设计从“内容导向”转为“问题导向”，积极探索“师—机—生”良好共创新范式，提升学生的自主学习能力、创新思维及解决复杂问题的能力，《随机过程》课程开展“问题导向的研讨式学习”教学模式探索项目。

本课程项目要求围绕近期兴起的离散扩散（语言）模型，特别是掩模扩散模型，掩模扩散语言模型范式，完成一次完整的文献调研、方法推导、小规模复现实验的问题导向型探索性研究。

1.1.1 问题背景

连续扩散模型在图像、音频和视频生成中取得了显着的成果，其基本思想是在前向过程中逐步破坏数据，在逆向过程中学习渐进去噪。然而，文本由离散令牌构成，不能像图像像素或潜在向量一样自然地添加高斯噪声。因此，语言扩散的核心难点是：

如何在离散代币空间中定义合理的前向噪声过程与反向生成过程？

一类重要的技术路线是掩码扩散。它将文本标记逐步替换成特殊符号 $mask$ ，训练模型从部分可见、部分被掩码的文本中恢复原始标记。该思想将BERT式掩码语言建模、MaskGIT式工具生成、以及扩散概率建模联系起来，是当前扩散语言模型走向基础模型的核心范式之一。

1.1.2 参考文献

- Austin 等人, *Structured Denoising Diffusion Models in Discrete State-Spaces*, NeurIPS 2021。
- Campbell 等人, *A Continuous Time Framework for Discrete Denoising Models*, NeurIPS 2022。
- 赵等人, *Unified Discrete Diffusion for Categorical Data*, JMLR 2025。
- Shi 等人, *Simplified and generalized masked diffusion for discrete data*, NeurIPS 2024。

- Sahoo 等人, *Simple and Effective Masked Diffusion Language Models*, NeurIPS 2024。
- Nie 等人, *Large Language Diffusion Models*, NeurIPS 2025。
- 叶等人, *Dream 7B: Diffusion Large Language Models*, 2025。

1.2 作业要求

- 基于CTMC的离散扩散模型相关文献的研究 (Deep Research) ;
- 目前研究基于CTMC的离散扩散模型的基本原理;
- 研究掩模扩散模型的基本原理;
- (选做)复现掩模扩散模型;
- (选做)探索 “大型” 扩散语言模型, 例如LLaDA;
- (选做) 探索更具体的理论研究、算法设计、下游任务...
- 标语为5人小组, 形成一篇中文研究报告, 可使用AI工具润色, 需要每个人的贡献。

1.3 作业评价

- 研究报告占用平时作业30分中的10分;
- 评价维度: –相关文献的缺陷; –
模型基本原理的程度具体实践;
–选作内容的探索。
- 评选2-3组其余优秀小组, 每组成员可获得额外5-10分期末总评, 并在课上汇报研究成果(每组45分钟)。

1.4 时间线

- 第一阶段: 智慧小雅提交研究报告 5.19 20: 00 - 5.29 24: 00
- 第二阶段: 评选优秀小组 6.2 随堂公布结果
- 第三阶段: 小组优秀汇报6.9、6.16