

离散数据的简化和广义掩蔽扩散

Jiaxin Shi*, Kehang Han*, Zhe Wang, Arnaud Doucet, Michalis K. Titsias
as Google DeepMind

抽象的

人们正在积极探索掩蔽（或吸收）扩散作为离散数据生成建模的自回归模型的替代方案。然而，该领域的现有工作受到不必要的复杂模型公式和不同视角之间不明确关系的阻碍，导致参数化、培训目标和临时调整来解决这些问题。在这项工作中，我们的目标是提供一个简单而通用的框架，以释放掩蔽扩散模型的全部潜力。我们证明了掩蔽扩散模型的连续时间变分目标是交叉熵损失的简单加权积分。我们的框架还可以使用状态相关的掩蔽时间表来训练广义掩蔽扩散模型。通过困惑度进行评估时，我们在 Open WebText 上训练的模型在 GPT-2 规模上超越了先前的扩散语言模型，并且在 5 个零样本语言建模任务中的 4 个上表现出了卓越的性能。此外，我们的模型在像素级图像建模方面远远优于以前的离散扩散模型，每维达到 2.75 (CIFAR-10) 和 3.40 (ImageNet 64×64) 位，优于类似大小的自回归模型。我们的代码可在 <https://github.com/google-deepmind/md4> 获取。

1 简介

自诞生以来[1,2,3]，扩散模型已成为生成媒体的主力，在图像合成[4,5,6]、音频[7,8]和视频生成[9,10,11,12,13]等任务中实现了最先进的技术。大多数现有的成功都是针对连续状态空间扩散。虽然扩散模型已扩展到离散状态空间[1,14,15]，并已成功应用于图形生成[16]、文本到声音生成[17]或蛋白质设计[18]等应用，但它们仍然没有像连续模型那样广泛使用，因为它们在文本建模等重要领域与自回归模型不具有竞争力。这推动了连续空间扩散模型的发展，其中离散数据嵌入欧几里德空间 [19,20,21,22,23] 或单纯形 [24,25,26,27,28] 中。我们认为，离散扩散成功有限的原因之一是它们受到相当复杂的公式和培训目标的阻碍。本文是朝着缩小这一差距迈出的一步。

在这项工作中，我们关注“掩蔽”（或“吸收”）扩散，这是由 Austin 等人首次提出的离散扩散公式。[14]，后来通过文献从不同的角度进行了探索[29,30,31,32]。我们在这里遵循一个连续时间框架，该框架已被证明对于改善连续状态空间扩散的训练和理解非常有用[参见例如 3、33、34]。我们做出了多项技术贡献，简化了这些模型的训练并显著提高了它们的性能。我们的贡献如下：

- 使用基本参数，我们为模型及其相应的时间反转引起的前向过程建立了几个属性，从而提高了我们对模型类的理解。

*Equal contribution. Correspondence to: jiaxins@google.com.

- 我们为掩蔽扩散模型提供了一个非常简单的证据下界（ELBO）表达式，表明它对应于交叉熵损失随时间的加权积分。与连续空间扩散[33]类似，该目标可以用信噪比重写，并表现出不变性。

- 我们对之前提出的连续时间离散扩散模型 [29,32,35] 有了统一的理解，揭示了它们对我们的 ELBO 目标和/或模型参数化所做的改变。我们表明，这些变化要么导致昂贵的模型评估，要么导致训练出现巨大差异，或者破坏正向和反向过程之间的一致性。

- 在 GPT-2 规模文本建模和像素级图像建模任务中，使用我们简单的 ELBO 目标训练的掩模扩散优于之前的建议，从而在离散扩散模型中实现最佳似然和零样本传输性能。

- 最后，基于我们简化的掩蔽扩散公式，我们提出了一种广义掩蔽扩散模型，该模型允许状态相关的掩蔽时间表。这种广义掩蔽扩散模型进一步提高了通过测试可能性衡量的预测性能。

Ou 等人的同时工作。[36] 和 Sahoo 等人。[37] 推导了 ELBO 的类似简化表达式。欧等人。[36] 的推导依赖于类似于我们在命题 1 中所做的观察。

2 掩模扩散

考虑一个句子，我们逐步用特殊的掩码标记替换每个单词，将句子转换为一系列掩码。我们的目标是训练一个生成模型来逆转这个过程，有效地将面具句子转回有意义的文本。更正式地说，假设我们的数据由来自有限离散状态空间的标记组成，具有 m 可能状态，由整数 $0, 1, \dots, m-1$ 及其相应的 one-hot 向量 $e_0, e_1, \dots, e_{m-1}$ 表示。为了适应掩码过程，我们用一个额外的掩码状态来扩充这个空间，用索引 m 表示。屏蔽过程在随机时间将每个令牌转变为屏蔽状态。该过程称为前向过程，独立应用于每个标记（例如每个单词），逐步将数据转换为一系列掩码标记。通过学习逆转这种掩蔽过程，我们创建了一个能够生成连贯离散数据的生成模型。

离散时间前向过程。我们从单个 token 的情况开始，然后扩展到多个维度。我们将前向过程定义为由时间 t 索引的离散随机变量 x_t 的马尔可夫序列，其中 t 从 0 到 1。在整个工作中，我们滥用这种表示法，使得 x_t 可以是整数或其相应的单热向量，只要从上下文中可以清楚地看出。我们将 $[0, 1]$ 划分为 T 区间，并令 $s(i) = (i-1)/T$ 、 $t(i) = i/T$ 。继奥斯汀等人之后。[14]， $[s(i), t(i)]$ 之间的状态转换由大小为 $(m+1) \times (m+1)$ 的 $Q_i = (1 - \beta_i)I + \beta_i \mathbf{1}e_m^\top$ 的转移矩阵确定，其中 $\mathbf{1}$ 是大小为 $m+1$ 的全一向量， e_m 表示索引 m 处的元素为 1 的单热向量。每个条目 $[Q_i]_{jk}$ 表示从状态 j 转移到状态 k 的概率：

$$[Q_i]_{jk} = q(x_{t(i)} = k | x_{s(i)} = j) = (1 - \beta_i)\delta_{jk} + \beta_i\delta_{km}.$$

这意味着，以 $1 - \beta_i$ 的概率， $x_{t(i)} = x_{s(i)}$ ，否则跳转到掩码状态。给定上述转移矩阵，给定 x_0 时，时间 $t(i)$ 的边缘分布为

$$q(x_{t(i)} | x_0) = \text{Cat}(x_{t(i)}; \bar{Q}_i^\top x_0) = x_0^\top \bar{Q}_i x_{t(i)}.$$

在这里，我们使用 $\text{Cat}(x; p)$ 表示分类分布，其中 p 是每个类别中存在的概率向量，而 $\bar{Q}_i \triangleq \prod_{j=1}^i Q_j = \alpha_i I + (1 - \alpha_i) \mathbf{1}e_m^\top$ 表示 $\alpha_i = \prod_{j=1}^i (1 - \beta_j)$ 。我们期望对于足够大的 T ， α_T 变得非常小或为零，使得任何 x_0 的 $q(x_1 | x_0)$ 将成为掩模状态下的增量质量。

连续时间限制。我们可以通过对上述离散时间过程进行限制来定义连续时间前向过程。我们首先指定一个连续函数 $\beta(t)$ 使得 $\beta_i = \beta(t(i))/T$ 。然后我们让 $T \rightarrow \infty$ 进入离散时间过程并计算 Austin 等人证明的 $\bar{Q}_i$ 的极限。14，附录 A.6，另见附录。A) 作为

$$\bar{Q}(t) \triangleq \lim_{T \rightarrow \infty} \bar{Q}_i = \alpha_t I + (1 - \alpha_t) \mathbf{1}e_m^\top, \text{ where } \alpha_t \triangleq \exp\left(-\int_0^t \beta(s) ds\right), \quad (1)$$




图 1: 文献中的掩蔽方案: (左) α_t ; (右) 交叉熵损失的权重 t ; 表中给出了这些时间表的方程式。4 见附录。

这样 $q(x_t|x_0) = \text{Cat}(x_t; \bar{Q}(t)^\top x_0)$ 。对于任意两个时间 $0 \leq s < t \leq 1$, 与上述边际 (即 $q(x_t|x_0) = \sum_{x_s} q(x_t|x_s)q(x_s|x_0)$) 兼容的转移分布为

$$q(x_t|x_s) = \text{Cat}(x_t; \bar{Q}(s,t)^\top x_s), \text{ where } \bar{Q}(s,t) \triangleq \bar{Q}(s)^{-1}\bar{Q}(t) = \frac{\alpha_t}{\alpha_s}I + \left(1 - \frac{\alpha_t}{\alpha_s}\right)\mathbf{1}e_m^\top.$$

请注意, 奥斯汀等人。[14]没有推导出两个任意时间 s 和 t 之间的这种明确形式的转移矩阵, 这后来出现在Zhao等人的论文中。[38]与我们的工作同时进行。

屏蔽时间表。根据 α_t 的定义, 我们得到 $\alpha_0 = 1$ 。与离散时间公式类似, 我们希望 α_1 为零或非常接近于零。我们在图 1 中总结了满足这些属性的文献中的掩蔽方案。Sohl-Dickstein 等人提出了线性方案。[1] 对于二元变量, 然后由 Austin 等人重新推导。[14]来自离散时间模型的互信息。几何调度 α_t 是针对 $\beta_{\min} = 10^{-5}$ 和 $\beta_{\max} = 20$ 绘制的。它首先用于连续扩散 [3], 然后由 Lou 等人用于离散扩散。[32]。余弦调度最初是在 MaskGIT [39] 中提出的, 这是一种受扩散启发的迭代揭蔽生成模型。该时间表具有在反向生成开始时减慢解锁过程的特性。与他们的观察一致, 我们发现这导致在生成开始时同时揭露冲突代币的可能性较低, 从而提高了整体生成质量。

给定 x_0 的前向过程的时间反转。我们的正向过程的分析属性允许以封闭形式计算许多感兴趣的量。扩散模型中经常使用的此类量之一是给定 x_0 : $q(x_s|x_t, x_0)$ for $s \leq t$ 的前向过程的时间反转。我们在App中导出它。C为

$$q(x_s|x_t, x_0) = \text{Cat}(x_s; \bar{R}^{x_0}(t,s)^\top x_t), \text{ where } \bar{R}^{x_0}(t,s) = I + \frac{\alpha_s - \alpha_t}{1 - \alpha_t}e_m(x_0 - e_m)^\top.$$

从转移矩阵 $\bar{R}^{x_0}(t,s) \in \mathbb{R}^{(m+1) \times (m+1)}$ 我们可以看到以 x_0 为条件的逆过程有一个非常简单的逻辑 - 如果 x_t 是一个掩码, 则概率为 $\frac{\alpha_s - \alpha_t}{1 - \alpha_t}$, 它将在 s 时刻跳转到状态 x_0 , 否则它将保持掩码状态。一旦 x_t 被解除屏蔽, 它就会保持相同的状态直到结束。

3 模型与目标

对于离散时间掩蔽扩散过程, 我们通过使用反向模型 $p_\theta(x_s|x_t)$ 近似反转前向转换来定义生成模型。定义该模型的一种方法是

$$p_\theta(x_s|x_t) \triangleq q(x_s|x_t, \mu_\theta(x_t, t)), \quad (2)$$

其中 $\mu_\theta(x_t, t) \in \Delta^{m+1}$ 是由神经网络 f_θ 参数化的概率向量, 并对输出 logits 应用了 softmax (请注意, 第 m 个输出被迫为 0, 因为干净的数据不能是掩码) :

$$\mu_\theta(x_t, t) = \begin{cases} \text{softmax}(f_\theta(x_t, t)) & x_t = m, \\ x_t & x_t \neq m. \end{cases} \quad (3)$$

这称为均值参数化, 因为它利用 x_0 均值的预测模型。 $p_\theta(x_s|x_t)$ 的矩阵形式如图 7 (右) 所示。事实上, 我们可以选择一个时不变的参数化 $\mu_\theta(x_t, t) = \mu_\theta(x_t)$, 因为[36]表明, 给定 $x_t = x$ 的 $p(x_0|x_t)$ 对于任何 t 都是相同的。

除了 $p_\theta(x_s|x_t)$ 之外，我们还需要指定 $p(x_0|x_{t(1)})$ 和先验分布 $p(x_{t(T)}) = p(x_1)$ 。遵循连续扩散模型[33]的实践，我们选择 $p(x_0|x_{t(1)}) \propto q(x_{t(1)}|x_0)$ 。由于任何 x_0 的 $q(x_1|x_0) \approx \delta_{x_1,m}$ 为 $\alpha_1 \approx 0$ ，因此我们设置 $p(x_1) \approx \delta_{x_1,m}$ ，请参阅 App. E。

然后，我们写出离散时间扩散模型目标 [1, 2]，它是模型 p (下数据 x_0 的对数边际似然的下界，称为证据下界，或 ELBO)：

$$\log p(x_0) \geq \mathbb{E}_{q(x_{t(1)}|x_0)} [\log p(x_0|x_{t(1)})] - \text{KL}(q(x_1|x_0)||p(x_1)) - \mathcal{L}_T,$$

其中 $\mathcal{L}_T = \sum_{i=2}^T \mathbb{E}_{q(x_{t(i)}|x_0)} [\text{KL}(q(x_{s(i)}|x_{t(i)}, x_0)||p_\theta(x_{s(i)}|x_{t(i)}))]$ 。对于先验分布的上述选择，项 $\text{KL}(q(x_1|x_0)||p(x_1))$ 变为零。在逆向模型(2)下， $\mathcal{L}_T$ 中的KL散度项变为 (App.D中的证明)

$$\text{KL}(q(x_s|x_t, x_0)||p_\theta(x_s|x_t)) = -\frac{\alpha_s - \alpha_t}{1 - \alpha_t} \delta_{x_t, m} \cdot x_0^\top \log \mu_\theta(x_t, t),$$

这是预测逻辑和干净数据之间的简单交叉熵损失。在应用程序中。D，我们证明 $\mathcal{L}_T$ 是黎曼和，并且下界为相应的连续积分：

$$\mathcal{L}_\infty \triangleq \lim_{T \rightarrow \infty} \mathcal{L}_T = \int_{t(1)}^1 \frac{\alpha'_t}{1 - \alpha_t} \mathbb{E}_{q(x_t|x_0)} [\delta_{x_t, m} \cdot x_0^\top \log \mu_\theta(x_t, t)] dt, \quad (4)$$

其中 α'_t 表示 α_t 相对于 t 的导数。因此，我们可以通过推 $T \rightarrow \infty$ 来获得比任何有限 T 更紧的ELBO。通过让 $t(1) \rightarrow 0$ 可以进一步简化此ELBO。因此， $\mathbb{E}_{q(x_{t(1)}|x_0)} [\log p(x_0|x_{t(1)})]$ 变为0，ELBO变为 $-\mathcal{L}_\infty$ 。

对于连续状态空间扩散，ELBO 取决于其端点处的信噪比 (SNR)，但在其他方面对噪声调度是不变的 [33]。我们在这里为离散扩散建立了类似的结果。考虑选择 $\alpha_t = \sigma(\lambda_t)$ ，其中 σ 表示 sigmoid 函数 $\sigma(x) = \frac{1}{1+e^{-x}}$ 。在这种情况下， $\log\text{-SNR}$ 由 $\lambda_t = \log \frac{\alpha_t}{1-\alpha_t} = \log\text{-SNR}(t)$ 定义。通过更改 (4) 中的变量以使所有内容成为对数 SNR 的函数，我们得到

$$\mathcal{L}_\infty = \int_{\lambda_{t(1)}}^{\lambda_1} \sigma(\lambda) \mathbb{E}_{\tilde{q}(x_\lambda|x_0)} [\delta_{x_\lambda, m} \cdot x_0^\top \log \tilde{\mu}_\theta(x_\lambda, \lambda)] d\lambda.$$

其中 $\tilde{\mu}_\theta(x, \lambda) := \mu_\theta(x, t)$ 和 $\tilde{q}(x_\lambda|x_0) := q(x_t|x_0)$ 表示 $t = \log\text{-SNR}^{-1}(\lambda)$ 。这表明 α_t 对损耗的唯一影响是通过端点处的 SNR 值。尽管如此，因为我们抽取 t 的统一样本来估计积分，所以掩蔽方案的选择会影响方差。

多维数据。在前面的部分中， x_t 被假定为单个离散标记。为了将该方法扩展到多维数据，让 x_t 现在是一个序列 $(x_t^{(1)}, x_t^{(2)}, \dots, x_t^{(N)})$ ，其中每个元素 $x_t^{(n)}$ 表示一个离散标记。我们选择一个对所有 N 标记进行因式分解的前向过程： $q(x_t|x_s) = \prod_{n=1}^N q(x_t^{(n)}|x_s^{(n)})$ 。因此，前向边缘 $q(x_t|x_0)$ 和反向边缘 $q(x_s|x_t, x_0)$ 也会因式分解。在这种情况下，我们将反向模型定义为 $p_\theta(x_s|x_t) \triangleq \prod_{n=1}^N q(x_s^{(n)}|x_t^{(n)}, \mu_\theta^{(n)}(x_t, t))$ ，其中 $\mu_\theta(x_t, t)$ 是一个神经网络，它将完整的 N 标记作为输入并输出 N 概率向量。² 第 n 个输出 $\mu_\theta^{(n)}(x_t, t)$ 是 $\mathbb{E}[x_0^{(n)}|x_t]$ (第 n 个标记的平均值) 的预测模型。重复以上推导可得

$$\mathcal{L}_\infty^{(N)} \triangleq \int_0^1 \frac{\alpha'_t}{1 - \alpha_t} \mathbb{E}_{q(x_t|x_0)} \left[\sum_{n: x_t^{(n)} = m} (x_0^{(n)})^\top \log \mu_\theta^{(n)}(x_t, t) \right] dt. \quad (5)$$

我们将使用损失 (5) MD4 (离散数据的掩模离散扩散) 训练的简单掩模扩散模型称为。Alg 中描述了 MD4 训练算法的单步。¹ 见附录。

4 取样

我们使用离散时间逆过程中的祖先采样来进行生成。我们发现，与欧拉离散化等其他方法相比，这种方法产生的样本质量略高[29, 32]。对于填充等条件生成任务，我们发现简单的方法效果最好——我们在整个生成过程中保持条件标记的暴露。采样算法的完整描述可以在 Alg 中找到。² 见附录。

²我们有意选择反向模型来跨维度进行因式分解，因为真正的反向转换 $q(x_s|x_t)$ 在连续时间限制中进行因式分解 (当 s 接近 t 时)。




图 2: 左图: 在 ImageNet 64×64 (表 6 中的数字) 的像素级建模上对从 MD4 随机生成的 50 k 样本进行 FID 评估。右: 每个生成步骤显示的代币数量 ($T = 256$)。每个图像由 $64 \times 64 \times 3 = 12288$ 个标记组成。

时间表和离散化的影响。为了比较不同的采样配置，我们主要使用图像数据集上的 FID 分数 [40] 作为我们的评估指标。我们更喜欢它而不是先前工作中使用的文本生成困惑度³ [32]，因为后者可以通过降低样本多样性来误导性地减少[41]。我们最初使用线性计划训练我们的模型，这实现了总体上最好的最终 ELBO；然而，我们发现使用标准均匀离散网格 $t(i) = \frac{i}{T}$ 进行采样效果不佳。我们假设时间离散化可能会通过在一个步骤中生成多个令牌而导致冲突。然后，我们切换到余弦时间表（表 4），这会减慢反向过程开始时的揭露速度。这将 ImageNet 64×64 上的 FID 从 70 大幅提高到 17， $T = 256$ 个步骤（图 2，左）。基于这一观察，我们建议使用“余弦”离散网格在使用线性计划训练的模型中进行采样：

$$t(i) = \cos\left(\frac{\pi}{2}\left(1 - \frac{i}{T}\right)\right). \quad (6)$$

这会在 α_t 中产生与具有均匀网格的余弦计划相同的离散化，从而产生可比较的样本质量，如图 2（左）所示。在图 2（右）中，我们使用统一网格绘制了线性和余弦计划每一步未屏蔽的标记数量。我们相信余弦计划表现更好，因为它利用了信息冗余：随着更多令牌的显示，剩余的令牌变得更加可预测，从而减少了在一步中揭开它们时的冲突。

尽管这些发现最初是在图像上开发的，但我们发现它们可以很好地转化为文本（见图 10）。我们期望其他技术，例如 top- p 采样 [41]、无分类器指导 [42, 43] 和预测校正器 [29, 44] 来进一步提高模型的样本质量。虽然我们为未来的工作保留这些，但我们注意到分类采样的 J AX [45] 实现隐式截断了小概率，从而产生了与 top- p 采样类似的效果。参见应用程序。G 了解详情。

5 与现有工作的关系

我们讨论如何使用我们的框架统一几个现有的掩模扩散模型。

连续时间马尔可夫链 (CTMC)。为了显示与 Austin 等人提出的 CTMC 观点的联系。[14]，坎贝尔等人。[29]，我们可以使用 CTMC 机制写出前向和反向掩模扩散。为了看到这一点，对于短时间 Δt ，给定 x_0 ，我们在 t 处的正向和反向转移矩阵的泰勒展开式为

$$\bar{Q}(t, t + \Delta t) = I + Q(t)\Delta t + o(\Delta t) \quad \text{for} \quad Q(t) \triangleq \beta(t)(\mathbf{1}e_m^\top - I), \quad (7)$$

$$\bar{R}^{x_0}(t, t - \Delta t) = I + R^{x_0}(t)\Delta t + o(\Delta t) \quad \text{for} \quad R^{x_0}(t) \triangleq -\frac{\alpha'_t}{1 - \alpha_t}e_m(x_0 - e_m)^\top, \quad (8)$$

其中 $Q(t)$ 和 $R^{x_0}(t)$ 称为 *transition rate* 矩阵。奥斯汀等人。[14]在App中导出了相同的 $Q(t)$ 。他们论文的 A.6。然而，他们并没有探索相反的过程或

³ 通过 GPT-2 等大型语言模型对生成样本进行评分的困惑度。

连续时间目标。坎贝尔等人。[29] 使用速率矩阵导出了另一种 ELBO 表达式, Kitouni 等人。[46] 进一步简化了吸收扩散。在应用程序中。H.1, 我们展示了如何通过从 ELBO 表达式 (4) 中分离出一个常数并应用离散的“按部分积分”来恢复它们的表达式。它们的表达的一个关键限制是它需要预测模型 $\mu_\theta(\cdot, t)$ 的 N 评估来计算内部求和。为了规避这种计算负担, 他们使用了双重随机估计。然而, 与仅需要一次 $\mu_\theta(\cdot, t)$ 的分析交叉熵 (4) 相比, 这会导致显着更高的方差。请参阅应用程序。H.2 了解更多详情。

分数参数化。虽然到目前为止, 我们使用预测模型 $\mu_\theta(x_t, t)$ 来表示给定 x_t (的干净数据的平均值, 即平均参数化), 但我们可以选择其他方法来参数化反向模型。卢等人。[32], 本顿等人。[35] 提出参数化离散“分数” $s(x_t, t)_j \triangleq \frac{q_t(j)}{q_t(x_t)}$, 并为离散扩散引入基于分数的损失。在应用程序中。H.3, 我们提供了一种更简单的损失的替代推导。我们通过以下命题展示分数和平均参数化之间的联系。

命题 1 (分数参数化与平均参数化) 。 *Let q_t be the marginal distribution of the masked diffusion defined in Sec. 2 at time t . The discrete score $s(x_t, t)_j = \frac{q_t(j)}{q_t(x_t)}$ for a mask state $x_t = m$ and $j \neq m$ can be expressed as*

$$s(m, t)_j = \frac{\alpha_t}{1 - \alpha_t} \mathbb{E}[x_0 | x_t = m]^\top e_j, \text{ which satisfies } \sum_{j \neq m} s(m, t)_j = \frac{\alpha_t}{1 - \alpha_t}. \quad (9)$$

命题 1 (在 App.H.3 中证明) 意味着掩模状态的合理评分模型是

$$s_\theta(m, t)_j = \frac{\alpha_t}{1 - \alpha_t} \mu_\theta(m, t)_j. \quad (10)$$

事实上, 将 (10) 代入 Lou 等人的基于分数的损失中。[32], 本顿等人。[35] 恢复了我们的目标 (4) 。在卢等人。[32], 分数被参数化为神经网络, 而不强制执行 (9) 中的约束。这意味着学习到的反向模型可能与正向过程不兼容。我们发现, 强制约束的参数化可以带来更稳定的训练和更好的结果。

任意阶自回归模型。我们的掩模扩散模型的连续时间逆过程可以被视为任意阶自回归模型 (AO-ARM) [47]。为了看到这一点, 我们根据相反过程中的解锁事件的时间对令牌进行重新排序。对于所有令牌, 解锁时间 $\{\tau_n\}_{n=1}^N$ 的累积分布函数 (CDF) 是相同的并且满足 $P(\tau_n \leq t) = P(x_t^{(n)} = m) = 1 - \alpha_t$ 。因此, 所有可能的排列中的排序都是均匀随机的, 并且每个揭开事件期间的令牌预测代表 AO-ARM 中的预测步骤。Hoogeboom 等人最初指出了这种联系。[48, 应用程序。C]。我们的简化 ELBO (5) 和 AO-ARM 目标之间的关系由 O u 等人独立阐明。[36]。尽管存在这种等价性, 但我们的工作表明, 掩蔽方案 α_t 在此类模型的设计中引入了新的自由度。 α_t 的变化可能导致揭露时间的不同分布, 从而显着影响时间离散化下扩散式并行采样的性能, 如图 2 所示。

其他相关工作。由于空间限制, 我们推迟了对其他相关工作的讨论, 包括 MaskGIT [39]、离散流匹配[49]、SDDM [30]、Blackout Diffusion [50] 和 SUNDAE [51], 到 App。 H.4。

6 状态相关屏蔽时间表的推广

考虑这样一种情况, 其中某些代币比其他代币更重要, 我们希望在此过程中尽早揭开它们的面纱。为了实现这一目标, 我们引入了与状态相关的屏蔽时间表, 其中解密令牌的概率不仅取决于时间, 还取决于令牌的价值。

我们首先定义单个令牌 x_t 的转发过程。令 α_t 为 $m + 1$ 维向量函数, 即, 对于标记 x_t 的每个可能值 i 都有一个不同的函数 $\alpha_{t,i}$ 。另外, 通过




图 3: MD4 无条件生成样本的迭代解密过程。此可视化仅包含生成的 1024 个标记序列中的一个子序列。“?”代表面具。被遮盖的标记按顺序显示: 绿色 (步骤 500-700)、黄色 (700-850) 和红色 (850-1000)。MD4 的附加无条件生成可以在 App 中找到。K.5。

向量 $\frac{\alpha_t}{\alpha_s}$ 我们表示两个向量的逐元素除法。我们将前向转换定义为 $q(x_t|x_s) = \text{Cat}(x_t; \bar{Q}(s, t)^\top x_s)$, 其中

$$\bar{Q}(s, t) = \text{diag}\left(\frac{\alpha_t}{\alpha_s}\right) + \left(I - \text{diag}\left(\frac{\alpha_t}{\alpha_s}\right)\right) \mathbf{1} e_m^\top$$

$\text{diag}\left(\frac{\alpha_t}{\alpha_s}\right)$ 是对角矩阵, 其对角线为向量 $\frac{\alpha_t}{\alpha_s}$ 。从当前状态 x_s 移动到与 x_s 或掩模) 相同的未来状态 x_t 的概率由状态相关速率 $\left(\frac{\alpha_t}{\alpha_s}\right)^\top x_s$ 确定, 而给定 x_0 时 s 时刻的边为

$$q(x_s|x_0) = \text{Cat}(x_s; \bar{Q}(s)^\top x_0) \quad \text{for} \quad \bar{Q}(s) = \text{diag}(\alpha_s) + (I - \text{diag}(\alpha_s)) \mathbf{1} e_m^\top.$$

此外, 对于任何时间 $0 \leq s < t \leq 1$ 都保持 $q(x_t|x_0) = \sum_{x_s} q(x_t|x_s)q(x_s|x_0)$, 因此上面是有效的连续时间马尔可夫链。

给定前向条件和边, 我们现在可以计算以 x_0 为条件的时间反转。 $q(x_s|x_t, x_0)$ 的完整形式是在 App 中导出的。一.1. 对于 $x_t = m$, 我们有

$$q(x_s|x_t = m, x_0) = q(x_s|x_t = m, x_0, x_0 x_0^\top) = \left(\frac{1-\alpha_s}{1-\alpha_t}\right)^\top x_0 e_m^\top x_s + \left(\frac{\alpha_s - \alpha_t}{1-\alpha_t}\right)^\top x_0 x_0^\top x_s. \quad (11)$$

这表明给定 $x_t = m$ 的反向模型可以选择为 $p_\theta(x_s|x_t = m) \triangleq q(x_s|x_t = m, \mu_\theta(x_t, t), \text{diag}(\mu_\theta(x_t, t)))$, 其中 $\mu_\theta(x_t, t)$ 是近似 $\mathbb{E}[x_0|x_t]$ 的神经网络, 而 $\text{diag}(\mu_\theta(x_t, t))$ 近似 $\mathbb{E}[x_0 x_0^\top | x_t] = \text{diag}(\mathbb{E}[x_0 | x_t])$ 。我们在应用程序中显示。I.1 状态相关速率情况下的负连续时间 ELBO 为

$$\mathcal{L}_\infty = \int_0^1 \left(\frac{\alpha'_t}{1-\alpha_t}\right)^\top \mathbb{E}_{q(x_t|x_0)} [\delta_{x_t, m} \cdot (x_0 - \mu_\theta(x_t, t) + x_0 x_0^\top \log \mu_\theta(x_t, t))] dt. \quad (12)$$

这里, α'_t 是 α_t 的元素导数。这概括了 MD4 损失 (4), 当 α_t 是标量调度乘以 1 向量时, MD 4 损失即可恢复。对于 N 令牌, 该模型进一步推广, 类似于第 2 节。3 and the loss is given in (32). We call this generalized model GenMD4.

为了使用 ELBO 优化学习依赖于令牌的掩码调度, 我们使用多项式调度 (见图 1) 将 $m+1$ 维函数 α_t 参数化为 $\alpha_{t,i} = 1 - t^{w_i}$ 并优化每个参数 $w_i > 0$ 。⁴ w_i 的值通过掩码概率 $1 - \alpha_{t,i}$ 确定值为 i 的令牌跳转到掩码的速度状态。由于在损失 (12) 中, 分布 $q(x_t|x_0)$ 取决于 α_t , 因此取决于向量 w , 因此优化 w 会带来离散梯度估计问题 [参见, 例如, 52]。朴素的自动微分会导致有偏差的梯度并将 w 推向零, 因为梯度无法通过从 $q(x_t|x_0)$ 提取的 (离散) 样本传播。为了解决这个问题, 我们使用 REINFORCE 留一法估计器 [53, 54] 来计算低方差无偏梯度以优化 w 。详细信息在应用程序中给出。I.2.

⁴对于 $i = 0, \dots, m-1$, 我们只需要 m 可学习参数 w_i , 因为 x_0 永远不能成为掩码标记。对于最终的掩模尺寸, 我们可以选择任意固定值, 例如 $w_m = 0$ 。

表 1: Radford 等人在五个基准数据集上的零样本无条件困惑度。[57]。其他方法的数字来自 Lou 等人。[32] 除了我们重新实现 SEDD Absorb 之外。我们的 MD4 模型在所有基准测试中都取得了最好的结果，除了 LAMBADA 之外，它是第二好的。*报告的 GPT-2 数字是在 WebText（而不是 OWT）上预训练的 GPT-2 检查点，因此不是直接比较。

Size	Method	LAMBADA	WikiText2	PTB	WikiText103	IBW
Small	GPT-2 (WebText)*	45.04	42.43	138.43	41.60	75.20
	D3PM	≤ 93.47	≤ 77.28	≤ 200.82	≤ 75.16	≤ 138.92
	Plaid	≤ 57.28	≤ 51.80	≤ 142.60	≤ 50.86	≤ 91.12
	SEDD Absorb	≤ 50.92	≤ 41.84	≤ 114.24	≤ 40.62	≤ 79.29
	SEDD Absorb (reimpl.)	≤ 49.73	≤ 38.94	≤ 107.54	≤ 39.15	≤ 72.96
	MD4 (Ours)	≤ 48.43	$\leq \mathbf{34.94}$	$\leq \mathbf{102.26}$	$\leq \mathbf{35.90}$	$\leq \mathbf{68.10}$
Medium	GPT-2 (WebText)*	35.66	31.80	123.14	31.39	55.72
	SEDD Absorb	≤ 42.77	≤ 31.04	≤ 87.12	≤ 29.98	≤ 61.19
	MD4 (Ours)	≤ 44.12	$\leq \mathbf{25.84}$	$\leq \mathbf{66.07}$	$\leq \mathbf{25.84}$	$\leq \mathbf{51.45}$

7 实验

7.1 正文

文本是具有丰富结构的自然离散数据。为了与之前的工作进行比较，我们评估了两个数据集的可能性：text8 [55]（字符级文本建模基准）和 OpenWebText [56]（用于训练 GPT-2 [57] 的未发布 WebText 数据集的开放克隆）。我们还通过在 FineWeb-Edu [58] 上进行训练来评估我们的模型在下游任务上的性能，FineWeb-Edu 是开源社区通常用于比较法学硕士的高质量优质教育文本数据集。除非另有说明，否则采用线性计划和余弦采样网格。

打开网络文本。我们在 OpenWeb-Text 上训练 GPT-2 小 (S) 和 GPT-2 中 (M) 大小的 MD 4，并在 Radford 等人使用的五个基准数据集上评估零样本困惑度。[57]。我们的评估设置与 SEDD [32] 相同。为了确保公平比较，我们在代码库中重新实现了 SEDD。我们的实施产生了比他们论文中报告的结果稍好的结果。

如表所示。如图 1 所示，我们的小模型在所有五项任务上都优于之前最好的离散扩散模型。我们在所有任务上都优于 GPT-2，除了 LAMBADA 之外，我们是第二好的方法。当扩展到中等规模时，MD4 在 5 个任务中的 4 个上同样击败了 SEDD 和 GPT-2。

为了确认强大的零样本性能源于改进的训练，我们在图 4 中绘制了 2% OpenWebText 验证集的困惑度。我们的模型收敛速度更快，并且比以前的方法具有更好的最终可能性。我们还观察到 SEDD [32] 存在训练不稳定，可能是由于分数参数化破坏了正向和反向过程之间的一致性（第 5 节）。尽管 GenMD4 实现了比 MD4 更低的复杂度，但我们观察到学习到的 w 可能会过度拟合数据集统计数据，从而使其在零样本传输任务上效果较差。

我们还评估模型的生成质量。图 3 显示了从 MD4 介质中随机选择的、特别一致的样本及其去噪过程。图 10 展示了 MD4 的文本填充能力，并强调了从均匀离散化过渡到余弦离散化时的显着质量增益（参见第 4 节）。尽管 MD4 在生成困惑度等定量指标上表现强劲，但由于该指标固有的不可靠性，我们将这些结果放在附录图 8 中，如第 2 节所述。4. 我们强调在我们的图像实验中发现的更可靠的基于 FID 的评估。




图 4: 训练期间 OpenWebText (OWT) 验证集的困惑。最终数字报告在表中。5 见附录。

表 2: Text8 测试集上的每个字符位数 (BPC)。所有模型都使用类似于 GPT-2 小 [57] 的标准 12 层变压器, 除了使用 8×3 层的离散流之外。

Method	BPC ($\downarrow$)
<i>Continuous Diffusion</i>	
Plaid [22] (Our impl.)	≤ 1.48
BFN [26]	≤ 1.41
<i>Any-order Autoregressive</i>	
ARDM [48]	≤ 1.43
MAC [61]	≤ 1.40
<i>Autoregressive</i>	
IAF/SCF [62]	1.88
AR Argmax Flow [15]	1.39
Discrete Flow [59]	1.23
Transformer AR [14]	1.23
<i>Discrete Diffusion</i>	
Mult. Diffusion [15]	≤ 1.72
D3PM Uniform [14]	≤ 1.61
D3PM Absorb [14]	≤ 1.45
SEDD Absorb [32]	≤ 1.39
MD4 (Ours)	≤ 1.37
GenMD4 (Ours)	≤ 1.34

表 3: CIFAR-10 测试集和下采样 ImageNet 64×64 [63] 验证集的每维位数 (BPD)。表中的所有模型都是在没有数据增强的情况下进行训练的。

	Method	#Params	BPD ($\downarrow$)
O I R A F C	<i>Autoregressive</i>		
	PixelRNN [63]		3.00
	Gated PixelCNN [64]		3.03
	PixelCNN++ [65]	53M	2.92
	PixelSNAIL [66]	46M	2.85
	Image Transformer [67]		2.90
	Sparse Transformer [68]	59M	2.80
	<i>Discrete Diffusion</i>		
	D3PM Absorb [14]	37M	≤ 4.40
	D3PM Gauss [14]	36M	≤ 3.44
4 6 X 4 6 E N E d g a m	Campbell et al. [29]	36M	≤ 3.59
	Campbell et al. [29] Absorb	28M	≤ 3.52
	MD4 (Ours)	28M	≤ 2.75
	<i>Autoregressive</i>		
	PixelRNN [63]		3.63
	Gated PixelCNN [64]		3.57
	Sparse Transformer [68]	152M	3.44
	Routing Transformer [69]		3.43
	Perceiver AR [68]	770M	3.40
	<i>Discrete Diffusion</i>		
	MD4 (Ours)	198M	≤ 3.40

文本8.继之前的工作 [14, 32] 之后, 我们在 text8 上训练了掩蔽扩散模型, 并评估了测试集上的每个字符的位数 (详细信息参见 App. J.1)。如表所示。如图2所示, 我们的模型优于以前的离散和连续扩散模型, 以及与离散扩散密切相关的最先进的AO-ARM [48]。我们的模型仅被自回归 (AR) 变压器和 AR 骨干离散流击败 [59]。我们认为这是因为 AR 模型只需要学习固定的生成顺序, 从而更好地利用模型容量。Text8 的词汇量较小 (26 个字母和一个空格), 导致我们对依赖于状态的表述的灵活性预期有限。然而, 使用 (12) 中的广义目标, GenMD4 实现了比 MD4 显著更好的 BPC, 证明了离散数据的状态相关扩散的潜力。

FineWeb-Edu. 我们在 FineWeb-Edu 上训练 MD4, 并在 Hellaswag 数据集 [60] 上评估其零样本精度, Hellaswag 数据集是法学硕士的流行常识推理基准。我们直接将 MD4 与其 AR 对应物进行比较——在相同数据上训练的具有相同配置 (因果屏蔽除外) 的变压器。结果总结于图 5 中。

随着规模的扩大, MD4 表现出稳定的性能增长。虽然性能优于相同尺寸的 AR 模型, 但性能差距并不会随着模型尺寸的增加而扩大。例如, AR-small 在 50k 步内达到 30% 的准确率, 而 MD4-small 需要 200k 步 (4 倍数据效率差异)。在中等规模下, AR 在 27 万步中实现了 37%, 而 MD4 为 100 万步。




图 5: GPT-2 小、中、大尺度下 MD4 和 AR 模型의 Hellaswag 准确度与训练步骤。

7.2 像素级图像建模

与处理离散数据的连续扩散不同, 我们证明 MD4 (一种离散扩散模型) 在本质上连续的数据上表现良好, 这表明它具有统一数据的潜力。




图 6: 来自在 ImageNet 64x64 上训练的 MD4 的非精选无条件样本, 将像素视为离散标记。更多示例请参见附录图 9。该模型针对可能性而不是视觉质量进行了优化, 例如, 参见 Kingma 等人。[33]对于来自连续扩散模型的样本, 对似然性进行了类似的优化。

方式。我们关注奥斯汀等人。[14] 并使用来自 CIFAR-10 和下采样 ImageNet 64×64 [63] 的顺序无关图像数据训练 MD4。每个图像都被视为一组 256 值的离散标记, 使模型与像素邻近度无关。我们将这些数据集上报告的似然结果与其他离散扩散和 AR 模型进行比较, 尽管据我们所知, 还没有直接对原始像素空间进行建模的 ImageNet 64×64 的离散扩散结果。

标签。3 总结了我们的结果。我们建立了一种新的最先进的离散扩散模型, 其性能显著优于之前的工作 [14, 29]。我们的 CIFAR-10 结果超过了报告的最佳 AR 结果。在 ImageNet 64×64 上, 我们的结果与大 $4 \times$ 的 Transformer AR 模型以及强大的连续扩散模型 VDM [33] 具有竞争力。值得注意的是, 尽管缺乏像素值顺序结构的知识, MD4 的性能优于使用这种归纳偏差训练的模型, 包括 D3PM Gauss 和 Campbell 等人。[29]其中噪声分布是离散高斯分布, 它将更大的概率分配给附近的像素值。为了隔离训练目标造成的差异, 我们还实施了 Campbell 等人的方法。[29] 吸收过程的目标表明, 即使在我们的架构中, 其高方差也会阻碍学习。

我们在图 6 中提供了来自 ImageNet 64×64 模型的随机样本。更多结果可以在 App 中找到。K. 在图 2 中, 我们绘制了在不同的计划和离散化网格选择下生成的样本的 FID 值。我们可以看到, 使用线性计划加余弦网格的模型实现的 FID 接近于使用余弦计划的模型, 两者都显著优于使用均匀网格的线性计划。我们在 ImageNet 64×64 上进一步训练了类条件模型, 将 FID 提高到 7 左右。尽管这些不是 ImageNet 64×64 上最先进的 FID, 但我们强调我们的模型针对可能性而不是样本质量进行了优化。

8 结论

在这项工作中, 我们重新审视了掩蔽扩散模型, 重点关注灵活的连续时间公式。该领域的现有工作对于非专业人士来说不容易访问, 并且存在难以优化的 ELBO, 通常导致性能与连续扩散和 AR 模型不具有竞争力。我们提出的框架提供了一种非常简单的 ELBO 表达式, 即交叉熵损失的加权积分。此外, 我们提出了一种广义掩蔽扩散公式 (GenMD4), 其中掩蔽时间表取决于过程的当前状态, 并推导其相应的 ELBO。在文本数据上, 我们的 MD4 模型优于现有的离散和连续扩散模型。对于像素级图像建模, 我们显著改进了离散扩散结果, 优于类似大小的 AR 模型, 并实现了与 VDM 等连续扩散模型相当的可能性。GenMD4 在与状态无关的情况的可能性方面提供了进一步的改进。

尽管我们改进了掩蔽扩散模型, 但它们仍然存在局限性。首先, 在某些任务 (例如 text8) 中, 掩模扩散尚无法与 AR 模型竞争。我们推测这是因为 AR 模型可以更好地利用模型能力, 因为它们只需要学习一个顺序。为离散扩散开发更好的架构将会很有趣。此外, GenMD4 很有前途, 但它很容易过度拟合数据集, 与更简单的版本相比, 它对于零样本传输的效果较差。此外, 使用依赖于状态的时间表进行推理更具挑战性。

参考

- [1] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan 和 Surya Ganguli。使用非平衡热力学的深度无监督学习。在 *International Conference on Machine Learning*, 2015 年。
- [2] 乔纳森·何 (Jonathan Ho)、阿杰·贾恩 (Ajay Jain) 和彼得·阿贝尔 (Pieter Abbeel)。去噪扩散概率模型。在 *Advances in Neural Information Processing Systems*, 2020 年。
- [3] 宋杨、Jascha Sohl-Dickstein、Diederik P Kingma、Abhishek Kumar、Stefano Ermon 和 Ben Poole。通过随机微分方程基于分数的生成模型。在 *International Conference on Learning Representations*, 2020 年。
- [4] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser 和 Björn Ommer。使用潜在扩散模型进行高分辨率图像合成。 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第 10684–10695 页, 2022 年。
- [5] Aditya Ramesh, Prafulla Dhariwal, Alex Nichol, Casey Chu 和 Mark Chen。具有剪辑潜在特征的分层文本条件图像生成。 *arXiv preprint arXiv:2204.06125*, 1(2):3, 2022。
- [6] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily L Denton, Kamyar Ghasemipour, Raphael Gontijo Lopes, Burcu Karagol Ayan, Tim Salimans 等。具有深入语言理解的真实感文本到图像扩散模型。在 *Advances in Neural Information Processing Systems*, 2022 年。
- [7] 陈南新、张宇、Heiga Zen、Ron J Weiss、Mohammad Norouzi 和 William Chan。Wavegrad: 估计波形生成的梯度。2021 年 *International Conference on Learning Representations*。
- [8] 孔志峰, 平卫, 黄家吉, 赵可欣, Bryan Catanzaro。Diffwave: 用于音频合成的多功能扩散模型。2021 年 *International Conference on Learning Representations*。
- [9] Jonathan Ho, Tim Salimans, Alexey Gritsenko, William Chan, Mohammad Norouzi 和 David J Fleet。视频扩散模型。在 *Advances in Neural Information Processing Systems*, 2022 年。
- [10] Ruben Villegas, Mohammad Babaeizadeh, Pieter-Jan Kindermans, Hernan Moraldo, Han Zhang, Mohammad Taghi Saffar, Santiago Castro, Julius Kunze 和 Dumitru Erhan。Phenaki: 根据开放域文本描述生成可变长度视频。在 *International Conference on Learning Representations*, 2023 年。
- [11] Omer Bar-Tal, Hila Chefer, Omer Tov, Charles Herrmann, Roni Paiss, Shiran Zada, Ariel Ephrat, Junhwa Hur, Yuanzhen Li, Tomer Michaeli 等。Lumiere: 用于视频生成的时空扩散模型。 *arXiv preprint arXiv:2401.12945*, 2024 年。
- [12] 开放人工智能。索拉。 <https://openai.com/index/sora/>, 2024。
- [13] 包凡, 项晨东, 岳刚, 何冠德, 朱洪洲, 郑凯文, 赵敏, 刘世龙, 王耀乐, 朱军。Vidu: 具有扩散模型的高度一致、动态且熟练的文本到视频生成器。 *arXiv preprint arXiv:2405.04233*, 2024 年。
- [14] 雅各布·奥斯汀、丹尼尔·D·约翰逊、乔纳森·何、丹尼尔·塔洛和瑞安·范登伯格。离散状态空间中的结构化去噪扩散模型。在 *Advances in Neural Information Processing Systems*, 2021 年。
- [15] Emiel Hoogeboom, Didrik Nielsen, Priyank Jaini, Patrick Forré 和 Max Welling。Argmax 流和多项式扩散: 学习分类分布。在 *Advances in Neural Information Processing Systems*, 2021 年。
- [16] Clément Vignac, Igor Krawczuk, Antoine Siraudin, Bohan Wang, Volkan Cevher 和 Pascal Frossard。DiGress: 用于图形生成的离散去噪扩散。在 *International Conference on Learning Representations*, 2023 年。
- [17] 杨东超, 于建伟, 王鹤林, 王文, 翁超, 邹月贤, 于东。Diffsound: 用于生成文本到声音的离散扩散模型。 *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2023 年。
- [18] 内特·格鲁弗、塞缪尔·斯坦顿、内森·弗雷、蒂姆·G·J 鲁德纳、伊西德罗·霍泽尔、朱利安·拉弗朗斯-瓦纳斯、阿文德·拉杰帕尔、Kyunghyun Cho 和安德鲁·G·威尔逊。具有引导离散扩散的蛋白质设计。在 *Advances in Neural Information Processing Systems*, 2023 年。

- [19] Sander Dieleman, Laurent Sartran, Arman Roshannai, Nikolay Savinov, Yaroslav Ganin, Pierre H Richemond, Arnaud Doucet, Robin Strudel, Chris Dyer, Conor Durkan 等。分类数据的连续扩散。 *arXiv preprint arXiv:2211.15089*, 2022。[20]陈婷, 张瑞祥, 杰弗里·辛顿。模拟位: 使用具有自调节功能的扩散模型生成离散数据。 *International Conference on Learning Representations*, 2022 年。[21]Xian g Li, John Thickstun, Ishaan Gulrajani, Percy S Liang 和 Tatsunori B Hashimoto。Diffusion-LM 改进了可控文本生成。在 *Advances in Neural Information Processing Systems*, 2022 年。
- [22] Ishaan Gulrajani 和 Tatsunori B Hashimoto。基于可能性的扩散语言模型。在 *Advances in Neural Information Processing Systems*, 2023 年。
- [23] Justin Lovelace, Varsha Kishore, Chao Wan, Eliot Shekhtman 和 Kilian Q Weinberger。语言生成的潜在扩散。 *Advances in Neural Information Processing Systems*, 2024 年。[24] Pierre H Richemond, Sander Dieleman 和 Arnaud Doucet。具有单纯形扩散的分类 SDE。 *arXiv preprint arXiv:2210.14784*, 2022 年。
- [25]帕维尔·阿夫德耶夫, 史晨来, 谭宇豪, 克谢尼娅·杜德尼克, 周健。用于生物序列生成的狄利克雷扩散评分模型。在 *International Conference on Machine Learning*, 2023 年。
- [26] 亚历克斯·格雷夫斯、鲁佩什·库马尔·斯里瓦斯塔瓦、蒂莫西·阿特金森和福斯蒂诺·戈麦斯。贝叶斯流网络。 *arXiv preprint arXiv:2308.07037*, 2023 年。
- [27] 薛凯文, 周宇豪, 聂沉, 徐敏, 张晓璐, 周军, 李崇轩。通过随机微分方程统一贝叶斯流网络和扩散模型。 *arXiv preprint arXiv:2404.15766*, 2024 年。
- [28] 刘冠宏, 陈天荣, Evangelos Theodorou, 陶莫雷。用于约束和水印生成的镜像扩散模型。在 *Advances in Neural Information Processing Systems*, 2024 年。
- [29] 安德鲁·坎贝尔、乔·本顿、瓦伦丁·德博托利、托马斯·雷福斯、乔治·德利吉安尼迪和斯阿诺·杜塞特。离散去噪模型的连续时间框架。在 *Advances in Neural Information Processing Systems*, 2022 年。
- [30] 孙浩然, 于立军, 戴波, Dale Schuurmans, 戴汉军。基于分数的连续时间离散扩散模型。在 *International Conference on Learning Representations*, 2022 年。
- [31] 林郑, 袁建波, 雷宇, 孔令鹏。用于文本生成的重新参数化离散扩散模型。 *arXiv preprint arXiv:2302.05737*, 2023 年。
- [32] 楼亚伦, 孟晨林, 斯特凡诺·埃尔蒙。通过估计数据分布的比率进行离散扩散语言建模。在 *International Conference on Machine Learning*, 2024 年。
- [33] Diederik Kingma, Tim Salimans, Ben Poole 和 Jonathan Ho。变分扩散模型。在 *Advances in Neural Information Processing Systems*, 2021 年。
- [34] Tero Karras, Miika Aittala, Timo Aila 和 Samuli Laine。阐明基于扩散的生成模型的设计空间。2022 年 *Advances in Neural Information Processing Systems*。
- [35] Joe Benton, Yuyang Shi, Valentin De Bortoli, George Deligiannidis 和 Arnaud Doucet。从去噪扩散到去噪马尔可夫模型。 *arXiv preprint arXiv:2211.03595*, 2022 年。
- [36] 欧景阳, 聂沉, 薛凯文, 朱凤起, 孙家成, 李振国, 李崇轩。您的吸收离散扩散秘密地模拟了干净数据的条件分布。 *arXiv preprint arXiv:2406.03736*, 2024 年。
- [37] Subham Sekhar Sahoo, Marianne Arriola, Yair Schiff, Aaron Gokaslan, Edgar Marroquin, Justin T Chiu, Alexander Rush 和 Volodymyr Kuleshov。简单有效的掩蔽扩散语言模型。 *arXiv preprint arXiv:2406.07524*, 2024 年。
- [38] 赵凌晓, 丁雪英, 于丽君, Leman Akoglu。改进和统一离散和连续时间离散去噪扩散。 *arXiv preprint arXiv:2402.03701*, 2024 年。
- [39] 张慧文, 张涵, 姜璐, 刘策, 威廉·T·弗里曼。Maskgit: 蒙版生成图像转换器。在 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022 年。

- [40] 马丁·赫塞尔、休伯特·拉姆绍尔、托马斯·翁特蒂纳、伯恩哈德·内斯勒和塞普·霍克赖特。通过两个时间尺度更新规则训练的 GAN 收敛到局部纳什均衡。 *Advances in Neural Information Processing Systems*, 2017 年 30 日。
- [41] Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes 和 Yejin Choi。神经文本退化的奇怪案例。在 *International Conference on Learning Representations*, 2019 年。
- [42] 乔纳森·何和蒂姆·萨利曼。无分类器的扩散指导。 *arXiv preprint arXiv:2207.12598*, 2022 年。
- [43] 亨特·尼森诺夫、熊俊豪、斯蒂芬·艾伦帕赫和詹妮弗·利斯特加滕。解锁离散状态空间扩散和流动模型的指导。 *arXiv preprint arXiv:2406.01572*, 2024 年。
- [44] 赵一秀, 史嘉欣, 莱斯特·麦基, 斯科特·林德曼。离散扩散模型的知情校正器。 *arXiv preprint arXiv:2407.21243*, 2024 年。
- [45] James Bradbury, Roy Frostig, Peter Hawkins, Matthew James Johnson, Chris Leary, Dougal Maclaurin, George Nectou, Adam Paszke, Jake VanderPlas, Skye Wanderman-Milne 和 Qiao Zhang。JAX: Python+NumPy 程序的可组合转换, 2018。URL <http://github.com/jax-ml/jax>。
- [46] Ouail Kitouni, Niklas Nolte, James Hensman 和 Bhaskar Mitra。磁盘: 结构化知识的扩散模型。 *arXiv preprint arXiv:2312.05253*, 2023 年。
- [47] 贝尼尼奥·乌里亚、伊恩·默里和雨果·拉罗谢尔。一个深入且易于处理的密度估计器。在 *International Conference on Machine Learning*, 第 467-475 页。PMLR, 2014。
- [48] Emiel Hoogeboom, Alexey A Gritsenko, Jasmijn Bastings, Ben Poole, Rianne van den Berg 和 Tim Salimans。自回归扩散模型。2021 年 *International Conference on Learning Representations*。
- [49] 安德鲁·坎贝尔、贾森·伊姆、雷吉娜·巴兹莱、汤姆·雷恩福斯和托米·贾科拉。离散状态空间上的生成流: 通过蛋白质协同设计的应用实现多模式流。在 *International Conference on Machine Learning*, 2024 年。
- [50] 哈维尔·E·桑托斯、扎卡里·R·福克斯、尼古拉斯·鲁伯斯和颜廷林。停电扩散: 离散状态空间中的生成扩散模型。在 *International Conference on Machine Learning* 中, 第 9034-9059 页。PMLR, 2023 年。
- [51] Nikolay Savinov, Junyoung Chung, Mikolaj Binkowski, Erich Elsen 和 Aaron van den Oord。用于文本生成的逐步展开去噪自动编码器。在 *International Conference on Learning Representations*, 2022 年。
- [52] 石嘉欣, 周宇豪, 黄杰西卡, 米哈利斯·蒂西亚斯, 莱斯特·麦基。使用离散 Stein 算子进行梯度估计。在 *Advances in Neural Information Processing Systems*, 2022 年。
- [53] 蒂姆·萨利曼和大卫·A·诺尔斯。关于使用具有随机近似的控制变量进行变分贝叶斯及其与随机线性回归的联系。 *arXiv preprint arXiv:1401.1022*, 2014 年。
- [54] W. Kool, H. V. Hoof 和 M. Welling。购买 4 个 REINFORCE 样品, 免费获得基线! 在 *DeepRLStructPred@ICLR*, 2019 年。
- [55] 马特·马奥尼。文本8。 <https://mattmahoney.net/dc/textdata.html>。访问时间: 2024 年 5 月 14 日。
- [56] 亚伦·戈卡斯科和万尼亚·科恩。Openwebtext 语料库。 <http://Skylion007.github.io/OpenWebTextCorpus>, 2019。
- [57] 亚历克·雷德福德、杰弗里·吴、Rewon Child、David Luan、Dario Amodei 和 Ilya Sutskever。语言模型是无监督的多任务学习者。 *OpenAI blog*, 1(8):9, 2019。
- [58] Guilherme Penedo, Hynek Kydlicek, Anton Lozhkov, Margaret Mitchell, Colin Raffel, Leandro Von Werra, Thomas Wolf 等。FineWeb 数据集: 在网络上大规模获取最精细的文本数据。 *arXiv preprint arXiv:2406.17557*, 2024 年。
- [59] 达斯汀·陈 (Dustin Tran)、科扬·瓦法 (Keyon Vafa)、库马尔·阿格拉瓦尔 (Kumar Agrawal)、劳伦特·丁 (Laurent Dinh) 和本·普尔 (Ben Poole)。离散流: 离散数据的可逆生成模型。在 *Advances in Neural Information Processing Systems*, 2019 年。
- [60] Rowan Zellers, Ari Holtzman, Yonatan Bisk, Ali Farhadi 和 Yejin Choi。Hellaswag: 机器真的能完成你的句子吗? *arXiv preprint arXiv:1905.07830*, 2019。

[61] Andy Shih、Dorsa Sadigh 和 Stefano Ermon。以正确的方式对任意阶自回归模型进行训练和推理。*Advances in Neural Information Processing Systems*, 2022 年。[62] 扎卡里·齐格勒和亚历山大·拉什。离散序列的潜在标准化流。*International Conference on Machine Learning*, 2019 年。[63] Aäron Van Den Oord、Nal Kalchbrenner 和 Koray Kavukcuoglu。像素递归神经网络。*International Conference on Machine Learning*, 2016 年。[64] Aaron Van den Oord、Nal Kalchbrenner、Lasse Espeholt、Oriol Vinyals 和 Alex Graves。使用 PixelCNN 解码器生成条件图像。*Advances in Neural Information Processing Systems*, 2016 年。[65] Tim Salimans、Andrej Karpathy、Xi Chen 和 Diederik P Kingma。Pixelcnn++: 通过离散逻辑混合似然和其他修改改进 Pixelcnn。*International Conference on Learning Representations*, 2016 年。[66] Xi Chen、Nikhil Mishra、Mostafa Rohaninejad 和 Pieter Abbeel。PixelSnail: 改进的自回归生成模型。*International Conference on Machine Learning*, 2018 年。[67] Niki Parmar、Ashish Vaswani、Jakob Uszkoreit、Lukasz Kaiser、Noam Shazeer、Alexander Ku 和 Dustin Tran。图像转换器。*International Conference on Machine Learning*, 2018 年。[68] Rewon Child、Scott Gray、Alec Radford 和 Ilya Sutskever。使用稀疏变压器生成序列。*arXiv preprint arXiv:1904.10509*, 2019。

[69] Aurko Roy、Mohammad Saffar、Ashish Vaswani 和 David Grangier。使用路由变压器实现基于内容的高效稀疏注意力。*Transactions of the Association for Computational Linguistics*, 9: 53-68, 2021。

[70] Aaron Van Den Oord、Oriol Vinyals 等。神经离散表示学习。*Advances in Neural Information Processing Systems*, 2017 年 30 月。[71] Kehang Han、Kathleen Kenealy、Aditya Barua、Noah Fiedel 和 Noah Constant。文本扩散模型的迁移学习。*arXiv preprint arXiv:2401.17181*, 2024。[72] Samy Bengio、Oriol Vinyals、Navdeep Jaitly 和 Noam Shazeer。使用循环神经网络进行序列预测的计划采样。*Advances in Neural Information Processing Systems*, 2015 年。[73] 彼得·W·格林。随机系统的似然比梯度估计。*Communications of the ACM*, 33(10): 75-84, 1990。[74] 罗纳德·J·威廉姆斯。用于联结强化学习的简单统计梯度跟踪算法。*Machine Learning*, 8(3-4):229-256, 1992。[75] 威廉·皮布尔斯和谢赛宁。具有变压器的可扩展扩散模型。在 *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 第 4195-4205 页, 2023 年。

表 4: 掩蔽方案公式。

Masking schedules	α_t	Cross-entropy loss weight $\frac{\alpha'_t}{1-\alpha_t}$
Linear	$1 - t$	$-\frac{1}{t}$
Polynomial	$1 - t^w$	$-\frac{w}{t}$
Geometric	$\exp(-\bar{\beta}_{\min}^{1-t} \bar{\beta}_{\max}^t)$	$-\frac{\exp(-\bar{\beta}_{\min}^{1-t} \bar{\beta}_{\max}^t)}{1 - \exp(-\bar{\beta}_{\min}^{1-t} \bar{\beta}_{\max}^t)} \bar{\beta}_{\min}^{1-t} \bar{\beta}_{\max}^t \log \frac{\sigma_{\min}}{\sigma_{\max}}$
Cosine	$1 - \cos(\frac{\pi}{2}(1 - t))$	$-\frac{\pi}{2} \tan(\frac{\pi}{2}(1 - t))$

离散时间推导

我们将从 0 到 1 的时间划分为 T 个区间, 并令 $s(i) = (i - 1)/T, t(i) = i/T$ 。前向转移矩阵 $Q_i \in \mathbb{R}^{(m+1) \times (m+1)}$ (m 是时间 $t(i)$ 时的词汇量大小)

$$[Q_i]_{jk} = \begin{cases} 1 & j = k = m \\ 1 - \beta_i & j = k \neq m \\ \beta_i & k = m, j \neq m \\ 0 & \text{otherwise} \end{cases}$$

或者更紧凑地写为

$$Q_i = (1 - \beta_i)I + \beta_i \mathbf{1} e_m^\top,$$

其中 $\mathbf{1}$ 表示大小为 $m + 1$ 的全一向量, 而 e_m 是大小为 $m + 1$ 的独热向量, 其中第 m 个元素 (回想一下, 从 0 开始计数) 为 1。我们使用长度为 $m + 1$ 的 one-hot 向量 x_t 来表示离散状态。前向条件定义为

$$q(x_{t(i)} | x_{s(i)}) = \text{Cat}(x_{t(i)}; Q_i^\top x_{s(i)}) = x_{s(i)}^\top Q_i x_{t(i)}, \quad (13)$$

其中 $Q_i^\top x_{s(i)}$ 是 $x_{t(i)}$ 可以采用的每个 $m + 1$ 类别的概率。给定 x_0 时, 时间 $t(i)$ 的边际前向分布为

$$q(x_{t(i)} | x_0) = \text{Cat}(x_{t(i)}; \bar{Q}_i^\top x_0) = x_0^\top \bar{Q}_i x_{t(i)},$$

其中 $\bar{Q}_i = \prod_{j=1}^i Q_j = \prod_{j=1}^i (1 - \beta_j)I + (1 - \prod_{j=1}^i (1 - \beta_j)) \mathbf{1} e_m^\top$ 。为了看看这在连续时间内会导致什么, 我们让 $\beta_i = \frac{\beta(t(i))}{T}$ 和 $T \rightarrow \infty$:

$$\begin{aligned} \prod_{j=1}^i (1 - \beta_j) &= \exp\left(\sum_{j=1}^i \log(1 - \beta_j)\right) \\ &= \exp\left(\sum_{j=1}^i -\frac{\beta(t(j))}{T} + o(1/T)\right) \\ &\xrightarrow{T \rightarrow \infty} \exp\left(-\int_0^{t(i)} \beta(s) ds\right). \end{aligned}$$

在这种情况下, 我们让 $\bar{Q}(t)$ 表示 $\bar{Q}_i$ 的极限:

$$\begin{aligned} \bar{Q}(t) &= \exp\left(-\int_0^t \beta(s) ds\right) I + \left(1 - \exp\left(-\int_0^t \beta(s) ds\right)\right) \mathbf{1} e_m^\top \\ &\triangleq \alpha_t I + (1 - \alpha_t) \mathbf{1} e_m^\top. \end{aligned}$$

这里我们定义 $\alpha_t \triangleq \exp(-\int_0^t \beta(s) ds)$ 。边际前向过渡是

$$q(x_t | x_0) = \text{Cat}(x_t; \bar{Q}(t)^\top x_0) = x_0^\top \bar{Q}(t) x_t = \alpha_t x_0^\top x_t + (1 - \alpha_t) e_m^\top x_t. \quad (14)$$

B 连续时间求导

我们考虑具有转移率的连续时间马尔可夫链

$$Q(t) = (Q_i - I)/(1/T) = \beta(t)(\mathbf{1}e_m^\top - I). \quad (15)$$

为了简单起见, 我们让 $Q = \mathbf{1}e_m^\top - I$ 。给定 x_0 时, 时间 t 的边际前向分布为 $q(x_t|x_0) = \text{Cat}(x_t; \bar{Q}(t)^\top x_0)$, 其中

$$\bar{Q}(t) = \exp\left(\int_0^t Q(s)ds\right) = \exp\left(Q \int_0^t \beta(s)ds\right) = \exp(\bar{\beta}(t)Q).$$

这里我们定义 $\bar{\beta}(t) \triangleq \int_0^t \beta(s)ds$ 。矩阵指数可以通过特征分解计算:

$$\bar{\beta}(t)Q = U\Lambda U^{-1},$$

在哪里

$$\begin{aligned} U &= I - e_me_m^\top + \frac{1}{\sqrt{n+1}}\mathbf{1}e_m^\top, \\ U^{-1} &= I + \sqrt{n+1}e_me_m^\top - \mathbf{1}e_m^\top, \\ \Lambda &= \bar{\beta}(t)(e_me_m^\top - I), \end{aligned}$$

因此 $\exp(\Lambda) = \alpha_t I + (1 - \alpha_t)e_me_m^\top$,

$$\bar{Q}(t) = U \exp(\Lambda) U^{-1} = \alpha_t I + (1 - \alpha_t)\mathbf{1}e_m^\top.$$

更简单的推导使用以下属性:

$$Q^2 = -Q.$$

所以,

$$\begin{aligned} \bar{Q}(t) &= \exp(\bar{\beta}(t)Q) \\ &= I + \bar{\beta}(t)Q + \frac{1}{2}\bar{\beta}(t)^2Q^2 + \frac{1}{3}\bar{\beta}(t)^3Q^3 + \dots \\ &= I + Q - (1 - \bar{\beta}(t) + \frac{1}{2}\bar{\beta}(t)^2 - \frac{1}{3}\bar{\beta}(t)^3 + \dots)Q \\ &= I + Q - \exp(-\bar{\beta}(t))Q \\ &= \alpha_t I + (1 - \alpha_t)\mathbf{1}e_m^\top. \end{aligned}$$

这个在时间 t 的边际前向转移矩阵与我们通过离散时间求导极限得到的结果 (1) 一致。

连续时间前向过程的任意离散化。对于离散时间过程, 我们在 (13) 中定义了每步转换。

对于连续时间过程, 我们可以推导出任意两个时间 s 和 t 之间的转移矩阵

$\bar{Q}(s, t)_{ij} \triangleq q(x_t = j | x_s = i)$ 作为以下微分方程 (称为柯尔莫哥洛夫前向方程) 的解

$$\frac{d}{dt}\bar{Q}(s, t) = \bar{Q}(s, t)Q(t) \text{ where } Q(t) = \beta(t)Q$$

初始条件为 $\bar{Q}(s, s) = I$ 。解由下式给出

$$\bar{Q}(s, t) = \exp((\bar{\beta}(t) - \bar{\beta}(s))Q) = \bar{Q}(s)^{-1}\bar{Q}(t).$$

罗日常工作 (使用伍德伯里矩阵求逆引理) 显示 是这样的

$$\bar{Q}(t)^{-1} = \alpha_t^{-1}I + (1 - \alpha_t^{-1})\mathbf{1}e_m^\top.$$

将结果插回, 我们得到从 s 到 t 的前向转移分布 :

$$\begin{aligned} q(x_t|x_s) &= \text{Cat}(x_t; \bar{Q}(s, t)^\top x_s) = x_s^\top \bar{Q}(s, t)x_t, \\ \text{where } \bar{Q}(s, t) &\triangleq \bar{Q}(s)^{-1}\bar{Q}(t) = \frac{\alpha_t}{\alpha_s}I + \left(1 - \frac{\alpha_t}{\alpha_s}\right)\mathbf{1}e_m^\top. \end{aligned} \quad (16)$$

$$\begin{array}{ccc}
& & x_0 & \text{MASK} & & & \text{MASK} \\
\begin{array}{c} \text{MASK} \end{array} & \left[\begin{array}{cccc} 1 & & & \\ & 1 & & \\ & & 1 & \\ & & & 1 \\ & & & & 1 \\ & & & & & 1 \\ 0 & \frac{\alpha_s - \alpha_t}{1 - \alpha_t} & 0 & \frac{1 - \alpha_s}{1 - \alpha_t} \end{array} \right] & & \left[\begin{array}{cccc} 1 & & & \\ & 1 & & \\ & & 1 & \\ & & & 1 \\ & & & & 1 \\ & & & & & 1 \\ \frac{\alpha_s - \alpha_t}{1 - \alpha_t} \mu_\theta(x_t, t) & & & \frac{1 - \alpha_s}{1 - \alpha_t} \end{array} \right] \\
& q(x_s = \cdot | x_t = \cdot, x_0) & & q(x_s = \cdot | x_t = \cdot, \mu_\theta(x_t, t))
\end{array}$$

图 7: 反向转移概率和我们的生成模型。左: 矩阵形式的 $q(x_s = \cdot | x_t = \cdot, x_0)$, 其中第一个索引是 x_t , 第二个索引是 x_s 。右: $p_\theta(x_s = \cdot | x_t = \cdot) \triangleq q(x_s = \cdot | x_t = \cdot, \mu_\theta(x_t, t))$ 也是矩阵形式。

C 给定 x_0 的前向过程的时间反转

我们的正向过程的分析属性允许以封闭形式计算许多感兴趣的量。扩散模型中经常使用的此类量之一是给定 x_0 : $q(x_s | x_t, x_0)$ 的前向过程的时间反转。我们可以使用 (14) 和 (16) 计算它:

$$\begin{aligned}
q(x_s | x_t, x_0) &= \frac{q(x_t | x_s) q(x_s | x_0)}{q(x_t | x_0)} \\
&= \begin{cases} \frac{\alpha_s - \alpha_t}{1 - \alpha_t} x_s^\top x_0 & x_s \neq m, x_t = m \\ \frac{1 - \alpha_s}{1 - \alpha_t} & x_s = m, x_t = m \\ x_s^\top x_t & x_t \neq m. \end{cases} \quad (17)
\end{aligned}$$

从视觉上看, eqn (17) 是一个 $\mathbb{R}^{(m+1) \times (m+1)}$ 矩阵 (图 7, 左), 其第一个索引是 x_t , 第二个索引是 x_s 。该矩阵几乎是单位矩阵, 除了对应于 x_t 的最后一行是掩码标记。最后一行意味着掩码令牌以 $\frac{\alpha_s - \alpha_t}{1 - \alpha_t}$ 的概率被取消掩码变为 x_0 , 并且以 $\frac{1 - \alpha_s}{1 - \alpha_t}$ 的概率保持掩码。

或者, 我们可以使用反向转移矩阵 $\bar{R}^{x_0}(t, s) \in \mathbb{R}^{(m+1) \times (m+1)}$ 将上面的重写为

$$q(x_s | x_t, x_0) = \text{Cat}(x_s; \bar{R}^{x_0}(t, s)^\top x_t), \text{ where } \bar{R}^{x_0}(t, s) = I + \frac{\alpha_s - \alpha_t}{1 - \alpha_t} e_m (x_0 - e_m)^\top.$$

我们还对无穷小的时间限制内会发生什么感兴趣, 即当 $s = t - \Delta t$ 和 $\Delta t \rightarrow 0$ 时。请注意

$$\alpha_{t-\Delta t} - \alpha_t = -\alpha'_t \Delta t + o(\Delta t).$$

将其代入原公式, 我们得到

$$\bar{R}^{x_0}(t, t - \Delta t) = I - \frac{\alpha'_t}{1 - \alpha_t} e_m (x_0 - e_m)^\top \Delta t + o(\Delta t).$$

将上述与转移率矩阵 $R^{x_0}(t)$ 定义进行比较

$$\bar{R}^{x_0}(t, t - \Delta t) = I + R^{x_0}(t) \Delta t + o(\Delta t),$$

我们已经确定 编辑逆向过程的转移率矩阵

在 x_0 上:

$$R^{x_0}(t) = -\frac{\alpha'_t}{1 - \alpha_t} e_m (x_0 - e_m)^\top. \quad (18)$$

D ELBO 的详细信息

使用 (17) 和 (3)，我们计算正向和反向转换之间的 KL 散度

$$\begin{aligned}
\text{KL}(q(x_s|x_t, x_0)||p_\theta(x_s|x_t)) &= \text{KL}(q(x_s|x_t, x_0)||q(x_s|x_t, \mu_\theta(x_t, t))) \\
&= \begin{cases} \sum_{x_s=0}^m q(x_s|x_t, x_0) \log \frac{q(x_s|x_t, x_0)}{q(x_s|x_t, \mu_\theta(x_t, t))} & x_t = m \\ 0 & x_t \neq m \end{cases} \\
&= \delta_{x_t=m} \sum_{k \neq m} \frac{\alpha_s - \alpha_t}{1 - \alpha_t} x_0^\top e_k \log \frac{x_0^\top e_k}{\mu_\theta(x_t, t)^\top e_k} \\
&= -\delta_{x_t=m} \frac{\alpha_s - \alpha_t}{1 - \alpha_t} x_0^\top \log \mu_\theta(x_t, t).
\end{aligned} \tag{19}$$

请注意， $0 \log 0 = 0$ 。或者，可以从图 7 所示的 $q(x_s|x_t, x_0)$ 和 $p_\theta(x_s|x_t)$ 的直观描述中轻松获得此结果。在这种情况下，重建项变为

$$\begin{aligned}
\mathbb{E}_{q(x_{t(1)}|x_0)}[\log p(x_0|x_{t(1)})] &= \sum_{k=0}^m q_{t(1)|0}(k|x_0) \log \frac{q_{t(1)|0}(k|x_0)}{\sum_{j \neq m} q_{t(1)|0}(k|j)} \\
&= \alpha_{t(1)} \cdot \log \frac{\alpha_{t(1)}}{\alpha_{t(1)}} + (1 - \alpha_{t(1)}) \log \frac{1}{m} \\
&= -(1 - \alpha_{t(1)}) \log m.
\end{aligned}$$

先前的 KL 项可以计算为

$$\text{KL}(q(x_1|x_0)||p(x_1)) = \text{KL}(\delta_{x_1,m}||\delta_{x_1,m}) = 0.$$

像往常一样，我们通过令 $T \rightarrow \infty$ 来获取连续时间限制：

$$\begin{aligned}
\mathcal{L}_\infty &\triangleq \lim_{T \rightarrow \infty} \mathcal{L}_T \\
&= \lim_{T \rightarrow \infty} \sum_{i=2}^T -\frac{\alpha_{s(i)} - \alpha_{t(i)}}{s(i) - t(i)} \frac{s(i) - t(i)}{1 - \alpha_{t(i)}} x_0^\top \mathbb{E}_{q(x_{t(i)}|x_0)} [\delta_{x_{t(i)},m} \log \mu_\theta(x_{t(i)}, t(i))] \\
&= \int_{t(1)}^1 \frac{\alpha'_t}{1 - \alpha_t} x_0^\top \mathbb{E}_{q(x_t|x_0)} [\delta_{x_t,m} \log \mu_\theta(x_t, t)] dt.
\end{aligned}$$

E 避免未定义的 KL 散度

在定义前向过程时，出于数值稳定性的原因，我们通常不希望 α_1 恰好为 0，或者等效地， λ_1 为 ∞ 。相反，我们将 λ_1 设置为有限值，因此 α_1 具有较小的正值。这样就有一个问题，就是 $q(x_1|x_0)$ 的支持度不再是 $\{m\}$ ，而是变成了 $\{m, x_0\}$ 。因此， $q(x_1|x_0)$ 和 $p(x_1)$ 之间的 KL 散度未定义，因为 $q(x_1|x_0)$ 相对于 $p(x_1) = \delta_{x_1,m}$ 不是绝对连续的。为了解决这个问题，我们修改了先验分布 $p(x_1)$ ，使其支持所有 $m+1$ 值。其中一个选择是让

$$p(x_1) = \frac{\alpha_1}{m} \sum_{j \neq m} \delta_{x_1,j} + (1 - \alpha_1) \delta_{x_1,m}.$$

那么，先验 KL 散度项就变为

$$\begin{aligned}
\text{KL}(q(x_1|x_0)||p(x_1)) &= \sum_{x_1=0}^m q(x_1|x_0) \log \frac{q(x_1|x_0)}{p(x_1)} \\
&= \sum_{x_1=0}^m (\alpha_1 \delta_{x_1,x_0} + (1 - \alpha_1) \delta_{x_1,m}) \log \frac{\alpha_1 \delta_{x_1,x_0} + (1 - \alpha_1) \delta_{x_1=m}}{p(x_1)} \\
&= \alpha_1 \log \frac{\alpha_1}{\alpha_1/m} + (1 - \alpha_1) \log \frac{1 - \alpha_1}{1 - \alpha_1} \\
&= \alpha_1 \log m.
\end{aligned}$$

F MD4 训练和采样细节

F.1 培训

Algorithm 1 A single step of training with MD4.

Input: data minibatch $\{x_t^i\}_{i=1}^B$, network $\mu_\theta(\cdot, t)$, masking schedule α_t
for $i = 1, \dots, B$ **do** (in parallel):
 $t_i \leftarrow \text{mod}(u + i/B, 1)$, $u \sim U[0, 1]$
for $n \in [N]$, mask out each token $x_0^{i,(n)}$ independently with probability $1 - \alpha_{t_i}$ to obtain $x_{t_i}^i$
for $n \in [N]$, if $x_{t_i}^{(n)} = m$, compute weighted cross entropy loss $\frac{\alpha'_{t_i}}{1 - \alpha_{t_i}} (x_0^{i,(n)})^\top \log \mu_\theta^{(n)}(x_{t_i}^i, t_i)$
Sum over all weighted cross entropy losses for mask positions and optimize via autodiff

F.2 采样

Algorithm 2 Unconditional and conditional generation (e.g., infilling) with MD4.

Input: Context sequence x^c of length N , with masks indicating the target areas for generation
Init: $\{t(i)\}_{i=0}^T \leftarrow \text{discretize}([0, 1])$, $x_{t(T)} \leftarrow x^c$
for $i = T, T-1, \dots, 1$ **do**
 $t \leftarrow t(i)$, $s \leftarrow t(i-1)$
for $n \in [N]$, if $x_t^{(n)} = m$, draw $x_s^{(n)} \sim \text{Cat}(\frac{\alpha_s - \alpha_t}{1 - \alpha_t} \mu_\theta^{(n)}(x_t, t) + \frac{1 - \alpha_s}{1 - \alpha_t} e_m)$ else $x_s^{(n)} \leftarrow x_t^{(n)}$
return x_0 .

G JAX 分类采样和隐式置顶- p

我们注意到 Alg 的以下等效实现。2 导致 JAX 中的样本质量明显变差：

Algorithm 3 Variant of Alg. 2 that yields lower sample quality when implemented in JAX.

Input: Token sequence x^c of length N , with masks indicating the target areas for generation
Init: $\{t(i)\}_{i=0}^T \leftarrow \text{discretize}([0, 1])$, $x_{t(T)} \leftarrow x^c$
for $i = T, T-1, \dots, 1$ **do**
 $t \leftarrow t(i)$, $s \leftarrow t(i-1)$
for $n \in [N]$ **do** (in parallel)
draw $u \sim U[0, 1]$
if $x_t^{(n)} = m$ **and** $u < \frac{\alpha_s - \alpha_t}{1 - \alpha_t}$ **then**
draw $x_s^{(n)} \sim \text{Cat}(\mu_\theta^{(n)}(x_t, t))$
else
 $x_s^{(n)} \leftarrow x_t^{(n)}$
return x_0 .

然而，从数学上讲，它相当于 Alg. 2 并且应该产生相同的结果。我们的调查显示，问题的出现是因为 Alg. 2 将 μ_θ 的输出概率缩放一个小因子 $\frac{\alpha_s - \alpha_t}{1 - \alpha_t}$ ，因为 s 接近 t ，导致某些类别的概率非常低。然而，JAX 使用 Gumbel argmax 实现分类采样，这在数值上不如二分搜索等方法稳定。因此，即使概率较低的类别的累积概率很大，也很少对它们进行采样。在我们的实验中，我们发现概率低于 $1e-8$ 的类别很少在总共 50K 个类别中被采样。因此，阿尔格。2 在 JAX 的分类采样下隐式执行 top- p 采样（使用动态 p ），产生比 Alg 更好的样本质量。3，其中 μ_θ 未按小因子缩放，并且被截断的类别较少。

H 统一现有的掩模扩散模型

H.1 CTMC 的观点

我们首先证明连接正向和反向转移率矩阵的引理。这是根据[29]中的结果得出的，但我们给出了完整性证明。

引理 2. *The forward transition rate matrix $Q(t)$ and the reverse transition rate matrix (given x_0) $R^{x_0}(t)$ satisfy:*

$$R^{x_0}(t)_{kj} = Q(t)_{jk} \frac{q_{t|0}(j|x_0)}{q_{t|0}(k|x_0)} \text{ for } j \neq k. \quad (20)$$

证明考虑从时间 $t + \tau$ 到 t 的反向转换。对于 $j \neq k$ ，贝叶斯规则得出

$$\begin{aligned} q(x_t = j | x_{t+\tau} = k, x_0) &= \frac{q(x_t = j | x_0) q(x_{t+\tau} = k | x_t = j)}{q(x_{t+\tau} = k | x_0)} \\ &= \frac{q(x_t = j | x_0) (\delta_{jk} + Q(t)_{jk} \tau + o(\tau))}{q(x_{t+\tau} = k | x_0)} \\ &\stackrel{\tau \rightarrow 0}{=} \delta_{kj} + \frac{q(x_t = j | x_0)}{q(x_t = k | x_0)} Q(t)_{jk} \tau + o(\tau). \end{aligned}$$

然后，根据转移率矩阵的定义可以得出 $R^{x_0}(t)_{kj} = Q(t)_{jk} \frac{q_{t|0}(j|x_0)}{q_{t|0}(k|x_0)}$ $\square$

命题 3. *We use the shorthand $R_\theta(t)_{kj}$ to denote the approximate reverse transition rate from the state k to j obtained by substituting our prediction model $\mu_\theta(k)$ for x_0 in $R^{x_0}(t)_{kj}$. Then, the continuous-time objective (4) can be equivalently expressed as*

$$\mathcal{L}_\infty = - \int_{t(1)}^1 \mathbb{E}_{q_{t|0}(k|x_0)} \left[R_\theta(t)_{kk} + \sum_{j \neq k} Q(t)_{kj} \log R_\theta(t)_{jk} \right] dt + C, \quad (21)$$

where C is a constant independent of θ .

证明为了用转移率矩阵重写我们的目标 $\mathcal{L}_\infty$ ，我们首先回到(19)。在那里，我们没有插入 $\bar{R}^{x_0}(t, s)$ 的显式形式，而是用利用转换率 $R^{x_0}(t)$ 的 (8) 代替它。为了简化表示法，我们假设 $x_t = k$ 并使用简写 $R_\theta(t)_{kj} \triangleq R^{\mu_\theta(k)}(t)_{kj}$ 。然后我们有

$$\begin{aligned} &\text{KL}(q(x_{t-\Delta t} | x_t, x_0) \| p_\theta(x_{t-\Delta t} | x_t)) \\ &= \text{KL}(\text{Cat}(x_s; \bar{R}^{x_0}(t, t - \Delta t)^\top e_k) \| \text{Cat}(x_s; \bar{R}^{\mu_\theta(k)}(t, t - \Delta t)^\top e_k)) \\ &= \sum_{j=0}^m e_k^\top (I + R^{x_0}(t) \Delta t + o(\Delta t)) e_j \log \frac{e_k^\top (I + R^{x_0}(t) \Delta t + o(\Delta t)) e_j}{e_k^\top (I + R_\theta(t) \Delta t + o(\Delta t)) e_j} \\ &= (1 + R^{x_0}(t)_{kk} \Delta t) \log \frac{1 + R^{x_0}(t)_{kk} \Delta t + o(\Delta t)}{1 + R_\theta(t)_{kk} \Delta t + o(\Delta t)} \\ &\quad + \sum_{j \neq k} (R^{x_0}(t)_{kj} \Delta t) \log \frac{R^{x_0}(t)_{kj} \Delta t + o(\Delta t)}{R_\theta(t)_{kj} \Delta t + o(\Delta t)} + o(\Delta t) \\ &= (R^{x_0}(t)_{kk} - R_\theta(t)_{kk}) \Delta t + \sum_{j \neq k} (R^{x_0}(t)_{kj} \Delta t) \log \frac{R^{x_0}(t)_{kj} \Delta t + o(\Delta t)}{R_\theta(t)_{kj} \Delta t + o(\Delta t)} + o(\Delta t). \end{aligned}$$

对于最后一个恒等式，我们使用了 $\log(1+x) = x + o(x)$ 这一事实。为了得到 $\mathcal{L}_\infty$ ，我们将 $\mathcal{L}_T$ 的极限取为 $T \rightarrow \infty$ ，相当于让 $\Delta t = 1/T \rightarrow 0$ 。我们得到

$$\begin{aligned}\mathcal{L}_\infty &= \lim_{T \rightarrow \infty} \sum_{i=2}^T \mathbb{E}_{q(x_{t(i)}|x_0)} [\text{KL}(q(x_{s(i)}|x_{t(i)}, x_0) \| p_\theta(x_{s(i)}|x_{t(i)}))] \\ &= \lim_{T \rightarrow \infty} \sum_{i=2}^T \mathbb{E}_{q(x_{t(i)}|x_0)} \left[\left(R^{x_0}(t(i))_{kk} - R_\theta(t(i))_{kk} \right. \right. \\ &\quad \left. \left. + \sum_{j \neq k} R^{x_0}(t(i))_{kj} \log \frac{R^{x_0}(t(i))_{kj} \Delta t + o(\Delta t)}{R_\theta(t(i))_{kj} \Delta t + o(\Delta t)} \right) \Delta t + o(\Delta t) \right] \\ &= \int_{t(1)}^1 \mathbb{E}_{q_{t|0}(k|x_0)} \left[R^{x_0}(t)_{kk} - R_\theta(t)_{kk} + \sum_{j \neq k} R^{x_0}(t)_{kj} \log \frac{R^{x_0}(t)_{kj}}{R_\theta(t)_{kj}} \right] dt.\end{aligned}$$

请注意， $R^{x_0}(t)$ 是独立于 θ 的常量矩阵。将所有常数项吸收到 C 中，我们有

$$\mathcal{L}_\infty = - \int_{t(1)}^1 \mathbb{E}_{q_{t|0}(k|x_0)} \left[R_\theta(t)_{kk} + \sum_{j \neq k} R^{x_0}(t)_{kj} \log R_\theta(t)_{kj} \right] dt + C.$$

下一个我们使用 Lem 将 $R^{x_0}(t)$ 替换为前向转移率

马2:

$$\begin{aligned}\mathcal{L}_\infty &= - \int_{t(1)}^1 \mathbb{E}_{q_{t|0}(k|x_0)} \left[R_\theta(t)_{kk} + \sum_{j \neq k} Q(t)_{jk} \frac{q_{t|0}(j|x_0)}{q_{t|0}(k|x_0)} \log R_\theta(t)_{kj} \right] dt + C \\ &= - \int_{t(1)}^1 \left[\sum_{k=0}^m q_{t|0}(k|x_0) R_\theta(t)_{kk} + \sum_{k=0}^m \sum_{j \neq k} Q(t)_{jk} q_{t|0}(j|x_0) \log R_\theta(t)_{kj} \right] dt + C \\ &= - \int_{t(1)}^1 \left[\sum_{k=0}^m q_{t|0}(k|x_0) R_\theta(t)_{kk} + \sum_{k=0}^m \sum_{j \neq k} Q(t)_{kj} q_{t|0}(k|x_0) \log R_\theta(t)_{jk} \right] dt + C,\end{aligned}$$

其中最后一个恒等式使用离散模拟来进行按部分积分（或按部分求和）：

$\sum_{k=0} \sum_{j \neq k} f(j, k) = \sum_{k=0} \sum_{j \neq k} f(k, j)$ 。重新排列各项即可得出 (21)。

□

H.2 与 Campbell 等人的差异[29]

坎贝尔等人。[29]使用 (21) 的第一项作为训练损失。该损失函数的一个关键限制来自内部求和项

$$\sum_{j \neq k} Q(t)_{kj} \log R_\theta(t)_{jk}.$$

对于单维情况，由于 $R_\theta(t)$ 的稀疏结构，总和是可解析计算的 - 如果 $x_t = k$ 是掩码，则第二项消失；否则唯一可能的邻居 j 是一个掩码。然而，对于多维数据， j 将表示前向过程中的所有 $N-1$ 邻居，即我们从屏蔽 $x_t = k$ 的单个未屏蔽维度获得的状态。回想一下， $R_\theta(t)_{jk}$ 的计算方法是将我们的神经网络预测模型 $\mu_\theta(j)$ 替换为 $R^{x_0}(t)_{jk}$ 中的 x_0 。因此，与 $R_\theta(t)_{kk}$ 一起求和需要对 $\mu_\theta(\cdot)$ 进行 N 评估。这是令人望而却步的，因为神经网络模型通常很昂贵。为了解决这个问题，坎贝尔等人。[29]建议将总和重写为

$$\mathbb{E}_{j \sim \tilde{q}(\cdot|k)} [Z_k \log R_\theta(t)_{jk}] \quad \text{where} \quad \tilde{q}(j|k) = \frac{Q(t)_{kj}}{Z_k}, Z_k \triangleq \sum_{j' \neq k} Q(t)_{kj'}$$

并通过蒙特卡洛进行估计。考虑到 $q_{t|0}(k|x_0)$ 下的外部期望，损失的计算就变成了双随机估计（使用 $k \sim q_{t|0}(k|x_0)$ 和 $j \sim \tilde{q}(j|k)$ ），其方差很大。相比之下，我们的损失 (4) 的形式只需要评估 μ_θ 一次即可对期望进行一次随机估计。 $q(x_t|x_0)$ 。

H.3 Score parameterization

我们在下面提供了基于分数的损失的更简单的推导 [32, 35]。我们从(21)中的ELBO形式开始，将其重写为

$$\mathcal{L}_\infty = \int_{t(1)}^1 \mathbb{E}_{q_{t|0}(k|x_0)} \left[\sum_{j \neq k} \left(R^{\mu_\theta}(t)_{kj} - R^{x_0}(t)_{kj} + R^{x_0}(t)_{kj} \log \frac{R^{x_0}(t)_{kj}}{R^{\mu_\theta}(t)_{kj}} \right) \right] dt. \quad (22)$$

对于最后一个恒等式，我们使用转移率矩阵的零行和性质：

$$R^{x_0}(t)_{kk} = - \sum_{j \neq k} R^{x_0}(t)_{kj}.$$

如果我们将 (20) 代入 (22) 并使用评分模型重新参数化

$$s_\theta(x_t)_j \triangleq \frac{q_{t|0}(j|\mu_\theta(x_t))}{q(x_t|\mu_\theta(x_t))}, \quad (23)$$

我们从 Lou 等人那里恢复了得分熵损失函数。[32]，本顿等人。[35]：

$$\mathcal{L}_\infty = \int_{t(1)}^1 \mathbb{E}_{q_{t|0}(k|x_0)} \left[\sum_{j \neq k} Q(t)_{jk} \left(s_\theta(k)_j - \frac{q_{t|0}(j|x_0)}{q_{t|0}(k|x_0)} \log s_\theta(k)_j + \psi \left(\frac{q_{t|0}(j|x_0)}{q_{t|0}(k|x_0)} \right) \right) \right] dt, \quad (24)$$

其中 $\psi(y) \triangleq y \log y - y$ 。请注意，我们上面的推导与 Campbell 等人的推导不同且更简单。[29] (Lou 等人[32] 的基础)，因为我们利用给定 x_0 的条件反向转移率，而不是反向过程的转移率矩阵。我们可以通过条件分数和 x_0 之间的关系进一步简化损失：

$$\frac{q_{t|0}(j|x_0)}{q_{t|0}(k|x_0)} = \frac{x_0^\top \bar{Q}(t) e_j}{x_0^\top \bar{Q}(t) e_k} = \frac{\alpha_t}{1 - \alpha_t} x_0^\top e_j \text{ for } k = m, j \neq k. \quad (25)$$

请注意，仅需要案例 $k = m$ 下的结果。这是因为当 x_t 未被屏蔽时，在 0 到 t 之间的任何时间，状态必须保持不变并保持 x_0 。结果，对于 $x_t \neq m$ ， $\text{KL}(q(x_{t-\Delta t}|x_t, x_0) \| p_\theta(x_{t-\Delta t}|x_t)) = 0$ 。从(15)，我们知道 $Q(t)_{jk} = \beta(t)(\delta_{mk} - \delta_{jk})$ 。结合(25)和(24)，我们得到

$$\mathcal{L}_\infty = \int_{t(1)}^1 \beta(t) \left(\mathbb{E}_{q_{t|0}(k|x_0)} \left[\delta_{mk} \left(\sum_{j \neq k} s_\theta(k)_j - \frac{\alpha_t}{1 - \alpha_t} x_0^\top \log s_\theta(k) \right) \right] + \psi \left(\frac{\alpha_t}{1 - \alpha_t} \right) \right) dt. \quad (26)$$

此外，我们可以通过使用 (23) 或等效的 $s_\theta(x_t)_j = \frac{\alpha_t}{1 - \alpha_t} \mu_\theta(x_t)^\top e_j$ 将分数参数化恢复为平均参数化来显示 (26) 和 (4) 之间的联系。通过这样做，我们得到

$$\mathcal{L}_\infty = \int_{t(1)}^1 \beta(t) \left(\mathbb{E}_{q_{t|0}(k|x_0)} \left[\delta_{mk} \left(\sum_{j \neq k} s_\theta(k)_j - \frac{\alpha_t}{1 - \alpha_t} x_0^\top \log \mu_\theta(k) \right) \right] + \frac{\alpha_t}{1 - \alpha_t} \right) dt.$$

观察到

$$\sum_{j \neq m} s_\theta(m)_j = \frac{\alpha_t}{1 - \alpha_t}, \quad (27)$$

我们得出结论，这恢复了 (4) 中的目标。有趣的是，在 Lou 等人中。[32] 分数参数化不限于满足 (27)。这意味着学习到的反向模型可能与正向过程不兼容。

下面，我们使用式 (1) 的结果证明命题 1。(25)。

命题1的证明

$$\begin{aligned} \frac{q_t(j)}{q_t(m)} &= \frac{\sum_{x_0} q_{t|0}(j|x_0)q(x_0)}{q_t(m)} = \frac{\sum_{x_0} q_{t|0}(j|x_0)q_0(x_0|m)}{q_{t|0}(m|x_0)} = \mathbb{E}_{x_0|x_t=m} \left[\frac{q_{t|0}(j|x_0)}{q_{t|0}(m|x_0)} \right] \\ &= \mathbb{E}_{x_0|x_t=m} \left[\frac{\alpha_t}{1 - \alpha_t} x_0^\top e_j \right] = \frac{\alpha_t}{1 - \alpha_t} \mathbb{E}[x_0|x_t = m]^\top e_j. \end{aligned}$$

□

H.4 其他相关工作。

MaskGIT [39]。MaskGIT 是一种受扩散启发的迭代去噪模型，用于通过 VQ-VAE [70] 等模型获得的离散图像标记。MaskGIT 的训练遵循以下步骤：(a) 样本 $t \in [0, 1]$ 。(b) 给定掩码调度函数 $\gamma(t)$ ，采样 $\gamma(t)N$ 标记来放置掩码。(c) 对于大小为 $(m+1) \times N$ 的数据 x_0 和部分屏蔽状态 x_t ，最小化负对数似然

$$\mathcal{L}_{\text{MaskGIT}} = - \int_0^1 \mathbb{E}_{x_t} \left[\sum_{n: x_t^{(n)} = m} (x_0^{(n)})^\top \log \mu_\theta^{(n)}(x_t, t) \right] dt. \quad (28)$$

我们的前向过程满足 $q_{t|0}(m|x_0) = 1 - \alpha_t$ 。因此，当我们将掩码调度函数设置为 $\gamma(t) = 1 - \alpha_t$ 时，我们会得到类似于 (5) 的损失，而无需 $\frac{\alpha'_t}{1-\alpha_t}$ 权重。请注意， x_t 的采样分布仍然存在差异：在掩码扩散前向过程中，令牌是独立采样的，并且不一定在时间 t 准确产生 $(1 - \alpha_t)N$ 掩码令牌，尽管预期数量是 $(1 - \alpha_t)N$ 。人们可能会对是否可以通过选择适当的时间表 α_t 来恢复统一权重感兴趣。然而，求解 α_t 使得 $\alpha'_t = \alpha_t - 1$ 产生 $\alpha_t = ce^t + 1$ ，并且不存在同时满足 $\alpha_0 = 1$ 和 $\alpha_1 = 0$ 的 c 。这表明使用 MaskGIT 损失 (28) 进行训练可能无法忠实地优化模型似然。

离散流匹配[49]。对于线性调度 $\alpha_t = 1 - t$ ，我们以 x_0 为条件的反向转移率矩阵 (8) 为：

$$R^{x_0}(t) = -\frac{\alpha'_t}{1-\alpha_t} e_m(x_0 - e_m)^\top = \frac{1}{t} e_m(x_0 - e_m)^\top.$$

这与 Campbell 等人使用的条件反向转换率相同。[49, 等式。(22)]—请注意，它们的时间 t 是相反的，因此速率矩阵的形式为 $R^{x_0}(t) = \frac{1}{1-t} e_m(x_0 - e_m)^\top$ 。

SDDM [30]。孙等人。[30]提出了一种类似伪似然的目标来训练离散扩散模型，该模型也可以应用于掩模扩散。然而，他们的目标遇到了与坎贝尔等人相同的挑战。[29] - 需要掩模预测模型的 N 遍。为了解决这个问题，他们引入了一种新的变压器架构，不幸的是，这导致了一些性能下降。

停电扩散[50]。桑托斯等人。[50]提出了一种“黑化”扩散过程，逐渐将图像扩散到黑色状态。虽然这种方法类似于二进制数据上的掩码扩散，但在处理更大的状态空间时出现了关键差异。在他们的方法中，图像像素强度逐渐淡出，而我们的方法直接过渡到掩模状态。我们的方法提供了更大的灵活性，适用于一般的离散状态空间，而不需要预定义的结构关系。它还展示了图像生成方面的竞争性能，在不知道像素值接近度的情况下实现这一点。

圣代 [51, 71]。与掩码扩散不同，SUNDAE 使用词汇中的随机标记统一破坏数据（称为均匀离散扩散 [14]）。此外，它还使用来自干净数据和一步展开模型预测之间的交叉熵的第二个损失项。[72]中也提出了类似的想法。

I 各州费率详情

I.1 导数和时间连续极限

本节中的所有推导均假设 x_t 是单个令牌，而对于 N 令牌，具有状态相关速率的掩码扩散在 N 令牌中进行因式分解。App 中讨论了使用变分推理从 N 标记的数据中学习。I.2.

给定正文中导出的正向转移 $q(x_t|x_s)$ 和边际 $q(x_s|x_0)$ (第6节), 给定 x_0 的反转为 $q(x_s|x_t, x_0) = \text{Cat}(x_s; \bar{R}^{x_0}(t, s)^\top x_t)$

$$\bar{R}^{x_0}(t, s)_{jk} = \begin{cases} \left(\frac{\alpha_s - \alpha_t}{1 - \alpha_t}\right)^\top x_0 x_0^\top e_k & j = m, k \neq m \\ \left(\frac{1 - \alpha_s}{1 - \alpha_t}\right)^\top x_0 & j = m, k = m \\ \delta_{jk} & j \neq m. \end{cases}$$

或者也可以写成

$$\begin{aligned} q(x_s|x_t, x_0) &= \frac{q(x_t|x_s)q(x_s|x_0)}{q(x_t|x_0)} \\ &= \frac{\left[\frac{\alpha_t^\top x_s}{\alpha_s^\top x_s} x_s^\top x_t + (1 - \frac{\alpha_t^\top x_s}{\alpha_s^\top x_s}) e_m^\top x_t\right] [\alpha_s^\top x_0 x_0^\top x_s + (1 - \alpha_s^\top x_0) e_m^\top x_s]}{[\alpha_t^\top x_0 x_0^\top x_t + (1 - \alpha_t^\top x_0) e_m^\top x_t]}. \end{aligned} \quad (29)$$

为了简化这个表达式, 我们考虑两种情况: 要么 $x_t = m$ (即 x_t 是掩码) 或 $x_t \neq m$, 其中第二种情况是 $x_t = x_0$. 对于情况 $x_t = m$, (29) 中的分母简化为

$$q(x_t = m|x_0) = 1 - \alpha_t^\top x_0$$

由于自 $x_0 \neq m$ 以来 $x_0^\top x_t = 0$, 即观察到的标记 x_0 不能是掩码。然后给定 $x_t = m$ 的概率是 $x_s = x_t = m$

$$\frac{1 - \alpha_s^\top x_0}{1 - \alpha_t^\top x_0} = \frac{(1 - \alpha_s)^\top x_0}{(1 - \alpha_t)^\top x_0} = \left(\frac{1 - \alpha_s}{1 - \alpha_t}\right)^\top x_0 \quad (30)$$

而 $x_s = x_0 \neq m$ 的剩余概率是

$$\frac{(\alpha_s - \alpha_t)^\top x_0}{1 - \alpha_t^\top x_0} = \frac{(\alpha_s - \alpha_t)^\top x_0}{(1 - \alpha_t)^\top x_0} = \left(\frac{\alpha_s - \alpha_t}{1 - \alpha_t}\right)^\top x_0. \quad (31)$$

然后, 将(30)和(31)组合起来统一写成 $q(x_s|x_t = m, x_0)$, 得到主Sec中的表达式(11)。6. 在第二种情况下, 当 $x_t = x_0 \neq m$ 时, (29) 中的 $q(x_s|x_t \neq m, x_0)$ 急剧简化, 变成 $q(x_s|x_t \neq m, x_0) = x_t^\top x_s$, 它是设置 $x_s = x_t$ 的点质量。

(12) 中损失的连续时间极限的推导。为了简化符号, 我们让 $\xi_{s,t} \triangleq \frac{\alpha_s - \alpha_t}{1 - \alpha_t}$ 。我们首先计算离散时间 ELBO 中的 KL 散度项为

$$\begin{aligned} &\text{KL}(q(x_s|x_t, x_0) \| p_\theta(x_s|x_t)) \\ &= \begin{cases} \sum_{x_s=0}^m q(x_s|x_t, x_0) \log \frac{q(x_s|x_t, x_0)}{p_\theta(x_s|x_t)} & x_t = m \\ 0 & x_t \neq m \end{cases} \\ &= \delta_{x_t, m} \left[\sum_{k \neq m} \xi_{s,t}^\top x_0 x_0^\top e_k \log \frac{\xi_{s,t}^\top x_0 x_0^\top e_k}{\xi_{s,t}^\top \text{diag}(\mu_\theta(x_t, t)) e_k} + (1 - \xi_{s,t})^\top x_0 \log \frac{(1 - \xi_{s,t})^\top x_0}{(1 - \xi_{s,t})^\top \mu_\theta(x_t, t)} \right] \\ &= \delta_{x_t, m} \left[-\xi_{s,t}^\top x_0 x_0^\top \log \mu_\theta(x_t, t) + (1 - \xi_{s,t})^\top x_0 \log \frac{(1 - \xi_{s,t})^\top x_0}{(1 - \xi_{s,t})^\top \mu_\theta(x_t, t)} \right]. \end{aligned}$$

让 $\Delta_t \triangleq \frac{1}{T} = t(i) - s(i)$ 代表所有 i 。将 $\alpha_{t-\Delta_t} = \alpha_t - \alpha'_t \Delta_t + o(\Delta_t)$ 代入上面的公式并让 $\gamma_t = \frac{\alpha'_t}{1 - \alpha_t}$, 我们得到

$$\begin{aligned} &\text{KL}(q(x_s|x_t, x_0) \| p_\theta(x_s|x_t)) \\ &= \delta_{x_t, m} \left[\gamma_t^\top x_0 x_0^\top \log \mu_\theta(x_t, t) \Delta_t + (1 + \gamma_t^\top x_0 \Delta_t) \cdot \log \frac{1 + \gamma_t^\top x_0 \Delta_t + o(\Delta_t)}{1 + \gamma_t^\top \mu_\theta(x_t, t) \Delta_t + o(\Delta_t)} + o(\Delta_t) \right] \\ &= \delta_{x_t, m} \left[\gamma_t^\top x_0 x_0^\top \log \mu_\theta(x_t, t) \Delta_t + (1 + \gamma_t^\top x_0 \Delta_t) (\gamma_t^\top x_0 \Delta_t - \gamma_t^\top \mu_\theta(x_t, t) \Delta_t + o(\Delta_t)) + o(\Delta_t) \right] \\ &= \delta_{x_t, m} \left[\gamma_t^\top x_0 x_0^\top \log \mu_\theta(x_t, t) \Delta_t + \gamma_t^\top x_0 \Delta_t - \gamma_t^\top \mu_\theta(x_t, t) \Delta_t + o(\Delta_t) \right] \\ &= \delta_{x_t, m} \cdot \gamma_t^\top (x_0 x_0^\top \log \mu_\theta(x_t, t) + x_0 - \mu_\theta(x_t, t)) \Delta_t + o(\Delta_t). \end{aligned}$$

所以,

$$\begin{aligned}
& \lim_{T \rightarrow \infty} \sum_{i=2}^T \mathbb{E}_{q(x_{t(i)}|x_0)} [\text{KL}(q(x_{s(i)}|x_{t(i)}, x_0) \| p_\theta(x_{s(i)}|x_{t(i)}))] \\
&= \lim_{T \rightarrow \infty} \sum_{i=2}^T \mathbb{E}_{q(x_{t(i)}|x_0)} [\delta_{x_{t(i)}, m} \cdot \gamma_t^\top (x_0 x_0^\top \log \mu_\theta(x_{t(i)}, t(i)) + x_0 - \mu_\theta(x_{t(i)}, t(i))) \Delta t + o(\Delta t)] \\
&= \int_{t(1)}^1 \gamma_t^\top \mathbb{E}_{q(x_{t(i)}|x_0)} [\delta_{x_t, m} \cdot (x_0 x_0^\top \log \mu_\theta(x_t, t) + x_0 - \mu_\theta(x_t, t))] dt.
\end{aligned}$$

令 $t(1) \rightarrow 0$ 证明结果。

I.2 训练和梯度估计

该模型应用于由 N 标记组成的数据, 其中 $x_0 = (x_0^1, \dots, x_0^N)$ 且掩码扩散中的每个状态为 $x_t = (x_t^1, \dots, x_t^N)$ 。反向生成模型具有 $\prod_{n=1}^N p_\theta(x_s^{(n)}|x_t)$ 形式的因式分解转换条件, 其中 $p_\theta(x_s^{(n)}|x_t) = q(x_s^{(n)}|x_t^{(n)}, \mu_\theta^{(n)}(x_t, t))$ 的形式取决于 $x_t^{(n)} = m$ 还是 $x_t^{(n)} \neq m$ 。对于第一种情况:

$$p_\theta(x_s^{(n)}|x_t^{(n)} = m, \{x_t^{(k)}\}_{k \neq n}) = \left(\frac{\mathbf{1} - \alpha_s}{\mathbf{1} - \alpha_t} \right)^\top \mu_\theta^{(n)}(x_t, t) e_m^\top x_s^{(n)} + \left(\frac{\alpha_s - \alpha_t}{\mathbf{1} - \alpha_t} \right)^\top \text{diag}(\mu_\theta^{(n)}(x_t, t)) x_s^{(n)},$$

其中 $\mu_\theta^{(n)}(x_t, t) = \text{softmax}(f_\theta(x_t))$ 是由 NN 建模的 $m+1$ 维概率向量 (其中最终值被限制为零, 因为 $\mu_\theta^{(n)}(x_t, t)$ 是无法掩码的 $x_0^{(n)}$ 的重建, 因此在实践中, NN 分类器只需要在 m 实际令牌类上有一个 softmax 输出)。至关重要的是, 请注意, NN 分类器接收所有标记的完整状态 x_t 作为输入, 同时还包括用于编码 t 的附加时间特征。当 $x_t^{(n)} \neq m$ 时, 反向转换模型设置为 $p_\theta(x_s|x_t^{(n)} \neq m, \{x_t^{(k)}\}_{k \neq n}) = (x_t^{(n)})^\top x_s^{(n)}$, 它与前向过程中的 $q(x_s^{(n)}|x_t^{(n)} = m, x_0^{(n)}) = (x_t^{(n)})^\top x_s^{(n)}$ 精确匹配。

全负洛 我们受状态相关率的约束, 并假设 N 代币是 给出的

$$\mathcal{L}_\infty^{(N)} = \int_0^1 \left(\frac{\alpha'_t}{1 - \alpha_t} \right)^\top \mathbb{E}_{q(x_t|x_0)} \left[\sum_{n: x_t^{(n)} = m} (x_0^{(n)} - \mu_\theta^{(n)}(x_t, t) + x_0^{(n)} (x_0^{(n)})^\top \log \mu_\theta^{(n)}(x_t, t)) \right] dt. \quad (32)$$

鉴于每个 $\alpha_{t,i} = 1 - t^{w_i}$, 逆向模型变为

$$p_\theta(x_s^{(n)}|x_t^{(n)} \neq m, \{x_t^{(k)}\}_{k \neq n}) = (e^{w \log \frac{s}{t}})^\top \mu_\theta^{(n)}(x_t, t) e_m^\top x_s^{(n)} + (1 - e^{w \log \frac{s}{t}})^\top \text{diag}(\mu_\theta^{(n)}(x_t, t)) x_s^{(n)},$$

其中 w 是所有 w_i 的 $m+1$ 维向量。请注意, $x_s^{(n)}$ 保持在掩码状态 (即 $x_s^{(n)} = m$) 的概率取决于完整的 x_t , 它由 $(e^{w \log \frac{s}{t}})^\top \mu_\theta^{(n)}(x_t, t) = \sum_{i=0}^{m-1} e^{w_i \log \frac{s}{t}} \mu_\theta^{(n)}(x_t, t)_i$ 给出, 而 $x_s^{(n)}$ 取某个非掩码标记值 i 的概率为 $(1 - e^{w_i \log \frac{s}{t}}) \mu_\theta^{(n)}(x_t, t)_i$ 。 t 的梯度为 $\alpha'_{t,i} = -w_i t^{w_i-1}$, 而 $\frac{\alpha'_{t,i}}{1 - \alpha_{t,i}} = -\frac{w_i}{t}$ 上述损失可写为

$$\mathcal{L}_\infty^{(N)} = - \int_0^1 \frac{1}{t} w^\top \mathbb{E}_{q(x_t|x_0)} \left[\sum_{n: x_t^{(n)} = m} (x_0^{(n)} - \mu_\theta^{(n)}(x_t, t) + x_0^{(n)} (x_0^{(n)})^\top \log \mu_\theta^{(n)}(x_t, t)) \right] dt,$$

其中 w 是所有 w_i 的向量。神经网络参数 θ 上的无偏梯度很容易获得, 因为我们只需要采样一个时间点 t 和一个 $x_t \sim q(x_t|x_0)$ 来近似积分和期望, 然后使用梯度:

$$-\nabla_\theta \sum_{n: x_t^{(n)} = m} \frac{1}{t} w^\top \left(x_0^{(n)} - \mu_\theta^{(n)}(x_t, t) + x_0^{(n)} (x_0^{(n)})^\top \log \mu_\theta^{(n)}(x_t, t) \right).$$

w 参数的梯度更加复杂, 因为这些参数也出现在不可重新参数化的离散分布 $q(x_t|x_0)$ 中。为了解决这个问题, 我们需要加强

无偏梯度 [73, 74], 在我们的实现中, 我们考虑使用两个样本强化留一法 (RLOO) [53, 54]。首先, 精确损失的精确梯度 wrt w 写为

$$-\int_0^1 \frac{1}{t} \mathbb{E}_{q(x_t|x_0)} [g(x_t, x_0)] dt - \int_0^1 \frac{1}{t} \mathbb{E}_{q(x_t|x_0)} [f(x_t, x_0) \nabla_w \log q(x_t|x_0)] dt. \quad (33)$$

在哪里

$$g(x_t, x_0) = \sum_{n: x_t^{(n)}=m} (x_0^{(n)} - \mu_\theta^{(n)}(x_t, t) + x_0^{(n)} (x_0^{(n)})^\top \log \mu_\theta^{(n)}(x_t, t)), \quad f(x_t, x_0) = w^\top g(x_t, x_0).$$

请注意, $g(x_t, x_0)$ 是向量, 而 $f(x_t, x_0)$ 是标量。 (33) 中的左边项很简单, 因为它只需要采样 t 和 $x_t \sim q(x_t|x_0)$, 而右边项是可能具有高方差的 REINFORCE 项。对于第二项, 我们使用 RLOO 和两个样本 x_t^1, x_t^2 并构建无偏估计

$$-\frac{1}{2t} (\nabla_w \log q(x_t^1|x_0) - \nabla_w \log q(x_t^2|x_0)) [f(x_t^1, x_0) - f(x_t^2, x_0)].$$

因此, 我们使用的 w 的整体无偏梯度是

$$-\frac{1}{2t} \{g(x_t^1, x_0) + g(x_t^2, x_0) + (\nabla_w \log q(x_t^1|x_0) - \nabla_w \log q(x_t^2|x_0)) [f(x_t^1, x_0) - f(x_t^2, x_0)]\}.$$

J 实验细节

在所有实验中, 除非另有说明, 模型均采用连续时间损失进行训练, 而样本则从 1000 个时间步长的离散时间反向模型中抽取。我们使用指数移动平均因子 0.9999 进行所有评估, 包括样本生成。

J.1 文本8

我们遵循 Austin 等人中的标准数据集分割。[14], 卢等人。[32] 并在长度为 256 的文本块上训练我们的模型, 执行 100 万步, 批量大小为 512。除非另有说明, 表中的所有模型都使用标准的 12 层转换器架构。我们的变压器也具有与 Austin 等人相同的头数 (12) 和隐藏维度 (784)。[14], 卢等人。[32]。

我们使用连续时间 ELBO 并为每个数据抽取一个 t 样本来估计积分。为了减少训练的方差, 我们使用了 Kingma 等人中描述的相同的对偶采样技巧。[33] 连续扩散模型。我们使用线性掩码方案 $\alpha_t = 1 - t$ 并在 t 接近 0 和 1 时添加一个小偏移 $\epsilon = 10^{-4}$ 以确保数值稳定性。更改后的时间表为 $\alpha_t = (1 - 2\epsilon)(1 - t) + \epsilon$ 。这种转变导致 $q(x_1|x_0)$ 和先前的 $p(x_1)$ 之间的支持不匹配, 从而导致未定义的 KL 散度项。我们在应用程序中解释。E 如何修改先验分布以允许非掩模状态中的小均匀概率来缓解此问题。这种转变导致先验分布的非零重构项和 KL 散度项, 但两者的规模都可以忽略不计, 因此我们在报告 ELBO 时可以安全地忽略它们。

我们使用余弦学习率计划, 线性预热为 2000 步。我们应用了速率为 0.05 的通道级 dropout, 并使用学习率为 0.0003 和权重衰减因子为 0.03 的 AdamW 优化器。我们的模型在 16 TPU-v5 lite 上训练了不到一天。

J.2 开放网络文本

我们保留了 2% 的原始训练集用于验证。我们的中小型变压器模型具有与 Lou 等人相同的层数、头数和隐藏尺寸。[32] 我们的分词器也保持不变, 词汇量约为 50k。训练目标、掩蔽时间表和其他架构选择与 text8 实验保持相同。我们保持训练超参数与 text8 实验相同, 只是将 dropout 率降低到 0.02。

J.3 FineWeb-Edu

我们保留与 OpenWebText 实验相同的训练设置。我们的 Transformer 模型具有与 GPT-2 模型相同的层数、头数和隐藏维度。我们使用相同的 GPT-2 分词器。

对于 Hellaswag 评估，我们将问题与每个答案选项连接起来，对连接的字符串进行标记，填充到 1024 的长度。填充的标记序列被馈送到我们的 MD4 模型的损失函数中以进行似然评估。我们对 32 个蒙特卡洛样本进行平均以减少方差。具有最高似然估计的答案是模型的预测。

J.4 图像

我们在所有似然结果中使用了与之前实验相同的线性掩蔽方案。我们使用了与 Kingma 等人描述连续扩散模型相同的 U-Net 加上自注意力架构。[33]对于 CIFAR-10，不同之处在于我们没有使用傅立叶特征输入，而是添加了一个额外的输入嵌入层，其嵌入大小与模型的隐藏维度相同。对于 ImageNet 64×64 ，我们将残差块的数量（在 U-Net 结构的一侧）从 64 个减少到 48 个，并添加了一个 12 层扩散变换器 [75]，隐藏维度为 768，中间有 12 个头。

对于这两个数据集，我们使用 AdamW 优化器并进行 2M 迭代训练。对于 CIFAR-10，我们使用学习率 0.0004、批量大小 256、权重衰减因子 0.01；对于 ImageNet 64×64 ，我们使用学习率 0.0002、批量大小 512、权重衰减因子 0.03。学习率遵循 100 个预热步骤后的余弦退火。我们的 CIFAR-10 模型在 32 TPU-v5 lite 上训练了 24 小时。我们的 ImageNet- 64×64 模型在 256 TPU-v5 lite 上训练了 3.5 天。

正如第 2 节中所解释的。如图 4 所示，我们观察到余弦时间表可以带来更好的样本质量，因此我们用它来训练更便宜的样本可视化模型。该模型与实现最佳似然模型的不同之处在于，我们使用了 8 个残差块（位于 U-Net 结构的一侧）和中间的 20 层扩散变换器。所有其他配置保持不变。

K 附加结果

K.1 GPT-2 的样本质量评估

遵循 Lou 等人的研究，我们使用 GPT-2 大模型来评估我们的模型生成的样本的困惑度。[32]。结果如图 8 所示。




图 8：遵循 Lou 等人的 GPT-2 Large 评估生成困惑度[32]。我们在生成 1024 个标记的文本序列时将 MD4 与 GPT-2 检查点（自回归基线）和 SEDD（此任务之前最好的离散扩散模型）进行比较。我们研究了两个正交因素对样本质量的影响：模型大小和解码步骤。GPT-2 和 SEDD 的数字来自 Lou 等人。[32]。

K.2 OpenWebText 验证集的困惑

标签。图 5 报告了 OpenWebText 验证集上实现的最终困惑数，对应于图 4。

表 5: OpenWebText 验证集的困惑度。

Size	Method	Perplexity ($\downarrow$)
Small	Gaussian Diffusion	≤ 27.28
	SEDD Absorb (reimpl.)	≤ 24.10
	MD4 (Ours)	≤ 22.13
	GenMD4 (Ours)	$\leq \mathbf{21.80}$
Medium	MD4 (Ours)	$\leq \mathbf{16.64}$

K.3 在 ImageNet 64×64 上训练的 MD4 的 FID 评估

我们提供了与表 2 中对应的 FID 编号。6.

表 6: 在 ImageNet 64×64 上训练的 MD4 生成的 50k 样本的 FID，对应于图 2。顶部三行显示来自无条件模型的结果，而底部行来自以类标签为条件的模型。Alg中使用了均匀离散化网格。2 除非另有说明。

Method	Timesteps T			
	64	128	256	512
Linear α_t	193.81	128.18	72.94	50.21
Linear α_t , cosine grid	42.07	25.16	18.31	18.22
Cosine α_t	47.46	23.84	17.8	18.74
Cosine α_t , class conditional	30.75	11.39	7.13	7.8

K.4 在 ImageNet 64×64 上训练的 MD4 的附加无条件生成

我们在图 9 中的 ImageNet 64×64 上进行像素级建模实验，提供了更多无条件生成结果。

K.5 在 OpenWebText 上训练的 MD4 的附加无条件生成

下面我们提供了两个由我们在 OpenWebText 上训练的 MD4 Medium 模型生成的无条件文本样本。

K.5.1 MD4-M无条件样本1: 1024个令牌

比如，我不必活着？有时候有些事情太真实了，你真的应该去体验它们。所以这是一种很好的感觉。这就是可怕的事情。实际上并非如此，能够体验事物，能够做这些事情，当你在做这些事情时，对于大多数必须在梦中醒来的人来说，这似乎是最重要的事情，然后你第二天就会想到它。这就像未来的希望，你现在醒来就会想到它。发生的事情是，然后你必须停下来想一想，然后突然间，有人总是说，“你在做梦。”

有时我想知道，当你做这样的节目时，现在是否是向演员传授直觉的好时机。因为即使在这个特定的节目中，感觉每个人以前都经历过这种情况，甚至是几年前。我的意思是，如果你们一起做一个节目，至少不是持续发展，那么你就是一名兽医。我的意思是，你真的应该在一起。



图 9：在 ImageNet 64×64 上训练的 MD4 的更多无条件样本。

如果你不确定，那么——

VS：我正在研究那个。

你们中有人觉得本能有用吗？我想，“好吧，因为你没有拍《戴德伍德》，所以你应该停止这样做。”但当我第一次读到这个故事时，我想：“我认为这会起作用。”我无法想象如何将其分开。

VS: 那就是我。这是我们必须做的。我们也是。当我们写第一集时，我们写了一个我们觉得我和我自己都想看的剧本。我知道我想要成为某种东西——我想要能够在真实的东西中寻求庇护，你可以看到并且真正走出自己。然后我看到了。然后，你就可以排练并付诸实践。然后我就真的开始拍摄了。我想我知道我认为这不会很好。但是，我知道那很好。现在人们谈论它是因为它还不够好。

在成长过程中，你说你完全讨厌《迷失》这部剧。这难道不是您最终所希望的吗？

VS: 我不喜欢这个概念。

所以有很多你不知道的事情，所以我认为对我来说，有了这些想法，如果你甚至不明白它来自这个不存在的世界，我们可能永远不会在一起。

太奇怪了。这竟然是同时发生的？

对比是的。事情发生的时间基本相同 时间。

甚至没有人看过演出或看过电影/从电影中出来，但是.....

VS: 如果我要假装我绝对不是你并且必须经历这些事情，我想我不会接受它。我没想到它会持续那么久。

现在《戴德伍德》总是会发生一些事情，你不知道下次它会在哪里结束，但我认为现在有些时候我们必须继续战斗，即使《迷失》在心态和形式上非常一致。

VS: 我很高兴我们确实克服了困难，因为我们应该明白两者之间存在直接联系。但几乎有一种感觉，我们不是在同一天出现的，我们知道我们在同样的地方工作，但有很多东西我们不知道。其中一些，我们需要处理。我们还必须接受这种语言，我们从他们那里学到了很多，我们做他们所做的事情，因为我们想要

K.5.2 MD4-M无条件样本2: 1024个令牌

这些团体允许休闲车使用在争取许可证期间保持开放的三条道路。“获得许可证的目的是确保我们与 NPS 合作，修建道路和休息区。我们不仅仅是吓唬那些乱搞的家伙。”在金县委员会正在进行的工作人员会议上，社区建设城市自行车设施的计划得到了推进。

步道将在 Greenview 5 南边结束。

这两条小路可以连接从 Market 到 14 的区域，拉近社区距离，而不是继续通过步行道和自行车道到达 MBTA 校园。

“这个项目将为金县提供一条无车道路，”安德鲁·威德说。在过去的几个月里，该政策已被搁置，但仍有居民持怀疑态度。

“我已经解决了社区提出的一些担忧。他们表达了一些担忧。我认为从一个角度来看这不是很合理。

交通运输的角度。”

当理事会批准为另一项提案提供资金时，这条路线已准备好持续一年多。

市长 Muriel Bowser 在周四与 Bushell 专员会面后表示，新计划将于 12 月实施。

鲍泽说：“这个项目已经完成了足够的工作，可以按时推出，我们将完成它。”

对于公众来说，这场运动似乎已经结束了。

“有一次会议我感觉自己在昨晚的会议上输了，”当地居民雪莉·波茨 (Shelley Potts) 说。

居住在乌曼路的当地居民乔尔·格里米也见到了那里的居民。

在其他骑行队伍中，市长助理史黛西·兰德 (Stacey Land) 甚至她的儿子都拿着传单，要求寻找灯光标志，并会见了鲍泽 (Bowser) 的儿子迪昂·鲍泽 (Deion Bowser)，讨论了未来在交通走廊上设立狗公园的计划。

布里克利活动的支持者中，许多人在公开会议开始时至少等待了 11 分钟，他们表示，即使在 11 月 13 日举行公开听证会之后，他们预计委员会至少还要等待一个月。

鲍泽说：“我们一直在努力成为一个健谈的董事会，我们提前开会，尊重人们。”

他认为 Greenview 5 和 3 之间的步道提案“必须按计划进行。我们还有其他历史保护项目可以接替这个项目。”

但该项目的当地倡导者查德·劳特利奇 (Chad Routledge) 公开反对市长的计划。

劳特利奇说：“市长已经向公众发送了一次新的会议，使用的路线与公众听证会期间社区委员会的大声批评和猛烈投诉相同。”

BDC 没有具体的计划，并表示“目前不会发生任何实际情况”。但是，她表示该机构仍在“寻求对沿线设施进行投资”。

这条小路的另一部分可能和汽车一样是狗的愿望：该地区希望向西走，向南走几个街区，以使这条小路对狗来说更安全。

“我觉得这条步道的可达性非常重要。我认为这条步道的教育以及不同路线的使用是平衡结果的非常重要的部分，”布谢尔说。

有轨电车从 1 号公路驶出

K.6 在 OpenWebText 上训练的 MD4 的条件生成

我们在图 10 中分享了由 MD4 Medium 有条件生成的文本样本，并观察到，由余弦时间表启用的 $t = 1$ 附近的缓慢解锁往往有助于生成比均匀解锁对应物更一致和更有意义的样本。

MD4-M linear schedule	skydiving is a fun sport, but it's pretty risky. You're getting is one to get last one for the season if something goes wrong and it can happen you know, we know about season, especially in Skydiving, but anybody that wins this year	Then some time on Saturday you should pretty much say: "This is what I am going to be doing right now." It's just the simplest thing—that is why I always shampoo twice a day and shower three times a day.
MD4-M linear schedule + cosine grid	skydiving is a fun sport. It is pure endurance and excitement for many people in the at many times we could have won or lost. So if something goes wrong and we can't make it, we have to help another friend as if we have come to our zoo	First, just keep your skin as healthy as possible,you never want to be oily,that is why I always shampoo twice a day and shower three times a day.
MD4-M cosine schedule	skydiving is a fun sport, but it's extremely risky. You can have so many injuries one time and then one next time. There are so many ways you can hurt, so, neuroconcussions, especially from Skydiving, are continuing to rise every year	Though antibacterial products are a poison, the skin needs a chemical solution that protects it from bacteria and spots that form within it —that is why I always shampoo twice a day and shower three times a day.

图 10: 从 MD4-M 有条件生成的文本样本。上图: MD4-M 使用线性计划进行训练, 使用统一网格进行采样; 中: MD4-M 使用线性计划进行训练, 使用余弦网格进行采样; 底部: MD4-M 使用余弦计划进行训练, 使用统一网格进行采样。上下文文本以蓝色显示, 模型生成的文本以黑色显示。

K.7 离散化对零样本困惑度的影响

我们对离散化对零样本困惑度的影响进行了消融研究。结果包含在选项卡中。7. 请注意, 这是使用相同训练模型的推理消融 (使用连续时间目标训练的 MD4-S)。

表 7: 离散化对零样本困惑度的影响。

Size	Timesteps	LAMBADA	WikiText2	PTB	WikiText103	IBW
Small	T = 100	≤ 49.8	≤ 36.1	≤ 105.2	≤ 36.1	≤ 70.3
	T = 1000	≤ 48.5	≤ 35.0	≤ 102.5	≤ 35.0	≤ 68.4
	T = 10000	≤ 48.4	≤ 34.9	≤ 102.4	≤ 34.9	≤ 68.2
	T = ∞ (continuous)	≤ 48.4	≤ 34.9	≤ 102.3	≤ 35.9	≤ 68.1